

Derin Öğrenme ile Şeftali Hastalıklarının Tespiti

Muzaffer Aslan^{1*}

^{1*} Bingöl Üniversitesi, Mühendislik ve Mimarlık Fakültesi, Elektrik elektronik Mühendisliği Bölümü, Bingöl, Türkiye, (ORCID: 0000-0002-2418-9472), muzafferaslan@bingol.edu.tr

(İlk Geliş Tarihi 20 Şubat 2021 ve Kabul Tarihi 9 Nisan 2021)

(DOI: 10.31590/ejosat.883787)

ATIF/REFERENCE: Aslan, M. (2021). Derin Öğrenme ile Şeftali Hastalıklarının Tespiti. *Avrupa Bilim ve Teknoloji Dergisi*, (23), 540-546.

Öz

Tarım ürünleri, dünyadaki canlıların beslenme ihtiyaçlarının karşılanması bakımından oldukça önemlidir. Dünya nüfusundaki hızlı artış tarımsal ürünlerde verimliğin artırılmasını zorunlu hale getirmektedir. Sınırlı tarım alanlarında ürün verimliliğinin sağlanabilmesi bitkilerde görülebilecek hastalıklarının etkili bir şekilde ve zamanında tespiti oldukça önemlidir. Özellikle bazı meyve ağaçlarının kısa ömürlü olması bu ağaçlardaki hastalıkların doğru, zamanında ve hızlı bir şekilde tespitini daha önemli hale getirmektedir. Son zamanlarda görüntü işlemede yaygın olarak kullanılan derin öğrenme, tarımsal faaliyetlerde etkili uygulamalar sunmaktadır. Bu çalışmada, şeftali ağacı hastalıklarının tespiti için evrişimli sinir ağ yöntemi önerilmiştir. Önerilen yöntemde, daha önceden eğitilmiş AlexNet modeli ile şeftali ağaçlarında görülen monilya ve koşnili hastalık tespiti yapılmıştır. Deneysel çalışmalarla, TRB1 bölgesindeki alınan gerçek hastalık görüntülerinden oluşan veri seti ile gerçekleştirildi. Yapılan deneysel çalışmalarla %99,30 doğruluk oranında hastalık tespiti yapılmıştır. Mevcut çalışmalardan %1,44 daha yüksek doğruluk oranına sağlandı.

Anahtar Kelimeler: Derin Öğrenme, Evrişimli Sinir Ağları, Bitki Hastalıkları.

Detection of Peach Diseases with Deep Learning

Abstract

Agricultural products are very important in meeting the nutritional needs of living creatures in the world. The rapid increase in the world population makes it necessary to increase the productivity in agricultural products. It is very important to ensure product productivity in limited agricultural areas and to detect diseases that can be seen in plants effectively and on time. Especially the short life of some fruit trees makes it more important to detect the diseases in these trees accurately, on time and quickly. Deep learning, which has been widely used in image processing recently, offers effective applications in agricultural activities. In this study, convolutional neural network method is proposed to detect peach tree diseases. In the proposed method, the detection of the disease with monilya laxa and sphaerolecanium prunastri in peach trees was made with the previously trained AlexNet model. Experimental studies were carried out with a dataset consisting of real disease images taken from the TRB1 region. In experimental studies, the disease was detected with an accuracy of 99.30%. Achieved 1.44% higher accuracy than existing studies.

Keywords: Deep Learing, Convolution Neural Network, Plant diseases.

* Sorumlu Yazar: muzafferaslan@bingol.edu.tr

1. Giriş

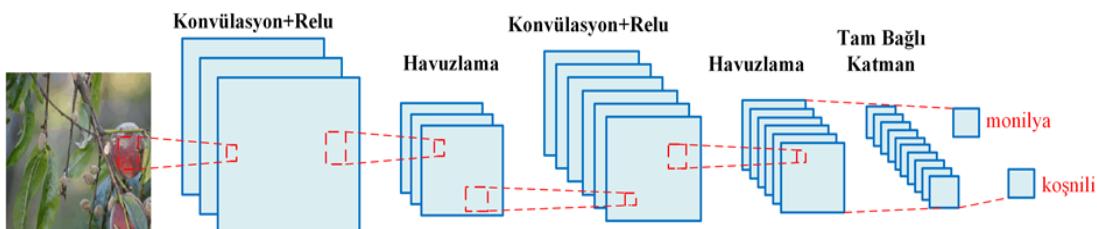
Tarım ürünlerini, insanların olduğu kadar doğadaki diğer canlıların da beslenme ihtiyaçlarını karşılamasında önemli bir yere sahiptir. Dünyada artan nüfus tarımsal ürünlere olan talebi daha da artırmaktadır. Talebin karşılanabilmesi tarımsal ürünlerin verimliliğine bağlıdır. Fakat bitkilerde görülen hastalıklar, tarımsal ürünlerin niteliği ve miktarında oldukça önemli olumsuzluklara neden olmaktadır. Birleşmiş Milletler Gıda ve Tarım Örgütü 2020 yılı verilerine göre zararlı böcek ve hastalıkların neden olduğu gıda üretim kaybı %20-%40 arasında değişmektedir (Savary, 2020). Bu nedenle erken uyarı ve tahmin sistemleri ile bitki hastalıklarının zamanında tespit edilmesi tarımsal gıda güvenliği açısından oldukça önemlidir (Chen, Yin & Zhang, 2020). Bitki hastalıklarının geleneksel tespitinde bu alandaki uzman veya deneyimli üreticilerin görsel gözlemlerine veya laboratuvar ortamındaki analizlere dayanmaktadır. Fakat bu yöntemler hem zaman alıcı hem de yoğun emek gerektirdiği için oldukça maliyetlidir. Bununla birlikte yine de bitki hastalık tespiti zamanında ve doğru bir şekilde yapılamamaktadır (Al Hiary et al., 2011). Son dönemlerde görüntü işleme teknolojisinin hızı gelişimi ile görüntü işleme ve örtüntü tanıma teknolojileri bitki hastalıklarının tespitinde yaygın olarak kullanılmıştır (Sahu & Swain, 2019), (Ayaz, Ari & Hanbay, 2017). Bu teknolojilerin kullanımı ile birlikte sadece bitki hastalıklarının tespitinde performans artışı sağlanmamış aynı zamanda tarım uzmanlarının eksikliğinden kaynaklanan sorunların çözümüne de katkı sağlanmıştır (Chen, Yin & Zhang, 2020), (Sahu & Swain, 2019).

Literatürde bitki hastalıklarının tespitine yönelik görüntü işleme temelli birçok çalışma mevcuttur. Bu çalışmaların bir kısmında genellikle bitki yapraklarının renk, doku ve şekil gibi özellikleri referans alınarak Markow (Chen & Shi, 2008), görsel kelime çantası (Pevný, Bas & Fridrich, 2010), uzamsal alan çıkarmalı piksel bitişikliği (Pires et al., 2016) ve Temel Bileşen Analizi (TBA) (Mangathayaru, Mathura Bai & Srikanth, 2018) gibi yöntemler ile çıkarılan özniteliklerin sınıflandırılmasına dayanmaktadır. Fakat bu yöntemler tek olarak kullanıldıklarında düşük performans göstermektedirler. Ayrıca gerçek hayatı elde edilmesi zor görüntüleri içeren veri setleri ile çalışması bakımından pratikte uygulanabilirliği olmaması gibi büyük dezavantajları bulunmaktadır (Türkoğlu & Hanbay, 2019a). Son dönemlerde derin Evrişimli Sinir Ağları (ESA) ile yapılan çalışmalar ile bu problem büyük oranda çözülmüş ve bitki hastalıklarının tespitinde önemli başarılar elde edilmiştir. Türkoğlu ve dig. bitki hastalıkların tespiti için AlexNet, GoogleNet, VGG16, VGG19, ResNet50, ResNet101, InceptionV3, Inception ResNetV2, and SqueezeNet gibi popüler olan dokuz ESA mimarisini kullanarak performans sonuçlarını karşılaştırdılar (Türkoğlu & Hanbay, 2019b). Mohanty ve dig. hastalıklı ve sağlıklı bitki yapraklarının 54306 adet görüntülerinden oluşan veri setinden farklı 14 bitki türüne ve 26 bitki hastalığını tespit için AlexNet ve GoogleNet derin öğrenme modellerini eğiterek yaptıkları çalışmalarında %99,35 oranında başarı elde ettiler (Mohanty, Hughes & Salathé, 2016). Gensheng ve dig. çay hastalıklarının doğru ve hızlı bir şekilde tanımlanması için ESA kullanarak yaptıkları deneyisel çalışmalarında %92,5 doğrulukta hastalık tespiti gerçekleştirtiler (Hu et al., 2019). Guan ve dig. elma çürükleri ve çürüklerin

seviyelerini belirlemek için VGGNet, ResNet ve Inception-V3 ağları ile yaptıkları çalışmada %90,4 doğrulukta elma çürüklerini tespit ettiler (Yan et al., 2020). Benzer şekilde elma yapraklarındaki hastalıkların tespiti yapılan çalışmada VGG16'ya dayalı geliştirilmiş bir model önerilmiştir. Yapılan deneysel çalışmada klasik VGG16 ile %89 başarı sağlanırken, önerilen model ile bu başarı %99,01'e çıkarılmıştır (Liu et al., 2018). Liu ve dig. üzümdeki antraknoz, kahverengi lekeler, karlar, siyah çürüklik, tüylü küp ve yaprak küfü hastalıklarını tespit etmek için ESA tabanlı bir yöntem önermektedirler. İlk olarak görüntü iyileştirme teknikleri ile 107336 üzüm yaprak görüntülerini içeren veri setine ait görüntüler iyileştirilerek çok boyutlu öznitelikleri elde edilmiştir. Daha sonra bu öznitelikler ESA tabanlı modele uygulayarak üzüm hastalıkları tespitinde %97,22 oranında başarı elde ettiler (Liu et al., 2020). Üzüm hastalıkların tespitine yönelik yapılan bir diğer çalışmada yöntem olarak Inception-V1 ve ResNet birlikte kullanımı önerilmiştir. Önerilen yöntem ile yapılan deneysel çalışmalarında %81,1 doğruluk ile üzüm hastalıklarını sınıflandırmayı başardılar (Xie et al., 2020). Ensari ve dig. Üzüm ve misirde görülen hastalıkların tespiti için ESA yöntemini önerdiler. Yapılan deneysel çalışmalarında 1600 sağlıklı ve hastalıklı yaparak görüntü kullanılmış ve çalışmada %97,03 başarı oranı sağlanmıştır (ENSARI et al., 2020). Zhang ve dig. yaprak hastalıklarını tanımlamak için GoogleNet ve Cifar10 olmak üzere iki model önerdiler. Bu modeller dokuz çeşit misir yaprağını eğitmek ve test etmek için kullandılar. Yapılan deneysel çalışmalarında sekiz tür misir yaprağı hastalığının tanınmasında, GoogLeNet modeli % 98,9'luk ve Cifar10 modeli ortalama % 98,8 doğrulukta misir hastalıklarını tespit ettiler (Zhang et al., 2018). Türkoğlu ve dig. elma hastalıklarının tespiti için çok modeli Uzun Kısa Süreli Bellek tabanlı (UKSB-LSTM) ESA tabanlı yöntem önermektedirler (Turkoğlu, Hanbay & Sengur, 2019). Önerilen model UKSB ağı ile önceden eğitilmiş ESA modelleri ile kombine edilmiştir. AlexNet, GoogleNet ve DenseNet201 ESA modellerinden elde edilen öznitelikler UKSB katmanı uygulanmıştır. UKSB çıkışları çoğuluk oylama sınıflandırıcıları sınıflandırılarak gerçek zamanlı elma hastalıkları tespiti gerçekleştirilmiştir.

Bu çalışma, derin öğrenme temelli ESA AlexNet modeli ile şeftali hastalıkları ve zararlarının tespitine yönelikdir. Literatürde şeftali hasadından sonra şeftalinin raf ömrünü sınırlayan çürümelerin tespitine yönelik çalışmalar yapılmıştır. Aslında şeftalinin çürümeye sürecini hızlandıran ve hasatta düşük rekoltenin nedeni hasat öncesi şeftali ağacındaki hastalıkların etkili bir şekilde tespit edilmesinden kaynaklanmaktadır. Bu nedenle çalışmamızda meyve hasadı gerçekleştirilmeden önce şeftali ağaçlarında sıkça görülen monilia ve koşnılı gibi hastalıkların zamanında tespit edilmesi ve gerekli önlemlerini alınması ile hem ürün rekoltesinin yükseltilmesi sağlanmış olacak hem de sağlıklı şeftalinin uygun ortamlardaki raf ömrü de uzatılmış olacaktır. Çalışmada, Türkiye'deki bitki hastalıkları ve zararlı görüntülerinden oluşan gerçek bir veri seti kullanılmıştır. Önerilen yöntem veri seti üzerinde test edildi ve sonuçlar akıllı tarım uygulamalarında faydalı modeller geliştirilmesine katkı sağlayabilecektir.

Çalışmanın geri kalanı şu şekilde düzenlenmiştir. ESA, AlexNet ve veri seti ikinci bölümde tanıtılmıştır. Üçüncü bölümde deneysel çalışma ve sonuçlar detaylı olarak verilmiştir. Son bölümde ise elde edilen sonuçlar tartışılmıştır.



Şekil 1. ESA genel Mimarisi

2. Materyal ve Metot

Bu bölümde, çalışmada kullanılan yöntemler, veri seti ve önerilen yöntemin performans değerlendirme kriterleri detaylandırılmıştır.

2.1. Evrişimli Sinir Ağı

Evrişimli Sinir Ağı (ESA), çok boyutlu diziler biçimindeki verileri işlemek için geliştirilen ve birçok işlem katmanından oluşan bir sinir ağı biçimidir (Yann LeCun Geoffrey Hinton, 2015). Bu bakımda ESA görsel nesne analizi, tanıma ve sınıflandırma, ses tanıma ve doğal dil işleme gibi alanlarda yaygın olarak kullanılmaktadır. ESA, klasik sinir ağlarından farklı olarak evrişim öznitelikleri çıkarma ve sınıflama özelliklerine sahiptir (Gunavathi et al., 2020). Şekil 1'deki ESA genel mimarisinde görüldüğü üzere ESA'lar birçok evrişim, aktivasyon, havuzlama, tam bağlı ve softmax katmanlarından oluşmaktadır.

Evrişim katmanı, giriş görüntü özelliklerinin çıkarıldığı ilk katmandır. Büyük boyutlu giriş görüntü üzerinde (3×3 , 5×5 , 7×7 gibi) farklı boyutlardaki filtrelerin hareketi ile görüntü özelliklerini içeren daha düşük boyutlu özelliklerin elde edilmesini sağlamaktadır (Yann LeCun Geoffrey Hinton, 2015), (Prabhu, 2018). Evrişim işlemi ile bir görüntünün düşük seviyeli özellikler ilk katmanda çıkarılırken, daha karmaşık özellikler sırasıyla sonraki evrişim katmanlarında çıkarılır (Budak et al., 2018), (Demir et al., 2020), (Tumen, Yıldırım & Ergen, 2018).

Aktivasyon katmanı evrişim işlemi sonucunda elde edilen görüntü özellikleri doğrusal olmayan Düzeltilmiş Doğrusal Birim (DDB, ReLU) olarak adlandırılan bir fonksiyon ile görüntü özelliklerindeki negatif değerler elemeye edilir (Turkoglu,

Hanbay & Sengur, 2019), (Budak et al., 2018). Havuzlama katmanında, aktivasyon işlemi sonucunda elde edilen özellikler matrisinin kanal sayısı sabit tutularak maksimum ya da ortalama değer yöntemi ile bu matrisinin genişlik ve yükseklikleri azaltılmaktadır (Ayyüce Kızrak, 2018). Tam bağlı katman ise evrişim, aktivasyon ve havuzlama işlemleri sonucunda elde edilen farklı boyutlarda özellikler tek boyutlu özelliklere dönüştürülmesini sağlar (Prabhu 2018).

Softmax önceki katmanlarda elde edilen özelliklerin sınıflandırılmasını sağlamaktadır. Sınıflandırma işleminde olasılıksal değerler kullanılarak ilgi sınıfı atama işlemi yapılır (Tumen et al. 2018)

2.1.1. AlexNet

Alex Krizhevsky ve dig. tarafından nesne tanıma için tasarlanmış bir ESA modelidir (Krizhevsky, Sutskever & Hinton, 2017). 2012'de ImageNet LSVR Challenge yarışmasında %15,3 hata oranı ile en iyi model olarak ilan edilmesi ile yaygın olarak kullanılmaya başlanmıştır. Bu ESA modeli, 5 konvolusyon, 8 ReLU, 3 maksimum havuzlama, 3 tam bağlı ve başarımı artırmak için normalizasyon katmanlarından oluşmaktadır (Tablo 1'de Alexnet mimarisindeki her bir katmana ait detaylar verilmiştir). İlk konvolusyon katmanına uygulanacak olan giriş görüntüsü $227 \times 227 \times 3$ boyutlarında olmalıdır. AlexNet, 60 milyon parametrenin yanı sıra 650.000 nöron içeren büyük bir ağıdır. Tablo 1'de görüldüğü gibi ilk iki evrişim katmanından sonra ReLU ve maksimum havuzlama katmanları bulunmaktadır (Ari, Alcin & Hanbay, 2020). Üç ve dördüncü evrişim katmanları direkt bağlıdır. Beşinci konvolusyon katman çıkışında yine sırası ile ReLU ve maksimum havuzlama katmanları yer almaktadır. Çıktılar tam bağlı üç katmana gider ve sınıflandırma yapılacak ise son tam bağlı katman çıkışıyla softmax sınıflandırıcı beslenir.

Tablo 1. AlexNet mimarisindeki her bir katmanın detayları

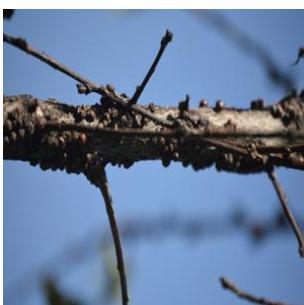
İşlem	Filtre boyutu	Derinlik	Adım	Katman çıkışı	Parametre Sayısı
Konv1+ReLU	11×11	96	4	$55 \times 55 \times 96$	$(11 \times 11 \times 3 + 1) \times 96 = 34944$
Mak. Havuzlama	3×3		2	$27 \times 27 \times 96$	
Konv2+ReLU	5×5	256	1	$27 \times 27 \times 256$	$(5 \times 5 \times 96 + 1) \times 256 = 614656$
Mak. Havuzlama	3×3		2	$13 \times 13 \times 256$	
Konv3+ReLU	3×3	384	1	$13 \times 13 \times 384$	$(3 \times 3 \times 256 + 1) \times 384 = 885120$
Konv4+ReLU	3×3	384	1	$13 \times 13 \times 384$	$(3 \times 3 \times 384 + 1) \times 384 = 1327488$
Konv5+ReLU	3×3	256	1	$13 \times 13 \times 256$	$(3 \times 3 \times 384 + 1) \times 256 = 884992$
Mak. Havuzlama	3×3		2	$6 \times 6 \times 256$	
FC6+ReLU				4096	$(256 \times 6 \times 6) \times 4096 = 37748736$
FC7+ReLU				4096	$4096 \times 4096 = 16777216$
FC8+ReLU				1000	$4096 \times 1000 = 4096000$

2.2. Transfer Öğrenme

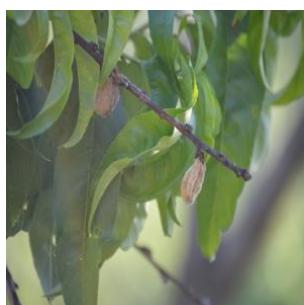
Transfer öğrenmesi, mevcut bir problemin çözümü için tasarlanıp geliştirilen modelden elde edilen özelliklerini kullanarak farklı bir problemin çözümü için kullanılmıştır. Aslında bu yaklaşım, insanoğlunun farkında olarak ya da farkında olmadan bir problemin çözümünde geçmiş deneyimlerden faydalananmasına benzemektedir (Fırıldak & Talu, 2019). Bu çalışmada, transfer öğrenmeye dayalı önceden eğitilmiş ESA modelinde bazı ayarlamalar yaparak kullanılmıştır. Çünkü önceden eğitilmiş bir modelin tercih edilmesi, rastgele ağırlıklar ile ESA modelin eğitilmesinden daha kolay ve hızlıdır.

2.3. Veri seti

Veri seti, Türkiye TRB1 bölgesindeki Malatya, Elazığ ve Bingöl illerinde yaygın bitki hastalıklarının tespiti için Bingöl Üniversitesi Ziraat Fakültesi ve İnönü Üniversitesi bitki koruma alanında çalışan akademisyenler tarafından hazırlanmıştır. Veri seti, Kayısı, Ceviz, Kiraz ve Şeftali gibi meyve ağaçlarında sıkça rastlanılan bitki hastalıklarına ait 1965 görüntüyü içermektedir. Tüm görüntüler renkli olup 4000×6000 çözünürlüğe sahiptir (Turkoğlu & Hanbay, 2019b). Bu çalışmada, veri setindeki 427 adet şeftali koşnili ve 327 adet şeftali monilya hastalıklarına ait renkli görüntüler kullanılacaktır.



(a) Koşnil



b) Monilya

Şekil 2. Şeftali hastalık görüntüleri

Şekil 2'de veri kümesindeki bazı hastalıklı şeftali görüntüleri yer almaktadır. Şekil 2 (a) şeftali koşnili hastalık görüntülerini ve Şekil 2 (b)'de şeftali monilya hastalık görüntülerini yer almaktadır. Şeftali koşnili, ağaç gövde ve dallarında görülen bir hastalıktır. Hastalıkla bölgeler hızla zayıflar ve zamanla yapraklar solar, dökülür ve sonunda ağaç dalları kurur. Şeftali koşnili bazen meyve üzerinde de görülebilir bu durumda şeftali meyvesinde kırmızı lekeler görülmektedir. Şeftali monilyası ise önce çiçekte ortaya çıkar daha sonra çiçek sapı ve oradan ağaç dallarına bulaşmaktadır. Bu hastalık ince sürgünlerde kurmaya yol açarken, ağaç dallarında yaralara neden olmaktadır.

2.4. Performans Değerlendirme Kriterleri

Şeftali hastalık türlerinin tespiti için önerilen yöntemin performans değerlendirmesi, Denklem 1-5'de bağıntıları verilen parametreler ile birlikte alıcı işlem karakteristik (Receiver Operating Characteristic - ROC) eğrisi seçildi. Bu parametreler veri setinden çıkarılan öznitelikler üzerindeki davranışını tahminine imkan sağlamaktadır (Siuly et al., 2020).

$$\text{Doğ} = \frac{\text{DP} + \text{DN}}{\text{DP} + \text{DN} + \text{YP} + \text{YN}} \times 100 \quad (1)$$

$$\text{Duy} = \frac{\text{DP}}{\text{DP} + \text{YN}} \times 100 \quad (2)$$

$$\text{Özg} = \frac{\text{DN}}{\text{DN} + \text{YP}} \times 100 \quad (3)$$

$$\text{Kes} = \frac{\text{DP}}{\text{DP} + \text{YP}} \times 100 \quad (4)$$

$$\text{F1 Skor} = 2 * \frac{\text{Duy} \times \text{Kes}}{\text{Duy} + \text{Kes}} \times 100 \quad (5)$$

Burada,

Doğ: Doğruluk oranını tanımlamaktadır. Veri setindeki koşnili ve monilya hastalıkların doğru olarak tespit edilme oranını göstermektedir,

Duy: Duyarlılık oranını tanımlamaktadır. Veri setinde toplam koşnili hastalıkların doğru olarak tespit edilme oranını ifade etmektedir,

Özg: Özgüllük oranını tanımlamaktadır. Veri setinde toplam monilya hastalıkların doğru olarak tespit edilme oranını ifade etmektedir.

Kes: Keskinlik oranını tanımlamaktadır. Doğru olarak tahmin edilen koşnili hastalıkların veri setindeki toplam koşnili hastalığına sahip verilere olan oranıdır,

F1 Skor: Duyarlılık ve keskinlik değerlerinin harmonik ortalaması olup, sınıflandırma algoritmaları kıyaslanırken en çok kullanılan ölçülerden biridir.

DP: önerilen modele göre doğru olarak sınıflandırılan koşnili hastalık sayısını;

YP: önerilen modele göre monilya hastalık olarak hatalı sınıflandırılan koşnili hastalık sayısını;

DN: önerilen modele göre doğru olarak sınıflandırılan monilya hastalık sayısını;

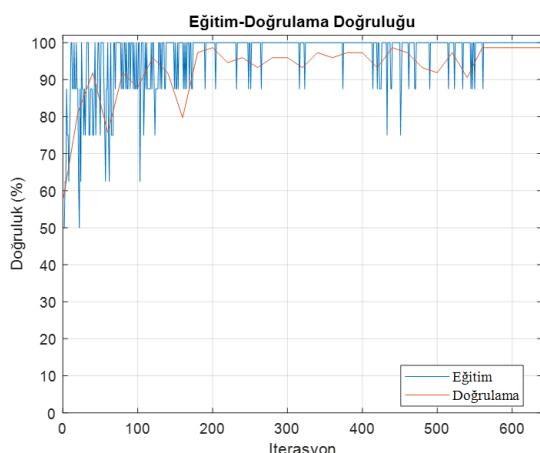
YN: önerilen modele göre koşnili olarak hatalı sınıflandırılan monilya hastalık sayısını tanımlamaktadır.

3. Deneysel Çalışmalar ve Tartışma

Bu çalışmada, ESA AlexNet modeli ile şeftali ağaçlarında görülen hastalıkların tespiti, 427 adet şeftali koşnili ve 327 adet şeftali monilya hastalıklarına ait renkli görüntülerini içeren veri seti test edilmiştir. Deneysel çalışmalar, dört çekirdekli Intel i7 işlemci, NVIDIA GTX 850M GPU ve 16GB hafızaya sahip bilgisayarda kurulu MATLAB (2019b) ile gerçekleştirildi. Ayrıca AlexNet modülü için MATLAB Derin Öğrenme Araç kutusu kullanıldı.

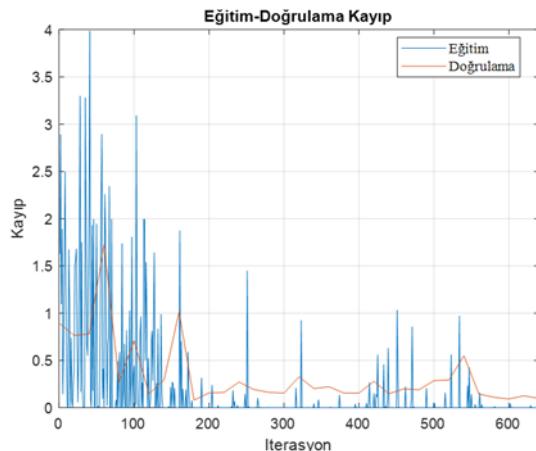
Tüm veri seti görüntülerini transfer öğrenimi için rastgele bir şekilde sırasıyla %70, %10 ve %20 oranlarında eğitim, doğrulama ve test olmak üzere üç bölüme ayrılmıştır. Eğitim veri seti önerilen modelin öğrenme sürecinde, doğrulama veri seti modeli oluşturabilmek amacıyla eğitim setinin bir parçası olarak kullanıldı. Ayrıca doğrulama veri seti ise model parametrelerinin ayarlamak için de kullanıldı. Test veri kümesi ise performans değerlendirmesi için kullanıldı.

En iyi model için AlexNet parametreleri (learning rate, validation frequency, batch size and number of epochs) eğitim süresince optimize edildi. Bu amaçla farklı parametreler için uygun değerleri bulmak için çok sayıda deney gerçekleştirildi. Buna göre başlangıç öğrenme oranı, doğrulama frekansı, toplu iş boyutu ve maksimum epochs sırasıyla 0.0001, 20, 8 ve 10 olarak seçilmiştir. Yapılan deneysel çalışmalarla kullanılan AlexNet modelinin her bir katmandaki veri değişiminin nasıl olduğu AlexNet mimarisinin detaylandırıldığı Tablo 1'de yer almaktadır.



Şekil 3. AlexNet eğitim-doğrulama doğruluk eğrisi

Transfer öğrenme sürecinde AlexNet modelinin eğitim validasyon doğruluğu Şekil 3'de ve Şekil 4'de ise eğitim validasyon kayıp bilgi grafikleri görülmektedir. Şekil 3'de görüldüğü gibi yaklaşık 550 sonrası iterasyonlarda doğrulama doğruluğunda önemli bir gelişme olmadığı eğitim sürecinin başarılı bir şekilde tamamlandığı görülmektedir. Ayrıca Şekil 4'de görüldüğü üzere eğitim süresince kayıp veri oranı 0.5 değerinin çok altında olduğu görülebilmektedir. Böylece önemli bir veri kaybı olmadan eğitim süreci başarılı bir şekilde tamamlanmıştır.



Şekil 4. AlexNet eğitim-doğrulama kayıp eğrisi

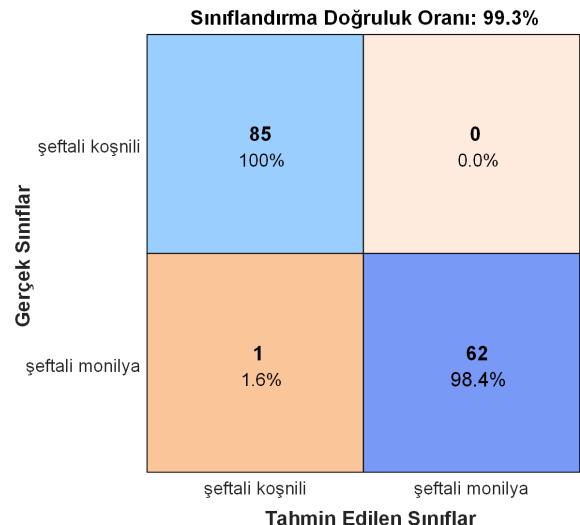
Deneysel çalışmalarla, önerilen yöntemin performans değerlendirmesinde daha önceki bölümlerde açıklanan

performans değerlendirme kriterleri referans alınmıştır. Yapılan deneysel çalışmanın genel sınıflandırma sonuçları Tablo 2'de görülmektedir. Tabloda doğruluk, duyarlılık, seçicilik, keskinlik ve F1 skor sonuçları verilmiştir.

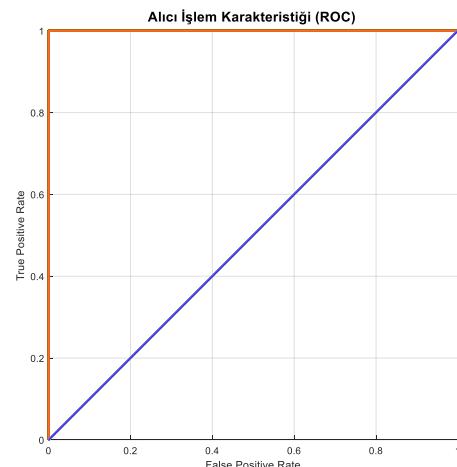
Tablo 2. AlexNet sınıflandırma sonuçları (%).

Dog	Duy	Özg	Kes	F1 Skor
99,32	98,41	100,00	100,00	99,20

Tablo 2'de gördüğü gibi şeftali ağacında görülebilecek monilya ve koşnili hastalıklarını %99,32 doğruluk oranında tespit edebilmektedir. Ayrıca seçicilik ve keskinlik değerlerinde %100'lük başarım oranına ulaşmıştır. Sınıflara özgü daha ayrıntılı performans değerlendirmesi için Şekil 5'de softmax sınıflandırıcı hata (confusion) matrisi verilmiştir. Şekil 5'deki hata matrisinde her bir sütünün toplamı o kategori için tahmin edilen veri sayısının gösterirken, her bir satır veri setindeki gerçek değerleri göstermektedir. Şekil 5'de görüldüğü üzere 85 (%100) şeftali koşnili sınıfı sınıflı veriler ve 62 (%98,40) şeftali monilya sınıfı veriler AlexNet softmax katmanı tarafından doğru bir şekilde sınıflandırılmıştır. Öte taraftan 1 (%1,6) şeftali monilya sınıfı veri hatalı bir şekilde koşnili sınıfı veri olarak sınıflandırıldığı görülmektedir. Hata matrisi değerleri veri setine ait veri etiketlerinin yüksek bir oranda tahmin edildiğini açıkça göstermektedir.



Şekil 5. Hata Matrisi



Şekil 6. Açıç işlem karakteristik eğrisi

Modelin etkinliğini daha fazla doğrulamak için Şekil 6'da ROC eğrisi görülmektedir. ROC eğrileri, YP oranlarına karşı DP oran grafiklerini gösterir ve eğrilarındaki alan 0-1 arasında olup sınıflandırıcıların genel performansının ölçüsünü göstermektedir.

Önerilen yöntemin daha ayrıntılı performans değerlendirmesi amacıyla, aynı veri setini kullanılan mevcut yöntemlerin performans karşılaştırması Tablo 3'de verilmiştir. Tablo 3 incelendiğinde önerilen yöntemin mevcut tüm yöntemlerden daha iyi performansa sahip olduğu görülmektedir. Bu bakımdan önerilen yöntem gerçek zamanlı uygulamaların geliştirilmesine katkı sağlayabileceğini göstermektedir.

Tablo 2. Önerilen yöntemin diğer yöntemler ile karşılaştırma

Yöntem	Doğruluk (%)
GoogleNet [9]	95,22
ResNet50 [9]	97,86
Inceptionv3 [9]	97,45
SqueezeNet [9]	97,96
Önerilen Yöntem	99,30

4. Sonuç

Bitki hastalıklarının tespitine yönelik geleneksel makine öğrenim yöntemleri ile hastalık görüntülerinden özellik çıkarımı manuel olarak yapılmaktadır. Bu hem zor hem de zaman alan bir süreçtir. Bu durumda tespit edilen bitki hastalıklarına karşı alınacak önlemlerde gecikmelere neden olabilmektedir. Bu çalışmada, şeftali hastalıklarının daha hızlı ve otomatik tespiti için derin öğrenme tabanlı etkili bir yaklaşım önerilmiştir. Çalışmada, hastalıklı şeftali görüntülerinden AlexNet ESA modelinde basit birkaç parametre tanımlaması ile hastalık türü hızlı ve yüksek doğruluk ile tespit edildi. Deneysel çalışmalarında %99,30 doğruluk oranı ile şeftali hastalıkları tespit edildi. Aynı veri seti ile yapılan mevcut çalışmalarından %1,44 daha yüksek doğruluk oranına ulaşmıştır. İleride yapılacak bir çalışma olarak, gerçek zamanlı ve akıllı tarım uygulamalarında faydalı modellerin geliştirilmesine katkı sağlayabilecektir.

Kaynakça

- Ari A, Alcin OF, Hanbay D. 2020. Brain MR Image Classification Based on Deep Features by Using Extreme Learning Machines. *Biomedical Journal of scientific & Technical Research* 25:19137–19144. DOI: 10.26717/BJSTR.2020.25.004.
- Ayaz F, Ari A, Hanbay D. 2017. Leaf recognition based on artificial neural network. In: *In 2017 International Artificial Intelligence and Data Processing Symposium (IDAP)*. 1–5. DOI: 10.1109/idap.2017.8090240.
- Ayyuce Kızrak. 2018. Derine Daha Derine: Evrimli Sinir Ağları. Available at <https://medium.com/@ayyucekizrak/derine-daha-derine-evrimli-sinir-aglari-2813a2c8b2a9> Erişim Tarihi: Ocak 2021
- Budak U, Alçin ÖF, Aslan M, Şengür A. 2018. Optic Disc Detection in Retinal Images via Faster Regional Convolutional Neural Networks. In: *In 1st International Engineering and Technology Symposium (IETS-2018)*.
- Chen C, Shi YQ. 2008. JPEG image steganalysis utilizing both intrablock and interblock correlations. In: *Proceedings - IEEE International Symposium on Circuits and Systems*. 3029–3032. DOI: 10.1109/ISCAS.2008.4542096.
- Chen J, Yin H, Zhang D. 2020. A self-adaptive classification method for plant disease detection using GMDH-Logistic model. *Sustainable Computing: Informatics and Systems* 28. DOI: 10.1016/j.suscom.2020.100415.
- Demir F, Turkoglu M, Aslan M, Sengur A. 2020. A new pyramidal concatenated CNN approach for environmental sound classification. *Applied Acoustics* 170. DOI: 10.1016/j.apacoust.2020.107520.
- ENSARİ T, ARMAH DC, BALSEVER AE, DAĞTEKİN M. 2020. Görüntü Tabanlı Dijital Bitki Fenotiplemesi için Konvolüsyonel Sinir Ağları. *European Journal of Science and Technology*:338–342. DOI: 10.31590/ejosat.780087.
- Fırıldak K, Talu MF. 2019. Evrişimsel Sinir Ağlarında Kullanılan Transfer Öğrenme Yaklaşımlarının İncelenmesi. *Anatolian Journal of Computer Science* 4:88–95.
- Gunavathi C, Sivasubramanian K, Keerthika P, Paramasivam C. 2020. A review on convolutional neural network based deep learning methods in gene expression data for disease diagnosis. *Materials Today: Proceedings*. DOI: 10.1016/j.matpr.2020.10.263.
- Al Hiary H, Bani Ahmad S, Reyalat M, Braik M, ALRahamneh Z. 2011. Fast and Accurate Detection and Classification of Plant Diseases. *International Journal of Computer Applications* 17:31–38. DOI: 10.5120/2183-2754.
- Hu G, Yang X, Zhang Y, Wan M. 2019. Identification of tea leaf diseases by using an improved deep convolutional neural network. *Sustainable Computing: Informatics and Systems* 24. DOI: 10.1016/j.suscom.2019.100353.
- Krizhevsky A, Sutskever I, Hinton GE. 2017. ImageNet classification with deep convolutional neural networks. *Communications of the ACM* 60:84–90. DOI: 10.1145/3065386.
- Liu B, Ding Z, Tian L, He D, Li S, Wang H. 2020. Grape Leaf Disease Identification Using Improved Deep Convolutional Neural Networks. *Frontiers in Plant Science* 11. DOI: 10.3389/fpls.2020.01082.
- Liu B, Zhang Y, He DJ, Li Y. 2018. Identification of apple leaf diseases based on deep convolutional neural networks. *Symmetry*. DOI: 10.3390/sym10010011.
- Mangathayaru N, Mathura Bai B, Srikanth P. 2018. Clustering and classification of effective diabetes diagnosis: computational intelligence techniques using PCA with kNN. In: *Smart Innovation, Systems and Technologies*. 426–440. DOI: 10.1007/978-3-319-63673-3_52.
- Mohanty SP, Hughes DP, Salathé M. 2016. Using deep learning for image-based plant disease detection. *Frontiers in Plant Science* 7. DOI: 10.3389/fpls.2016.01419.
- Pevný T, Bas P, Fridrich J. 2010. Steganalysis by subtractive pixel adjacency matrix. *IEEE Transactions on Information Forensics and Security* 5:215–224. DOI: 10.1109/TIFS.2010.2045842.
- Pires RDL, Gonçalves DN, Oruê JPM, Kanashiro WES, Rodrigues JF, Machado BB, Gonçalves WN. 2016. Local descriptors for soybean disease recognition. *Computers and Electronics in Agriculture* 125:48–55. DOI: 10.1016/j.compag.2016.04.032.
- Prabhu R. 2018. Understanding of Convolutional Neural Network (CNN) Deep Learning. Available at <https://medium.com/@RaghavPrabhu/understanding-of-convolutional-neural-network-cnn-deep-learning-99760835f148>
- Sahu AK, Swain G. 2019. Dual stego-imaging based reversible data hiding using improved LSB matching. *International*

- Journal of Intelligent Engineering and Systems* 12:63–73.
DOI: 10.22266/ijies2019.1031.07.
- Savary S. 2020. Plant health and food security. *Journal of Plant Pathology* 102:605–607. DOI: 10.1007/s42161-020-00611-5.
- Siuly S, Alcin OF, Kabir E, Sengur A, Wang H, Zhang Y, Whittaker F. 2020. A New Framework for Automatic Detection of Patients with Mild Cognitive Impairment Using Resting-State EEG Signals. *IEEE Transactions on Neural Systems and Rehabilitation Engineering* 28:1966–1976. DOI: 10.1109/TNSRE.2020.3013429.
- Tumen V, Yildirim O, Ergen B. 2018. Detection of driver drowsiness in driving environment using deep learning methods. *2018 Electric Electronics, Computer Science, Biomedical Engineerings' Meeting, EBBT 2018*:1–5. DOI: 10.1109/EBBT.2018.8391427.
- Türkoğlu M, Hanbay D. 2019a. Plant recognition system based on extreme learning machine by using shearlet transform and new geometric features. *Journal of the Faculty of Engineering and Architecture of Gazi University* 34:2097–2112. DOI: 10.17341/gazimmfd.423674.
- Türkoğlu M, Hanbay D. 2019b. Plant disease and pest detection using deep learning-based features. *Turkish Journal of Electrical Engineering and Computer Sciences* 27:1636–1651. DOI: 10.3906/elk-1809-181.
- Turkoglu M, Hanbay D, Sengur A. 2019. Multi-model LSTM-based convolutional neural networks for detection of apple diseases and pests. *Journal of Ambient Intelligence and Humanized Computing*. DOI: 10.1007/s12652-019-01591-w.
- Xie X, Ma Y, Liu B, He J, Li S, Wang H. 2020. A Deep-Learning-Based Real-Time Detector for Grape Leaf Diseases Using Improved Convolutional Neural Networks. *Frontiers in Plant Science* 11. DOI: 10.3389/fpls.2020.00751.
- Yan Q, Yang B, Wang W, Wang B, Chen P, Zhang J. 2020. Apple leaf diseases recognition based on an improved convolutional neural network. *Sensors (Switzerland)* 20:1–14. DOI: 10.3390/s20123535.
- Yann LeCun Geoffrey Hinton YB. 2015. Deep learning (2015), Y. LeCun, Y. Bengio and G. Hinton. *Nature*.
- Zhang X, Qiao Y, Meng F, Fan C, Zhang M. 2018. Identification of maize leaf diseases using improved deep convolutional neural networks. *IEEE Access* 6:30370–30377. DOI: 10.1109/ACCESS.2018.2844405.