

Faster R-CNN Evrişimsel Sinir Ağrı Üzerinde Geliştirilen Modelin Derin Öğrenme Yöntemleri ile Doğruluk Tahmini ve Analizi: Nesne Tespiti Uygulaması

Okan Yılmaz¹, Hakan Aydın², Ali Çetinkaya^{3*}

^{1*} İstanbul Gelişim Üniversitesi, Mühendislik ve Mimarlık Fakültesi, Bilgisayar Mühendisliği Bölümü, İstanbul, Türkiye (ORCID: 0000-0003-4412-1771)

² İstanbul Gelişim Üniversitesi, Mühendislik ve Mimarlık Fakültesi, Bilgisayar Mühendisliği Bölümü, İstanbul, Türkiye (ORCID: 0000-0002-0122-8512)

³ İstanbul Gelişim Üniversitesi, Teknoloji Transfer Ofisi Uygulama ve Araştırma Merkezi, İstanbul, Türkiye (ORCID: 0000-0003-4535-3953)

(İlk Geliş Tarihi 23 Haziran 2020 ve Kabul Tarihi 5 Aralık 2020)

(DOI: 10.31590/ejosat.753896)

ATIF/REFERENCE: Yılmaz, O., Aydın, H. & Çetinkaya, A. (2020). Faster R-CNN Evrişimsel Sinir Ağrı Üzerinde Geliştirilen Modelin Derin Öğrenme Yöntemleri ile Doğruluk Tahmini ve Analizi: Nesne Tespiti Uygulaması. *Avrupa Bilim ve Teknoloji Dergisi*, (20), 783-795.

Öz

Günümüz teknolojisiyle sonuçların daha doğru şekilde elde edilmesi için yapay zeka, makine öğrenmesi ve derin öğrenme algoritmalarından faydalananlarak başarılı sonuçlar elde edilmeye çalışılmaktadır. Literatürdeki çalışmalar içerisinde, başarı (succes) ve kayıp oranlarının (loss), seçilen algoritmaların performanslarını etkileyen en önemli faktörlerin; farklı eğitim adımları (epoch) ve veri setlerindeki karmaşık olduğu tespit edilmiştir. Bu çalışmada, belirli bir algoritmanın belirlenmiş bir nesneden oluşturulan veri seti üzerinde çalıştırılarak başarılı bir şekilde tespit etme işleminin gerçekleştirilmesi hedeflenmiştir. Gerçekleştirilen bu çalışmada Faster R-CNN (Faster Region Based Convolutional Networks) evrişimsel sinir ağları kullanılarak 18 ayrı deney içerisinde 502 adet görüntü ile oluşturulan veri setinin derin öğrenme teknikleriyle nesne tespit işlemi gerçekleştirilmiştir. Nesne tanıma yaparken fotoğraf, video ve anlık olarak görüntü alınabilecek kameraların seçeneklerinin bulunduğu ara yüz tasarlanmıştır. Çalışmada farklı eğitim adımları ile modeli eğitip, en doğru oranla tahmin yapan eğitim adımı değeri bulunmaya çalışılmıştır. Eğitim sürecinde en başarılı tahmin oranının bulunması için ise farklı eğitim adımlarıyla deneyler gerçekleştirilmiştir. Yapılan toplam 100.000 eğitim adımlık eğitimin sonucunda elde edilen başarı oranı %97,835 ve kayıp oranı %2,165'tir.

Anahtar Kelimeler: Faster R-CNN, Nesne tanıma, Object Detection API, Evrişimsel Sinir Ağrı, Derin Öğrenme.

Accuracy Estimation and Analysis of The Model Developed on The Faster R-CNN Evolutionary Neural Network Using Deep Learning Methods: Object Detection Application

Abstract

With today's technology, successful results are tried to be achieved by using artificial intelligence, machine learning and deep learning algorithms in order to obtain the results more accurately. In studies in the literature, it has been found that success and loss rates, the most important factors affecting the performance of selected algorithms, are complex in different training steps (epoch) and data sets. In this study, it is aimed to successfully detect a particular algorithm by running it on a dataset created from a specified object. In this study, object detection was performed using deep learning techniques of the data set created with 502 images in 18 separate experiments using the Faster R-CNN (Faster Region Based Convolutional Networks) convolutional neural network. An interface is designed with camera options that can take photos, videos, and images instantly when deconstructing objects. In the study, we tried to find the value of the training step that trains the model with different training steps and estimates the most accurate ratio. In order to find the most

* Sorumlu Yazar: İstanbul Gelişim Üniversitesi, Teknoloji Transfer Ofisi Uygulama ve Araştırma Merkezi, İstanbul, Türkiye, ORCID: 0000-0003-4535-3953, alacetinkaya@gelisim.edu.tr , 0212 422 70 00 – D.No: 7187

successful prediction rate in the training process, experiments were conducted with different training steps. A total of 100,000 training steps, the success rate achieved as a result of the training is 97.835% and the loss rate is 2,165%.

Keywords: Faster R-CNN, Object detection, Object Detection API, Convolutional Neural Networks, Deep Learning.

1. Giriş

Günümüzde, teknolojinin gelişmesiyle birlikte gelişmeye devam eden bir konu olan yapay zeka, 1956 yılında John McCarthy tarafından bir toplantı sırasında adını duymuştur. Gelişmeye devam etmesiyle birlikte 2006 yılında Geoffrey Hinton tarafından sunulan çoklu öğrenme tanımı, derin öğrenmenin başlangıcı için ön ayak olmuştur. İnsan iş yükünü hafifletmek, daha doğru sonuçlara ulaşmak, çözüme en hızlı şekilde ulaşabilmek adına gerekliliğini koruyan bir konu olan derin öğrenme, sağlık sektörü, otomotiv sektörü, otonom sistemler, güvenlik sistemleri, görüntü işleme, ses tanıma gibi birçok çalışma alanında kullanılmaya başlamıştır.

Birçok alanda olduğu gibi nesne tanıma alanında da kullanılmaya başlayan yapay zeka, insanlar için bu alanda da birçok kolaylık sağlamaıyla bilinmektedir. Görme engelli kişilerin nesne tanıma sayesinde çevresinde olan nesneleri algılayabilmesi bu alandaki bir örnektir. Görüntü işleme, günümüzde bulunan şirketlerin çeşitli amaçlar için kullandıkları ve hızla büyümekte olan bir yöntemdir. Bu yöntem mühendislik ve bilgisayar alanlarında da temel araştırma alanı oluşturur. Bu yönteme fotoğraf, video ve kamera üzerinden anlık olarak alınan görüntüler girdi olarak verilmektedir ve girdi olarak verilen verilerin işlenmesiyle elde edilen görüntü içerisindeki yararlı bilgiler elde etmeyi amaçlayan bir yöntemdir.

Derin öğrenme görüntü işleme ve analizi, ses işleme ve analizi, robotik sistemler, kanser gibi ciddi hastalıkların teşhisini gibi çok fazla alanda kullanılmıştır. Görüntülerde bulunan nesneleri hızlı ve doğru şekilde tespit etmek amacıyla geliştirilen ilk algoritmayı Viola Jones 2001 yılında geliştirmiştir (Viola ve ark., 2001). Günümüzde bulunan sınıflandırma yöntemlerine ait algoritmaları derin öğrenmenin makine öğrenmesinin karşısında daha performanslı ve doğruluk oranına sahip olması sebebiyle alternatif olarak bir derin öğrenme algoritması kullanılmış ve sınıflandırma işlemi yapıldığı görülmüştür (Döş ve ark., 2019). Makine öğreniminde önemli aşamalardan biri olan özellik vektörlerinin çıkarılması ve bu vektörlerin çıkarılmasında ihtiyaç duyulan uzman bilgilerinin kullanılması, uzman kişileri çok mesgul etmektedir ve aynı zamanda çok fazla zaman aldığı görülmüştür. Bu yüzden makine öğrenimi bir veriyi ön işleme tabi tutulmadan ve uzmanların bilgilerinden yararlanılmadan işlenilemez olduğu görülmüştür. Derin öğrenme ise makine öğreniminin aksine öğrenme işlemlerini ham veri üzerinden yaptığı görülmüş ve bu işlemlerin, oluşturulan modellerin farklı katmanlarda kullanılmasıyla tamamlandığı görülmüştür (Inik ve ark., 2017). Elde edilmiş olan görüntülerin içerisinde yüz olup olmadığını gösteren bir sistem üzerinde yapılan testlerin sonucunda ise OpenCV ile gelen Viola & Jones sınıflandırıcısından daha başarılı doğruluk oranlarının elde edildiği görülmüştür (Baykara, 2018).

Geliştirilen uygulamada güvenliği, kullanıcı adı ve paroladan daha üst düzeye çıkarmak için yüz tanıma işleminin kullanıldığı görülmüştür (Vurgun, 2017). Yüz ifadelerini baz alarak duyu tespiti temel duyguların (mutlu, kızgın, üzgün, iğrenme, korku, şaşkına ve nötr) olmak üzere 7 tanesi baz alınarak geliştirilmiştir.

4 erkek ve 3 kadın olmak üzere toplam 7 kişiden 9296 adet görüntü üzerinde veri seti oluşturulmuştur (Sağbaş ve ark., 2019). Gerçek zamanlı olarak kamera görüntülerinden alınmış olan yüz görüntülerinin işlenmesi sonucunda elde edilen cinsiyet bilgisi ve kameralara olan uzaklığını incelenerek ekran'a belirlenen reklamların görüntülenmesinin sağlanması amaçlanmıştır (Kabasakal, 2018). E-ticaret platformlarında kullanıcılar renk ve desen seçimleri halinde önerilen kıyafet değerlendirmelerini sunmasının hedeflendiği vurgulanmıştır. Desen analizi için Hough Dönüşüm Algoritması kullanılmış aynı zamanda renk sınıflandırılması için ise Bulanık Mantık Sistemi kullanıldığı görülmüştür (Abusabra, 2018).

Geçerleştirilmiş olan bir çalışmada Melanom türünün tanısını yapması için tasarlanmış olan C4Net sinir ağı modeli ve aynı zamanda günümüzde çok duyulan AlexNet, VGGNet, GoogLeNet, ResNet gibi derin öğrenme modelleri ve yapay sinir ağları kullanılmış aynı zamanda ise yine çok duyulmuş olan en yakın komşu algoritması gibi makine yöntemlerini de içerisinde barındıran deneyel bir çalışma yapıldığı görülmüştür. Yapılmış olan bu çalışmada C4Net sinir ağı modeli %96,94 oranındaki bir doğrulukla teşhisini doğru koyarak diğer modellere göre daha başarılı sonuç elde ettiği görülmüştür (Yıldız, 2019). Kadınlarda görülen kanser çeşidi olan meme kanseri, kanser türleri arasında ölümle sonuçlanan akciğer kanserinden sonra ki en ölümcül kanser türü olmasından dolayı ve bu kanser türünün en önemli iyileşme sürecinde ise birinci sırada erken teşhis yer almışından dolayı bu yapılan çalışma ile bu teşhisin kolaylaştırılması öngörülmüştür (Alpaslan, 2019). Kan yapılarında bulunmakta olan beyaz kan hücreleri sayesinde önemli olan bu bilgilere ulaşmanın sağlık sektörü için önemli olmasından dolayı ve bu bilgilere ulaşmak için mikroskop görüntüleri hekimler tarafından manuel olarak incelenip elde edilen bulgulardan sonuçların çıkarılması yorucu ve zaman kaybına sebebiyet vermesinden kaynaklı bu iş yükünü hafifletmek amacının hedeflendiği görülmüştür (Çam ve ark., 2019). Antep fistığına ait verilerin alınarak kalite oranına göre sınıflandırılması hedeflenmiştir. Derin öğrenme ağı ile Antep fistıklarına ait 11 adet sınıflandırılma grubundan 2750 tane görüntü verileriyle eğitildiği gözlemlenmiştir. Test edilmesi için ise gerçek zamanlı görüntülerin ve bilgisayar görüntülerinin kullanıldığı görülmüştür. Elde edilen test sonuçlarına göre %100 oranında başarılı olduğu görülmüştür (Rashid, 2019).

Uzmanların incelemekte olduğu MR görüntülerinin daha hızlı incelenmesinin gereği ve bu sayede beyin tümörlerinden kaynaklanan ölümlerin enaza inceceği kanısı ortaya çıkmış ve yapılmış olan bu çalışmada MR görüntülerinden tümörü kolayca bulup yerini uzmanlara bu durumu bildirebilecek bir tümör tespit sisteminin geliştirilmesi hedef gösterilmiştir. Geliştirilen bu sisteme Bölgesel tabanlı Evrişimsel Sinir Ağları (BESA) kullanılmış ve aynı zamanda bu sistemin Evrişimsel Sinir Ağı (ESA) mimarisini de içerisinde barındırdığı görülmüştür (Ari ve ark., 2017). İnfertilite hastalığının teşhisinde kullanılan spermistogram (sperm testi) isimli testin önemi vurgulanmış ve hem daha kolay hem de objektif olarak değerlendirilmesi hedef gösterilmiştir. Bu çalışma kapsamında infertil hastalığına sahip olan 15 hastaya ait olan spermlerin testi sonucunda elde edilen mikroskop görüntüleri örnek olarak alındığı vurgulanmıştır (Başarslan, 2018). Klasik yöntemde insan gücüyle yapılmakta

olan kan hücrelerinin sayımı sebebiyle ortaya çıkan azalma, güvenilirliğin azalması, verimliliğin düşük olması ve yüksek düzeyde öznellik gibi eksiklerinin bulunmasından dolayı mikroskopik ortamda elde edilecek olan kan örneği görüntüleri baz alınarak bu örnekler üzerinde görüntü işleme yöntemleri kullanılarak kan hücrelerinin tespitinin yapılması ve aynı zamanda sayılarını bulup sınıflandırılmasını gerçekleştiren bir yazılımın geliştirilmesi hedef gösterilmiştir (Karakuzulu, 2018). Diyabetik Retinopati hastalığı üzerinde sınıflandırma yapılrken evrimsel sinir ağları kullanılmış test verisi olarak ta MESSIDOR veri setinin kullanıldığı görülmüştür. Elde edilen test sonuçlarına göre %95'lik bir başarım oranının kazanıldığı görülmüştür (Tükel, 2019).

Fiziksel ve motor engelli kişilerin doktorları tarafından sınıflandırma işlemlerinin yapılabilmesi için birçok etken bulunduğuundan bu süreç zor ve uzun süren bir işlem olduğu için sınıflandırmaları konusundaki zorluğu göz önüne alınarak örnek bir çalışma önerilmiştir (Karaci, 2020). İşitme problemi yaşayan kişilerin yaşam koşullarını kolaylaşturma amacının hedeflendiği görülmüştür. Bu çalışmada Türk İşaret Dili (TİD)'ne ait olan parmak hareketleri Konvolüsyonel Sinir Ağları (Convolutional Neural Networks, CNN) yöntemi kullanılarak yazı diline çevrildiği görülmüştür (Ezel, 2018). Su kalitesini tespit etmek açısından önemli bir role sahip olan ve 4 türü bulunan Spirulina isimli alg mikroorganizmasının otomatik olarak tespit edilmesi hedef gösterilmiştir. Bu tespit işlemleri geleneksel olarak uzmanlar aracılığıyla manuel olarak yapılmasından kaynaklı olarak ortaya çıkabilecek hataların sonucunda yanlış işlemler gerçekleştirilebileceğinden dolayı otomatik yapılacak tespit işlemleri uzmanlara olabildiğince yardımcı olması hedef gösterilmiştir. Bu yöntemden elde edilen verilere göre %84 başarı oranının elde edildiği görülmüştür. Diğer yöntemlerle karşılaştırılması için diğer yöntemlerle de test edilmiş ve bunun sonucunda elde edilen sonuçlara göre SURF %63 oranında, FAST %64 oranında, CNN ise %99 oranında bir başarı elde ettiği görülmüştür (Siddik, 2019). İşitme ve görme engelli kişilerin el hareketlerinin algılanması ve istenilen işlemlerin gerçekleştirilmesi için 2D görüntülerin yapılarından faydalanan bilmek ve aynı zamanda eğitimlerinin kolay olmasından kaynaklı olarak CNN mimarisinin kullanıldığı görülmüştür (Mahmood, 2019).

Saldırı tespit sistemlerinin performansının geliştirilmesi için, Deep Feed-Forward neural network (derin ileri besleme yapay sinir ağı), Random Forest (Rastgele Orman) ve Gradient Boosting Tree (Gradyan Arttırma ağaçları) isimli sınıflandırma yöntemlerinin kullanıldığı görülmüştür. Test işlemlerinin yapılması için ise UNSW-NB15 ve CICIDS2017 veri setleri kullanılmıştır. Aynı zamanda Apache Spark kullanılarak derin öğrenme teknigi uygulanmış ve elde edilen sonuçlara göre CICIDS2017 veri seti ikili sınıflandırmada %99,99 doğruluk oranının yakalarken çoklu sınıflandırma için ise DNN yöntemi %99,56 doğruluk oranyla yüksek seviyede olduğu görülmüştür (Faker, 2019). Gerçekleştirilmiş olan bir çalışmada, DDOS tespiti, IDS tanıma, Epileptik nöbet tanımlama ve başka bir veri seti olan basamak sınıflandırma veri setlerinin kullanıldığı görülmüştür (Karim, 2019).

Atmege328P mikrodenetleyici kontrollü konveyör bant sisteminin ve görüntü işleme teknolojisinin entegre olarak çalışarak önceden tanımlanmış ürünlerin parça şeklinde ayırmak için bir sistem tasarlanmıştır (Danışman ve ark., 2017). RFID

teknolojisiyle birlikte derin öğrenme tekniklerini kullanarak konum bulma işleminin gerçekleşmesi hedef gösterilmiştir. Sistemin eğitilebilmesi için 60 cm kenarlardan oluşan kare bir alanın her bir köşesinden ölçümler alınarak dijital ortama aktarılmış ve vektörlere dönüştürülmüş ve eğitime tabi tutulduğu söylemiştir (İşleyici, 2019). Doğada bulunan mantarların insanlar tarafından yenilmesi ve bu mantarların bazı çeşitlerinin zehirli olmasından dolayı yaşanabilecek sıkıntıların önüne geçmek hedef gösterilmiştir. Selçuk Üniversitesi Kampüsü'nde bulunan mantar türlerinin sınıflandırılması için görüntü işleme tekniklerinden olan K-NN algoritması ve Naive Bayes algoritmasının kullanıldığı gözlemlenmiştir. Testler ile K-NN algoritmasıyla %80 doğruluk oranı, Naive Bayes algoritmasıyla ise %96 doğruluk oranı elde edildiği görülmüştür (Erkan, 2019). İnsansız hava araçlarının (İHA) düşük maliyet, yüksek hız ve aynı zamanda yüksek hassasiyet ile elde ettiği verilerin büyük miktarda veri içermesinden dolayı elde edilen bu verilerin detay tespit aşamalarını manuel olmak şartıyla operatörler aracılığıyla yapılmasından dolayı bu çalışma ile otomatik bir şekilde yapılmasının hedeflendiği görülmüştür (Kabadayı ve ark., 2019). Internetten alınan fotoğraflar kullanılarak oluşturulmuş olan RidNet veri seti ile yedi adet farklı yüz ifadesi için derin öğrenme teknikleri kullanılarak duyu belirlemesinin yapıldığı görülmüştür. Sonrasında ise literatürde popüler olmuş olan AlexNet, GoogLeNet, ResNet101 gibi evrimli sinir ağları yöntemleriyle RidNet üzerinden transfer öğrenimi yapılmış ve test verileri olarak ise Compound Facial Expressions of Emotion (CE) ve Static Facial Expressions in the Wild (SFEW) veri setleri belirlenildiği görülmüştür. (SWEF) ise RidNet ile eğitilmiş olan diğer ağlara oranla belirgin üstünlük sağladığı görülmüştür (Koç ve ark., 2019).

Otonom araçların yaya geçidi, trafik lambaları gibi nesnelerin tanıtılmasının ve algılamasının hedeflendiği görülmüştür. 172 fotoğrafta toplamda 185 adet yaya geçidi tabelası bulunduğu görülmüştür. Tasarlanan otonom aracı ise parkurda test edilmiş ve testin başarıyla gerçekleştiği görülmüştür (Bingöl, 2018). Trafik denetimleri, otopark kontrolleri, otoyol denetlemelerinin iş yükünü hafifletmek amacı öngörülmüştür. Kameralar aracılığı ile alınan görüntüler işlenerek plaka tanımlaması yapabilen bir sistem geliştirilmiştir (Bayram, 2020). Görüntü işleme teknikleri kullanılarak trafik işaretlerinin sınıflandırılması hedeflenmiştir. Bu sistemde 43 adet farklı sınıf grubu ve 39.209 tanesi eğitim, 12.630 tanesi test olmak üzere toplamda ise 51.839 adet görüntüyü içerisinde barındıran German Traffic Sign Recognition Benchmark (GTSRB) veri seti kullanılmıştır (Tiryaki, 2019). Trafik yoğunluk haritalarından elde edilen görüntüler işlenerek trafik yoğunluk bilgisi üreten bir yöntem sunulduğu görülmüştür (Çavdaroglu, 2016). Araçların otomatik olarak sürücüye ihtiyaç duymadan yol gidebilmesi için PID kontrol tabanlı model geliştirilmiş ve sürüş simülöründe test edildiği görülmüştür (Aki, 2019).

Son zamanlarda süt sigircılığı yapan işletmelerde ineklerin refah ve sağlıklarının önemi ön plana çıktıgı süre içerisinde hayvan takiplerinin bireysel olarak takip edilme ihtiyacı doğmasından dolayı hayvanlardan elde edilen biyometrik veriler kullanılarak bir sistem oluşturup bu sistem aracılığıyla hayvanların bireysel olarak tanınması hedef gösterilmiştir. Gerçekleştirilen test aşamalarından elde edilen sonuca göre %98,44 oranında başarı elde edilirken bu sistemin uzmanlara yardımcı olabileceği kısmında olumlu sonuca varıldığı görülmüştür (Dandıl ve ark., 2019). Yaban hayvanlarının türlerini

belirlemek ve aynı zamanda sayımlarının kontrolünü sağlamak hedef olarak gösterilmiştir. Bu sistem için gauss karma modelleri (GMM) yöntemi ile videolardan alınmış olan görüntülerin arka planlarının çıkarıldığı görülmüştür. Sonra ise arka plan ve ön plandaki görüntüler kullanılarak hayvanların öznitelikleri çıkarılmıştır. Testini gerçekleştirmeye için ise yaban hayvanlarının yoğunlukla görüldüğü yerlerden alınan video görüntülerile alan testi, öznitelik testi ve renk testleri yapılmış olup bunun sonucunda ise tilki, kurt, geyik ve yaban atından oluşan 4 türün doğruluk tespiti %100 oranında tamamlandığı görülmüştür (Yabanova ve ark., 2019). Nesne takibi (Başarır, 2019) ile gerçek zamanlı olarak video görüntülerinden elde edilen meyvelere ait verilerin alınması ve bu meyvelerin boyutlarına göre sınıflandırılmasının amaçlandığı vurgulanmıştır. Bu sınıflandırılmanın gerçekleşmesi için görüntü işleme yöntemlerinden birisi olan EmguCV kütüphanesi kullanılmıştır (Akinci, 2017). Görüntü işleme teknikleriyle (Aydın, 2019) görüntü işleme yöntemleri kullanılarak optik işaretleme yapılması hedeflenmiştir. Test edilmek üzere 100'den fazla sınav kağıdı kullanılmış elde edilen test sonuçlarına göre %100 doğruluk orANIYLA başarı elde edildiği görülmüştür (Balq, 2019). Sınıf ortamında bulunan öğrencilerin tespiti ve hareketlerinin analizi yapılarak dikkat dağınlıklarının oranlarını tespit etme amacı vurgulanmıştır. OpenCV ve Dlib kütüphaneleri kullanılmış ve aynı zamanda C++ programlama dili ile bir yazılım geliştirildiği görülmüştür (Uçar, 2019). Görüntü sınıflandırma işlemlerinin gömülü sistemler üzerinden denenerek elde edilen başarı bu mimaride, %85,9 oranında olurken aynı zamanda bu mimarı 4 saat içerisinde eğitilmiş olup 0,7 ms içerisinde sonucu sunduğu vurgulanmıştır (Çalik, 2018). OpenCV ile geliştirilen bir yazılımda yapılan testlerin sonuçları ele alındığında yüz görüntülerü üzerinde ön profilden alınan bilgilerin eşleşmesi %85-90 oranında bir doğruluk payıyla başarı elde ederken bu performansa direkt olarak etki eden durumlar ise elde edilen görüntülerin çözünürlüğü, kalitesi, işıklandırması gibi etmenlerden oluştuğu görülmüştür (Tombak, 2019).

Haber türlerinin sınıflandırılmasında Support Vector Machines (SVM) yöntemi ve Recurrent Neural Network (RNN) yöntemi olmak üzere 2 ayrı yöntem kullanılmıştır (Abbas, 2019). Nesne tanımlama için kullanılmış olan SVM yöntemi %7 başarı orANIYLA ekstra bir başarı sağlanırken aynı zamanda eğitilmesinde ve sonuç üretmesinde 250 ms gibi bir zamana ekstra olarak ihtiyaç duyulduğu görülmüştür. Elde edilen bu verilere göre SVM ve CNN mimarilerinin beraber kullanılmamasının öngördüğü görülmüştür (Çalik, 2018). Yüz algılanması için sınıflandırma işlemleri yapılrken aynı zamanda cinsiyet tespitini yapması için Destek Vektör Makineleri (SVM) ve Evrişimsel Sinir Ağları (CNN) sınıflandırıcıları da kullanılmıştır. SVM sınıflandırıcı ise öznitelik çıkarımlarında elde edilen başarı oranı %75,32 olurken HOG yönteminin elde ettiği başarı oranı ise %80,58 olduğu görülmüştür. CNN sınıflandırıcı ilede %94,76 oranında bir başarı elde edildiği görülmüştür (Kabasakal, 2018).

Yapılmış olan altyapılarda oluşturabilecek çatlıkların açılabileceği sorunların tespitinin yapılması için yer radarı analizleri kullanılarak tahrıbsız yöntemin incelenmesi hedef gösterilmiştir. Derin öğrenme algoritması olan Evrişimsel Sinir Ağı (ESA) kullanılarak sınıflandırılmış ve yapılmış olan bu sınıflandırılmanın doğruluk oranının hesaplandığı görülmüştür (Tanimu, 2019). Hasta kişilerin maksimum oksijen tüketmesindeki değerlerinin tahmin edilebilmesi üzerinde tasarlanan sistem Destek Vektör Makinesi Support Vector

Machine (SVM), Çok Katmanlı Algılayıcı Multilayer Perceptron (MLP) ve Tek Karar Ağacı Single Decision Tree (SDT) gibi modellerde geliştirilerek çalışma içerisinde karşılaştırma yapılmıştır (Abdulkader, 2019).

Derin öğrenme ve görüntü işleme yöntemlerinin kullanılarak bir kumaş üzerindeki hataların otomatik olarak tespit edilmesi ve sınıflandırılması için çalışma yapılmıştır. Sınıflandırma yapmak için ise evrişimsel sinir ağı yöntemlerinden birisi olan Fast R-CNN kullanılarak sınıflandırma yapılmıştır (Nawaf, 2019). Derin öğrenme teknikleri kullanılarak araçların sınıflandırılması hedef gösterilmiştir. Bu sistem gerçekleştirilirken Faster R-CNN ResNet50, Faster R-CNN ResNet101, R-FCN ResNet101 ve SSD Mobilenet v2 olmak üzere 4 adet derin öğrenme mimarisi kullanılmış ve bu mimariler ile transfer öğrenme yöntemi eğitimlerinin tamamlandığı görülmüştür. Yapılan testlere göre Faster R-CNN ResNet50 modeli %94,24 başarı orANIYLA sınıflandırmada en başarılı model olduğu görülmüştür. kayıp oranları ise her modelde 0,05'ten az olması sebebiyle eğitim'in başarısı vurgulanmıştır (Tan, 2019). Parçacık Süre Optimizasyonu (PSO) algoritması kullanılarak lineer bir modelin üzerinde parametrelerin tahmin edilmesinde başarı elde edildiği vurgulanmıştır (Karim, 2019).

Ses tanıma işlemlerinin derin öğrenme tekniklerinden birisi olan RNN yapısı kullanılmış test edilmesi için ise Speech Commands veri setinin kullanıldığı vurgulanmıştır. Yapılan testler sonucunda ise %70,63 doğruluk oranında başarı elde edilirken daha fazla verinin kullanılması halinde daha iyi sonuçların elde edilebileceği vurgulanmıştır (Ateş, 2019). Çiçeklerin türlerine göre ayırt edilmesinde evrişimsel sinir ağı kullanılarak sınıflandırıldığı ve test sonuçlarına göre çalışma, literatürde bulunan diğer yöntemlere oranla daha başarılı olduğu vurgulanmıştır (Mete, 2019). Elde edilen görüntüler üzerinde işleme yapılarak görüntülerin ait olduğu kişilerin cinsiyeti ve bu kişilerin yaşlarının tahmin edilebilmesi hedef gösterilmiştir (Gündüz, 2019). Orman yangınlarının enaza indirilmesi ve erken müdahale edilebilmesi için çok önemli olan en kısa sürede orman yangınlarının algılanması için Yerel İkili Örütüller (LBP) ve Law's Doku Enerji Değerler (LAWS) yöntemleri kullanılırken renk öznitelikleri için ise RGB renklerinden duman rengine eş değer olan özniteliklerinin kullanıldığı görülmüştür (Toptaş, 2018).

Geçerleştirilen bu çalışmada, video, fotoğraf veya kamera üzerinden algılanan görüntüler üzerinde belirtilen nesnelerin var olup olmadığıın belirlenmesi amaçlanmıştır. Bu çalışma gerçekleştirilirken Faster R-CNN ağı kullanılmaktadır. Geliştirilmiş olan ara yüz sayesinde istenilen yöntem (video, fotoğraf veya kamera) seçilerek o yönteme uygun alanların girilmesi sonucunda elde edilen görüntülerdeki nesnelerin tahmin edilme işlemi gerçekleştirilecektir. Tablo 1'de gösterilmekte olan çalışmalardan birbirlerine oranla en yüksek doğruluk oranını elde ederek başarı sağlayan 3 çalışma bulunmaktadır. Teknik olarak, derin öğrenme tekniklerinin kullanıldığı görülen bu çalışmaların farklı algoritmaları kullandığı görülmektedir. Bu çalışmalardan birinin Adadelta optimazyon algoritmasını kullandığı görülmüştür (Karaci, 2020). Diğer bir çalışmada ise derin öğrenme algoritmalarını kullanarak %100 başarı orANIYLA sağladığı görülmüştür (İşleyici, 2019). %100 başarı orANIYLA sağlayan son çalışmanın da derin öğrenme algoritmalarını kullandığı görülmüştür (Rashid, 2019).

Bu çalışmada, ilk olarak derin öğrenme tekniklerinden algoritmalar uygulama yönünden incelenmiştir. Ayrıca literatür taramasından da analizler yapıp veri setleri üzerinde incelemeler yapılmıştır. İncelemesi yapılan algoritmaların genel olarak hangi uygulama alanlarında kullanıldıkları tablo 1 üzerinden başarı ve

hata payı olarak detaylı bilgi verilmiştir. Bu çalışma, belirli bir algoritmanın belirlenmiş bir nesneden oluşturulan veri seti üzerinde çalıştırılarak başarılı bir şekilde nesne tespit etme işleminin gerçekleştirilmesi çalışmalarını adına bir fikir sunmaktadır.

Tablo 1. Literatür taraması olarak araştırılan çalışmaların değerlendirilmesi

Çalışma Numarası	Kullanılan Teknik	Kullanılan Algoritma	Alınan Başarı Sonucu	Alınan Hata Payı
Akinci, İ. B. (2017)	EmguCV	Canny Algoritması	%95	%5
Abusabra, A. K. (2018)	Bulanık Mantık	Hough Dönüşüm Algoritması	%100	%0
Karakuzulu, A. (2018)	Belirtilmemektedir.	Hough Dönüşüm Algoritması	%87 - 96	%4 - 13
Ari, A., & Hanbay, D. (2018)	Evrişimsel Sinir Ağları	Bölgesel Tabanlı Evrişimsel Sinir Ağları	%98,66	%1,34
Kabasakal, B. (2018)	Evrişimsel Sinir Ağları	Fisher Yüz Algoritması	%61,30	%38,70
Toptaş, M. (2018)	Görüntü İşleme Teknikleri	En Yakın Komşu Algoritması	%95,95	%4,5
Çalık, R. C. (2018)	Evrişimsel Sinir Ağları	Belirtilmemektedir.	%85,9	%4,1
Yıldız, O. (2019)	Derin Öğrenme	En Yakın Komşu Algoritması	%96,94	%3,06
Abbas, S. S. I. (2019)	Derin Öğrenme	Destek Vektör Makine Algoritması	%98	%2
Döş, M. E., Uysal, M. (2019)	Derin Öğrenme	Belirtilmemektedir.	%95	%5
Tombak, M. E. (2019)	Görüntü İşleme	OpenCV	%85 - 90	%5 - 10
Rashid, M. K. (2019)	Derin Öğrenme	Derin Öğrenme Algoritmaları	%100	%0
Erkan, Y. R. (2019)	Görüntü İşleme Teknikleri	KNN ve Naive Bayes Algoritması	%96	%4
Faker Faker, O. M. (2019)	Derin Öğrenme	Random Forest ve Gradient Boosting Tree Algoritmaları	%99,56	%0,44
Uçar, M. U. (2019)	Yerel İkili Örütüler ve Gradyanların Histogramı	Destek Vektör Makine Algoritması	%72,4	%27,6
Tükel, T. (2019)	Evrişimsel Sinir Ağları	Karınca Aslanı Algoritması	%95	%5
Aydın, M. (2019)	Görüntü İşleme	Belirtilmemektedir	%95,22	%4,78
Gündüz, G. (2019)	Derin Öğrenme	Caffe Model Algoritması	%99	%1
Tan, Z. (2019)	Derin Öğrenme	Nesne Tanıma Algoritması	%94,24	%5,76
İşleyici, A. M. (2019)	Derin Öğrenme	Derin Öğrenme Algoritması	%100	%0
Ateş, E. (2019)	Derin Öğrenme	Belirtilmemektedir	%70,63	%29,37
Tiryaki, B. (2019)	Derin Öğrenme	Makine Öğrenme Algoritmaları	%96,22	%3,78
Tombak, M. E. (2019)	Görüntü İşleme	OpenCV	%85 - 90	%5 - 10
Karacı, A. (2020)	Derin Öğrenme	Adadelta Optimizasyon	%100	%0
Bayram, F. (2020)	Derin Öğrenme	Maskeli Bölgesel Evrişimsel Sinir Ağları	%98,46	%1,54

2. Materyal ve Metot

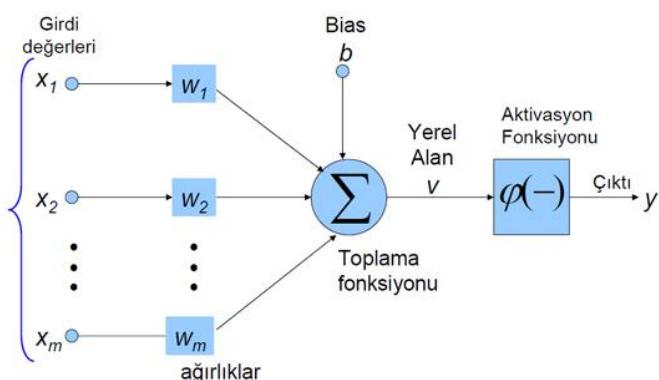
2.1. Çalışmada Önerilen Sistem

Bu çalışmayı gerçekleştirmek için derin öğrenme tekniği olan Faster R-CNN mimarisi ve Object Detection API kullanılmıştır. Nesne tespiti yapılacak yöntemin belirlenmesi için arayüz tasarlanmıştır. Bu arayüz tasarlanırken ise Tkinter kütüphanesi kullanılmıştır. Çalışmada uygulama yapılacak nesne “bardak” olarak seçilmiştir. 502 adet bardak resminden oluşturulan veri setini etiketlemek için “LabelImg” programı kullanılmıştır. Bu program sayesinde bardakları tek tek etiketleyerek farklı arkaplan ve ışık ortamlarındaki resimlerin doğru olarak sisteme öğretilmesi amaçlanmıştır. Bu sayede istemin başarı sonucu artmıştır. Gerçekleştirilen deneylerde 40.000 eğitim adımlarından sonra sistemin aşırı şekilde öğrenmesi nedeniyle doğruluk oranlarında düşüş gerçekleştiği tespit edilmiştir. Deneylerde anlık kamera görüntülerinin yanında video ve resimler üzerinde de çalışmalar gerçekleştirılmıştır.

2.2. Çalışmada Kullanılan Yöntemler

Sistemin kontrol yapısı, en az insan kontrolü kadar başarı sağlayabilecek yapay zeka metodu olan derin öğrenme tekniklerine dayanmaktadır. Derin öğrenme, elde edilmiş olan verileri eğiterek dışarıdan gelen ve herhangi bir fikir sahibi olunmayan veriler üzerinden varsayılmış yaparak bir sonuca ulaşmayı hedefler. Aynı zamanda yapılan işlemlerin kontrol kolaylığını sağlama açısından derin öğrenme ile birlikte bardak veri setinin eğitilmesini sağlayan Object Detection API ve Faster R-CNN mimarisi kullanılmıştır. Görüntü işlemleri için OpenCV, arayüz tasarlama işlemleri için ise Tkinter kütüphaneleri kullanılmıştır.

Biyolojik sinir hücresi, sinir sisteminin temel yapı taşıdır. Görevi ise genel olarak bilgi transferini sağlamaktır. Uyarıları alır, iletir ve cevap verir. Yapay sinir hücresiyle benzerlikleri ve yapısı akson, sinaps, dendrit, miyelin kılıfı ve çekirdekten oluşmaktadır. Yapay sinir ağları, yapay sinir hücrelerinden oluşmaktadır. Girdiler, ağırlıklar, toplama fonksiyonu, aktivasyon fonksiyonu ve çıktılar olmak üzere beş temel bölümü vardır. Bu bölümler Şekil 1'de gösterilmiştir (Çınar, 2018). Tek katmanlı sinir ağlarında giriş ve sonuç katmanları bulunmaktadır (Ari, 2017). Bu katmanlar genel olarak lineer olan problemlerin çözümünde kullanılmaktadır. Katmanlarda bir veya birden fazla nöron bulunmaktadır.



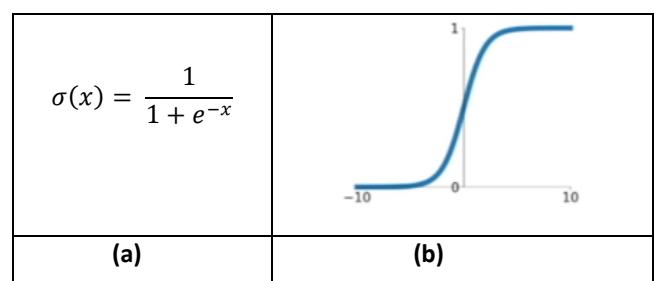
Şekil 1. Yapay sinir ağı örneği

Şekil 1 üzerindeki toplama fonksiyonu, hücrenin net girdisini hesaplamak amacıyla gelen veri, kendi ağırlığıyla çarpılır böylelikle ağa girmiş olan net girdi elde edilmektedir. Matematiksel ifadesi Denklem 1'de belirtilmektedir.

$$Net = \sum_{i=0}^n X_i W_i \quad (1)$$

Şekil 1 üzerindeki çıktılar, aktivasyon fonksiyonunun belirlediği değerlerin sunulduğu yerdır. Bu çıktılar kullanıcıya sunulacağı gibi aynı zamanda farklı bir yapay sinir hücresinde gönderilebilmektedir. Şekil 1 üzerindeki aktivasyon fonksiyonu, bulunmuş olan net girdi üzerinde işlemler yaparak çıktı olarak gösterilecek durumu belirler. Bu durumu belirlemek için farklı aktivasyon fonksiyonları da mevcuttur. Günümüzde popüler olan aktivasyon fonksiyonu ise Sigmoid fonksiyonudur. Sigmoid fonksiyonunun matematiksel ifadesi tablo 1-a üzerinde ve sigmoid fonksiyonunun görseli tablo 1-b üzerinde gösterilmiştir.

Tablo 1. Sigmoid Fonksiyonu Görseli ve Matematiksel ifadesi



Evrişimsel sinir ağı giriş değeri olarak resim ya da video almaktadır. Alacağı resim veya videonun standart duruma getirilmesi gerekmektedir. Verilecek olan resim veya video matris formatında verilmelidir. Matris formatında almış olduğu veriyi öncelikle evrişim katmanına göndermektedir. Evrişim katmanında gönderilen verinin özelliklerini filtreler uygulayarak algılamaktadır. Daha sonrasında bu veri aktivasyon katmanına iletilmektedir.

Aktivasyon katmanında ise bu veriler işlenerek, doğrusal olmayan özelliklerin tanıtılması gerçekleştirilmektedir. İşlenen bu veriler pooling katmanına ulaşır. Pooling katmanında ise 2×2 boyutlarında oluşturulan filtreler, alınan matris üzerinde gezinti uygulayarak en büyük değerleri almaktadır. Alınan değerler flattening katmanına gönderilir. Bu katmanda ise gelen veriler tek boyutlu dizi haline dönüştürülür. Daha sonrasında dönüştürülen veriler Fully-Connected katmanına gönderilir ve bu katmanda ise alınan veriler gizli katmanlara dağıtılmaktadır. Evrişimsel sinir ağıının temel taşı olan bu katman, girdi olarak verilen değerin özelliklerini algılamakla görevlidir. Görüntüde bulunan belirgin özellikleri ön plana çıkarmak için görüntüye çeşitli filtreler uygulamaktadır. Katmanın matematiksel işlemi Denklem 2'de gösterilmiştir. Denklem 2'de gösterilmiş olan matematiksel ifade, X ifadesi girdi değerini, Y çıktısı aktivasyon fonksiyonunu, b bias, W ifadesi ise filreyi temsil etmektedir.

$$Y_{mn} = f(\sum_{j=0}^{j-1} \sum_{i=0}^{i-1} X_{m+i, n+j} W_{ij} + b) \quad (2)$$

R-CNN bölge bazlı nesne tanıma yapılmasında kullanılmaktadır. Öncelikle almış olduğu görüntüde seçici arama uygulayarak o görüntüye ait en iyi ihtimali olan 2000 adet farklı bölge önerileceği bölgeleri tanımlar. Daha sonrasında bu 2000 adet bölgenin her birisi Evrişimsel Sinir Ağı mimarisine gönderilir. Evrişimsel sinir ağı ise gelen bölgelerde özellikleri belirler. Bu bölge eğer bir nesneye ait ise seçici arama yöntemiyle

belirlenmiş olan bu bölge evrişimsel sinir ağı özelliklerile birlikte destek vektör makineleri metodunu kullanarak hesaplamalar yapar ve nesneyi verilen örneklerin özelliklerine göre sorgulayarak sonuca ulaşır. Bu işlem uygulanırken görüntü başına belirlenen 2000 adet bölgenin sürekli evrişimsel sinir ağıyla işleme sokulduğundan bu işlem oldukça yavaş bir işlem ve gerçek zamanlı olarak yapılacak olan nesne tanıma işlemleri için pek önerilmez ve bu durum farklı bir mimarinin yani Fast R-CNN mimarisinin ortayamasına sebep olmuştur (Inik ve ark., 2017).

R-CNN mimarisinin yaşadığı zaman kaybını önlem adına geliştirilen bu mimaride R-CNN'nin aksine önce bölge belirlemek yerine görüntüyü ilk başta evrişimsel sinir ağına göndererek işlem yapıyor daha sonrasında evrişimsel sinir ağıının oluşturmuş olduğu özellik haritasını kullanarak bölge önermesi yapmaktadır. Diğer bir farkı ise CNN'in sınıflandırma için kullanmış olduğu destek vektör makineleri metodunu kullanmayarak derin öğrenme metodunu softmax classification kullanmaktadır. Bütün işlemler boyunca CNN bir defa kullanıldığı için işlem süresi büyük oranda azalmıştır. Bu işlemde Fast R-CNN gibi öncelikle görüntüyü evrişimsel sinir ağıyla işleme sokuyor ve bir özellik haritası elde ediyor. Daha sonrasında bu haritayı Fast R-CNN'den farklı olarak bölge seçimi uygulamak yerine direkt olarak seçici arama uygulanıyor. Daha sonrasında Fast R-CNN gibi bu mimaride softmax classification metodunu kullanarak nesne tanımayı gerçekleştiriyor.

Derin öğrenme çok katmanlı bir yapay sinir ağıdır. Girdi, gizli ve çıktı katmanları mevcuttur. Katmanlar arasındaki ağırlıklar sürekli güncellendiğinden dolayı hata oranının oldukça azaltıldığı görülmüştür. Bu yöntem dışarıdan gelen görüntü verilerini tekrar eden işlemlerle işleyerek bir öğrenim kazanmaktadır. Öğrendiği verilerin öznitelik kümelerini ortaya çıkartarak daha sonrasında hiç karşılaşmamış olduğu bir görüntü verisi geldiğinde öğrenciklerinden yola çıkararak bir sonucu bulmayı hedeflemektedir. Birçok algoritmeye sahiptir. Video, metin, ses gibi verileri işlemek için kullanılan derin öğrenme, ulaşmış olduğu başarılar sayesinde günümüzde popülerliğini korumaktadır. Gün geçtikçe artmakta olan veri sayılarına karşılık oldukça büyük verilerle yaptığı çalışmalarda daha fazla başarı oranı elde etmesiyle nesne tanıma, veri işleme gibi durumlarda tercih edilen metodların başında gelmektedir. Derin öğrenme algoritmalarının başarı oranları, öğrenme sayılarının oraneli olarak doğru oranda artmaktadır. Genel olarak lineer olmayan problemlerin çözümü için kullanılmaktadır.

2.3. Çalışma İçin Oluşturulan Veri Seti

Geçerkleştirilen bu çalışmanın ilk aşaması olan eğitim aşamasına başlamadan önce eğitilecek olan görüntülerin elde edilmesi gerekmektedir. 502 adet bardak görüntüsü içerisinde %80'i eğitim verisi olacak şekilde 402 tanesi eğitim verisi, %20'si test verisi olacak şekilde 100 tanesi test verisi olmak üzere

ayrılmıştır. Elde edilen bardak görüntülerinin etiketlenmesi gerekmektedir. Etiketleme işlemi için LabelImg programı kullanılmıştır.



Şekil 2. Etiketleme yapılan görüntü örnekleri

Aynı bardak üzerinden farklı arka planlarda çekilmiş görüntülerin etiketlenmesi Şekil 2 üzerinde gözükmemektedir. Farklı arka planlara sahip olunması, farklı bardaklara sahip olunması eğitim sonunda nesne tanıma yapılrken tespit etme oranını artırmaya yaramaktadır. Etiketlenen görüntüler .xml uzantısında bir dosya halinde kaydedilmektedir. Her görüntüye ait bir .xml dosyası mevcuttur. Bu .xml dosyası içerisinde Şekil 3 üzerinde gösterildiği gibi görüntüye ait, görüntünün bulunduğu dosya ismi, görüntünün ismi, bulunduğu dosya konumunun, görüntünün boyutlarının, class ismi olarak tanımlanan nesne isminin ve görüntü üzerinde etiketlenen nesnenin çerçeveye değerlerinin bulunduğu bazı özellikler tutulmaktadır.

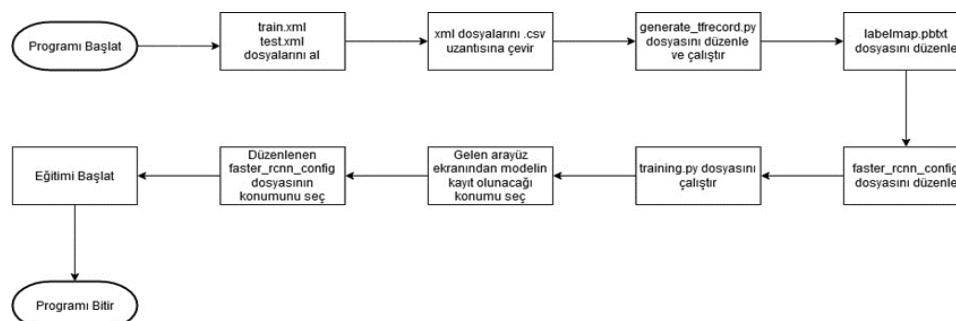
Daha sonrasında etiketleme işlemleri bittiğten sonra .xml olarak kaydedilmiş olan görüntü özelliklerini, TFRecord oluşturmak için .csv dosyasına çevrilmesi gerekmektedir. Şekil 3'te *.csv dosyasının içeriği gözükmemektedir. Dönüşüm uygulandıktan sonra model eğitiminde kullanılacak olan TFRecord dosyası oluşturulmaktadır.

test_labels.csv - Not Defteri	
	Dosya Düzen Biçim Görünüm Yardım
filename	,width,height,class,xmin,ymin,xmax,ymax
10.JPG	,450,600,bardak,149,203,334,486
11.JPG	,450,600,bardak,73,150,353,527
12.JPG	,450,600,bardak,76,39,433,483
13.JPG	,450,600,bardak,95,226,353,531
15.JPG	,450,600,bardak,76,151,370,528
16.JPG	,450,600,bardak,99,160,370,477
17.JPG	,450,600,bardak,125,144,450,524
18.JPG	,450,600,bardak,76,145,450,520
18.JPG	,450,600,bardak,424,113,450,219
19.JPG	,450,600,bardak,143,241,303,503

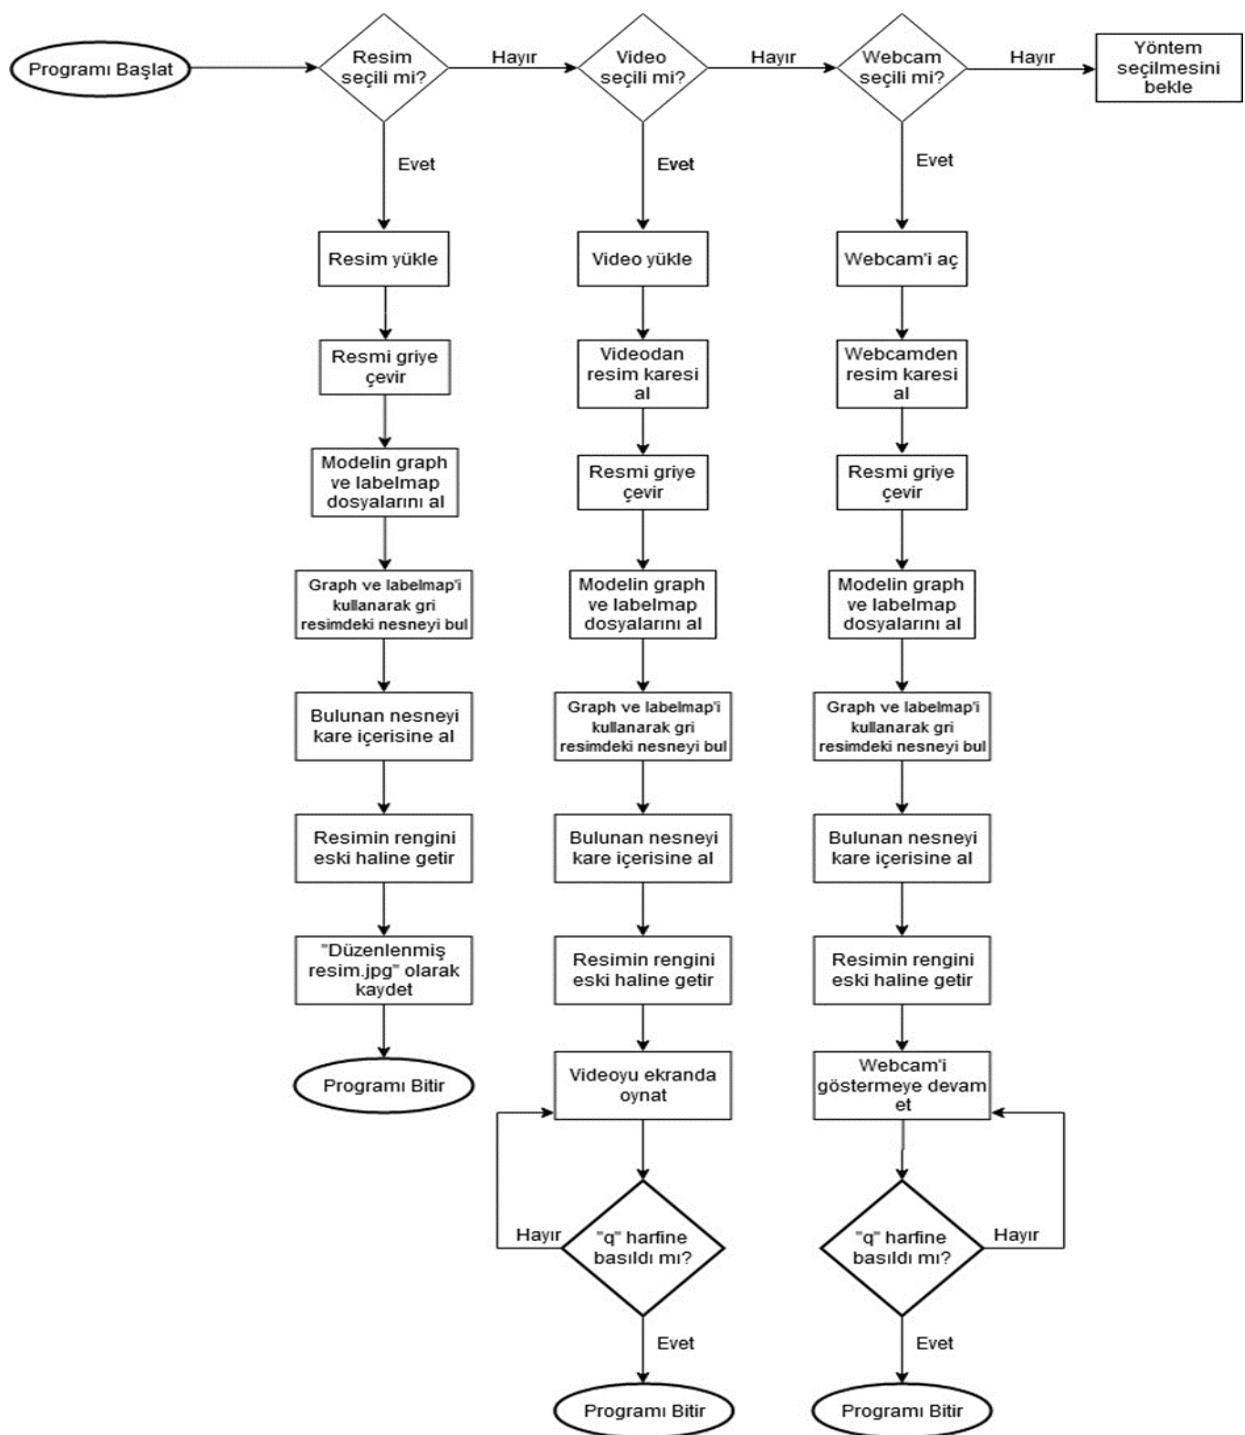
Şekil 3. Csv dosyasına ait örnek

2.4. Çalışmanın Akış Diyagramı

Geçerkleştirilen bu çalışma iki aşamadan oluşmaktadır. Bu çalışmanın birinci aşaması olan veri setinin hazırlanmasının ardından eğitim işlemeye başlanıldığı kısımdır. Sistemin birinci aşamasının akış diyagramı Şekil 4'de verilmiştir. Bu çalışmanın ikinci aşaması ise gerçekleştirilen eğitimin sonunda elde edilmiş olan modelin kullanılmasıyla belirtilen yöntem doğrultusunda istenen görüntü üzerinden nesne tanıma işleminin yapılmalıdır. Sistemin ikinci aşamasının akış diyagramı Şekil 5'de verilmiştir.



Şekil 4. Model eğitme işlemlerinin akış diyagramı

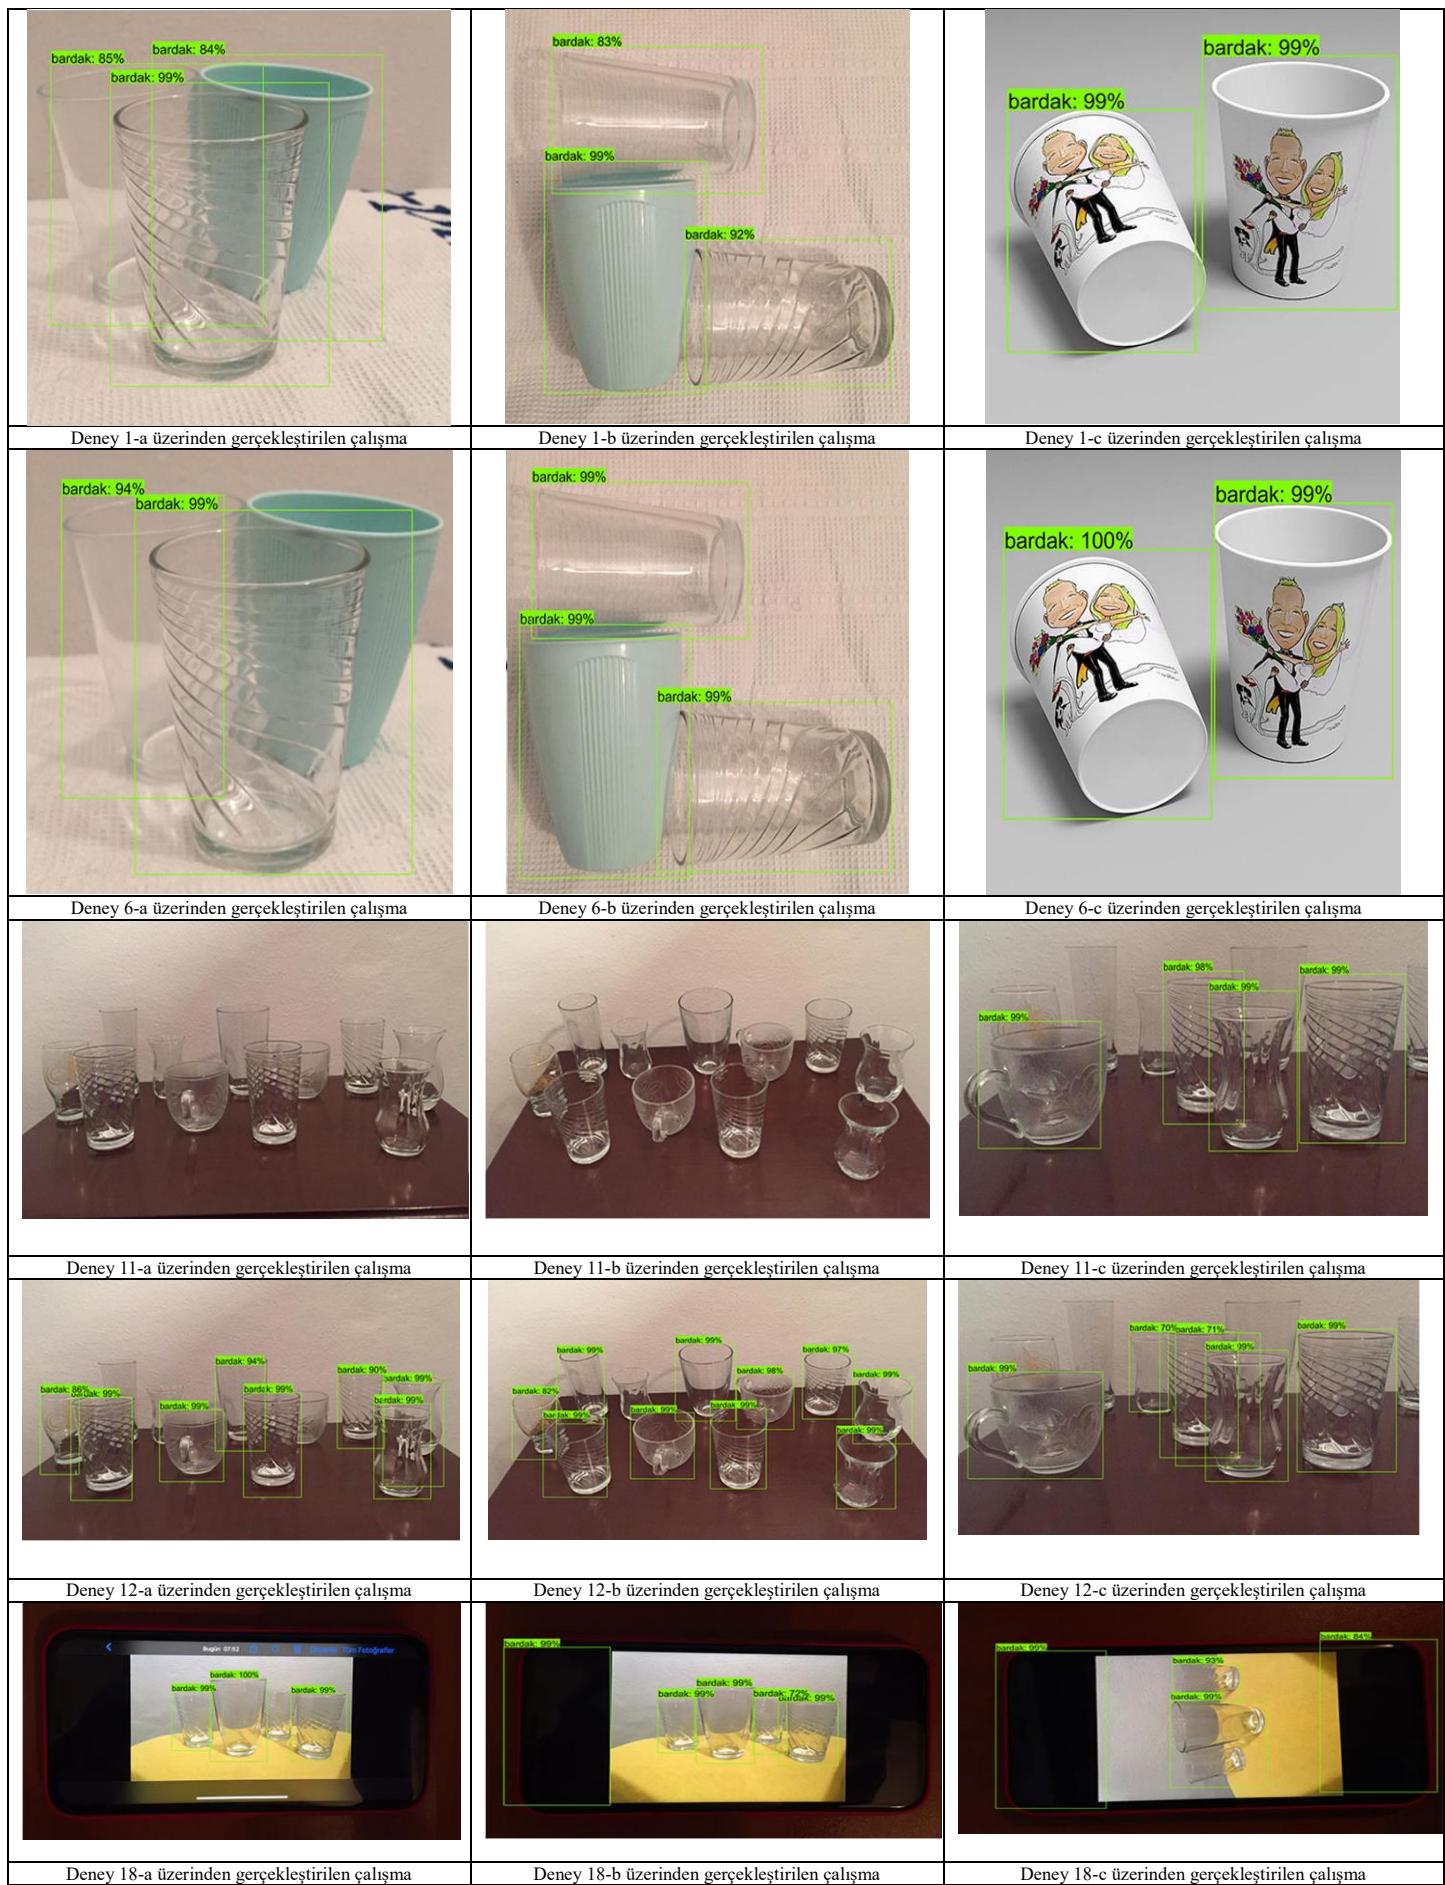


Şekil 5. Nesne tanıma işleminin akış diyagramı

3. Deneysel Çalışmalar

Geçerleştirilmiş olan bu çalışmada, python programlama dili ile birlikte tensorflow, numpy, tkinter, opencv kütüphaneleri kullanılmış aynı zamanda Eğitilecek olan nesnelerin isimlerini ve ID’lerini barındıran LabelMap düzenlenerek Object Detection API üzerinden eğitim gerçekleştirilmiştir. Çalışma boyunca farklı eğitim adımlarında farklı görseller üzerinden deneysel çalışmalar

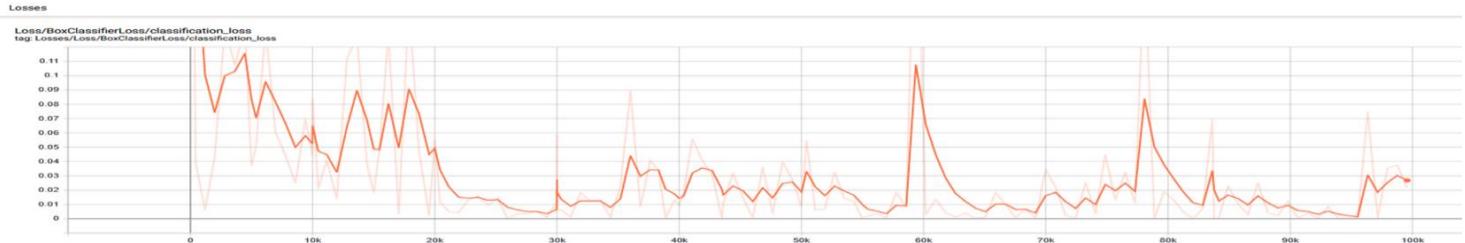
geçerleştirilmiştir. Yapılan bu çalışmalar sayesinde doğru eğitim adımının bulunması ile bu eğitim adımıyla gerçekleştirilen eğitimin nesne tanıma üzerindeki etkisinin farkı görülebilmektedir. Toplamda 18 adet deney gerçekleştirilmiştir. Gerçekleştirilen her deney kendi içerisinde 3 farklı aşamada yapılmıştır. Bu deneyler Şekil 6 üzerinde gösterilmiştir. Ayrıca bu deneylerin her biri için eğitim adımı değiştirilerek deneylerin başarı ve kayıp sonuçları incelenmiştir.



Şekil 6. Uygulama üzerinde gerçekleştirilen deneylerden görüntüler.

Şekil 6'da farklı eğitim adımlarıyla gerçekleştirilen deneysel çalışmaların görsel karşılaştırmaları gösterilmektedir. Gösterilen bu çalışma görsellerinden yola çıkarak eğitim adımlarının nesne tanıma üzerinde etkisinin, doğru kullanıldığında büyük olabileceği görülmüştür.

Şekil 6 üzerinde belirtilen deneyler farklı ışık ortamlarında, farklı arka planlarda ve söz konusu olan bardakların konumlandırması (yatay-dikey) değiştirilerek gerçekleştirılmıştır. Bu sayede deneylerin başarı ve kayıp sonuçları ölçülmüştür. 18 ayrı deneyin yapılması oluşturulan modelin detaylı şekilde incelenmesini sağlamıştır.



Şekil 7. Eğitim sürecinin kayıp oranları

Şekil 7'de eğitim sürecinde, alınan kayıp oranlarının grafiksel şekilde gösterilmektedir. Bu süreçte en düşük kayıp orana sahip olan adım sayısı 10 farklı eğitim adımı içerisinde 0,018 başarı oranıyla 40.000 eğitim adımı olduğu tespit edilmiştir. Buna rağmen yapılan deneyler sonucunda en başarılı sonucun 100.000 eğitim adımda alındığı görülmüştür. Tablo 2'de çalışma boyunca gerçekleştirilen 18 adet deney gösterilmiştir. Bu deneyler, oluşturulan model üzerinde gerçekleştirilmiş ve her bir deney için aynı veri seti kullanılmıştır. Eğitim sürecinde en başarılı tahmin oranının bulunması için ise farklı eğitim adımlarıyla deneyler gerçekleştirilmiştir.

Tablo 2. Oluşturulan model üzerinde gerçekleştirilen deneylerin değerlendirilmesi

Çalışma Numarası	Eğitim Sayısı	Alınan Başarı Sonucu	Alınan Kayıp Oranı
Deney 1	1000	0,97134	0,02866
Deney 2	5000	0,96325	0,03675
Deney 3	10000	0,91627	0,08373
Deney 4	20000	0,94462	0,05538
Deney 5	30000	0,94146	0,05854
Deney 6	40000	0,98176	0,01824
Deney 7	50000	0,94528	0,05472
Deney 8	83767	0,92398	0,07602
Deney 9	95513	0,92557	0,07443
Deney 10	100000	0,97835	0,02165
Deney 11	1000	0,97134	0,02866
Deney 12	10000	0,91627	0,08373
Deney 13	50000	0,94528	0,05472
Deney 14	100000	0,97835	0,02165
Deney 15	1000	0,97134	0,02866
Deney 16	10000	0,91627	0,08373
Deney 17	50000	0,94528	0,05472
Deney 18	100000	0,97835	0,02165

Yapılan 1. Deneyde 1000 eğitim adımıyla eğitim gerçekleştirılmıştır. Eğitim aşaması tamamlandıktan sonra yapılmış olan bu deney, verilmiş olan 3 farklı görüntü içerisinde farklı bardakların bulunduğu görüntüler ile gerçekleştirmiştir. Aynı zamanda bu bardaklar, farklı yerlerde konumlandırılmış vaziyette gözükmemektedir. Yapılan nesne tanıma işlemi sonucunda Şekil 6 üzerinde gösterilen deney 1-a birbiri ardına saklanmış olan bardaklardan önceki olan bardak %99 ve arkalarına saklanmış olan bardaklar ise %85 ve %84 doğruluk oranında tahmin edilmiştir. Deney 1-b'de ise %99, %92 ve %83'lük oranla bardaklar doğru tahmin edilmiştir. Deney 1-c görüntülerde de aynı şekilde bardaklar %99 oranla doğru tahmin edilmiştir. Deney 1'de alınan başarı sonucu %96,33 olmakla birlikte alınan kayıp oranı ise %3,67'dir.

Yapılan 6. Deneyde 40000 eğitim adımıyla eğitim gerçekleştirılmıştır. Eğitim aşaması tamamlandıktan sonra yapılmış olan bu deney, verilmiş olan 3 farklı görüntü içerisinde farklı bardakların bulunduğu görüntüler ile gerçekleştirmiştir. Aynı zamanda bu bardaklar, farklı yerlerde konumlandırılmış vaziyette gözükmemektedir. Şekil 6 üzerinde Deney 6-a ile yapılan nesne tanıma işlemi sonucunda birinci görüntüde birbiri ardına saklanmış olan bardaklardan bir tanesi %99 diğeri ise %94 oranında tahmin edilmiştir. Bu oran 5. Deneye oranla artış sağlamıştır. Sonuncu bardak ise çerçeveye içine alınmamıştır. Deney 6-b ile bardaklar %99, Deney 6-c'de bulunan bardaklar ise biri %99 diğeri %100 doğruluk oranıyla tahmin edilmiştir. Deney 6'de alınan başarı sonucu %94,15 olmakla birlikte alınan kayıp oranı ise %5,85'dir.

Yapılan 11. Deneyde 1000 eğitim adımıyla eğitim gerçekleştirılmıştır. Eğitim aşaması tamamlandıktan sonra yapılmış olan bu deney sonuçları Şekil 6 üzerinde verilmiştir. Deney 11'de verilmiş olan 3 farklı görüntü içerisinde, masanın üzerinde bulunan 11 adet farklı bardakların bulunduğu görüntüler ile gerçekleştirmiştir. Aynı zamanda bu bardaklar, farklı yerlerde konumlandırılmış vaziyette gözükmemektedir. Yapılan nesne tanıma işlemi sonucunda Deney 11-a'da birbiri ardına saklanmış çok sayıda bardaktan hiçbirini algılanamamıştır. Deney 11-b'de görüntü konumu değiştirilmesine rağmen bardaklar tahmin edilmemiştir. Deney 11-c'de ise görüntü bardaklara yakınlaştırıldığından bazı bardakların algılandığı, bazlarının ise algılanmadığı görülmüştür. Deney 11'de alınan başarı sonucu %97,13 olmakla birlikte alınan kayıp oranı ise %2,87'dir.

Yapılan 12. Deneyde 10000 eğitim adımıyla eğitim gerçekleştirılmıştır. Eğitim aşaması tamamlandıktan sonra yapılmış olan bu deney Şekil 6 üzerinde verilmiştir. Deney 12 olan 3 farklı görüntü içerisinde, masanın üzerinde bulunan 11 adet farklı bardakların bulunduğu görüntüler ile gerçekleşmiştir. Aynı zamanda bu bardaklar, farklı yerlerde konumlandırılmış vaziyette gözükmektedir. Yapılan nesne tanıma işlemi sonucunda Deney 12-a'da birbiri ardına saklanmış çok sayıda bardaktan net belli olan 8 bardak tahmin edilebilirken arkalarda bulunan tam belli olmayan bardaklar tahmin edilememiştir. Deney 12-b'de, görüntü konumu değiştirerek yapılan bu deneyde 11 adet bardaktan 10 tanesi algılanmış arkada bulunan bardaklardan bir tanesi tespit edilememiştir. Deney 12-c'de ise görüntü bardaklara yaklaştırıldığında ondeki bardakların algılandığı görülmüştür. Aynı zamanda 2 farklı bardağı 1 bardak olarak algılandığı da görülmüştür. Arkada bulunan bardakların algılanmadığı görülmüştür. Deney 12'de alınan başarı sonucu %91,63 olmakla birlikte alınan kayıp oranı ise %8,37'dir.

Yapılan 18. Deneyde 100000 eğitim adımıyla eğitim gerçekleştirılmıştır. Eğitim aşaması tamamlandıktan sonra yapılmış olan bu deney şekil 6 üzerinde gösterilmiştir. Deney 18'de verilmiş olan 3 farklı görüntü içerisinde, masanın üzerinde bulunan telefonun içerisindeki bardaklar gösterilmiştir. Aynı zamanda bu bardaklar, farklı yerlerde konumlandırılmış vaziyette gözükmektedir. Yapılan nesne tanıma işlemi sonucunda Deney 18-a'da telefonun ekranında bulunan bardaklardan 3 tanesi tahmin edilirken telefon ekranında herhangi bir çerçeve çizilmemiştir. Deney 18-b'de telefon ekranında bulunan bardakların hepsi doğru tahmin edilirken telefonun üst kısmında bulunan siyah alanda bardak olarak işaretlenmiştir. Deney 18-c'de telefon ekranındaki 3 adet bardaktan 2 tanesi tek bardakmış gibi işaretlenmiş, diğer 2 bardaktan 1 tanesi doğru işaretlenirken telefon ekranının alt ve üst çerçevesi bardak olarak işaretlenmiştir. Deney 18'de alınan başarı sonucu %97,84 olmakla birlikte alınan kayıp oranı ise %2,16'dır. Yapılan toplam 100.000 eğitim adımıyla eğitilen eğitimin sonucunda elde edilen kayıp oranları Şekil 8 üzerinde verilmiştir.

4. Sonuçlar ve Tartışmalar

Bu çalışma kapsamında araştırılan en önemli, işlem belirli bir algoritmanın belirlenmiş bir nesneden oluşturulan veri seti üzerinde uygulanarak, başarılı bir şekilde algılanma işleminin yapıp yapılmadığının araştırılmasıdır. Çalışmanın literatür taraması tablosunda (tablo 1) belirtildiği üzere farklı algoritmalarla farklı sonuçlar görülmüştür. Sonuçların farklılaşmasındaki en önemli etken çalışmalar içerisinde seçilen algoritmaların farklı eğitim adımlarından ve veri setlerindeki karmaşıklıktan olduğu anlaşılmıştır. Gerçekleştirilen bu çalışmada Faster R-CNN algoritmasıyla başarı sonuçlarının farklı eğitim adımlarında en üst düzeyde başarı hedeflemiştir. Bu kapsamında oluşturulan 502 adet resimden oluşan bardak veri seti ile model eğitilmiştir. Eğitilen model üzerinde resim, video ve kamera üzerinde alınan anlık görüntüler ile deneyler yapılmıştır. Yapılan deney sonucunda en düşük başarı oranı 0,91627 ve en yüksek başarı oranı 0,98176 şeklinde tespit edilmiştir. Bu sonuçlar gösterdiği eğitim adımlarının (epoch) farklılaştırılması başarı sonucuna doğrudan etki etmiştir. Ayrıca eğitim adımlarının artırılması sistemde aşırı öğrenmeye neden olarak başarı oranının düşmesine sebep olmuştur.

Alınan sonuçlara göre literatür incelemesi yapılan tablo 1'de yer alan çalışmalar incelendiğinde, derin öğrenme teknigi kullanılan çalışmalarla, başarı oranının yüksek olduğu görülmüştür. Derin öğrenme ile birlikte farklı algoritmalar kullanılmış olsa da çalışmaların benzer doğruluk oranlarına sahip oldukları görülmüştür. Gerçekleştirilen bu çalışmada, derin öğrenme teknikleriyle beraber Faster R-CNN ağı kullanılmaktadır. Sistem güvene bağlı olmakla birlikte, istenildiği takdirde başarım oranı Faster R-CNN ağına oranla daha yüksek model seçilerek tahmin işlemindeki doğruluk oranı artırlabilir. Sistem gücü düşük ise hızlı fakat başarım oranı Faster R-CNN'e göre daha düşük olan modellerde tercih edilebilir.

Yapılan ilk 10 deney incelendiğinde, eğitim adımlarının arttığı durumlarda karmaşık görüntülerin tespiti sırasında problemler ortaya çıktıgı görülmektedir. Eğitim adiminin gerektiği yerde durmamasıyla birlikte ortaya çıkmakta olan ezber eğitime, deneyler içinde bulunan 9. Deneyde rastlanmıştır. 1. Deneyde tercih edilen eğitim adımı diğer deneylere göre az olmasına rağmen 1. Görüntüdeki en iyi sonuca ulaşmıştır. Son 8 deney incelendiğinde ise bardak fazlalığı ve telefon ekranından gösterilen bardak fotoğraflarının tespiti sırasında eğitim adiminin artmasıyla daha başarılı sonuçlar elde edildiği görülmüştür. Aynı zamanda veri seti hazırlanırken birden fazla bardağın aynı görüntüde etiketlenip, arttırılması ve algılanabileceği zor olan durumlarda etiketlenmesi karışık görüntülerde bardak nesnesinin daha kolay ve doğru algılayabileceği düşünülmektedir. Bardak nesnesinin bulunmadığı yerlerin, bardak olarak işaretlenmesi ise veri seti sayısının artırılması ve doğru eğitim adiminin belirlenmesiyle asılabilceği düşünülmektedir. Yapılan deney 6-a ve 6-c görüntülerindeki sol arka tarafta bulunan bardağın algılanmadığı görülmektedir. Bunun sebebi olarak arka plan rengi ve ışıklandırmadan dolayı bardağın oluşan rengi ve arka plan renginin benzerliklerinden dolayı algılanmadığı düşünülmektedir. Veri setinde oluşturulacak görüntülerin farklı ışıklandırma ve farklı arka planlarda çekilmiş olmasının sonucunda bu durumun ortadan kalkabileceği düşünülmektedir. Gerçekleştirilen çalışmada 502 adet bardak görüntüsü bulunan veri seti kullanılmıştır. Kullanılan bu veri setinde bardak çeşitliliğinin az olmasından kaynaklı yapılan deneyler kısıtlı olarak gerçekleştirilmişdir. Veri setinde bulunan bardak çeşitlilik sayısı ve toplam görüntü sayısı artırıldığından tahmin etme oranının da artırılabileceği düşünülmektedir.

Sonuç olarak, çalışma içerisinde oluşturulan modelin elektronik devre sistemlerinde uygulanması durumunda; güvenlik sistemlerinde, gıda üretim tesislerinde ve imalat endüstrisinde hatalı parça tespit etme uygulamalarında kullanılabileceği düşünülmektedir. Bu sayede mevcut sistemlerde işlem aşamasında doğruluk tahmini ve analizi yapılarak kalite kontrol süreçleriyle birlikte sistemin başarı oranını artırlabilir.

Kaynakça

- Abbas, S. S. I. (2019). Automatic Text Categorization of Turkish News with Machine Learning and Deep Learning Techniques (Doctoral dissertation, Ankara Yıldırım Beyazıt Üniversitesi Fen Bilimleri Enstitüsü), Ankara.
- Abdulkader, H. (2019). Derin öğrenme ile maksimum oksigen tüketimi tahmini. (Yüksek Lisans Tezi). Çukurova Üniversitesi Fen Bilimleri Enstitüsü, Adana.

- Abusabra, A. K. (2018). Örütü ve renk tabanlı mobil kıyafet arama motoru (Doctoral dissertation, Selçuk Üniversitesi Fen Bilimleri Enstitüsü).
- Aki, K. (2019). Derin öğrenme tabanlı sürücüsüz araç sistemleri. (Yüksek Lisans Tezi). Bursa Uludağ Üniversitesi Fen Bilimleri Enstitüsü, Bursa.
- Akıncı, İ. B. (2017). Gerçek zamanlı olarak meyveleri görüntü işleme ile sınıflandırın otomasyon sistemi. (Yüksek Lisans Tezi). Karabük Üniversitesi Fen Bilimleri Enstitüsü, Karabük.
- Alpaslan, N. (2019). Memekanseri tanısı için derin öznitelik tabanlı karar destek sistemi. Selçuk Üniversitesi Mühendislik, *Bilim ve Teknoloji Dergisi*, 7(1), 213-227.
- Ari, A., & Berberler, M. E. (2017). Yapay Sinir Ağları ile Tahmin ve Sınıflandırma Problemlerinin Çözümü İçin Arayüz Tasarımı. *Acta Infologica*, 1(2), 55-73.
- Ari, A., & Hanbay, D. (2018). Bölgesel evrişimsel sinir ağları tabanlı MR görüntülerinde tümör tespiti. *Journal of the Faculty of Engineering & Architecture of Gazi University*.
- Ateş, E. (2019). Derin öğrenme ile sesli komut tanıma. (Yüksek Lisans Tezi). Eskişehir Osmangazi Üniversitesi Fen Bilimleri Enstitüsü, Eskişehir.
- Aydın, M. (2019). Görüntü işleme teknigi ile granüler zeminlerde dane boyutu analizi. (Yüksek Lisans Tezi). Mersin Üniversitesi Fen Bilimleri Enstitüsü, Mersin.
- Balq, A. A. A. (2019). Görüntü işleme tekniklerini kullanarak optik işaret tanıma sistemi (Doctoral dissertation, Kastamonu Üniversitesi), Kastamonu.
- Başarır, B. (2019). Derin öğrenme tabanlı nesne takibi. (Yüksek Lisans Tezi). Bursa Uludağ Üniversitesi Fen Bilimleri Enstitüsü, Bursa.
- Başarslan, Ş. (2018). Görüntü işleme teknikleri kullanarak sperm sayısı ve hareketliliğinin analizi. (Yüksek Lisans Tezi). Erciyes Üniversitesi Fen Bilimleri Enstitüsü, Kayseri.
- Baykara, S. (2018). Ardışıl sınıflandırıcılar kullanılarak profil yüz sezimi. (Yüksek Lisans Tezi). Eskişehir Osmangazi Üniversitesi Fen Bilimleri Enstitüsü, Eskişehir.
- Bayram, F. (2020). Derin Öğrenme Tabanlı Otomatik Plaka Tanıma. *Politeknik Dergisi*.
- Bingöl, M. S. (2018). Grafik işleme ünitesi (GPU) tabanlı öğrenme kullanarak otonom araçlar için algılama sisteminin geliştirilmesi/Development of perception system for autonomous vehicles by using GPU-based learning.
- Çalık, R. C. (2018). Gömülü sistem üzerinde evrişimsel sinir ağları ile nesne sınıflandırması (Master's thesis, TOBB ETÜ Fen Bilimleri Enstitüsü), Ankara.
- Çam, F., & Güven, A. (2019). Dijital Mikroskop Altında Alınan Kan Hücresi Görüntülerinden Beyaz Kan Hücrelerinin Algılanması ve Sınıflandırılması. *Electronic Letters on Science and Engineering*, 15(3), 23-43.
- Çavdaroglu, G. Ç. (2016). Trafik Yoğunluk Harita Görüntülerinin Görüntü İşleme Yöntemleriyle İşlenmesi. *Akademik Platform Mühendislik ve Fen Bilimleri Dergisi*, 5(2), 22-28.
- Çınar U. K. (2018). *Yapay Sinir Ağları ve R Programıyla Uygulama*, Yapay sinir ağı örneği görüntüsü, <https://www.veribilimiokulu.com/yapay-sinir-aglari/>, 21.05.2020.
- Dandıl, E., Turkan, M., Boğa, M., & Çevik, K. K. (2019). Daha Hızlı Bölgesel-Evrişimsel Sinir Ağları ile Sığır Yüzlerinin Tanınması. *Bilecik Şeyh Edebali Üniversitesi Fen Bilimleri Dergisi*, 6, 177-189.
- Danışman, A., Kaçar, İ., Danışman, E., & Yalçın, M. K. (2017). Renk ayırtıcı bant sisteminin görüntü işleme esası kontrolü.
- Döş, M. E., & Uysal, M. (2019). Uzaktan algılama verilerinin derin öğrenme algoritmaları ile sınıflandırılması. *Türkiye Uzaktan Algılama Dergisi*, 1(1), 28-34.
- Erkan, Y. R. (2019). Görüntü işleme teknikleri kullanılarak mantar türlerinin tüketilebilirliğinin tespiti. (Yüksek Lisans Tezi). Selçuk Üniversitesi Fen Bilimleri Enstitüsü, Konya.
- Ezel, E. (2018). Derin öğrenme yöntemi kullanılarak görüntü-tabanlı tür işaret dili tanıma (Doctoral dissertation, Selçuk Üniversitesi Fen Bilimleri Enstitüsü).
- Faker, O. M. (2019). Intrusion detection using big data and deep learning techniques (Master's thesis).
- Gündüz, G. (2019). Derin öğrenme ile fotoğrafstan yaş ve cinsiyet tespiti. (Yüksek Lisans Tezi). Sakarya Üniversitesi Fen Bilimleri Enstitüsü, Sakarya.
- Inik, Ö., & Ülker, E. (2017). Derin Öğrenme ve Görüntü Analizinde Kullanılan Derin Öğrenme Modelleri. *Gaziosmanpaşa Bilimsel Araştırma Dergisi*, 6(3), 85-104.
- İşleyici, A. M. (2019). Derin öğrenme yaklaşımı ile RFID tabanlı 2 boyutlu konum belirleme uygulaması. (Yüksek Lisans Tezi). KTO Karatay Üniversitesi Fen Bilimleri Enstitüsü, Konya.
- Kabadayı, A., & Uysal, M. (2019). İnsansız hava aracı ile elde edilen verilerden binaların tespiti. *Türkiye İnsansız Hava Araçları Dergisi*, 1(1), 8-14.
- Kabasakal, B. (2018). Uzaklık ve cinsiyet tabanlı akıllı reklam görüntüleme sistemi (Master's thesis, Başkent Üniversitesi Fen Bilimleri Enstitüsü), Ankara.
- Karaci, A. (2020). Fiziksel ve motor engelli çocukların öz bakım problemlerinin derin sinir ağları ile sınıflandırılması. *Politeknik Dergisi*.
- Karakuzulu, A. (2018). Kan hücrelerinin görüntü işleme teknikleriyle tespiti, sayılması ve sınıflandırılması. (Yüksek Lisans Tezi). Mersin Üniversitesi Fen Bilimleri Enstitüsü, Mersin.
- Karim, M. K. (2019). Veri işleme için derin öğrenme teknikleri kullanarak yeni bir çerçeve. (Yüksek Lisans Tezi). Ankara Yıldırım Beyazıt Üniversitesi Fen Bilimleri Enstitüsü, Ankara.
- Koç, M., & Özdemir, R. (2019). Yeni Bir Veri Kümesi (RidNet) Kullanarak Kontrolsüz Ortamda Yüz İfadeleri Tanımanın Derin Öğrenme Yöntemleri ile İyileştirilmesi. *Bilecik Şeyh Edebali Üniversitesi Fen Bilimleri Dergisi*, 6(2).
- Mahmood, Z. S. (2019). İşaret dili ile akıllı kontrol sistemi. (Yüksek Lisans Tezi). Atatürk Üniversitesi Sosyal Bilimler Enstitüsü, Erzurum.
- Mete, B. R. (2019). Derin öğrenme ile görüntü sınıflandırma. (Yüksek Lisans Tezi). İstanbul Üniversitesi-Cerrahpaşa / Lisansüstü Eğitim Enstitüsü, İstanbul.
- Nawaf, A. M. (2019). Görüntü işleme ve makine öğrenme yöntemleri kullanarak kumaş hata tespiti ve sınıflandırması. (Yüksek Lisans Tezi). Çukurova Üniversitesi Fen Bilimleri Enstitüsü, Adana.
- Rashid, M. K. (2019). Görüntü işleme teknikleri kullanılarak Antep fistığının özellik tespiti ve sınıflandırılması. (Yüksek Lisans Tezi). Gaziantep Üniversitesi Fen Bilimleri Enstitüsü, Gaziantep.
- Sağbaş, E. A., Gökalp, O., & Uğur, A. (2019). Yüz İfadeleri Tanıma için Mesafe Oranlarına Dayalı Öznitelik Çıkarması ve Genetik Algoritmalar ile Seçimi. *Veri Bilimi*, 2(1), 19-29.
- Siddik, O. (2019). Görüntü işleme yöntemleri kullanılarak otomatik spirulina tespiti. (Yüksek Lisans Tezi). Atılım Üniversitesi Fen Bilimleri Enstitüsü, Ankara.

- Tan, Z. (2019). Derin öğrenme yardımıyla araç sınıflandırma. (Yüksek Lisans Tezi). Fırat Üniversitesi Fen Bilimleri Enstitüsü, Elazığ.
- Tanım, M. B. (2019). Yer radarı ham verisi analizi ile kırıkların dalgacık ve derin öğrenme yöntemleri ile tespiti. (Yüksek Lisans Tezi). Yaşar Üniversitesi Fen Bilimleri Enstitüsü, İzmir.
- Tiryaki, B. (2019). Trafik işaretlerinin derin sinir ağları ile sınıflandırılması. Tez Yük. (Yüksek Lisans Tezi). Atatürk Üniversitesi Fen Bilimleri Enstitüsü, Erzurum.
- Tombak, M. E. (2019). Python ve OpenCv ile yüz tanıma ve otomatik Blur uygulaması. (Yüksek Lisans Tezi). Kırıkkale Üniversitesi Fen Bilimleri Enstitüsü, Kırıkkale.
- Toptaş, M. (2018). Orman yangınlarının görüntü işleme yöntemleri ile tespit edilmesi ve sınıflandırılması. (Yüksek Lisans Tezi). İnönü Üniversitesi Fen Bilimleri Enstitüsü, Malatya.
- Tükel, T. (2019). Görüntü işleme ve evrişimsel sinir ağları kullanılarak diyabetik retinopati hastalığının tespiti. (Yüksek Lisans Tezi). Süleyman Demirel Üniversitesi Fen Bilimleri Enstitüsü, Isparta.
- Uçar, M. U. (2019). Gerçek zamanlı görüntü işleme ile sınıf ortamındaki öğrencilerin tanınması ve dikkat dağınlıklarının tespiti. (Yüksek Lisans Tezi). İskenderun Teknik Üniversitesi Mühendislik ve Fen Bilimleri Enstitüsü, Hatay.
- Viola, P., & Jones, M. (2001, December). Rapid object detection using a boosted cascade of simple features. In *Proceedings of the 2001 IEEE computer society conference on computer vision and pattern recognition. CVPR 2001* (Vol. 1, pp. I-I). IEEE.
- Vurgun, Y. (2017). Biyometrik yüz tanımeye dayalı web üzerinden güvenli erişim sistemi tasarımi (Doctoral dissertation, Selçuk Üniversitesi Fen Bilimleri Enstitüsü).
- Yabanova, İ., & Kaya, K. (2019). Kaynak değeri olan yaban hayvanlarının görüntü işleme tekniği ile tespiti ve sayımı. Pamukkale University Journal of Engineering Sciences, 25(2).
- Yıldız, O. (2019). Derin öğrenme yöntemleriyle dermoskop Görüntülerinden melanom tespiti: Kapsamlı bir çalışma. *Journal of the Faculty of Engineering & Architecture of Gazi University*, 34(4).