



Glokom Hastalığının Evrişimli Sinir Ağlı Mimarileri ile Tespiti

Diagnosis of Glaucoma Disease using Convolutional Neural Network Architectures

Murat Uçar ^{1*}

¹ İskenderun Teknik Üniversitesi, İşletme ve Yönetim Bilimleri Fakültesi, Yönetim Bilişim Sistemleri Bölümü, Hatay, TÜRKİYE

Sorumlu Yazar / Corresponding Author *: murat.ucar@iste.edu.tr

Geliş Tarihi / Received: 27.06.2020

Araştırma Makalesi/Research Article

Kabul Tarihi / Accepted: 27.11.2020

DOL:10.21205/deufmd.2021236815

Atıf Şekli/How to cite: UÇAR M. (2021). Gllokom Hastalığının Evrişimli Sinir Ağlı Mimarileri ile Tespiti. DEÜFMD 23(68), 521-529.

Öz

Glokom, genellikle göz içi basıncının yükselmesi nedeniyle optik sinire zarar veren bir hastalıktır ve dünya genelinde geri döndürülemez körlüğün yaygın bir sebebidir. Ancak hastalık erken dönemde tespit edilebilirse görme kaybı önlenemektedir. Günümüzde glokom hastalığının tanısı, gelişmiş yapay zeka teknikleri kullanılarak bilgisayar destekli sistemler yardımıyla yapılmaktadır. Bu çalışmada, yeni oluşturulmuş büyük ölçekli bir veri setine ait dijital fundus görüntüleri kullanılarak otomatik glokom tespiti için derin evrişimli sinir ağları yöntemi kullanılmıştır. Literatürde sınıflandırma problemlerinde en sık kullanılan mimarilerden VGG16, Inception-V3, EfficientNet, DenseNet, ResNet50 ve MobileNet mimarileri seçilmiştir. Deneysel çalışmalar sonucunda DenseNet mimarisinin %96.19 ile en yüksek başarı oranını elde ettiği görülmüştür. Elde edilen bulgular evrişimli sinir ağlarının normal ve glokomlu görüntüleri sınıflandırmada başarılı bir yöntem olduğunu kanıtlamıştır.

Anahtar Kelimeler: *Glokom, Derin öğrenme, Evrişimli sinir ağları, Transfer öğrenimi*

Abstract

Glaucoma is a disease that damages the optic nerve, often due to increased intraocular pressure, and is a common cause of irreversible blindness worldwide. However, if the disease can be detected in the early period, vision loss can be prevented. Today, the diagnosis of glaucoma disease can be made with the help of computer-aided systems using advanced artificial intelligence techniques. In this study, deep convolutional neural networks were used for automatic glaucoma detection using digital fundus images of a newly created large-scale data set. VGG16, Inception-V3, EfficientNet, DenseNet, ResNet50 and MobileNet architectures which are the most frequently used architectures in classification problems were selected. As a result of experimental studies, it was seen that the DenseNet architecture achieved the highest accuracy rate with 96.19%. The findings have proven that convolutional neural networks are a successful methods on classification of normal and glaucoma images.

Keywords: *Glaucoma, Deep learning, Convolutional neural networks, Transfer learning*

1. Giriş

Glokom, sağlıklı görebilmemiz için hayatı öneme sahip olan optik sinire zarar veren bir grup göz hastalığıdır. Bu zarar genellikle gözdeki çok yüksek bir basınçtan kaynaklanmaktadır. 2020 yılında 76 milyon, 2040 yılında ise 111.8 milyon insanın glokomdan etkilenmesi beklenmektedir [1]. Maalesef hastlığın son aşamasına kadar fark edilmeden ilerleyebilen glokom, geç teşhis edildiğinde kalıcı körlüğe neden olmaktadır. Şu anda henüz bir tedavisi olmaması nedeniyle, gözde görme kaybını önlemek için glokomun erken teşhis edilmesi önemlidir.

Derin öğrenme yöntemleri son yıllarda tıbbi ve oftalmolojik görüntülerde nesne tanıma, görüntü sınıflandırma ve bölütleme konularında sıklıkla kullanılmış ve çok başarılı sonuçlar elde edilmiştir. Özellikle derin evrişimli sinir ağları (ESA), retinal görüntülerden diyabetik retinopati, yaşa bağlı maküler dejenerasyon ve glokom gibi retinal hastalıkların erken teşhisini ve tanımlanması gibi görevler için kullanılmıştır [2,3,4].

Bu çalışmada fundus görüntülerinden glokom hastlığını saptamak için evrişimli sinir ağları yöntemi kullanılmıştır. Bu bağlamda literatürde sık kullanılan ve yüksek doğruluk sonucu elde edilen Visual Geometry Group-16(VGG16), Inception-V3, EfficientNet, Densely Connected Convolutional Network(DenseNet), Residual Neural Network(ResNet50) ve MobileNet mimarileri kullanılmıştır.

Bu makalenin geri kalanı aşağıdaki gibi düzenlenmiştir. Bölüm 2'de ilgili çalışmalar sunulmuştur. Bölüm 3'te, çalışmada kullanılan veri seti ve önerilen yöntemler ayrıntılı olarak açıklanmıştır. Bölüm 4'te, çalışmada elde edilen sonuçlar ve literatürdeki benzer çalışmalara ait bulgularla karşılaştırılması sunulmuştur. Makalenin tartışma ve sonuç bölümü Bölüm 5'te sunulmuştur.

2. Literatür Taraması

Son yıllarda glokom hastlığının teşhisini için derin öğrenme tabanlı yöntemleri öneren çalışmalar yapılmaktadır ancak sınırlı sayıdadır. Glokom tanısı için derin öğrenme modellerini kullanan çalışmalar iki türde ayrılabılır.

Birinci türde yapılan çalışmalar glokom tanısını doğrudan derin öğrenme modellerini kullanarak gerçekleştirir. Chen ve arkadaşları glokom tanısı için altı katmanlı bir evrişimli sinir ağı yapısı

kullanmış ve önerdikleri modeli ORIGA ve SCES veri setleri üzerinde test etmişlerdir [4]. Raghavendra ve arkadaşları glokomun tanısı için derin öğrenme temelli yeni bir model geliştirmiştir. Geliştirilen model dijital fundus görüntülerinden özellik çıkarımı için on sekiz katmanlı bir evrişimli sinir ağı kullanmıştır. Daha sonra elde ettikleri bu özellikler test aşamasında normal ve glokom olarak sınıflandırılmışlardır. Geliştirilen bu model %98.13'lük bir doğruluk oranı elde etmiştir [5]. Bir başka çalışmada Chai ve arkadaşları glokom tanısı için çok branşlı bir sinir ağı modeli önermişlerdir. Önerilen modelin aynı anda hem görüntülerin çok fazla bilgi içeren önemli alanlarını otomatik olarak ayırt edebildiğini hem de görüntünün gizli özellikleri çıkarabildiğini bildirmiştir. Önerilen modeli gerçek veri setleri üzerinde test ettiklerinde 0,9151'lük bir başarı elde etmişlerdir [6]. Fu ve arkadaşları otomatik glokom tanısı için farklı ESA'ları birlestiren yeni bir topluluk ağı önermiştir. Önerdikleri modeli ORIGA veri setinde bulunan görüntülerle eğitmiş SCES ve SINDI veri setleri üzerinde test etmişlerdir. Önerilen modelin diğer algoritmalarдан daha iyi bir performans gösterdiğini bildirmiştir [7]. Li ve arkadaşları glokom tespiti için öncelikle büyük ölçekli bir veri seti oluşturmuş daha sonra dikkat temelli bir model geliştirerek evrişimli sinir ağlarıyla birleştirmiştir. Deneysel sonuçlarda önerdikleri modelin glokomun doğru tespitini önemli ölçüde artırdığını bildirmiştir [8]. Bir başka çalışmada Christopher ve arkadaşları glokomatöz optik nöropati (GON) tanısı için derin öğrenme algoritmalarından ResNet, VGG16 ve Inception-v3 modellerini kullanarak transfer öğrenmesinin etkisini değerlendirmiştir. GON hastlığını sağlıklı gözlerden ayırmada en iyi modelin 0.91 AUC ile Resnet50 modeli olduğunu bildirmiştir [9]. Bajwa et al. glokom tespiti için öncelikle retinal fundus görüntüsünden optik diskı saptayan ve daha sonra onu sağlıklı veya glokomatöz olarak sınıflandıran iki aşamalı bir çerçeve önermiştir. Önerilen modeli Glokom sınıflandırması için halka açık bir veri seti olan ORIGA veri seti üzerinde değerlendirmiştir ve 0.874 AUC değerine ulaştıklarını bildirmiştir [10]. Lee ve arkadaşları, glokomu saptamak için spektral alanlı optik koherens tomografisi kullanmışlardır. Önerdikleri Neural Architecture Search (NASNet) mimarisinin 0,990 AUC, % 94,7

duyarlılık ve % 100 özgüllük ile glokomu teşhis edebildiğini bildirdiler [11].

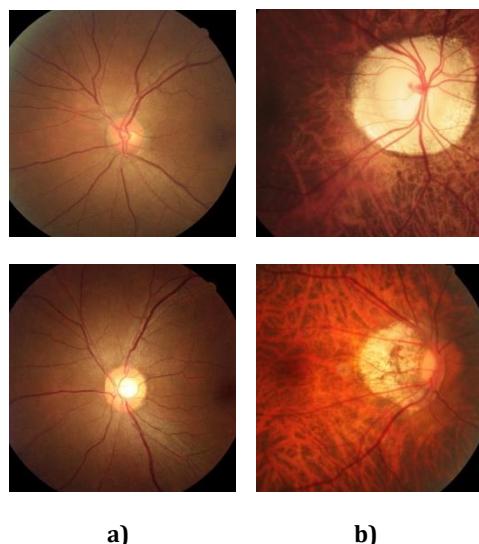
Literatürde yapılan ikinci çalışma türü derin öğrenme modellerini böülütlere ayırmak için kullanmaktadır. Bisneto ve arkadaşları glokomun otomatik tespiti için bölütleme temelli çekişmeli üretici ağlar kullanmıştır. Önerilen yöntem RIM-ONE ve Drishti-GS gibi halka açık veri setleri üzerinde değerlendirilmiş ve 100% doğruluk elde etmiştir [12]. Bir başka çalışmada Shankaranarayana ve arkadaşları optik disk bölütleme için bir derin öğrenme modeli önermiştir. RIM-ONE veri seti üzerinde yapmış oldukları testler neticesinde önerilen yöntemin en gelişmiş yöntemlerden daha iyi sonuçlar elde etiğini bildirmiştirler [13]. Zilly ve arkadaşları optik disk bölütlemesi için topluluk öğrenme tabanlı evrişimli sinir ağı mimarilerini kullanan yeni bir model geliştirmiştir. Önerilen modeli DRISHTI-GS veri seti üzerinde test etmişler ve mevcut yöntemlerden daha iyi bir performans gösterdiğini bildirmiştir [14].

3. Materyal ve Metot

Bu bölümde çalışmada kullanılan veri seti ve yöntemler hakkında detaylı bilgi verilmiştir.

3.1. Veri seti

Bu çalışmada Li ve arkadaşları tarafından oluşturulan büyük ölçekli bir veri seti kullanılmıştır [8].



Şekil 1. Örnek fundus görüntüleri a) Normal
b) Glokom

Veri seti Beijing Tongren Hastanesinden elde edilen 2392 glokom ve 3432 normal olmak üzere 5824 fundus görüntüsü içermektedir. Ancak bu çalışmada 4854 fundus görüntüsü içeren ve yalnızca araştırmacılar ile paylaşılan birinci bölüm kullanılmıştır. Bu bölümde ise 1711 glokom ve 3143 normal görüntü bulunmaktadır. Veri setindeki her bir fundus görüntüsünün pozitif veya negatif olarak etiketlenmesi alanında uzman hekimler tarafından yapılmıştır. Veri setine ait örnek fundus görüntüleri Şekil 1'de gösterilmektedir.

3.2. Yöntem

Bu çalışmada VGG16, Inception-V3, EfficientNet, DenseNet, ResNet50 ve MobileNet gibi çok gelişmiş evrişimli sinir ağı mimarileri kullanılmıştır.

VGG16 modeli, Simonyan ve Zisserman tarafından ESA modelini temel alarak geliştirilen bir mimarıdır [15]. 2014 yılında yapılan ImageNet Large Scale Visual Recognition Challenge (ILSVRC- 2014) yarışmasını % 92,7 doğruluk puanı ile kazanmıştır. VGG16 modeli 224x224 RGB giriş katmanına sahip, 13 konvolüsyon, 3 tam bağlı katman olmak üzere toplamda 16 katmandan oluşmaktadır. VGG16, giriş görüntülerini maksimum havuzlama katmanları boyunca küçültür. Ayrıca, model 138 milyon parametreden oluşmaktadır. Modelin derinliğinin önceki diğer ESA modelleriyle karşılaştırıldığında daha derin olduğu düşünülürse, bu kadar büyük bir modelin eğitilmesi uzun bir süre almaktadır.

Google tarafından geliştirilen Inception-V3 mimarisini Derin Öğrenme Evrişimli Mimariler serisinin üçüncü sürümüdür [16]. Inception-V3, görüntü sınıflandırma alanında kullanılan en gelişmiş mimarilerden biridir. Bu mimari, birden fazla farklı boyuttaki evrişimlifiltreyi yeni bir filtrede birleştiren bir başlangıç modeli önermektedir. Bu tür bir tasarım eğitilecek parametre sayısını azaltır ve böylece hesaplama karmaşıklığını da azaltır. Model, evrişim, ortalama havuzlama, maksimum havuzlama ve tam bağlantılı katmanlar içeren simetrik ve asimetrik yapı taşlarından oluşur. Son katmanda Softmax fonksiyonu bulunan Inception-V3 mimarisini toplamda 42 katmandan oluşur ve girişte 299x299 piksel boyutlarında görüntü alır.

ImageNet sınıflandırma probleminde 66M parametre hesaplama yükü ile %84.4'lük doğruluğa ulaşan EfficientNet modeli, bir grup

evrişimli sinir ağı modeli olarak düşünülebilir. EfficientNet grubu B0-B7 arasında 8 tane modelden oluşur ve model numarası büyündükçe hesaplanan parametre sayısı çok fazla artmaz iken ve doğruluk dikkat çekici şekilde artar [17]. Derin öğrenme mimarilerinde amaç daha küçük modeller ile daha verimli yaklaşımalar ortaya koymaktır. EfficientNet modeli, diğer gelişmiş modellerden farklı olarak, modeli küçültmeye çalışırken derinlik, genişlik ve çözünürlük açısından ölçekleme yaparak daha verimli sonuçlar üretir. Bileşik ölçekleme yöntemindeki ilk adım, sabit bir kaynak kısıtlaması altında temel ağını farklı ölçeklendirme boyutları arasındaki ilişkiyi bulmak için bir ızgara(grid) arama algoritması kullanmaktadır. Bu sayede derinlik, genişlik ve çözünürlük boyutları için uygun bir ölçekleme katsayısı tespit edilir. Daha sonra bu katsayılar temel ağı istenen hedef ağa ölçeklemek için uygulanır.

Sinir ağıları eğitilirken konvolüsyon ve alt-örneklemme işlemleri nedeniyle özellik haritalarında azalma meydana gelmektedir. Aynı zamanda katmanlar arası geçişlerde görüntü özelliginde kayıplar olmaktadır. Görüntü özellik bilgilerinin daha etkili kullanılması için Huang tarafından DenseNet sistemi geliştirilmiştir [18]. Yapılan sistemde her bir katman diğer katmanlara ileri beslemeli bir şekilde bağlanmıştır. Bu sayede herhangi bir katman kendinden önceki bütün katmanlara ait özellik bilgisine erişebilmektedir.

2015 yılında yapılan ILSVRC-2015 yarışmasını kazanan ResNet mimarisi, kimlik haritalarını ve doğrusal olmayan çoklu katman problemini çözmek için önerilen bir mimaridir [19]. Resnet mimarisi birkaç kalıntı bloklarından oluşur. Bu mimari, VGG16 benzeri 3x3 filtreler kullanır ve girişte 224x224 piksellik görüntü alır.

MobileNet mimarisi 2017 yılında önerilmiştir [20]. MobileNet, esas olarak Google tarafından mobil yerleşik terminallerin uygulanamayacağı sorununu çözmek için önerilen hafif bir derin sinir ağıdır. MobileNetV1 Ağ tasarımı, hafif bir derin sinir ağı oluşturmak için derinden ayrılabilir bir evrişim kullanın modern bir mimariye dayanmaktadır. Araştırma yönü model sıkıştırması yönündedir ve ana fikri, evrişim çekirdeğinin ustaca ayrışmasıdır. Optimizasyon gecikmesini dikkate alarak ağ parametrelerini etkili bir şekilde azaltabilir.

3.3. Değerlendirme Kriterleri

Bu çalışmada ikili sınıflandırma yapılmıştır ve kullanılan modellerin performansları Doğruluk, Duyarlılık, Özgüllük ve Kesinlik gibi farklı metrikler kullanılarak değerlendirilmiştir. Eşitlik 1-4'te verilen bu metrikler karşılık matrisinde elde edilen Doğru Pozitif (DP), Doğru Negatif (DN), Yanlış Pozitif (YP) ve Yanlış Negatif (YN) gibi değerler kullanılarak hesaplanır. Burada DP, doğru olarak tahmin edilen ve gerçekte de doğru olan değerleri; DN ise doğru tahmin edilen ancak gerçekte yanlış olan değerleri, YP, yanlış olarak tahmin edilen ancak gerçekte doğru olan değerleri; YN ise yanlış olarak tahmin edilen ve gerçekte de yanlış olan değerleri ifade eder.

$$\text{Doğruluk} = \frac{(DP + DN)}{(DP + YP + DN + YN)} \quad (1)$$

$$\text{Duyarlılık} = \frac{DP}{DP + YN} \quad (2)$$

$$\text{Özgüllük} = \frac{DN}{DN + YP} \quad (3)$$

$$\text{Kesinlik} = \frac{DP}{DP + YP} \quad (4)$$

Bu çalışmada ayrıca sınıflandırma başarısını değerlendirmek için popüler metriklerden bir başkası (AUC-ROC) eğrisi de kullanılmıştır. İşlem Karakteristik (Receiver Operating Characteristic) Eğrisi, farklı eşik değerleri için hesaplanan, dikey eksen üzerinde doğru pozitiflik (duyarlılık) ve yatay eksen üzerinde yanlış pozitiflik (1- özgüllük) oranlarının yer aldığı bir grafiktir. ROC eğrisinin altında kalan alan Area Under Curve (AUC) olarak ifade edilir. AUC ne kadar büyük ise, hastalığın tahmin edilmesinde kullanılan modelin, o kadar iyi bir model olduğunu gösterir.

4. Bulgular

Bu çalışmada Li ve arkadaşları tarafından oluşturulan normal sınıfı ait 3143 ve glokom sınıfına ait 1711 resim kullanılmıştır. Deneysel çalışmalar NVIDIA T80 GPU grafik kartı, Intel (R) Xeon (R) 2.00 GHz CPU ve 12GB bellek ile donatılmış Google Cloud ortamında gerçekleştirilmiştir. Modellere ait tüm kodlar,

Tensorflow yapısını kullanan Python dilinde yazılmış Keras Kütüphanesi ile geliştirilmiştir. <https://github.com/mrtucar/glokomtespiti> adresinden kodlara erişilebilir.

Çalışmada kullanılan veri seti önce %80 eğitim ve %20 test olarak ayrılmıştır. Daha sonra eğitim veri setinin %10'u doğrulama için kullanılmıştır. Eğitim ve doğrulama verileri sadece modelin eğitimi ve uyumu için kullanılırken test seti, modelin daha önce görmediği görüntüler üzerindeki tahmin performansını değerlendirmek için kullanılmıştır. Bu oranlara göre her bir veri kümelerinde kullanılan görüntü sayısı Tablo 1'de sunulmuştur.

Tablo 1. Görüntülerin eğitim, doğrulama ve test kümelerine ayrılmış hali.

Eğitim	Doğrulama	Test	Toplam
3494	389	971	4854

Bu çalışmada kullanılan veri setinde 500x500 olan görüntüler her bir model için yeniden boyutlandırılmış ve standardize edilmiştir. Tüm modellerin eğitimi transfer öğrenimi ile gerçekleştirilmiş ve optimize edici olarak Adam, loss fonksiyonu olarak çapraz entropi kullanılmıştır. Her bir model için eğitim 50 adımda gerçekleştirilmiştir. Eğitim sürecinde her adım sonrasında doğrulama verileri ile modelin başarısı hesaplanmış ve aşırı öğrenmeye engellemek için en düşük doğrulama hata oranına sahip model ağırlığı saklanarak test için kullanılmıştır. Deneysel çalışmalarında kullanılan

modellere ait ana parametreler Tablo 2'deki gibidir.

Tablo 2. Modellere ait ana parametreler.

Model Adı	Giriş boyutu	Mini Topluluk Değeri	Öğrenme Oranı
VGG16	224 x 224 x 3	64	0.00005
InceptionV3	299 x 299 x 3	32	0.001
EfficientNet	224 x 224 x 3	32	0.00005
DenseNet	224 x 224 x 3	16	0.00005
ResNet50	224 x 224 x 3	32	0.001
MobileNet	224 x 224 x 3	64	0.00005

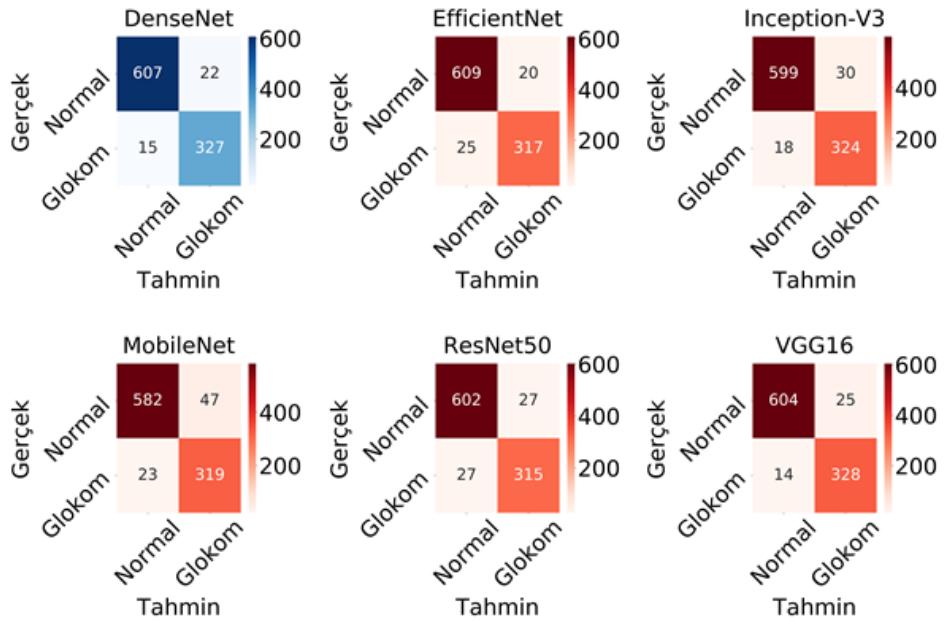
Tüm modellerin test veri setinde elde ettiği doğruluk, duyarlılık, özgüllük ve kesinlik değerleri ile toplam eğitim süreleri Tablo 3' te verilmiştir. Tablo 3'te görüldüğü üzere tüm modeller birbirine oldukça yakın doğruluk değerleri elde etmiştir. En yüksek doğruluk değerini %96.19 ile DenseNet modeli; en düşük doğruluk değerini ise %92.79 ile MobileNet modeli sağlamıştır. Eğitim süresine bakıldığında MobileNet modeli en düşük eğitim süresine sahip model olurken VGG16 modelinin eğitimi en uzun sürede tamamlanmıştır. En başarılı sonucu veren DenseNET modelinin ise eğitim süresinin 4293 saniye olduğu görülmektedir.

Tablo 3. Modellere ait sonuçlar.

	Doğruluk	Duyarlılık	Özgüllük	Kesinlik	Toplam eğitim süresi (saniye)
VGG16	95.98	95.97	95.97	95.33	7067
InceptionV3	95.06	94.98	94.98	94.30	3961
EfficientNet	95.37	94.76	94.76	95.06	2995
DenseNet	96.19	96.06	96.06	95.64	4293
ResNet50	94.44	93.91	93.91	93.91	3492
MobileNet	92.79	92.90	92.90	91.68	1692

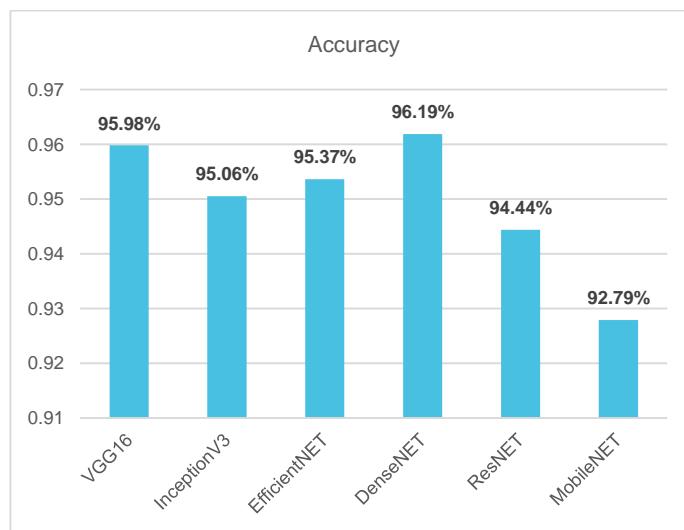
Modellerin performanslarını değerlendirmek için karşıtlık matrisleri (confusion matrix) elde

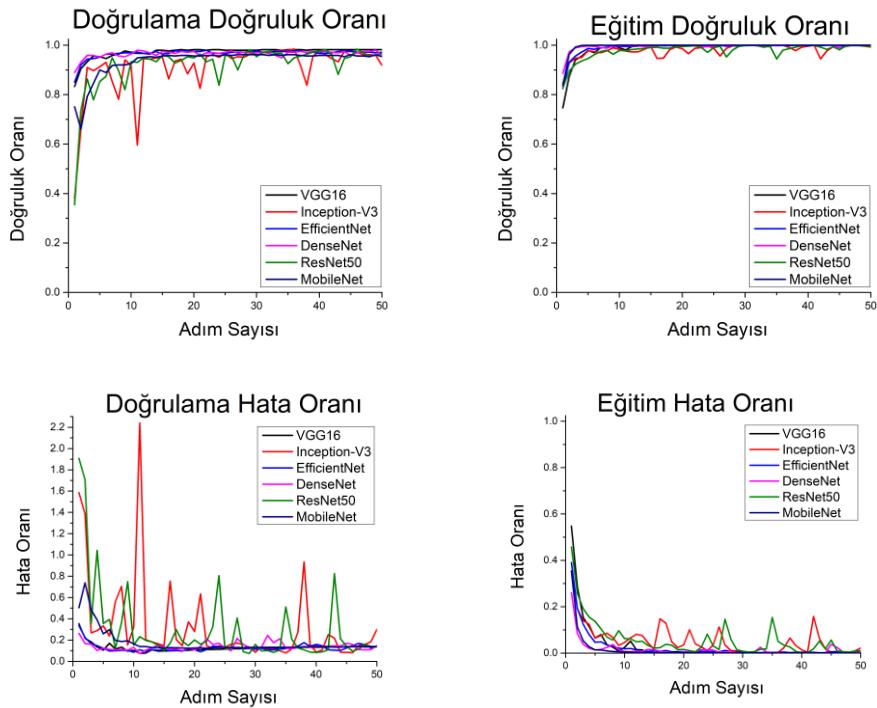
edilmiştir. Her bir model için elde edilen karşıtlık matrisleri Şekil 2'de verilmiştir.

**Şekil 2.** Modellere ait karşıtlık matrisler

DeneySEL çalışmalar ile elde edilen sonuçlar DenseNet mimarisinin tüm performans metriklerinde en yüksek değerleri ürettiğini göstermiştir. Şekil 3 tüm modeller için test veri setinde elde edilen doğrulukları göstermektedir.

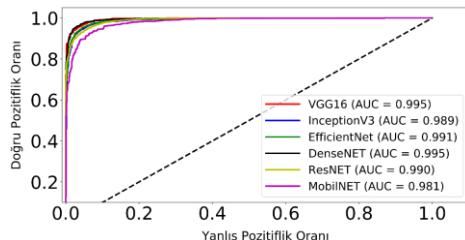
Tüm modellerin eğitimi sırasında, eğitim ve doğrulama kümelerinde elde edilen doğruluk ve hata eğrileri Şekil 4'te verilmiştir.

**Şekil 3.** Modellere ait doğruluk değerleri



Şekil 4. Eğitim ve doğrulama kümelerine ait doğruluk ve hata değerleri

Çalışmada kullanılan tüm modellerin başarısı ayrıca (AUC-ROC) eğrileri ile de değerlendirilmiştir. ROC eğrisi ve AUC değerleri Şekil 5'te verilmiştir.



Şekil 5. Modellere ait ROC eğrisi ve AUC değeri

5. Tartışma ve Sonuç

Bu çalışmada fundus görüntülerinden glokom vakalarının otomatik tespiti ve sınıflandırılması için çeşitli ESA mimarileri kullanılmıştır. Yöntemin başarısını karşılaştırmak için, glokom tanısında derin öğrenme yöntemleri kullanan önceki çalışmalara ait yöntem, veri sayısı ve başarı oranı Tablo 4'te verilmiştir.

Tablo 4'ten görüleceği üzere glokom ve normal görüntülerin ikili sınıflandırılmasında halka açık

bazı veri setleri kullanılarak çalışmalar yapıldığı ancak bu veri setlerinde glokom hastalarına ait görüntülerin sınırlı olduğu tespit edilmiştir. Yapılan bazı çalışmalarda çeşitli veri setleri birleştirilerek sınıflandırma yapıldığı görülmüştür. ESA modellerinin doğru sınıflandırma yapabilmesinde veri seti büyülüğu önemli bir parametredir. Bu çalışmada oldukça büyük bir veri setine ait görüntülerin kullanılmasının çalışmanın başarısını artırdığı görülmüştür. Çalışma sonucunda DenseNet mimarisile elde edilen %96.19'luk doğruluk oranı oldukça yüksek bir değere sahiptir. Bunun yanı sıra çalışmada önerilen çözüm yaklaşımı literatürde aynı veri setini kullanan Li ve dig.[8] tarafından geliştirilen model ile karşılaştırıldığında, birbirine çok yakın sonuçlar elde edildiği görülmektedir. Genel olarak modelin, göz doktorlarının klinik tanılarını kontrol etmelerine yardımcı olabileceği düşünülmektedir.

Gelecek çalışmalarla, yeni bir derin öğrenme modeli geliştirilerek glokom hastalığının tespitinde daha başarılı sonuçlar elde edilmesi amaçlanmaktadır.

Tablo 4. Önceki çalışmalara ait sonuçlar.

Yazar	Yöntem	Veri Seti	Veri sayısı	Başarı Oranı (%)
Chen ve diğ. [4]	ESA	ORIGA ve SCES veri setleri	1676	88,70
Raghavendra ve diğ. [5]	18 katmanlı ESA	Kasturba Medikal Kolejinden elde edilen özel veri seti	1426	98.13
Chai ve diğ. [6]	Çok branşlı sinir ağrı	Özel veri seti	2554	91.51
Fu ve diğ. [7]	Topluluk öğrenmesi	ORIGA(Eğitim veri seti) SCES ve SINDI (Test Veri Seti)	650	84.29
Li ve diğ. [8]	Dikkat temelli ESA	Beijing Tangren Hastanesinden elde edilen özel veri seti	5824	95.30
Bu çalışma	ESA (DenseNet)	Li ve diğ. [8] tarafından oluşturulan veri seti	4854	96.19

Teşekkür

Yazar, glokom ve normal fundus görüntülerini içeren büyük ölçekli veri setine erişim izni için Li ve arkadaşlarına teşekkür eder.

Kaynakça

- [1] Y.-C. Tham, X. Li, T. Y. Wong, H. A. Quigley, T. Aung, and C.-Y. Cheng, "Global prevalence of glaucoma and projections of glaucoma burden through 2040: a systematic review and meta-analysis," *Ophthalmology*, vol. 121, no. 11, pp. 2081–2090, 2014.
- [2] V. Gulshan *et al.*, "Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs," *Jama*, vol. 316, no. 22, pp. 2402–2410, 2016.
- [3] C. S. Lee, D. M. Baughman, and A. Y. Lee, "Deep learning is effective for classifying normal versus age-related macular degeneration OCT images," *Ophthalmol. Retin.*, vol. 1, no. 4, pp. 322–327, 2017.
- [4] X. Chen, Y. Xu, D. W. K. Wong, T. Y. Wong, and J. Liu, "Glaucoma detection based on deep convolutional neural network," in *2015 37th annual international conference of the IEEE engineering in medicine and biology society (EMBC)*, 2015, pp. 715–718.
- [5] U. Raghavendra, H. Fujita, S. V Bhandary, A. Gudigar, J. H. Tan, and U. R. Acharya, "Deep convolution neural network for accurate diagnosis of glaucoma using digital fundus images," *Inf. Sci. (Ny.)*, vol. 441, pp. 41–49, 2018.
- [6] Y. Chai, H. Liu, and J. Xu, "Glaucoma diagnosis based on both hidden features and domain knowledge through deep learning models," *Knowledge-Based Syst.*, vol. 161, pp. 147–156, 2018.
- [7] H. Fu *et al.*, "Disc-aware ensemble network for glaucoma screening from fundus image," *IEEE Trans. Med. Imaging*, vol. 37, no. 11, pp. 2493–2501, 2018.
- [8] L. Li, M. Xu, X. Wang, L. Jiang, and H. Liu, "Attention based glaucoma detection: A large-scale database and CNN Model," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2019, pp. 10571–10580.
- [9] M. Christopher *et al.*, "Performance of deep learning architectures and transfer learning for detecting glaucomatous optic neuropathy in fundus photographs," *Sci. Rep.*, vol. 8, no. 1, pp. 1–13, 2018.
- [10] M. N. Bajwa *et al.*, "Two-stage framework for optic disc localization and glaucoma classification in retinal fundus images using deep learning," *BMC Med. Inform. Decis. Mak.*, vol. 19, no. 1, p. 136, 2019.
- [11] J. Lee, Y. K. Kim, K. H. Park, and J. W. Jeoung, "Diagnosing Glaucoma With Spectral-Domain Optical Coherence Tomography Using Deep Learning Classifier," *J. Glaucoma*, vol. 29, no. 4, pp. 287–294, 2020.
- [12] T. R. V. Bisneto, A. O. de Carvalho Filho, and D. M. V. Magalhães, "Generative adversarial network and texture features applied to automatic glaucoma detection," *Appl. Soft*

- [13] S. M. Shankaranarayana, K. Ram, K. Mitra, and M. Sivaprakasam, "Joint optic disc and cup segmentation using fully convolutional and adversarial networks," in *Fetal, Infant and Ophthalmic Medical Image Analysis*, Springer, 2017, pp. 168–176.
- [14] J. Zilly, J. M. Buhmann, and D. Mahapatra, "Glaucoma detection using entropy sampling and ensemble learning for automatic optic cup and disc segmentation," *Comput. Med. Imaging Graph.*, vol. 55, pp. 28–41, 2017.
- [15] K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," *arXiv Prepr. arXiv1409.1556*, 2014.
- [16] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, "Rethinking the inception architecture for computer vision," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 2818–2826.
- [17] M. Tan and Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," *36th Int. Conf. Mach. Learn. ICML 2019*, vol. 2019-June, pp. 10691–10700, 2019.
- [18] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, "Densely connected convolutional networks," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, pp. 4700–4708.
- [19] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," *Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit.*, vol. 2016-Decem, pp. 770–778, 2016, doi: 10.1109/CVPR.2016.90.
- [20] A. G. Howard *et al.*, "Mobilenets: Efficient convolutional neural networks for mobile vision applications," *arXiv Prepr. arXiv1704.04861*, 2017.