



Siyam Sinir Ağlarını Kullanarak Türk İşaret Dilindeki Rakamların Tanımlanması

Recognition of the Digits in Turkish Sign Language using Siamese Neural Networks

Mesut Toğaçar ¹, Zafer Cömert ^{2*}, Burhan Ergen ³

¹ Fırat Üniversitesi Teknik Bilimler Meslek Yüksekokulu Bilgisayar Teknolojileri Programı, Elazığ, TÜRKİYE

² Samsun Üniversitesi Mühendislik Fakültesi Yazılım Mühendisliği Bölümü, Samsun, TÜRKİYE

³ Fırat Üniversitesi Mühendislik Fakültesi Bilgisayar Mühendisliği, Elazığ, TÜRKİYE

Sorumlu Yazar / Corresponding Author *: zcomert@samsun.edu.tr

Geliş Tarihi / Received: 26.08.2019

Araştırma Makalesi/Research Article

Kabul Tarihi / Accepted: 27.04.2020

DOI:10.21205/deufmd.2021236801

Atıf Sekili/How to cite: TOĞAÇAR M., CÖMERT Z., ERGEN B. (2021). Siyam Sinir Ağlarını Kullanarak Türk İşaret Dilindeki Rakamların Tanımlanması. DEUFMD, 23(68), 349-356.

Öz

İletişim, insanların duygusal, düşünce veya bilgiyi çeşitli yollar kullanarak karşı tarafa aktarma sürecidir. İletişimde en etkili yollardan birisi ise dildir. Dil, insanların günlük hayatını kolaylaştıran bir iletişim aracıdır ve bu iletişim aracını kullanamayan işitme engelli birçok insan vardır. İşitme engelli insanların, toplum içerisinde iletişimini kolaylaştırmak için işaret dilleri geliştirilmiştir. Her ülkenin kendi konuşma diline özgü işaret dili mevcuttur. Bu çalışma erişime açık Türk işaret dili rakamlarına odaklanmıştır. İşaret dili, toplumun her kesimi tarafından bilinmemektedir. Bu durum, işitme engelli insanların bulunduğu sosyal ortamlarda iletişim aksaklılarına neden olmaktadır. İşitme engelli olmayan ancak işaret dilini bilmeyen bir birey de aynı problemi yaşamaktadır. Bu çalışmanın amacı, işaret dilini kullanan insanların ne anlatmak istediklerini derin öğrenme mimarisini üzerinde tespit etmektir. Bu amaçla, işaret dili rakamlarının, son zamanlarda popülerliği artan siyam sinir ağları ile tanımlanması bu çalışmada gerçekleştirilmiştir. Siyam sinir ağları, görüntü kümelerinde aynı görüntüleri eşleştiren bir derin öğrenme modelidir. Bu ağları kullanarak Türk işaret dilinde kullanılan rakam görüntülerini tanımlamayı gerçekleştirdik. Elde edilen eşleştirme başarı oranı %98,16'dır. Sonuç olarak, bu çalışma ile Türk işaret dili rakamlarının tanımlanmasında siyam sinir ağlarının başarılı olduğu görülmüştür.

Anahtar Kelimeler: Siyam Sinir Ağları, Türk İşaret Dili, Rakam Tanımlama, Derin Öğrenme.

Abstract

Communication is the process of people transferring emotions, thoughts or information to the other party in various ways. One of the most effective ways of communication is language. Language is a communication tool that makes people's daily life easier and there are many hearing impaired people in our lives who cannot use this communication tool. Sign languages have been developed to facilitate the communication of hearing impaired people in society. There are specific sign languages varying according to the language of the countries. This study focuses on the Turkish sign language digits that are publicly available. Sign language is not known by all people of society. This situation causes communication disruptions in the social environments where hearing impaired people are present. A person who has not hearing impaired but cannot use sign language has the same problem. The aim

of this study is to determine what people using sign language want to tell by using a deep learning architecture. For this purpose, the identification of digits in Turkish sign language has been realized by using the recently popular siamese neural network in this study. Siamese neural networks are a type of deep learning model that matches the same images in an image dataset. Using these networks, we have identified the digits used in Turkish sign language. The success rate of the matching was 98.16%. Consequently, siamese neural networks were found to be successful in identifying Turkish sign language digits with this study.

Keywords: *Siamese Neural Networks, Turkish Sign Language, Digit Recognition, Deep Learning.*

1. Giriş

İletişim, gönderici tarafından ifade edilmek istenen duyguya, düşünce veya bilgilerin alıcıya çeşitli araçlar vasıtasiyla aktarılması sürecidir [1]. İletişimde en önemli unsur aracı dildir [2]. İnsanlar kendi aralarında iletişimini kolaylaştırmak için dil unsurunu sıkça kullanmaktadır [3]. Her toplumun kendine özgü bir konuşma dili vardır [4]. İnsanlar bu konuşma dilini doğrudan veya dolaylı bir şekilde kullanarak kendilerini ifade ederler. Ancak duyma yetisini bazı insanlar çeşitli sebeplerden dolayı kaybedebilmektedir. İşitme engelli olan bu insanlar sosyal ortamlarda kendilerini ifade etmede güçlükler çekerilmektedir. Bu sebeple, her toplum işitme engelli insanların yönelik bir işaret dili geliştirilmiştir [5]. İşaret dili, ses olmadan vücudun parmak, el ve kol uzuvaları ile ifade edilen bir dildir [6]. İşaret dili engelli insanların kendilerini ifade etmek için kullandıkları ve iletişimlerini kolaylaştıran bir beden dili olarak değerlendirilmektedir. Bu dil, konuşma dili gibi harf, özel karakter ve rakamlardan oluşmaktadır [7].

Ülkemizde 2015 yılında Türkiye İstatistik Kurumu (TÜİK)'in verilerine göre, 406 bin erkek ve 429 bin kadın olmak üzere toplamda yaklaşık 836 bin işaret engelli vatandaşımız bulunmaktadır [8]. İşaret dili işaret engelleri için bir kolaylık olsa da toplumun her kesimi işaret dilini bilmemektedir [9]. Bu kapsamda, teknolojik araçlar kullanılarak işaret dilini bilmeyen kişilerin ihtiyaç halinde bu dili kullanmalarını sağlamak üzere akıllı araçların sunulması makul bir çözüm olarak görülmektedir. İlgili problemin çözümüne katkı sunmak amacıyla bu çalışma kapsamında Türk işaret dilindeki rakamların ileri düzey görüntü işleme teknikleri yardımıyla tanımlanmasını sağlayan bir model önerisi sunulmuştur.

Bu makalenin geriye kalan bölümleri şu şekilde düzenlenmiştir: 2.bölümde ilgili literatür

özetlenmiştir. 3. bölümde, veri seti ve SSA hakkında kısa bilgiler verilmiştir. Bölüm 4 deneyde elde edilen bulguları içermektedir. Son iki bölüm ise sırasıyla tartışma ve sonuç bölümlerinden oluşmaktadır.

2. İlgili Çalışmalar

Giriş bölümünde sözü geçen problemi en alt seviyeye düşürmek için teknolojinin olanaklarından faydalanan ve bunu pratiğe dönüştürmek uygulanabilir bir çözüm olarak görülmektedir. Bu amaçla görüntü işleme, insanın uzuv hareketlerini tespit eden, hedefi doğrultusunda hızlı ve doğru bir şekilde sonuçlandıran yazılım teknolojisi olarak kullanılabilir [10,11]. Bu teknoloji ile hali hazırda çeşitli modeller geliştirilmiş durumdadır. Geliştirilen bu modeller içerisinde, son zamanlarda popülerliğini artırmış olan yöntemlerden biri de derin öğrenme modelleridir [12,13].

Bu çalışmada, belirtilen problemin çözümüne katkıda bulunmak için derin öğrenme ağları Türk işaret dilinin rakamlarından oluşan görüntü kümesi üzerine uygulanmış ve siyam sinir ağları (SSA) kullanılarak görüntüleri tanımlama ve sonrasında eşleştirme işlemi gerçekleştirılmıştır.

İşaret dillerinin tanımlanması ve sınıflandırılması işleminde birçok teknik ve yöntem önerilmiştir. Lionel Pigou ve ark [14], İtalyan işaret dilinden 20 el hareketini tanımlamaya yönelik bir çalışma gerçekleştirmiştirler. İşaret dilini tanımlamada kendilerinin tasarladığı iki adet Evrişimsel Sinir Ağı (ESA) modeli ile bir adet Yapay sinir ağı (YSA)'nı kullanarak sonuçları birleştirmiştirler. Elde ettikleri başarı oranı %91,7'dir. Vivek Bheda ve ark [15] çalışmalarında Amerikan işaret dilindeki rakamları derin öğrenme modelini kullanarak tanımlamışlardır. Kullandıkları veri seti küçük ölçekli olduğu için, görüntü seti veri çoğaltma yöntemleri

kullanılarak arttırlılmıştır. Çalışmalarında araştırmacıların tasarlamış olduğu ESA modeli ile tanımlama işlemi gerçekleştirılmıştır. Elde edilen başarı oranı %97 olarak rapor edilmiştir. Burçak Demircioğlu ve ark [16] çalışmalarında, Türk işaret dili alfabetesini tanımlamayı başarmışlardır. Bunun için parmak, el ve kol uzuvlarının hareketini takip eden Leap Motion adı verilen sensörlü bir cihaz kullanılmıştır. Bu cihaz ile eş zamanlı uzuv hareketlerini yakalayıp daha sonra Rastgele Orman (RO) ve Çok Katmanlı Algılayıcı (ÇKA) yöntemleri ile sınıflandırma işlemi araştırmacılar tarafından gerçekleştirilmişdir. Elde ettikleri sınıflandırma başarı oranı en iyi ÇKA yöntemi ile %96,67'dir. Abul Kalam ve ark [17] çalışmalarında Amerikan işaret dilindeki rakam imgelerini sınıflandırmıştır. Araştırmacılar veri setindeki 700 adet imgeyi 10 farklı açıdan döndürmüştür ve toplamda 7000 görüntü kümlesi oluşturmuştur. Daha sonra tasarladıkları ESA mimarisine artan blokları (Residual blok) katarak sınıflandırma işlemini gerçekleştirmiştirlerdir. Elde edilen başarı oranı %97,28 olarak bildirilmiştir. Bogdan Kwolek ve ark [18] çalışmalarında Japon işaret dilindeki 41 karakteri tanımlamak ve sınıflandırmak için SSA'yı kullanmıştır. Eşleştirme işleminde siyam ağ modelinin sonunda Destek Vektör Makineleri (DVM) çalışmada kullanılmıştır. Test aşamasında tek SSA ile iki adet SSA modelini birlikte kullanarak deneysel çalışma gerçekleştirilmiştir. Tek SSA ile elde edilen başarı oranı %74,3 iken, iki SSA modelinin birleşimi ile elde edilen başarı oranı %78,6 olarak rapor edilmiştir.

3. Materyal, Model ve Metot

3.1. Veri Kümesi

Veri kümlesi, 0 ile 9 arasındaki rakamları temsil eden Türk işaret dili görüntülerinden oluşmaktadır. Görüntüler, Ankara Ayrancı Anadolu Lisesi'nde eğitim görmüş 218 öğrencinin katılımıyla oluşturulmuştur. Her bir öğrenciden 0-9 arası rakamları gösterecek şekilde 10 adet işaret dili görüntüsü elde edilmiştir. Veri kümlesi toplamda 2180 imgeden oluşmaktadır. 0 ile 9 arası rakamların işaret görüntülerine ait bir alt örnek kümlesi Şekil 1' de gösterilmiştir. Veri görüntüleri erişime açıktır [19] ve her bir görüntü 100×100 piksel çözünürlüğe sahiptir. İmge formatı JPEG olup, üç renk kanalından (RGB) oluşmaktadır.



Şekil 1. Rakamlardan oluşan Türk İşaret Dili görüntülerinin bir alt örnek kümlesi [19].

Bu çalışmada veri kümlesi 0 ile 9 arasındaki rakamları temsil edecek şekilde 10 adet sınıfı ayrılmıştır. Veri kümnesinin %75'i eğitim verisi, %25'i ise test verisi olarak ayrılmıştır. Sınıf bazında imgé sayısının değişmesi nedeniyle her sınıfın toplamda 205 görüntü rastgele seçilmiştir. Neticede 2050 görüntüden oluşan bir veri kümlesi üzerinde çalışılmıştır. Buradaki amaç, sınıflar arasında dengeyi sağlayarak SSA modelini verimli bir şekilde kullanabilmektir [20]. Ayrıca bu çalışmada, JPEG görüntü formatı taşınabilir gri harita (PGM) formatına çevrilmiştir. Böylece deneysel çalışmalar gri-seviyeli imgeler üzerinde gerçekleştirilmiştir.

3.2. Optimizasyon Yöntemi

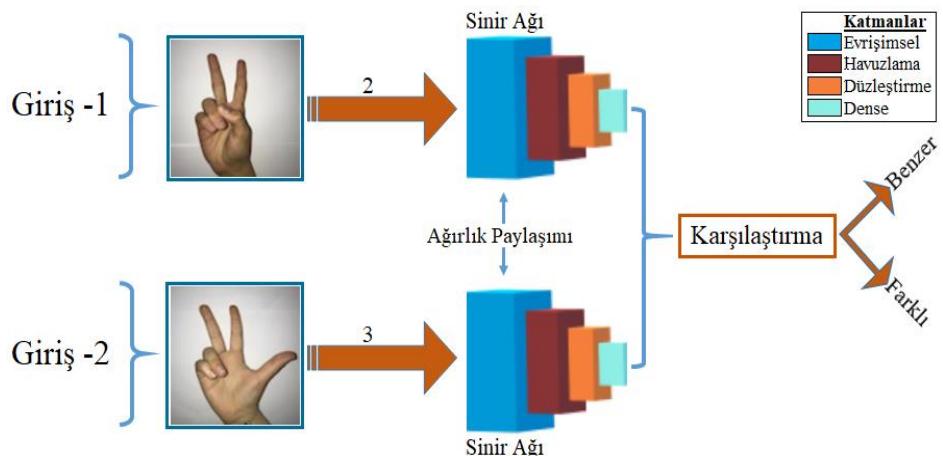
Adaptive moment (Adam) optimizasyon yönteminde temel amaç her devir sayısında öğrenme katsayıları kendilerini yenileterek hedef noktasına daha da yaklaşımaktadır. Yani, Adam Adadelta ve RMSProp gibi optimizasyon yöntemlerinde uygulandığı gibi sadece elde edilen gradientlerin (g) karelerini (v_t) işleme dahil etmez, ayrıca geçmişteki gradientlerin karelerini almadan da (m_t) işleme tabi tutar [21]. Belirtilen işlem adımları Denklem (1)-(5) arasında gösterilmiştir.

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (1)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (2)$$

$$m_t = \frac{m_t}{1 - \beta_1^t} \quad (3)$$

$$v_t = \frac{v_t}{1 - \beta_2^t} \quad (4)$$



Şekil 2. SSA modelinin çalışma prensibi.

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{v_t + \epsilon}} m_t \quad (5)$$

3.3. SSA Modeli

SSA, birbirinin aynısı iki YSA modelinden oluşan ve iki farklı girdisi olan derin öğrenme mimarisini türündür. SSA, sinir ağlarında kullanılan ağırlık değerleri modelin içinde yer alan her iki YSA ağında da ortak olarak kullanmaktadır. Yani parametre değerleri ve güncellemleri SSA modelinin içerisinde bulunan iki YSA modeliyle paylaşılarak sonuca gidilmektedir [22]. SSA modeli, girdi olarak verilen iki görüntünün birbirine benzer ya da farklı olup olmadığını ağlı eğiterek kullanıcıya verir. SSA modelinin çalışma prensibi blok şemalar ile Şekil 2'de gösterilmiştir.

SSA modeli ilk olarak LeCun tarafından imza doğrulama problemini çözümlemek için kullanılmıştır [23]. Burada imzaların ilgili kişiye ait olup olmadığını doğrulamak amaçlanmıştır. SSA modelleri girdi olarak girilen iki adet görüntüyü eşleştirme yaparak iki görüntü verisinin de aynı olup olmadığını, model içerisinde kullanılan sinir ağlarının birbirleri ile paylaştığı ağırlık parametrelerine göre belirlemektedir. Eğer iki görüntünün elde ettikleri ağırlık parametreleri yaklaşık değer olarak birbirine benzer sonuçlar üretiyor ise görüntülerin aynı olduğunu karar verilmektedir. Burada SSA modelinde bir eşik değeri kullanılmaktadır. Bu nedenle, SSA modeli

icerisinde yer alan iki sinir ağından elde edilen sonuç değerleri arasındaki fark alınmaktadır. Bu fark eğer eşik değerin altında ise model, görüntüler benzerdir ya da aynıdır sonucunu vermektedir; aksi halde model sonuçların farklı olduğu şeklinde bir çıktı üretmektedir. Görüntü üzerinde piksellerin her birinin bir sayısal değeri olduğundan, SSA modeli içerisinde pikseller arasında uzaklık formülü olarak genelde Öklid kullanılmaktadır.

Öklid formülünün tanımına Denklem (6)'da yer verilmiştir. SSA modeli içerisinde ağırlık parametreleri için kullanılan bir eşik değerini hesaplamada ise Hata fonksiyonu formülü kullanılmaktadır. Hata fonksiyonu ile ilgili formül Denklem (7)'de tanımlanmıştır. Bu denklemlerde U değişkeni, uzaklığını; x ve y değişkenleri, sinir ağlarının üretmiş olduğu iki vektörü temsil etmektedir. Y , iki girdi görüntüsünün aynı olması durumunda bir değerini; farklı olması durumunda sıfır değerini alan bir durum değişkenini temsil eder.

$$U = \sqrt[2]{\sum_{i=1}^n (x^i - y^i)^2} \quad (6)$$

$$H = (1 - Y) \frac{1}{2} U^2 + (Y) \frac{1}{2} \max(0, m - U)^2 \quad (7)$$

Tablo 1. SSA modelinde kullanılan katmanlar ve parametre değerleri.

Katman		Tür / Boyut	Filtre Boyutu	Oran	Aktivasyon
Giriş	Görüntü	Pgm / 100×100	-	-	-
1	Evrişimsel	- / 50×50	-	-	relu
2	Havuzlama	En büyük / 2, 2	3×3	-	relu
	Seyreltme	-	-	0,25	-
3	Evrişimsel	- / 50×50	-	-	relu
4	Havuzlama	En büyük / 2, 2	3×3	-	relu
	Seyreltme	-	-	0,25	-
5	Düzleştirme	-	-	-	relu
	Dense	128	-	-	relu
Çıkış	Seyreltme	-	-	0.1	-
	Dense	50	-	-	relu

SSA modeli içerisinde kullanılan ESA model mimarisinde, evrişimsel katman, havuzlama katmanı, aktivasyon katmanları ve düzleştirme (flatten) katmanı bulunmaktadır [18,24]. Bu katmanların görevleri şu şekilde açıklanabilir: Evrişimsel katmanın görevi, giriş görüntüsünün seçilen filtre ile dolaştırılması işlemine dayanır. Filrenin boyutu 3×3 , 5×5 veya 7×7 piksel olabilir. Böylece görüntüye uygulanan filtre ile sonraki katmanın $(m_1 \times m_2)$ girişi oluşturulur [25,26].

Aktivasyon haritaları bu evrişim sürecinin bir sonucu olarak ortaya çıkar. Aktivasyon haritaları yerel ayırt edici özelliklere sahiptir. Yani veri kümesinden elde edilen özniteliklerin tutulduğu haritalardır [26,27]. Havuzlama katmanı, görüntü özelliklerini korur, görüntü boyutunu ve maliyetlerini azaltır ve ayrıca görüntü bilgilerini bozulmadan tutar. Düzleştirme katmanı ise çok boyutlu bir çıktıyi Dense gibi sınır ağının son katmanında yer alan katmanlara doğrusallaştırarak girdi verisi olarak verir [28,29]. Ayrıca seyreltmefiltresi (dropout) ise katmanlardaki özellikleri azaltarak modelin işleyişini rahatlamak üzere kullanılır [30]. Bu çalışmada kullanılan sınır ağlarının parametre değerleri Tablo 1'de gösterilmiştir.

Deneysel çalışmada, kullanılan SSA modelinin veri giriş boyutu 50×50 olarak ayarlanmıştır. Çalışmanın SSA modeli, Python dilinde Keras kütüphanesi kullanılarak derlenmiştir [31]. SSA modeli için Adam optimizasyon yöntemi seçilmiştir ve devir sayısı (epoch) 40 olarak ayarlanmıştır. Devir sayısının 40 alınmasının sebebi eşleştirme başarısını artık geliştirememesinden kaynaklanmıştır.

4. Bulgular

Bu makaledeki deney, 64 bitlik Windows 10 işletimi üzerinde kurulan Python 3.6 yazılımı kullanılarak derlendi. Python kodlarının derlenmesi Jupyter Notebook arayüzü üzerinden gerçekleştirildi. Kullanılan bilgisayarın özellikleri; NVIDIA GeForce 2 GB grafik kartı, Intel® i5 -Core 2.5 GHz işlemci ve 8 GB RAM'e sahiptir. Ayrıca, bu çalışmanın SSA modelinde mini-batch değeri 5, öğrenme oranı 0.001 ve Adam optimizasyonunda beta (β) değeri ve gecikme faktörü 0.9 almıştır. Mini-batch parametresi birden fazla girdinin model üzerinde aynı anda işlemesi durumudur [32]. Bu durum ise kullanılan bilgisayarın donanımsal gereksinimlerinden kaynaklandığı için 5 değeri alınmıştır.

Bu çalışmanın geçerliliğinin ve performansının ölçülmesi; duyarlılık, özgünlük ve doğruluk ile ilişkili olarak doğru pozitif (DP), doğru negatif (DN), yanlış pozitif (YP), yanlış negatif (YN) indislerine dayanmaktadır [33,34]. Performans metriklerinin hesaplanması için kullanılan formüller Denklem (8) ile Denklem (11) arasında tanımlanmıştır.

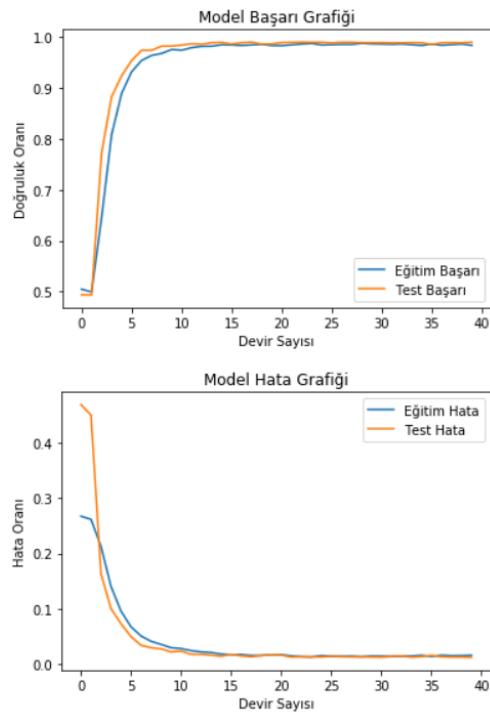
$$\text{Duyarlılık (Duy)} = \frac{(DP)}{(DP+YN)} \quad (8)$$

$$\text{Özgünlük (Öz)} = \frac{(DN)}{(DN+YP)} \quad (9)$$

$$\text{F-skor (F-skr)} = \frac{(2xDP)}{(2xDP+YP+YN)} \quad (10)$$

$$\text{Doğruluk (Doğ)} = \frac{(DP+DN)}{(DP+YN)+(YP+DN)} \quad (11)$$

Bu çalışmada 2050 işaret imgesi (her bir rakam sınıfı için 205 görüntü) kullanılarak, ilgili imgelerin SSA modeli tarafından otomatik olarak tanımlamaları gerçekleştirildi. Eğitim için veri kümesinin %75'i kullanıldı. SSA modeli içerisinde, iki girdi görüntüsünün eşleştirilmesi rastgele gerçekleştirildi. Bu deneyde, toplam eşleştirme sayısı 15 bin olarak ayarlandı. Eğitim imgelerindeki eşleştirme sayısı 11250 ve test görüntülerinde kullanılan eşleştirme sayısı ise 3750 olarak ayarlandı. Deneyin sonucunda eğitim ve test görüntülerinin başarı ve hata grafikleri sırasıyla Şekil 3'te gösterildiği gibi elde edilmiştir. Ek olarak, modelin veri seti eğitiminde her bir devir sayısı için ortalama 111,3 saniye ve toplamda 4452 saniye zaman harcamıştır.

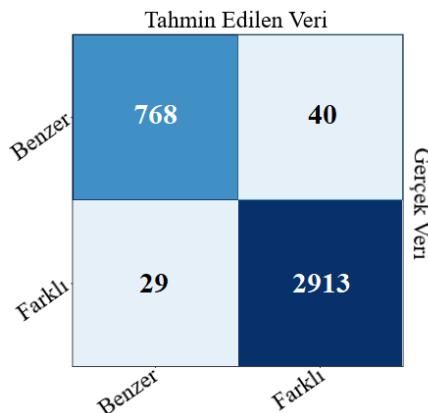


Şekil 3. Deney sonuçlarının analiz grafikleri.

Test verilerinin eşleştirilmesindeki başarı oranı %98,16 olarak elde edildi. Test verisinin diğer metriklerine ait sonuçlarına Tablo 2.'de yer verilmiştir. Ayrıca, İlgili Çalışmalar bölümünde siyam modelleri ile gerçekleştirilen analiz sonuçlarında Tablo 2'de verilmiştir. Deney sonucunda elde edilen metrik değerleri; duyarlılık başarısı %96,36 özgünlük değeri %98,65 ve F-skor başarısı %95,70 olarak elde edilmiştir. Elde edilen eşleştirme sonucunun karmaşılık matrisi ise Şekil 4'te gösterilmiştir.

Tablo 2. SSA modelini kullanarak Türk işaret dilindeki rakamlarının yüzdelik eşleştirme sonuçları ve ilgili literatürdeki siyam çalışmaların analiz sonuçları.

Mimari	Sınıf	Doğ	Duy	Öz	F-skr
Bir SSA ve DVM [18]	Farklı, Benzer	74.30	74.60	-	72.20
İki SSA ve DVM [18]	Farklı, Benzer	78.60	79.10	-	78.10
SSA (Bu çalışma)	Farklı, Benzer	98.16	96.36	98,65	95.70



Şekil 4. Test Verilerinin eşleştirme sonuçlarından elde edilen karmaşıklık matrisi.

5. Tartışma

İşaret dili görüntülerinin eşleştirilmesi işlemi oldukça zor bir süreçtir. Özellikle alfabe sayısı artırılsa bu durumun zorluğu daha da artmaktadır. SSA modelleri eşleştirme tercih edilen bir derin öğrenme modeli türüdür. Bu çalışmada kullanılan SSA modeli açık kaynak kodları kullanarak derlenmiştir.

Çalışmanın başarısında model için seçilen parametre değerleri ve optimizasyon yönteminin eşleştirme prosedürüne pozitif katkısı gözlemlenmiştir. Literatürde, SSA modelini kullanarak işaret dillerini eşleştirten yeterli sayıda çalışma henüz literatürde yer almamaktadır. Dolayısıyla bu çalışmanın alanda yapılacak çalışmalarla öncülük edeceğini düşünülmektedir.

Tablo 3'te bu çalışmayı, benzer nitelikler taşıyan bir başka çalışma ile kıyasladık. Bogdan Kwolek ve ark [18] çalışmalarında, Japon işaret dili verilerini kullanarak SSA modeliyle bir sınıflandırma gerçekleştirmiştir. Çalışmalarında elde ettikleri başarı %78,6 olarak rapor edilmiştir. Sınıflandırma başarısının düşük olmasının sebebi, Japon işaret dili veri setinde yeterli sayıda imgé olmaması ve oldukça fazla sınıfı (41 işaret dili sınıfı) sahip olmasından kaynaklanmaktadır. İlgili çalışmanın bir başka yenilikçi yönü ise SSA modelinin sonunda DVM, RO, en Yakın Komşu gibi makine öğrenme tekniklerinin kullanılmasıdır. Gelecek çalışmalarında farklı makine öğrenme yöntemlerini SSA modelinin içerisinde kullanılması çeşitli veri setleri üzerinde test edilmesi planlanmaktadır.

Tablo 3. SSA modelini kullanarak Türk işaret dilindeki rakamlarının yüzdelik eşleştirme sonuçları.

Çalışmalar	Yıl	Sınıf	Yöntem	Doğ(%)
Bogdan Kwolek ve ark [18]	2017	41	SSA & DVM	78,60
Bu Çalışma	2019	10	SSA & Dense	98,16

6. Sonuç

Son zamanlarda derin öğrenme modelleri ile eşleştirme, sınıflandırma ve bölütleme gibi görevleri yerine getirmek üzere yapılan çalışmaların sayısında kayda değer bir artış gözlemlenmektedir. Bu çalışmada, on sınıfı işaret dili görüntülerini eşleştirme işlemi gerçekleştirılmıştır. Bu kapsamda, iki girdili veriler için eşleştirme işleminde tercih edilen siyam ağları kullanılmıştır. Çalışmanın sonucunda %98,16'lık bir başarı elde edilmiştir.

Gelecek çalışmalarında, farklı veri setleri dikkate alınarak SSA modelinin, ESA ve makine öğrenme modelleri ile birlikte kullanımı konusunda araştırmaların gerçekleştirilemesi planlanmaktadır.

Kaynakça

- [1] Redondo M. Investigación de la enseñanza ética de los periodistas en España . Análisis bibliométrico y prescripciones formativas aplicadas (2005-2015) Research on ethics education for journalists in Spain .2017;235-52 doi:10.4185/RLCS.
- [2] Thomas J, McDonagh D. Shared language:Towards more effective communication. Australas Med J [Internet]. 2013/01/31. 2013;6(1):46-54. Available from: <https://www.ncbi.nlm.nih.gov/pubmed/23422948> doi:10.4066/AMJ.2013.1596.
- [3] Lindquist KA, MacCormack JK, Shabrack H. The role of language in emotion: predictions from psychological constructionism. Front Psychol [Internet]. 2015 Apr 14;6:444. Available from: <https://www.ncbi.nlm.nih.gov/pubmed/25926809> doi:10.3389/fpsyg.2015.00444.
- [4] Hassen R. Language as an Index of Identity, Power, Solidarity and Sentiment in the Multicultural Community of Wollo. J Soc. 2016;5(3):1-5. doi:10.4172/2471-8726.1000174.
- [5] Alnfiai M, Sampali S. Social and Communication Apps for the Deaf and Hearing Impaired. In: 2017 International Conference on Computer and Applications (ICCA). 2017. p. 120-6. doi:10.1109/COMAPP.2017.8079756.
- [6] Vijayalakshmi P, Aarthi M. Sign language to speech conversion. In: 2016 International Conference on Recent Trends in Information Technology (ICRTIT). 2016. p. 1-6. doi:10.1109/ICRTIT.2016.7569545.

- [7] Oktekin B. Development of Turkish Sign Language Recognition Application. Near East University; 2018.
- [8] Yıldız Z, Yıldız S, Bozyer S. İşitme Engelli Turizmi Sessiz Turizm: Dünya Ve Türkiye Potansiyeline Yönelik Bir Değerlendirme. Süleyman Demirel Üniversitesi Vizyoner Derg. 2018;103-17. doi:10.21076/vizyoner.339776.
- [9] von Agris U, Zieren J, Canzler U, Bauer B, Kraiss KF. Recent developments in visual sign language recognition. *Univers Access Inf Soc.* 2008;6(4):323-62. doi:10.1007/s10209-007-0104-x.
- [10] Toğacar M, Ergen B. Biyomedikal Görüntülerde Derin Öğrenme ile Mevcut Yöntemlerin Kullanılması. Fırat Üniversitesi Mühendislik Bilim Derg. 2019;31(1):109-21.
- [11] Cömert Z, Kocamaz AF. Fetal Hypoxia Detection Based on Deep Convolutional Neural Networks with Transfer Learning Approach. In: Silhavy R, editor. *Software Engineering and Algorithms in Intelligent Systems*. Cham: Springer International Publishing; 2019. p. 239-48.
- [12] Sertkaya ME, Ergen B, Togacar M. Diagnosis of Eye Retinal Diseases Based on Convolutional Neural Networks Using Optical Coherence Images. In: 2019 23rd International Conference Electronics. 2019. p. 1-5. doi:10.1109/ELECTRONICS.2019.8765579.
- [13] Altuntaş Y, Cömert Z, Kocamaz AF. Identification of haploid and diploid maize seeds using convolutional neural networks and a transfer learning approach. *Comput Electron Agric.* 2019;163:104874. doi:<https://doi.org/10.1016/j.compag.2019.104874>.
- [14] Pigou L, Dieleman S, Kindermans P-J, Schrauwen B. Sign Language Recognition Using Convolutional Neural Networks. Vol. 8925. 2015. 572-578 p. doi:10.1007/978-3-319-16178-5_40.
- [15] Bheda V, Radpour ND. Using Deep Convolutional Networks for Gesture Recognition in American Sign Language. 2017;1710. 0683. Available from: <https://arxiv.org/ftp/arxiv/papers/1710/1710.06836.pdf>
- [16] Demircioglu B, Bülbül G, Kose H. Leap Motion ile Türk İşaret Dili Tanıma / Turkish Sign Language Recognition With Leap Motion. 2016. doi:10.13140/RG.2.1.4923.3529.
- [17] Abul Kalam M, Nazrul M, Mondal I, Ahmed B. Rotation Independent Digit Recognition in Sign Language. In: 2019 International Conference on Electrical, Computer and Communication Engineering (ECCE). 2019; 2019.
- [18] Kwolek B, Sako S. Learning Siamese Features for Finger Spelling Recognition. 2017. 225-236 p. doi:10.1007/978-3-319-70353-4_20.
- [19] Arda Mavi. Turkey Ankara Ayrancı Anadolu High School's Sign Language Digits Dataset [Internet]. 2017 [cited 2019 Aug 21]. Available from: <https://github.com/ardamavi/Sign-Language-Digits-Dataset>
- [20] Berlement S, Lefebvre G, Duffner S, Garcia C. Class-Balanced Siamese Neural Networks. *Neurocomputing.* 2017 Oct 1; doi:10.1016/j.neucom.2017.07.060.
- [21] YAZAN E, Talu MF. Comparison of the stochastic gradient descent based optimization techniques. In: 2017 International Artificial Intelligence and Data Processing Symposium (IDAP). 2017. p. 1-5. doi:10.1109/IDAP.2017.8090299.
- [22] R. V, K.P. S. Siamese neural network architecture for homoglyph attacks detection. *ICT Express* [Internet]. 2019 May 31 [cited 2019 Aug 21]; Available from: <https://www.sciencedirect.com/science/article/pii/S2405959519300025> doi:10.1016/J.ICTE.2019.05.002.
- [23] Jansen H, Gallee MP, Schroder FH. Analysis of sonographic pattern in prostatic cancer: Comparison of longitudinal and transversal transrectal ultrasound with subsequent radical prostatectomy specimens. *Eur Urol.* 1990;18(3):174-8. doi:10.1159/000463903.
- [24] Hariharan B, Arbeláez P, Girshick R, Malik J. Object Instance Segmentation and Fine-Grained Localization Using Hypercolumns. *IEEE Trans Pattern Anal Mach Intell.* 2017;39(4):627-39. doi:10.1109/TPAMI.2016.2578328.
- [25] Toğacar M, Ergen B, Sertkaya ME. Zatürre Hastalığının Derin Öğrenme Modeli ile Tespitı Detection of Pneumonia with Deep Learning Model. 2019;31(1):223-30.
- [26] Toğacar M, Ergen B. Deep Learning Approach for Classification of Breast Cancer. In: 2018 International Conference on Artificial Intelligence and Data Processing (IDAP). 2018. p. 1-5. doi:10.1109/IDAP.2018.8620802.
- [27] Cömert Z, Kocamaz AF. Comparison of Machine Learning Techniques for Fetal Heart Rate Classification. *Acta Phys Pol A.* 2017;132(3):451-4. doi:10.12693/APhysPolA.131.451.
- [28] İník Ö, ÜLKER Bilgisayar Mühendisliği Bölümü E, Üniversitesi G, Bilgisayar Mühendisliği Bölümü T, Üniversitesi S, yazar S, et al. Derin Öğrenme ve Görüntü Analizinde Kullanılan Derin Öğrenme Modelleri Deep Learning and Deep Learning Models Used in Image Analysis. *GBAD Gaziosmanpasa J Sci Res.* 2017;ISSN:2146-8168.
- [29] Cibuk M, Budak U, Guo Y, Ince MC, Sengur A. Efficient deep features selections and classification for flower species recognition. *Measurement.* 2019;137:7-13. doi:<https://doi.org/10.1016/j.measurement.2019.01.041>.
- [30] Ioffe S, Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. 2015; Available from: <http://arxiv.org/abs/1502.03167>
- [31] keras/mnist_siamese.py at master · keras-team/keras · GitHub [Internet]. [cited 2019 Aug 22]. Available from: https://github.com/keras-team/keras/blob/master/examples/mnist_siamese.py
- [32] Reeskamp P. Is comparative advertising a trade mark issue? *Eur Intellect Prop Rev.* 2008;30(4):130-7. doi:10.1145/262330.2623612.
- [33] Powers DMW, Ailab. Evaluation: From Precision, Recall and F-Measure To Roc, Informedness, Markedness & Correlation. 2011;2(1):37-63. Available from: http://www.bioinfo.in/_contents.php?id=51 doi:10.9735/2229-3981.
- [34] Arican M, Cömert Z, Fatih Kocamaz A, Polat K. Analysis of Fetal Heart Rate Signal based on Neighborhood-based Variance Compression Method. 2018. doi:10.1109/IDAP.2018.8620898.