



Yanık Görüntülerinin Bulanık Kümeleme Mesinde Uzaklık Ölçülerinin Başarımlarının Değerlendirilmesi **Performance Evaluation of Distance Metrics on Fuzzy Clustering of Burn Images**

Yeşim Akbaş^{1*} , Tolga Berber¹

¹ Karadeniz Teknik Üniversitesi, Fen Fakültesi, İstatistik ve Bilgisayar Bilimleri Bölümü, Trabzon, TÜRKİYE
Sorumlu Yazar / Corresponding Author *: yesimyeginoglu@ktu.edu.tr

Geliş Tarihi / Received: 02.06.2019

Araştırma Makalesi/Research Article

Kabul Tarihi / Accepted: 06.02.2020

DOI: 10.21205/deufmd.2020226529

Atf seklili/How to cite: AKBAŞ, Y., BERBER, T.(2020). Yanık Görüntülerinin Bulanık Kümeleme Mesinde Uzaklık Ölçülerinin Başarımlarının Değerlendirilmesi. DEÜFMD 22(65), 639-647.

Öz

Dünya Sağlık Örgütü yanık nedeni ile gerçekleşen ölümlerin sayısını yaklaşık 265.000 olarak belirlemiştir. Bu sayı, yanık tedavisinin ne denli önemli olduğunu gözler önüne sermektedir. Yanık / normal cilt bölgesi, yanık tedavisinin planlanması saptanması gereken en önemli parametrelerden biridir.

Bu çalışmada, Karadeniz Teknik Üniversitesi Tıp Fakültesi Farabi Hastanesi yanık ünitesinin yanık yarısı veri setinden 40 görüntü seçilmiş ve bu görüntülere yanık / normal cildi belirlemek için bulanık kümeleme yöntemi kullanılmıştır. Görüntü kümeleme yöntemlerinde en sık kullanılan uzaklık ölçüsü Öklid uzaklılığımasına rağmen, bu çalışmada farklı uzaklık ölçülerinin yanık görüntülerinin kümeleme üzerindeki etkilerini incelenmiştir. Farklı kümeye sayıları için Bulanık C ortalama yaklaşımında kullanılabilecek Öklid, Manhattan, Jaccard, Kosinüs, Chebyshev, Minkowski uzaklık ölçülerinin kümeleme başarımları incelenmiştir. Uzaklık ölçülerinin performansları PBMF, Bölme Katsayı, Bağılilik ve Ayrılık geçerlilik indeksleri ile değerlendirilmesi sonucunda en iyi kümelemeye, Kosinüs uzaklık ölçüsü ve 3 kümeye sayısı ile ulaşılmıştır.

Anahtar Kelimeler: Yanık Görüntüleri, Bulanık C Ortalama, Uzaklık Ölçüleri

Abstract

The World Health Organization determined the annual number of deaths caused by burn is approximately 265,000. This number clearly reveals the importance of burn wound diagnosis. Determining the burn/normal skin region is the one of the most important parameters which are needed to be determined in the planning of burn wound treatment.

In this study, fuzzy clustering method have been used to determine the burn / normal skin. We selected 40 images, from the burn wound image dataset of the burn unit of the Karadeniz Technical University Faculty of Medicine Farabi Hospital. Although Euclidean distance is the most commonly used distance metric in image clustering methods, we examined the effects of different distance metrics on the clustering of burn wounds, in this study. We have evaluated the clustering performance of Euclidean, Manhattan, Jaccard, Cosine, Chebyshev, Minkowski distance metrics. We measured the performance of the distance metrics in terms of PBMF, Partition Coefficient, Cohesion and Separation validity indexes. As a result, we found that the Cosine distance metric gives the best result with 3 clusters.

Keywords: Burn Images, Fuzzy C Means, Distance Measures

1. Giriş

Her yıl, çoğunluğu düşük ve orta gelirli ülkelerde olmak üzere ortalama 265.000 ölüm yanık nedeni ile meydana gelmektedir [1]. Bu sayı doğru yanık tedavilerinin, ne denli hayatı önem taşıdığını gözler önüne sermektedir. Yanık yüzey alanının belirlenmesi yanık tedavisinin ilk ve en önemli adımlarından biridir. Günümüzde yanık yüzey alanları genelde uzman deneyimlerine göre yapılmaktadır. Ancak hesaplamalarda yapılacak yanlışlıklar, tedaviyi olumsuz yönde etkileyebilmektedir. Yanık yüzey alanlarının otomatik olarak belirlenmesi, hastaya verilecek sıvı resüsitasyonlarına, hastaneye giriş çıkış endikasyonlarına ve yapılacak cerrahi prosedürlere karar verilmesi gibi bir çok karar aşamasında uzmanlara yardımcı olacaktır.

Yanık yüzey alanının belirlenebilmesinin ilk adımı, yanık / normal deri ayrimının yapılabilmesidir. Bu ayrimın yapılmasıının il adımı bulanık kümeleme yaklaşımlarının uygulanmasıdır. Bulanık kümeleme yaklaşımları görüntülerin kümelenmesinde sıkılık kullanılmaktadır [2]-[8]. Hispatolojik görüntülerden ilgilenilen alanların tespit edilmesi [9], göğüs ve beyin ultrason görüntülerinden kanser hücrelerinin tespit edilmesi [10]-[12] bir çok görüntü işleme alanında bulanık kümeleme yaklaşımları ile yüksek başarımlar elde edilmiştir[13], [14]. Zhang & Chen ile Ahmed ve arkadaşlarının çalışmalarında, beyin manyetik rezonans görüntüleme (MRG) verilerinin bulanık böülümlendirilmesinde Bulanık C-Ortalama (BCO) algoritması kullanılmıştır [13], [14]. Szilagyi ve arkadaşları da yine beyin MR görüntülerinin kümelenmesinde klasik BCO yerine yanlık-düzeltilmiş versiyonunu kullanmışlar ve bu versiyonun klasige göre daha hızlı ve daha iyi olduğunu öne sürmüştür[15]. Mathew ve Vidya, ultrasonografik görüntüler üzerinde tümörlerin yapısını değerlendirdirken olasılıksal BCO kullanarak görüntüleri kümelemelerinin sonucunda, Tümör kitlelerinin benign ve malign olak değerlendirilmesindeki hata oranlarının sırası ile 0,092 ve 0,000034 oranında azaldığını belirtmektedirler [10]. Kannan ve arkadaşları meme ve beyin manyetik rezonans görüntülerinin otomatik böülümlenmesinde klasik BCO'da kullanılan Öklid uzaklık ölçüsü yerine, özellik uzayındaki çekirdek fonksiyonlarının özellikleri kullanarak yeni bir objektif fonksiyon elde etmişlerdir.

Deneysel sonuçlar, önerilen yöntemin tıbbi görüntülerin kümelenme görevinde daha başarılı sonuçlar elde ettiğini göstermektedir [12]. Mandal ve arkadaşları ise histolojik görüntülerden ilgi bölgelerini otomatik olarak saptanmasına için BCO ve K-Ortalamalar yöntemlerini kullanmışlardır. Öklid uzaklık ölçüsü ve LAB renk uzayı kullanılıp gerçekleştirilen deneylerde her iki segmentasyon yönteminin küçük nüanslarla aynı performansı gösterdiği belirtilmektedir [9]. Gueorguieva ve arkadaşları klasik BCO yaklaşımını Mahalanobis ve Minkowski uzaklık ölçütleri kullanarak modifiye ederek, 2 boyutlu ve 3 boyutlu iki ayrı veri seti üzerinde deneylerini uygulamışlardır. Deneyler sonucunda modifiye edilmiş BCO ile yapılan kümelemenin, klasik BCO kümelemesinin sonuçlarını önemli ölçüde iyileştirdiğini ileri sürmektedirler[16]. Raj ve arkadaşları da çeşitli görüntülerin kümelenmesinde, klasik BCO ile Mahalanobis uzaklığını kullanan BCO yaklaşımını karşılaştırmış, deneyler sonucunda Mahalanobis uzaklık ölçütü kullanan BCO'nun, Öklid uzaklık ölçütü kullanan klasik BCO'dan daha başarılı sonuçlar ortaya koyduğunu belirtmektedirler[17].

Bu çalışmada yanık görüntüler, Bulanık C Ortalama (BCO) kümeleme yaklaşımı ile kümelenmiştir. Klasik BCO'da uzaklık ölçüsü olarak Öklid uzaklığa ölçüsü kullanılmamasına rağmen, bu çalışmada Minkowski, Manhattan, Chebishev, Jaccard ve Kosinüs uzaklıklarının da kümelemeye kattıkları başarımlar değerlendirilmiştir. Deney sonuçları kümeleme geçerlilik indeksleri ile değerlendirilip, en başarılı kümeleme sonucunu vere uzaklık ölçüsü ve kume sayısı belirlenmiştir.

2. Materyal ve Metot

Çalışmada, Karadeniz Teknik Üniversitesi Tıp Fakültesi Farabi Hastanesi yanık unitesine başvuran hastaların hiçbir standart gözetmeksız çekilen görüntülerini içeren veri kümесinden 8 Mpixel (3500x2500) 40 adet örnek görüntü seçilmiştir. Görüntüler, hesaplama kolaylığı ve gürültü azaltımı için %25 oranında küçültülmüştür. Görüntülerin hepsi aynı ortamda çekildiği için arka planlar genelde benzer nesneleri içermektedir. Bu yüzden bütün görüntüler birleştirilip tek bir görüntü haline getirilmiştir. Bu sayede, oluşturulan yaklaşımın gereğiinde yeni görüntüler eklenerek

öğrenebilir bir yapıda olmasına olanak sağlanmıştır.

Yanık görüntülerinin kümelenmesinde Bulanık C-Ortalama yaklaşımı ele alınmıştır. Bulanık C-Ortalama yaklaşımında genel olarak Öklid uzaklıği kullanılmaktır iken, bu çalışmada Öklid, Minkowski, Manhattan, Chebyshev, Jaccard ve Kosinüs uzaklıklar kullanılmıştır. Uzaklıkların kümelenmedeki başarımları değerlendirilmiştir. Deneyler farklı küme sayıları için tekrarlanmıştır.

Seçilen örnek görüntüler aracılığıyla en uygun küme sayısının belirlenmesi ve Bulanık C-Ortalama yaklaşımında en uygun uzaklık ölçüsünün seçilmesi hedeflenmektedir.

2.1. Bulanık C ortalama

Bulanık C-Ortalama algoritması 1973'te Dunn tarafından ortaya atılmış ve 1981'de Bezdek tarafından geliştirilmiştir [18] [19]. Bulanık mantığa göre her birim, her kümeye [0,1] aralığında birer üyelik derecesi ile atanır ve tüm kümelere üyelik derecelerinin toplamı 1 olmak durumundadır. Her birimin kümelere üyelik dereceleri, küme merkezlerine olan uzaklıklar ile ters orantılıdır.

D boyutlu bir Öklid uzayında N örnekten oluşan bir $X = \{x_1, x_2, \dots, x_N\}$, ($x_i \in R^D$) veri kümесinin verildiği ve v_i i. küme merkezini göstermek üzere c adet kümeye $\{v_1, v_2, \dots, v_c\}$ bölüneceği varsayıldığında, Bulanık C-Ortalama algoritması Eşitlik 1'de verilen amaç fonksiyonunu minimize etmeye çalışır [20].

$$J_m = \sum_{i=1}^N \sum_{j=1}^c U_{ij}^m \|x_i - v_j\|^2 \quad (1)$$

U_{ij} , i. elemanın j. kümeye üyelik değerini, m ise bulanıklaştırma parametresini ifade etmektedir.

Bu en küçükleme problemi Eşitlik 2'de verilen kısıtları sağlamalıdır:

$$\begin{aligned} \sum_{j=1}^c U_{ij} &= 1 \\ 0 < \sum_{i=1}^N U_{ij} &< N \\ U_{ij} &\in [0,1] \end{aligned} \quad (2)$$

Başlangıç üyelik değerleri $U^0 = [U_{ij}]$, [0,1) aralığında düzgün dağılımdan rastgele belirlenir. Bu üyelik değereleri kullanılarak Eşitlik 3 yardımı ile küme merkezleri hesaplanır[20].

$$v_j = \frac{\sum_{i=1}^N U_{ij}^m x_i}{\sum_{i=1}^N U_{ij}^m}, \quad j = 1, 2, \dots, c \quad (3)$$

Hesaplanan küme merkezlerine göre, U üyelik matrisi Eşitlik 4 kullanılarak güncellenir.

$$U_{ij} = \frac{1}{\sum_{k=1}^c \left(\|x_i - v_k\| \right)^{\frac{2}{m-1}}} \quad (4)$$

İki ardışık üyelik matrisinin farklarının normu ϵ 'dan küçük olduğunda işlem durdurulur (Eşitlik 5) [21].

$$||U^t - U^{t-1}|| < \epsilon \quad (5)$$

2.2. Uzaklık ölçüleri

Bu çalışmada yanık görüntülerinin kümelenmesinde uzaklık ölçülerinin etkisinin araştırılması amacıyla Minkowski, Öklid, Manhattan, Chebishev, Jaccard ve Kosinüs uzaklıklarında Bulanık C Ortalama kümelenme yönteme yöntemi denenmiştir. Farklı geçerlilik indeksleri kullanılarak en iyi küme sayısı belirlenmiştir.

p değişken sayısı olmak üzere, çalışmada gözlem değerleri arasındaki uzaklıkların belirlenmesinde kullanılan uzaklık ölçülerini Eşitlik 6-7-8-9-10-11'de verilmektedir.

- Minkowski uzaklığı

$$d(x, y) = \left[\sum_{k=1}^p (|x_{ik} - x_{jk}|^m) \right]^{\frac{1}{m}} \quad (6)$$

$i, j = 1, 2, \dots, n; \quad k = 1, 2, \dots, p$

- Öklid Uzaklığı

Minkowski uzaklığında m değeri 2'ye eşit alındığında Öklid Uzaklığı elde edilir (Eşitlik 7).

$$d(x, y) = \left[\sum_{k=1}^p (|x_{ik} - x_{jk}|^2) \right]^{\frac{1}{2}} \quad (7)$$

$i, j = 1, 2, \dots, n; \quad k = 1, 2, \dots, p$

- Manhattan Uzaklığı

Minkowski uzaklığında m değeri 1'e eşit alındığında CityBlok uzaklığı elde edilir (Eşitlik 8). Manhattan uzaklık ölçüsü aynı zamanda Cityblok uzaklığı, Taxicab uzaklığı, doğrusal uzaklık ve sağ açılı uzaklık olarak da adlandırılmaktadır[38].

$$d(x, y) = \sum_{k=1}^p (|x_{ik} - x_{jk}|) \quad (8)$$

$i, j = 1, 2, \dots, n; k = 1, 2, \dots, p$

- Chebishev Uzaklığı

$$d(x, y) = \max\{|x_1 - y_1|, |x_2 - y_2|\} \quad (9)$$

- Jaccard Uzaklığı

$$d(x, y) = 1 - \frac{\sum_i \min(x_i, y_i)}{\sum_i \max(x_i, y_i)} \quad (10)$$

- Kosinüs Uzaklığı

$$\begin{aligned} d(x, y) &= 1 - \frac{x \cdot y}{\|x\|_2 \|y\|_2} \\ &= 1 - \frac{\sum_{i=1}^n x_i y_i}{\sqrt{\sum_{i=1}^n x_i^2} \sqrt{\sum_{i=1}^n y_i^2}} \end{aligned} \quad (11)$$

2.3. Geçerlilik indeksleri

Kümeleme algoritmalarının çalıştırılmasının ardından, veriyi optimum kümeleyen, küme sayısının belirlenebilmesi için farklı ölçüler kullanılmıştır.

2.3.1. PBMF geçerlilik indeksi

Pakhira ve arkadaşları, kendi isimlerinin baş harflerinden oluşan ve PBM indeksi [22] olarak adlandırılan bir geçerlik indeksi önermişlerdir. Hem kesin hem de bulanık kümeleme için geliştirilen indeksin bu çalışmada yalnızca PBMF dizini olarak adlandırılan bulanık hali ele alınmıştır. İndeks,

$$V_{PBMF} = \left(\frac{1}{C} * \frac{E_1}{J_m} * D_c \right)^2 \quad (12)$$

PBMF indeksi $\frac{1}{C} \frac{E_1}{J_m}$ ve D_c faktörlerinden oluşmaktadır. İlk faktör küme sisteminin bölünebilirliğini ifade etmektedir ve küme sayısı (C) ile ters orantılıdır. İkinci faktör ağırlıklandırılmış kümeler arası uzaklıkların toplamını içermektedir.

$$E_1 = \sum_{j=1}^n u_{ij} \|x_j - v\| \quad (13)$$

$$J_m(U, V) = \sum_{j=1}^n \sum_{i=1}^c (u_{ij})^m \|x_j - v_i\| \quad (14)$$

Bu faktör bir c küme sisteminin kompaktlığını ölçmektedir. Üçüncü faktör D_c bir c küme sistemindeki en büyük sınıf içi bölütlenmedir.

$$D_c = \max_{i,j=1 \dots n} \|v_i - v_j\| \quad (15)$$

En yüksek V_{PBMF} değeri en iyi kümeleme değerini vermektedir [23].

2.3.2. Bölme katsayısı geçerlilik indeksi

Bezdek tarafından bulanık kümeleme için önerilen bölüm katsayısi (PC) Eşitlik 16'daki gibidir.

$$v_{PC} = \frac{\sum_{j=1}^n \sum_{i=1}^c U_{ij}^2}{n} \quad (16)$$

En yüksek v_{PC} değeri en iyi kümeleme değerini vermektedir[23].

2.3.3. Uyum ve ayrılma geçerlilik indeksleri

Ayrılma (S), bir kümenin diğer kümelerden ne kadar kesin ve doğru ayrıldığını, uyum (C) ise aynı kümedeki nesnelerin birbiri ile ne kadar ilişkini olduğunu ölçer[23].

v_i , i . küme merkezini, v küme merkezlerinin ortalamasını, C küme sayısını ve $|C_i|$ i . kümenin boyutu olmak üzere eşitlik 17 ve 18 sırası ile ayrılık ve bağlılık değerlerini ifade etmektedir.

$$S = \sum_i |C_i| (v - v_i)^2 \quad (17)$$

$$C = \sum_i \sum_{x \in C_i} (x - v_i)^2 \quad (18)$$

En iyi kümeleme için ayırt edicilik değerinin büyük, bağlılık değerinin ise küçük olması beklenmektedir.

3. Bulgular

Farklı küme sayıları için Bulanık C ortalama yaklaşımında kullanılan Öklid, Manhattan, Jaccard, Cosine, Chebyshev, Minkowski uzaklık ölçülerinin kümeleme başarımları incelenmiştir. Uzaklık ölçülerinin performansları PBMF, PC, C, S geçerlilik indeksi ile değerlendirilmiştir. Bu dört geçerlilik indeksini kullanıp ortak bir karar

verilmek istenmektedir. Ancak, indekslerin değer değişim aralıklarının farklı olması ve başarılı bir kümemeleme deneyi için PBMF, PC, S indekslerinin büyük değer alması beklenirken, C'nin küçük değer almasının beklenmesi, ortak bir karar vermeyi zorlaştırmaktadır.

Bu sebeple, bu dört geçerlilik indeksinin tek bir değerde toplanması amacıyla yeni bir birleşik geçerlilik indeksi kullanılması yoluna gidilmiştir. Birleşik indeksi hesaplayabilmek için ilk olarak tüm geçerlilik indeksi puanları [0, 1] kapalı aralığına Eşitlik 19'da görülen Min-Max normalizasyonu kullanılarak dönüştürülmüştür.

$$GI_{i,norm} = \frac{GI_i - \min(GI_i)}{\max(GI_i) - \min(GI_i)} \quad (19)$$

Her bir uzaklık ölçüsünün her bir küme sayısı için normalize edilmiş her bir kümemeleme indeks değerleri Tablo 1'de verilmektedir. Normalize edilen geçerlilik indekslerinden C değeri diğer indekslerden farklı yorumlandığı için bu değerin 1'den çıkarılmış hali $C'_{norm} = 1 - C_{norm}$, birleşik indekste kullanılmıştır.

Tablo 1. Her bir uzaklık ölçüsünün her bir küme sayısı için her bir kümemeleme indeks değerleri

Küme Sayısı	CHEBISHEV				CITYBLOCK				KOSİNÜS			
	PBMF	PC	C	S	PBMF	PC	C	S	PBMF	PC	C	S
2	1,000	1,000	1,000	0,000	1,000	1,000	0,000	0,000	1,000	0,927	0,000	0,000
3	0,713	0,800	0,668	0,317	0,692	0,791	0,253	0,348	0,992	1,000	0,548	0,453
4	0,524	0,662	0,511	0,705	0,644	0,634	0,369	0,350	0,115	0,855	0,593	0,708
5	0,481	0,539	0,422	0,815	0,446	0,510	0,463	0,417	0,208	0,497	0,594	0,750
6	0,316	0,442	0,343	0,883	0,383	0,419	0,489	0,526	0,305	0,459	0,683	0,754
7	0,359	0,394	0,222	0,838	0,244	0,412	0,779	0,697	0,334	0,389	0,766	0,778
8	0,161	0,318	0,205	0,919	0,163	0,333	0,784	0,754	0,031	0,440	0,846	0,753
9	0,138	0,273	0,156	0,938	0,229	0,269	0,784	0,768	0,046	0,318	0,858	0,814
10	0,105	0,231	0,135	0,920	0,195	0,232	0,856	0,741	0,179	0,196	0,883	0,848
11	0,157	0,186	0,118	0,935	0,095	0,190	0,858	0,695	0,018	0,262	0,861	0,813
12	0,147	0,153	0,094	0,946	0,144	0,160	0,874	0,786	0,084	0,259	0,875	0,878
13	0,066	0,143	0,060	0,938	0,117	0,136	0,887	0,724	0,009	0,206	0,913	0,832
14	0,112	0,118	0,052	0,949	0,077	0,132	0,945	0,979	0,122	0,198	0,939	0,955
15	0,111	0,088	0,048	0,968	0,031	0,109	0,950	0,958	0,098	0,166	0,952	0,963
16	0,102	0,072	0,022	0,988	0,021	0,088	0,961	0,939	0,000	0,165	0,965	0,979
17	0,076	0,044	0,020	0,996	0,009	0,063	0,963	0,900	0,005	0,152	0,991	0,962
18	0,081	0,028	0,020	0,993	0,023	0,042	0,972	0,920	0,006	0,021	0,986	0,967
19	0,038	0,014	0,006	1,000	0,023	0,035	1,000	1,000	0,029	0,003	1,000	1,000
20	0,000	0,000	0,000	0,999	0,000	0,000	0,983	0,898	0,023	0,000	0,949	0,918
Küme Sayısı	ÖKLİD				JACCARD				MINKOWSKI			
	PBMF	PC	C	S	PBMF	PC	C	S	PBMF	PC	C	S
2	1,000	1,000	0,000	0,000	1,000	1,000	0,000	0,000	1,000	1,000	0,000	0,000
3	0,718	0,779	0,292	0,242	0,646	0,760	0,241	0,175	0,795	0,776	0,296	0,195
4	0,489	0,631	0,475	0,426	0,247	0,601	0,360	0,187	0,508	0,640	0,485	0,497
5	0,307	0,542	0,597	0,619	0,566	0,530	0,656	0,387	0,457	0,537	0,588	0,655
6	0,298	0,471	0,743	0,688	0,129	0,453	0,729	0,434	0,307	0,455	0,711	0,733
7	0,206	0,405	0,784	0,833	0,364	0,382	0,766	0,472	0,382	0,396	0,772	0,851
8	0,156	0,324	0,801	0,832	0,369	0,328	0,820	0,640	0,328	0,315	0,789	0,868
9	0,129	0,266	0,828	0,827	0,112	0,282	0,847	0,675	0,250	0,267	0,836	0,885
10	0,105	0,229	0,862	0,799	0,171	0,234	0,854	0,717	0,181	0,222	0,855	0,839
11	0,141	0,197	0,898	0,830	0,079	0,191	0,869	0,776	0,152	0,187	0,886	0,874
12	0,160	0,160	0,902	0,840	0,075	0,172	0,931	0,871	0,086	0,149	0,890	0,876
13	0,113	0,128	0,912	0,813	0,028	0,141	0,946	0,869	0,130	0,116	0,901	0,847
14	0,128	0,124	0,946	0,971	0,017	0,110	0,948	0,881	0,060	0,088	0,914	0,873
15	0,109	0,106	0,963	0,954	0,151	0,087	0,962	0,894	0,036	0,093	0,948	0,952
16	0,072	0,077	0,963	0,960	0,098	0,067	0,975	0,924	0,081	0,065	0,955	0,934
17	0,083	0,053	0,972	0,942	0,000	0,045	0,978	0,916	0,016	0,040	0,963	0,958
18	0,000	0,046	0,995	1,000	0,024	0,028	0,986	0,932	0,010	0,024	0,973	0,988
19	0,054	0,014	0,990	0,953	0,010	0,014	0,990	0,996	0,030	0,005	0,975	0,995
20	0,036	0,000	1,000	0,960	0,034	0,000	1,000	1,000	0,000	0,000	1,000	1,000

Son olarak, normalize edilmiş geçerlilik indekslerinin harmonik ortalaması alınarak, birleşik geçerlilik indeksi Eşitlik 20'de görüldüğü gibi elde edilmiştir.

$$BI = \left(\frac{\sum_{i=1}^4 GI_{i,norm}^{-1}}{4} \right)^{-1} \quad (20)$$

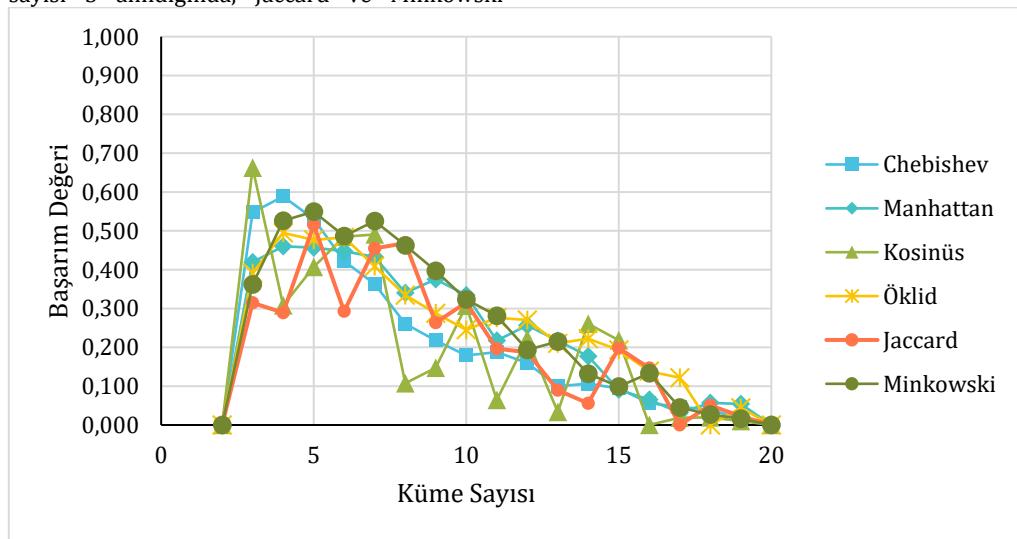
Her bir uzaklık ölçüsü için, geçerlilik indekslerinden elde edilen birleşik geçerlilik indeks (BI) değerlerine Tablo 2'de yer verilmektedir.

Tablo 2. Her bir uzaklık ölçüsünün her bir küme sayısı için ortalama kümeleme indeks değerleri

Küme Sayısı	CHEBISHEV	CITYBLOCK	KOSİNÜS	ÖKLİD	JACCARD	MINKOWSKI
2	0,000	0,000	0,000	0,000	0,000	0,000
3	0,548	0,419	0,662	0,391	0,315	0,362
4	0,588	0,460	0,308	0,495	0,289	0,526
5	0,531	0,457	0,407	0,477	0,515	0,549
6	0,422	0,447	0,485	0,483	0,293	0,486
7	0,363	0,433	0,491	0,409	0,455	0,525
8	0,261	0,340	0,108	0,334	0,468	0,462
9	0,218	0,375	0,147	0,288	0,264	0,397
10	0,179	0,334	0,307	0,245	0,315	0,323
11	0,188	0,217	0,065	0,276	0,196	0,281
12	0,160	0,256	0,221	0,270	0,188	0,194
13	0,100	0,217	0,034	0,210	0,090	0,215
14	0,106	0,177	0,261	0,222	0,056	0,132
15	0,094	0,091	0,218	0,193	0,198	0,099
16	0,056	0,065	0,000	0,138	0,146	0,134
17	0,046	0,031	0,019	0,122	0,000	0,045
18	0,040	0,057	0,020	0,000	0,050	0,027
19	0,015	0,054	0,010	0,044	0,022	0,016
20	0,000	0,000	0,000	0,000	0,000	0,000

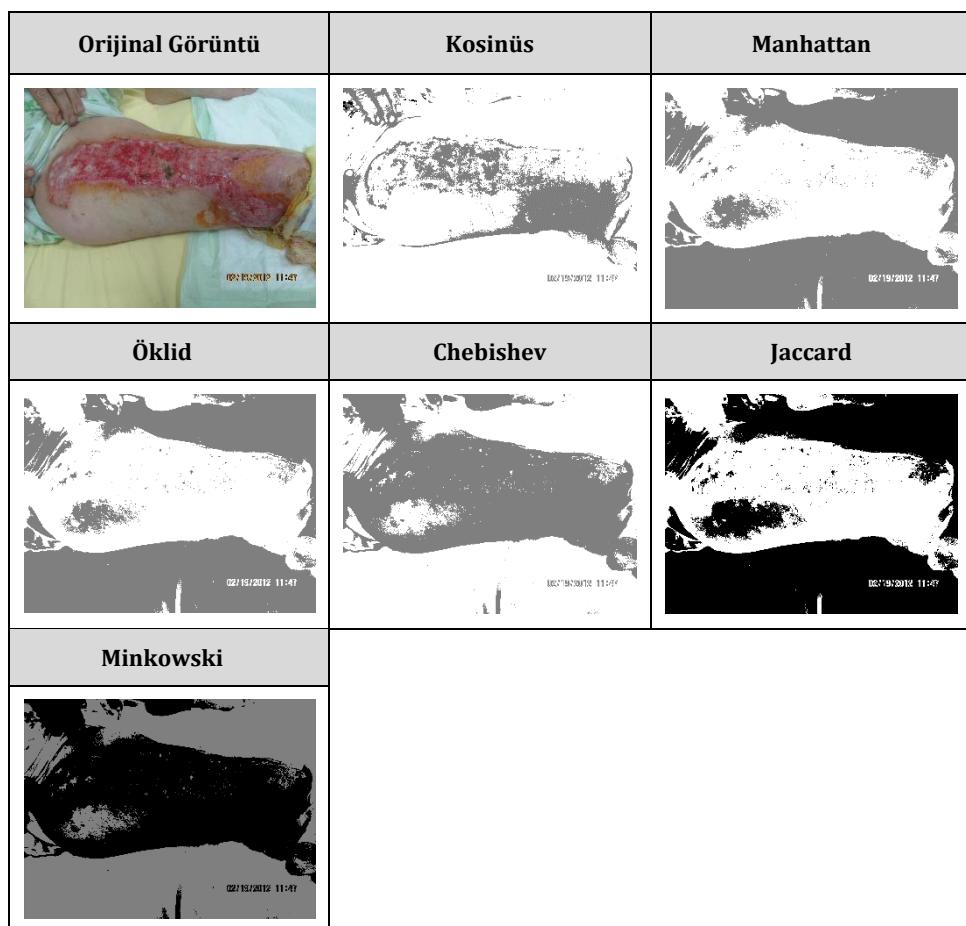
Tablo 2 incelendiğinde, en iyi kümelemeye Chebishev, Manhattan ve Öklid uzaklık ölçülerini kullanıldığında küme sayısı 4 alındığında, Kosinüs uzaklık ölçüsü kullanıldığında küme sayısı 3 alındığında, Jaccard ve Minkowski

uzaklık ölçüsleri kullanıldığımda ise küme sayısı 5 alındığında ulaşıldığı görülmektedir. Bu değerlerin grafiksel gösterimi Şekil 1'de görülmektedir.



Şekil 1. Uzaklık ölçülerinin kümelemedeki başarımlarının BI'ne göre karşılaştırılması

Tablo 2 ve Şekil 1 ortak incelendiğinde en yüksek kümeleme başarı (BI) değerine Kosinüs uzaklığı kullanıldığında ve 3 kümeye ayrıldığında ulaşıldığı görülmektedir. Örnek bir yanık görüntüsünün her bir uzaklık ölçüsü kullanılarak kümelenmiş halleri Şekil 2'de verilmektedir.



Şekil 2. Uzaklık Ölçülerine Göre Kümelenen Örnek Bir Yanık Görüntüsü

4. Tartışma ve Sonuç

Çalışmada piksel tabanlı bir öğrenme algoritması geliştirilmeye çalışılmıştır.

Öklid, Manhattan, Jaccard, Kosinüs, Chebyshev, Minkowski uzaklık ölçülerinin kümeleme başarıları incelenmiştir. Deneyler sonucunda, Kosinüs uzaklık ölçüsü kullanılarak gerçekleştirilen FCM kümelemesinin diğer uzaklık ölçülerini ile gerçekleştirilen kümelemelere göre daha başarılı olduğu görülmüştür. Farklı görüntü sayıları ile yapılan ön deneyler sonucunda, FCM'nin başarısının 12

küme'den sonra düşüş trendine girdiği, 20 kümeden sonra ise durağan bir başarı gösterdiği gözlemlenmiştir. Bu yüzden çalışmada küme değer aralığı 2 ile 20 arasında seçilmiştir. Dolayısıyla, küme sayısının artmasının başarısının azalmasına neden olduğu söylenebilir.

Bu çalışma kapsamında RGB renk uzayında ve benzer ortamda elde edilmiş yanık görüntülerinin kümelenmesinde uzaklık ölçülerinin başarıları değerlendirilmiştir. Farklı renk uzaylarının bu anlamdaki başarılarının test edilmesi sonucunda farklı

uzaklık ölçülerinin başarım değerlerinin yükselmesi söz konusu olabilir. Bu konu ilerleyen çalışmalarda ele alınacaktır.

Teşekkür

Bu çalışma, Karadeniz Teknik Üniversitesi Bilimsel Araştırma Projeleri Koordinasyon Birimi tarafından desteklenmiştir. Proje numarası FAY-2016-5588

Kaynakça

- [1] "WHO | Burns," *World Health Organization*, 2017. [Online]. Available: http://www.who.int/violence_injury_prevention/other_injury/burns/en/. [Accessed: 12-Nov-2018].
- [2] G. E. Meyer, J. C. Neto, D. D. Jones, and T. W. Hindman, "Intensified fuzzy clusters for classifying plant, soil, and residue regions of interest from color images," *Comput. Electron. Agric.*, vol. 42, no. 3, pp. 161–180, 2004.
- [3] J. C. Neto, G. E. Meyer, and D. D. Jones, "Individual leaf extractions from young canopy images using Gustafson-Kessel clustering and a genetic algorithm," *Comput. Electron. Agric.*, vol. 51, no. 1–2, pp. 66–85, 2006.
- [4] S. Chen and D. Zhang, "Robust image segmentation using FCM with spatial constraints based on new kernel-induced distance measure," *IEEE Trans. Syst. Man, Cybern. Part B Cybern.*, vol. 34, no. 4, pp. 1907–1916, 2004.
- [5] K. S. Chuang, H. L. Tzeng, S. Chen, J. Wu, and T. J. Chen, "Fuzzy c-means clustering with spatial information for image segmentation," *Comput. Med. Imaging Graph.*, vol. 30, no. 1, pp. 9–15, 2006.
- [6] H. Huang, F. Meng, S. Zhou, F. Jiang, and G. Manogaran, "Brain Image Segmentation Based on FCM Clustering Algorithm and Rough Set," *IEEE Access*, vol. 7, pp. 12386–12396, 2019.
- [7] A. H. M. J. I. Barbhuiya and K. Hemachandran, "Hybrid Image Segmentation Model using KM, FCM, Wavelet KM and Wavelet FCM Techniques," *Int. J. Comput. Sci. Eng.*, vol. 6, no. 9, pp. 315–323, 2018.
- [8] U. Şevik, E. Karakullukçu, T. Berber, Y. Akbaş, and S. Türkyılmaz, "Automatic classification of skin burn colour images using texture-based feature extraction," *IET Image Process.*, vol. 13, no. 11, pp. 2018–2028, Sep. 2019.
- [9] R. Mandal, M. Gupta, and C. Kar, "Automated ROI detection for histological image using fuzzy c-means and K-means algorithm," *Int. Conf. Electr. Electron. Optim. Tech. ICEEOT* 2016, pp. 1173–1178, 2016.
- [10] V. V. K and S. Mathew, "An Accurate Method of Breast Cancer Detection from Ultra Sound images Using Probabilistic Fuzzy Clustering Algorithm," *IEEE Int. Conf. Commun. Syst. Networks*, no. July, pp. 231–235, 2016.
- [11] A. S. Shankar, A. Asokan, and D. Sivakumar, "Brain Tumor Classification Using Gustafson-Kessel (G-K) Fuzzy Clustering Algorithm," *Int. J. Latest Eng. Res. Appl.*, vol. 01, no. 05, pp. 68–72, 2016.
- [12] S. R. Kannan, S. Ramathilagam, R. Devi, and E. Hines, "Strong fuzzy c-means in medical image data analysis," *J. Syst. Softw.*, vol. 85, no. 11, pp. 2425–2438, 2012.
- [13] M. N. Ahmed, S. M. Yamany, N. Mohamed, A. A. Farag, and T. Moriarty, "A modified fuzzy C-means algorithm for bias field estimation and segmentation of MRI data," *IEEE Trans. Med. Imaging*, vol. 21, no. 3, pp. 193–199, 2002.
- [14] D. Q. Zhang and S. C. Chen, "A novel kernelized fuzzy C-means algorithm with application in medical image segmentation," *Artif. Intell. Med.*, vol. 32, no. 1, pp. 37–50, 2004.
- [15] L. Szilagyi, Z. Benyo, S. M. Szilagyi, and H. S. Adam, "MR Brain Image Segmentation using an Enhanced Fuzzy C-Means Algorithm," *Proc. 25th Annu. Int. Conf. IEEE EMBS*, vol. 1, pp. 724–726, 2003.
- [16] N. Gueorguieva, I. Valova, and G. Georgiev, "M&MFCM: Fuzzy C-means Clustering with Mahalanobis and Minkowski Distance Metrics," *Procedia Comput. Sci.*, vol. 114, pp. 224–233, 2017.
- [17] V. R. Jincy, M. S. Jini, G. Das Jisha, and R. S. Sajitha, "Image Segmentation Using Fuzzy C Means Clustering With Mahalanobis Distance Norm," *i-manager's J. Digit. Signal Process.*, vol. 5, no. 4, p. 1, 2017.
- [18] J. C. Dunn, "A Fuzzy Relative of the ISODATA Process and Its Use in Detecting Compact Well-Separated Clusters," *J. Cybern.*, vol. 3, no. 3, pp. 32–57, 1974.
- [19] J. C. Bezdek, "A Convergence Theorem for the Fuzzy ISODATA Clustering Algorithms," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. PAMI-2, no. 1, pp. 1–8, 1980.
- [20] F. Hopner, F. Klawonn, R. Kruse, and T. Runkler, "Fuzzy Cluster Analysis: Methods for Classification, Data Analysis and Image Recognition," *J. Oper. Res. Soc.*, vol. 51, no. 6, p. 769, Jun. 2000.
- [21] V. S. Moertini, "Introduction To Five Data Clustering Algorithms," *Integral*, vol. 7, no. 2,

pp. 87–96, 2002.

- [22] M. K. Pakhira, S. Bandyopadhyay, and U. Maulik, "Validity index for crisp and fuzzy clusters," *Pattern Recognit.*, vol. 37, no. 3, pp. 487–501, 2004.
- [23] W. Wang and Y. Zhang, "On fuzzy cluster validity indices," *Fuzzy Sets Syst.*, vol. 158, no. 19, pp. 2095–2117, 2007.