



Yapay Sinir Ağları ve Destek Vektör Regresyonu ile Talep Tahmini: Gıda İşletmesinde Bir Uygulama

Demand Forecasting with Artificial Neural Networks and Support Vector Regression: An Application in a Food Company

Feyza Çoban¹ , Leyla Demir^{2*} 

¹ Süleyman Demirel Üniversitesi Rektörlüğü, Kalite Güvence Ofisi, Isparta, TÜRKİYE

² İzmir Bakırçay Üniversitesi, Mühendislik ve Mimarlık Fakültesi, Endüstri Mühendisliği Bölümü, İzmir, TÜRKİYE

Sorumlu Yazar / Corresponding Author *: leyla.demir@bakircay.edu.tr

Geliş Tarihi / Received: 17.06.2020

Araştırma Makalesi/Research Article

Kabul Tarihi / Accepted: 23.10.2020

DOI:10.21205/deufmd.2021236729

Atıf Şekli/ How to cite: Çoban, F., Demir, L. (2021). *Yapay Sinir Ağları ve Destek Vektör Regresyonu ile Talep Tahmini: Gıda İşletmesinde Bir Uygulama.* DEUFMD, 23(67), 327-338.

Öz

Son yıllarda, değişen ve küreselleşen koşullar insan ihtiyaçlarını değiştirerek hızlı değişiklıklere ve talep belirsizliğine neden olmuştur. Bu hızlı değişim ve belirsiz koşullar altında işletmelerin etkin planlama yapmalarının yolu, doğru ve güvenilir tahminler yapmaktan geçmektedir. Günüümüzde teknolojik gelişmelerle birlikte talep tahmininde zaman serileri analizi gibi klasik yöntemlerin yerini yapay zekâ tabanlı tahmin algoritmaları almıştır. Bu yöntemler özellikle belirsizliğin ve değişkenliğin çok fazla olduğu durumlarda klasik tahmin yöntemlerinden çok daha başarılı sonuçlar vermektedir. Bu çalışmada bir gıda işletmesinde değişkenliğin ve belirsizliğin fazla olduğu ürünler için Yapay Sinir Ağları (YSA) ve Destek Vektör Regresyonu (DVR) yöntemleri ile talep tahmini yapılmıştır. Yöntemler uygulanmadan önce parametre optimizasyonu amacıyla deney tasarımları yapılmış ve en iyi parametre değerleri bulunarak tahmin doğruluğu artırılmıştır. Sayısal sonuçlar, incelenen ürünler için YSA'nın DVR'ye kıyasla daha iyi tahminler yaptığı göstermiştir.

Anahtar Kelimeler: Talep Tahmini, Belirsizlik, Yapay Sinir Ağları, Destek Vektör Regresyonu

Abstract

In recent years, the changing and globalizing conditions caused the rapid changes and demand uncertainty by changing human needs. Under these rapid changes and uncertain conditions, the way for companies to make effective planning is to make accurate and reliable forecasting. As the technological developments increases artificial intelligence-based forecasting algorithms are widely used for demand forecasting instead of the classical methods such as time series analysis. These methods yield much more successful results than classical forecasting methods, especially in cases where the uncertainty and variability are high. In this study, Artificial Neural Networks (ANN) and Support Vector Regression (SVR) are employed to forecast the demands of the products with high variability and uncertainty in a food company. Before the methods were applied, an experimental design was conducted to find the best parameter values, and in this way, the accuracy of forecasts was increased. Numerical results showed that ANN makes better forecasts than SVR for the examined products.

Keywords: Demand Forecasting, Uncertainty, Artificial Neural Networks, Support Vector Regression

1. Giriş

Gelişen, değişen ve küreselleşen dünya koşulları ile birlikte artan teknoloji insan ihtiyaçlarında büyük değişimlere sebep olmuştur. Teknolojideki hızlı gelişmeler hemen her sektörde hızlı ve değişken talep olgusunu doğurmuştur. Değişen talep olgusu sadece mikarda değil ürün çeşitliliğinde de bir artış meydana getirmiştir. Teknolojide ve piyasa koşullarında meydana gelen bu değişimler firmaları rekabet etmeleri için daha etkin stratejiler üretmeye zorlamaktadır. Pazarda meydana gelen hızlı değişimlere ayak uydurabilmenin ve firmaların rekabet üstünlüklerini koruyabilmelerinin ilk şartı piyasa koşullarını göztererek stratejik planlar yapabilmekten geçmektedir. İyi bir planlama yapmanın birincil koşulu ise geleceğe dair güçlü öngörülerde bulunabilmektir. Yani planların iyi yapılmış tahminlere dayandırılmasıdır. Talep tahmini yaparken genellikle işletmelerin geçmiş satış verileri mevsimsellik ve trend gibi özelliklere bakılarak analiz edilip, daha sonra istatistiksel yöntemlerle gelecekte olusablecek satış miktarları belirlenmektedir. Bu süreç yürütürken uzman görüşleri de dikkate alınmaktadır. Ancak değişkenliğin ve belirsizliğin fazla olduğu durumlarda geleneksel tahmin yöntemleri yetersiz kalabilmektedir. Bu gibi durumlarda yapay zekâ teknikleri gibi öğrenmeye dayalı algoritmalar geleneksel yöntemlere göre çok daha iyi sonuçlar vermektedir. Özellikle değişkenliğin fazla olduğu ve satışların herhangi bir trendi takip etmediği durumlarda yapay zekâ teknikleri ile oldukça başarılı tahminler yapmak mümkün olmaktadır.

Talep tahmini konusunda çok geniş bir literatür bulunmaktadır. McCarthy ve dig. [1], satış tahmini üzerine 20 yıllık bir süreci kapsayan ayrıntılı bir literatür araştırması yapmışlardır. Villegasa ve dig. [2], satış tahmininde model seçimi için Destek Vektör Makinesi (DVM) tabanlı bir model seçim yaklaşımı önermişlerdir. Model tahmini için herhangi bir kriteri göz önünde bulundurmak yerine her tahmin kaynağından en iyi modeli seçmek için bir DVM eğitilmiştir. Petropoulos ve dig. [3], zaman serileri analizinde üç temel belirsizlik kaynağı (veri belirsizliği, model belirsizliği, parametre belirsizliği) üzerinde durmuş ve her bir belirsizlik kaynağı için zaman serileri tahmininde torbalamanın yararlarını araştırmışlardır. Guo ve dig. [4], çalışmalarında

belirsizlik teorisine geliştirilmiş bir belirsiz doğrusal regresyon modeli önermişler ve bu modelle Çin'in gayrisafi milli hasila değerini tahmin etmişlerdir. Murphy ve dig. [5], bir çig süt üretim çiftliğinde süt üretim veriminin tahminini yapmışlardır. 3 yıllık bir veri setine Dış Girişli Doğrusal Olmayan Oto-Regresif model, Statik Yapay Sinir Ağları (YSA) ve Çoklu Doğrusal Regresyon yöntemlerini uygulamışlardır. Çalışmanın sonucunda Dış Girişli Doğrusal Olmayan Oto-Regresif modelin en iyi tahmini ürettiği gözlenmiştir. Jaipuria ve Mahapatra [6], belirsiz ortamda doğru talep tahmini yapmak ve aynı zamanda talepteği değişkenliğin sebep olduğu kamçı etkisini azaltmak amacıyla üç farklı sektörden (otomotiv, cimento ve çelik) alınmış veriler ile talep tahmini yapmışlardır. Tahmin için Ayrik Dalgacık Dönüşümleri ve YSA tabanlı bütünselik bir yaklaşım önermişler ve önerdikleri modeli ARIMA yöntemi ile karşılaştırmışlardır. Önerilen modelin daha düşük tahmin hatası ile daha doğru sonuçlar verdiği gözlenmiştir ve önerilen modelin veri tipi ve niteliği fark etmeksızın tüm sektörlerdeki firmalar tarafından kullanılabileceği belirtilmiştir. Babu ve Reddy [7], ARIMA ve YSA modellerini birleştirerek her iki modelin avantajlarından faydalanan melez bir tahmin yöntemi önermişlerdir. Önerilen melez modelin en doğru tahmin sonuçlarını verdiği gözlemlenmiştir. Du ve dig. [8], DVM metodunu kullanarak bozulabilir çiftlik ürünlerinin tahmini için bir uygulama yapmışlardır. DVM modeli ile Radyal Temel Fonksiyon metodu karşılaştırılmış, DVM metodunun bozulabilir çiftlik ürünlerini üzerinde olumlu sonuçlar verdiği gözlenmiştir. Kandananond [9], tüketici ürünleri talebini tahmin etmek için DVM ile YSA yöntemlerini karşılaştırmıştır. En iyi sonucu veren metodun DVM olduğu görülmüştür. Sun ve dig. [10], satış miktarıyla talebi etkileyen faktörler arasındaki ilişkiyi araştırmak için ekstrem öğrenme makinesi yöntemini uygulamışlardır. Çalışmada talep dalgalanmasının daha büyük olduğu ürünlerde ekstrem öğrenme makinesi yönteminin tahmin hatasının geri yayılma sınır ağlarına dayanan diğer yöntemlere kıyasla daha düşük olduğu görülmüştür. Kılıç ve dig. [11], bir üniversitenin yemek şirketlerinden talep ettiği günlük yemek miktarını tahmin etmek için yaptıkları çalışmada YSA, DVM ve regresyon analizi yöntemlerini kullanmışlar ve bu yöntemlerin sonuçlarını karşılaştırmışlardır. Çalışmanın sonunda her bir

yerleşkedeki kullanıcı profilinin farklı olması nedeni ile en iyi sonucu veren baskın bir modelin olmadığı görülmüştür. Sönmez ve Zengin [12], bir yiyecek içecek işletmesinde YSA ve Çoklu Regresyon modellerini kullanarak talep tahmin çalışması yapmışlar ve YSA yönteminin daha başarılı olduğunu gözlemlemişlerdir.

Literatürden de görüleceği gibi makine öğrenmesine dayalı tahmin teknikleri zaman serileri analizi gibi klasik tahmin yöntemlerine göre daha başarılı sonuçlar vermektedir. Bu tekniklerin üstünlükleri ve başarısı göz önünde bulundurularak bu çalışmada gıda sektöründe faaliyet gösteren bir işletme için YSA ve Destek Vektör Regresyonu (DVR) yöntemleri ile bir talep tahmini çalışması yürütülmüştür. Çalışmaya konu olan işletmenin bulunduğu sektörün içeriği belirsizlikler nedeni ile geleneksel yöntemler yerine makine öğrenmesine dayalı yöntemler tercih edilmiştir. Çalışmanın ikinci bölümünde uygulanan yöntemler kısaca tanıtılmıştır. Üçüncü bölümde uygulamanın ayrıntılarına yer verilmiş ve elde edilen bulgular ayrıntılı olarak tartışılmıştır. Son bölümde ise çalışma özetlenmiş ve gelecekte yapılabilecek çalışmalara degeňilmiştir.

2. Materyal ve Metot

Bir ürünün gelecek dönemde nasıl bir satış durumuna sahip olabileceğiinin geçmiş dönemlerdeki satış hareketlerine ait veriler incelenerek analiz edildiği süreç, talep tahmini olarak adlandırılmaktadır. Talep tahmini, öngörüye dayalı işletme kararlarının oluşması açısından hayatı önem taşımaktadır. Talep tahmininde kantitatif (nicel), kalitatif (nitel) ve yapay zekâ/makine öğrenmesi tabanlı üç farklı yöntem kullanılmaktadır. Kantitatif yöntemler istatistiksel ve matematiksel verilere, kalitatif yöntemler ise kişisel çıkarım ve deneyimlere bağlı tahmin yürütme yöntemleridir. Klasik yöntemlerin (kantitatif ve kalitatif) yetersiz kaldığı durumlarda, karmaşık veri yapılarını

çözebilen yapay zekâ tabanlı yöntemler talep tahmininde sıkılıkla kullanılmaktadır [13].

Bu çalışmada özellikle karmaşık ve belirsizliğin ön planda olduğu problemlerin çözümünde sıkılıkla tercih edilen tahmin yöntemlerinden olan YSA ve DVR yöntemleri kullanılmış ve iki yöntemin tahmin performansları karşılaştırılmıştır. Ayrıca her bir yöntemde kullanılacak en iyi parametre değerlerini belirlemek amacıyla bir deney tasarımı yapılmış ve her iki yöntem de tahmin performanslarının en iyi olduğu parametre değerleri ile çalıştırılmıştır.

2.1. Yapay sinir ağları

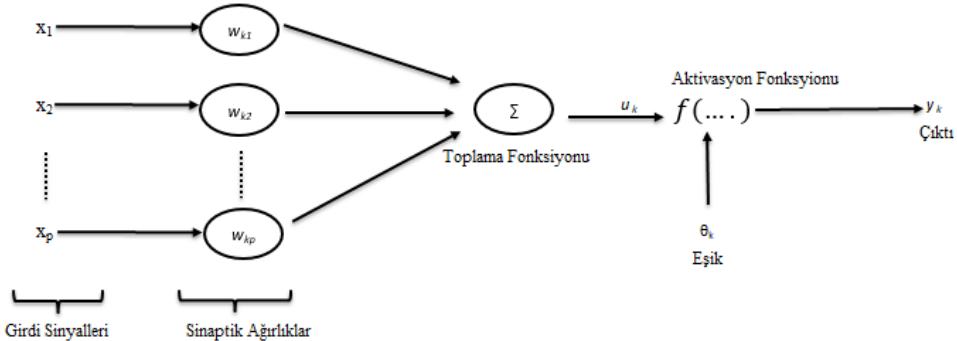
YSA insan beyninin bilişsel öğrenme sürecini taklit eden hesaplama yapılarıdır. Klasik hesaplama yöntemlerinin aksine YSA tahmin, optimizasyon, tanıma, kontrol gibi doğrusal olmayan problemleri çözme yeteneğine sahiptir. İlk olarak McCulloch ve Pitts [14] tarafından ortaya atılmıştır. Zamanla artan bir ilgi gösteren YSA ile ilgili çeşitli çalışmalar yapılmıştır [15].

Tablo 1'de biyolojik sinir sistemi yapısındaki her bir elemana karşı gelen yapay sinir ağları gösterilmektedir.

Tablo 1. Biyolojik sinir sistemi elemanları ve ona karşı gelen yapay sinir ağları [16]

Biyolojik Sinir Sistemi	Yapay Sinir Ağları
Nöron	İşlemci elemanı
Sinaps	Ağırlıklar
Dendrit	Toplama Fonksiyonu
Hücre gövdesi	Aktivasyon Fonksiyonu
Akson	Çıkış

Nöron bilgisi işleyen temel YSA öğesidir. Yapay sinir hücresi yapısı Şekil 1'de gösterilmiştir.



Şekil 1. Yapay sinir hücresi yapısı [15]

Şekil 1'den de görüldüğü üzere, j sinapsının girişindeki x_j sinyali w_{kj} sinaptik ağırlığı ile çarpılır ve k nöronuna bağlanır. Toplama fonksiyonu giriş sinyallerini ve nöronun ilgili sinapslarını doğrusal bir birleştirici aracılığıyla ekler. Bir nöronun çıkış genliği bir aktivasyon fonksiyonu ile sınırlıdır. Literatürde aktivasyon fonksiyonu olarak eşik, parçalı doğrusal, Sigmoid ve Gauss fonksiyonları kullanılmaktadır [15].

Bir yapay sinir ağındaki ilişkiler matematiksel olarak Denklem (1) ve Denklem (2)'de gösterilmiştir.

$$u_k = \sum_{j=1}^m w_{kj}x_j \quad (1)$$

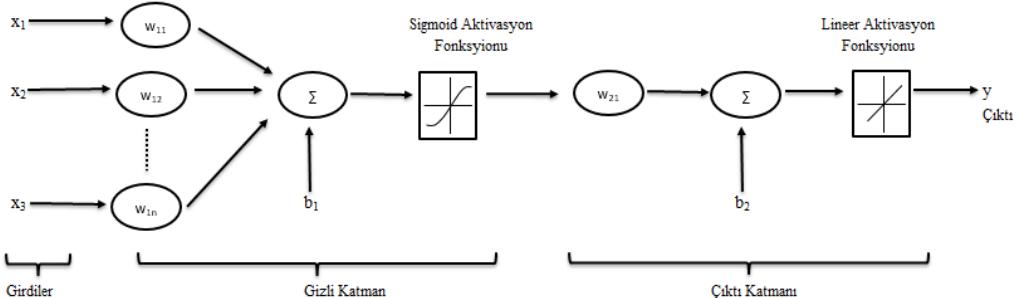
$$y_k = f(u_k + b_k) \quad (2)$$

Burada u_k ; doğrusal birleştirici çıkış, $w_{k1}, w_{k2}, \dots, w_{km}$; k nöronunun sinaptik ağırlıkları, x_1, x_2, \dots, x_m ; giriş sinyalleri, y_k ; nöronun çıkış sinyali, $f(\dots)$; aktivasyon fonksiyonu, b_k ; sapma (bias) değeridir.

Yapay nöronlar düğümlerle gösterilirse ve nöron giriş ve çıkışları yönlendirilmiş oklarla bağlanırsa, YSA ağırlıklı yönlendirilmiş grafikler haline gelir. Grafiğin yapısına göre, YSA'lar iki sınıfa ayrılabilir. Birincisi, döngüsü olmayan ileri beslemeli ağlar, diğeri ise geri besleme bağlantıları nedeniyle döngülere sahip tekrarlayan ağlardır. Şekil 2'de ileri beslemeli bir YSA yapısı gösterilmiştir [15].

Yapay sinir ağları çalışma mantığı açısından birbirlerine benzerler, fakat bazı yapısal farklılıklar gösterirler.

Bağlantı yapılarına göre YSA, İleri Beslemeli ve Geri Beslemeli olmak üzere ikiye ayrılır. İleri beslemeli ağlarda bir katmanda işlenen veriler bir sonraki katmana iletildikten geri beslemeli ağlarda ileri veri akışının yanı sıra geriye doğru da bir veri akışı bulunur. Geri beslemeli ağlar doğrusal olmayan dinamik bir yapıya sahiptirler. Bu yapı hataları önlemeye yönelik çalıştığı için tahmin problemlerinde daha makul sonuçlar vermektedir. Öğrenmelerine göre ağlar danışmanlı, danışmansız, takviyeli ağlar ve karma stratejiler olarak ayrılmaktadır. Danışmanlı ağlarda ağın eğitimi için bir danışman bulunur. Danışman ağa girdi ve çıktı seti göndererek öğrenmesini sağlar. Ağın çıktıları ile danışmanın çıktıları karşılaştırılarak hata oranları belirlenir. Bu hataları minimize etmek için ağırlıklar yeniden düzenlenir ve optimum sonuca ulaşıcaya kadar işlemler devam eder. Danışmansız ağlarda herhangi bir danışman bulunmaz, ağa yalnızca girdiler verilir ve çıktı oluşturulması beklenir. Takviyeli ağlarda ise danışman bulunmaktadır fakat danışman ağa veri vermek yerine ağın ürettiği çıktıının doğru ya da yanlış olduğuna dair sinyal göndermektedir. Ağ bu sinyale dayanarak çıktısını düzenemeye devam eder. Karma stratejilerde ise birden fazla ağ yapısı kullanılır. Zamanına göre ağlar ağın eğitim sürecindeki parametrelerin zaman içinde değişip değişmediğine göre ikiye ayırlırlar: Statik öğrenme ve dinamik öğrenme. Eğer YSA eğitim sürecinde ağı üzerindeki katsayılarla bir değişme olmuyorsa yani katsayılar eğitim süreci boyunca sabitse bu ağlarda statik öğrenme söz konusudur. Eğer ağ yapısındaki katsayılar eğitim



Şekil 2. Yapay sinir ağının yapısı [15]

sürecindeki öngörülere göre değişiyorsa yani eğitim süreci boyunca katsayılar ağıın öğrenme düzeyine göre değişim gösteriyorsa bu ağlarda dinamik öğrenme söz konusudur.

YSA modelleri tek katmanlı algılayıcılar ve çok katmanlı algılayıcılar olmak üzere ikiye ayrılırlar. Tek katmanlı YSA'da bir girdi ve bir çıktı katmanı bulunur. Her hücrede birden fazla girdi veya çıktı bulunabilir. Bütün çıktılar bütün girdilere bağlanırlar. Bütün bağlantıların bir ağırlığı vardır. Bu modelde çıktıının sıfır olmasını engelleyen bir eşik değeri bulunur ve bu değer her zaman 1'dir. Çıktı bu eşik değeri ile ağırlıklandırılmış girdiler toplanarak elde edilir. Tek katmanlı algılayıcıların en önemlileri basit algılayıcı (perceptron) ve Adaline/Madaline'dir. Çok katmanlı algılayıcılarında girdi ve çıktı katmanlarının yanı sıra bir gizli katman bulunur. Çok katmanlı algılayıcılar Delta öğrenme kuralını kullanırlar. Temel amacı ağıın çıktıısı ile hedeflenen değer arasındaki farkı minimize ederken bunu yayarak yapmak olduğu için bu YSA modellerine hata yayma ağı veya geriye yayılma modeli de denmektedir [17].

2.1. Destek vektör regresyonu

Destek vektör makineleri ilk olarak Vapnik [18] tarafından önerilmiştir. Temeli istatistiksel öğrenme teorisine dayanmaktadır. Bu metot ilk olarak sınıflandırma ve regresyon problemlerini çözmek için tasarlanmıştır. Daha sonra tahmin için kullanılan DVR geliştirilmiştir [19].

DVR yöntemi tahmin hatasını minimize etmeye çalışır ve bu şekilde eğitim verisi setine yaklaşan bir fonksiyon bulmayı amaçlar. Bu süreçte, fonksiyonun düzlüğü maksimize edilerek yerel değerlere takılma riski azaltılır [15].

$x_i \in R^n$ gelecek vektörü ve $y_i \in R$ hedef çıktıısı olan bir $\{(x_1, y_1), \dots, (x_\ell, y_\ell)\}$ eğitim noktaları veri seti dir. Teoride, girdi ve çıktı verileri arasındaki doğrusal olmayan ilişkiler doğrusal bir fonksiyonla formüle edilmelidir. Bu ilişkiye gösteren fonksiyon Denklem (3)'te verilmiştir.

$$f(x) = w^T \Phi(x) + b \quad (3)$$

Burada $f(x)$ öngörülen tahmin değerleridir. Φ ; doğrusal olmayan haritalama fonksiyonu ve w ($w \in R^\ell$) ve b ($b \in R$) ise ayarlanabilir katsayılardır. DVR standart formu $C > 0$ ve $\varepsilon > 0$ olmak üzere aşağıdaki gibi tanımlanır:

$$\text{Min}_{w,b,\xi} \frac{1}{2} w^T w + C \sum_{i=1}^{\ell} \xi_i + \xi_i^* \quad (4)$$

Kısıtlar;

$$\begin{cases} w^T \Phi(x_i) + b - y_i \leq \varepsilon + \xi_i \\ y_i - w^T \Phi(x_i) - b \leq \varepsilon + \xi_i^* \\ \xi_i, \xi_i^* \geq 0; i = 1, 2, \dots, \ell \end{cases} \quad (5)$$

ξ_i^* ε üzerindeki eğitim hatalarını, ξ_i ise ε altındaki eğitim hatalarını ifade eder.

Eşitsizlik kısıtlamaları ile yukarıdaki ikinci dereceden optimizasyon problemi çözüldükten sonra, Denklem (3)'teki parametre vektörü w ; Denklem (6) ile bulunur.

$$w = \sum_{i=1}^{\ell} (\lambda_i^* - \lambda_i) \Phi(x_i) \quad (6)$$

Burada λ_i^* ve λ_i Lagrange çarpanlarıdır.

Boylelikle DVR formülü Denklem (7)'deki gibi elde edilmiş olur.

$$f(x) = \sum_{i=1}^{\ell} (\lambda_i^* - \lambda_i) K(x_i, x_j) + b \quad (7)$$

Denklem (7)'de $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$

fonksiyonu radyal temelli kernel fonksiyonunu (Raidal Basis Function-RBF) ifade etmektedir.

3. Uygulama

Bu çalışma çabuk bozulabilir ürünlerin üretildiği bir gıda işletmesinin verileri kullanılarak gerçekleştirilmiştir. Firmadan 4 farklı ürüne ait 52 aylık satış miktarı, üretim miktarı, birim üretim maliyeti, depolama maliyeti, satış fiyatı, dönem başı stok miktarı, hazırlık maliyeti ve elde bulundurma maliyeti gibi veriler temin edilmiş ve tahminde bu veriler kullanılmıştır. Verilere ait istatistiksel göstergeler Tablo 2'de verilmiştir. Bu 4 ürün firmaya en çok kar getiren ürünler olduğu için seçilmiştir.

Tablo 2. Ürünlerin geçmiş satış miktarlarına ait istatistiksel değerler

Ürün	N	Minimum Değer	Maksimum Değer	Standart Sapma
Ürün 1	52	94,920	126,258	8,527
Ürün 2	52	2,586	11,697	2,745
Ürün 3	52	1,430	7,451	1,594
Ürün 4	52	1,247	9,405	2,064

Klasik zaman serisi yöntemleri belirsiz koşullar altında ve talebin belirgin bir yapı izlemediği durumlarda talep tahmininde yetersiz kalmaktadır. Seçilen 4 ürünün talebindeki değişkenlikler nedeniyle zaman serileri yerine önceki bölümde ayrıntıları verilmiş olan yöntemler kullanılarak bu ürünler için satış tahmini yapılmıştır. Tahminde MATLAB® 2018a paket programının YSA ve DVR araçlarından yararlanılmıştır. Her bir yöntem ile en başarılı tahmin sonuçlarını elde edebilmek için öncelikle yöntemlerde kullanılan parametrelerin en iyi değerleri deney tasarımları yöntemi ile belirlenmiştir. Daha sonra bulunan en iyi parametre değerleri ile satış tahmini yapılmıştır. Bir sonraki alt bölümde parametre optimizasyonunun ayrıntılarına yer verilmiştir.

3.1. Parametre optimizasyonu

YSA ve DVR yöntemlerinde en uygun parametre setinin belirlenmesi amacıyla parametre optimizasyonu yapılmıştır.

YSA'da parametre olarak verilerin ne kadarının eğitimde ne kadarının geçerlilikte ve ne kadarının testte kullanılacağını belirlemek üzere 3 farklı seviye tespit edilmiştir. Bir diğer parametre olarak da ağıda kullanılacak nöron sayısının ne olacağına karar vermek üzere 4 seviye belirlenmiş ve bu parametrelerle tam faktöriyel deney tasarımları oluşturulmuştur. Deney tasarımları kapsamında kullanılan parametreler ve değerleri Tablo 3'te verilmiştir.

Her bir parametre kombinasyonu için kırk kez deneme yapılmış ve her bir denemenin sonuçları kaydedilmiştir. Deney tasarımları sonuçları değerlendirilirken istatistiksel performans göstergesi olarak en düşük Ortalama Hata Kare (OHK) değeri dikkate alınmış ve en düşük OHK değerini veren parametre seti en iyi parametre seti olarak seçilmiştir.

Tablo 3. Deney tasarımlı kapsamında kullanılan parametreler ve seviyeleri (YSA)

Parametre	Seviye			
	1	2	3	4
Nöron Sayısı	5	10	15	20
Eğitim Seti (%)	60	70	80	
Geçerlilik Seti (%)	20	15	10	
Test Seti (%)	20	15	10	

Deney tasarımlı sonucunda tüm ürünler için verilerin %80'nin eğitimde, %10'un geçerlilikte ve geri kalan %10'un da testte kullanılması ile en düşük OHK değeri elde edilmiştir. En iyi nöron sayısı ise 3. Ürün hariç 5 olarak tespit edilmiştir. Ürün 3'te 10 nöron ile en düşük OHK değerine ulaşılmıştır.

DVR metodunda ise radyal temelli kernel fonksiyonu parametreleri (γ, C) ile eğitim hata değeri (ε) olmak üzere üç parametrenin en iyi değerleri araştırılmıştır. Burada da yine ürün bazında en düşük OHK değerini veren parametre kombinasyonu tahmin için kullanılmıştır. DVR'de kullanılacak en iyi parametre değerlerini belirlemek üzere kullanılan parametreler ve bu parametrelerin seviyeleri Tablo 4'te verilmiştir.

Kernel fonksiyonu ve Epsilon katsayısı için iki seviye, kısıt fonksiyonu içinse üç seviye belirlenerek tam faktöriyel deney tasarımları oluşturulmuştur.

Tablo 4. Deney tasarımında kullanılan parametreler ve değerleri (DVR)

$\gamma = 0,1$		$\gamma = 0,2$	
$\varepsilon = 0,005$	$\varepsilon = 0,01$	$\varepsilon = 0,005$	$\varepsilon = 0,01$
$C=80$	$C=80$	$C=80$	$C=80$
$C=100$	$C=100$	$C=100$	$C=100$
$C=120$	$C=120$	$C=120$	$C=120$

Deney tasarımları sonucunda bulunan en iyi parametre değerleri Tablo 5'te verilmiştir.

Tablo 5. DVR ile tahminde kullanılan en iyi parametre değerleri

Ürün	c	γ	ε
Ürün 1	120	0,1	0,01
Ürün 2	80	0,1	0,005
Ürün 3	120	0,1	0,005
Ürün 4	100	0,1	0,01

3.2. Yapay sinir ağları

YSA ile tahmin çalışmasında MATLAB programının Nftool aracından yararlanılmıştır. Kullanılacak YSA'nın yapısı belirlenirken önceki çalışmalar referans alınarak ileri beslemeli iki katmanlı bir YSA kullanılmıştır. Gizli katmanda aktivasyon fonksiyonu olarak Sigmoid fonksiyonu, çıkış katmanında ise doğrusal fonksiyon kullanılmıştır. Öğrenme методu olarak ileri beslemeli ağlarda en hızlı öğrenme yöntemi olan Levenberg Marquardt metodundan yararlanılmıştır. Eldeki verilerin ne kadarının eğitileceği ne kadarının test verisi olarak kullanılacağı ve ağda kullanılacak nöron sayısı gibi parametreler önceki bölümde anlatılmış olan deney tasarımları ile belirlenmiştir. Deney tasarımları aşamasından önce veriler Denklem (8) yardımı ile normalize edilmiştir.

$$X_{normalized} = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (8)$$

Deney tasarımları sonucunda her bir ürün için en iyi sonucu veren parametre kombinasyonu ile tahminler yapılmıştır.

Şekil 3, 4, 5 ve 6'daki grafiklerde her bir ürün için YSA ile yapılan tahminlerden elde edilen R değerleri görülmektedir. Ürün 1 haricinde R değerlerinin %80'nin üzerinde olduğu, Ürün 1 için ise %71 ile kabul edilebilir bir seviyede olduğu görülmektedir.

Tablo 6'da ise YSA ile yapılan tahmin sonucunda her bir ürün için elde edilen tahmin hataları ve R^2 değerleri verilmiştir. Tahmin hataları üç farklı ölçüte göre hesaplanmıştır: Ortalama Hata Kare (OHK), Ortalama Mutlak Hata (OMH) ve Ortalama Mutlak Yüzde Hata (OMYH).

Tablo 6. YSA ile yapılan tahminlere ait hata değerleri

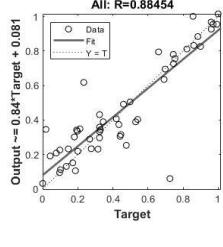
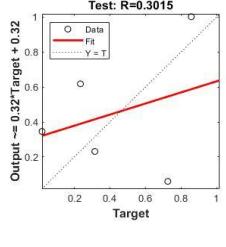
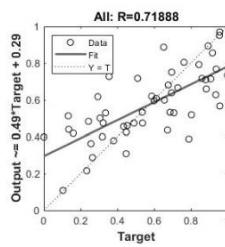
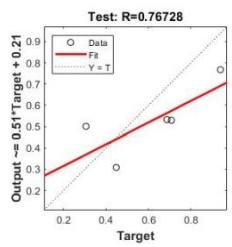
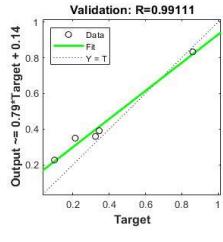
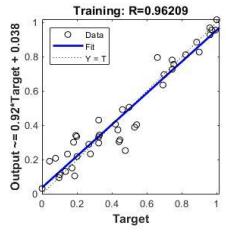
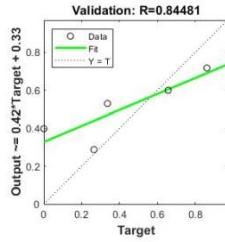
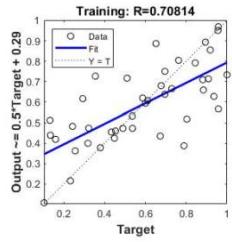
Ürün	OHK	OMH	OMYH (%)	R^2
Ürün 1	76263797	7527	6,5	0,51
Ürün 2	11517215	2904	54,11	0,62
Ürün 3	1094733	721	19,45	0,82
Ürün 4	2869915	1432	30,75	0,54

3.3. Destek Vektör Regresyonu

DVR metodunda da YSA yönteminde olduğu gibi öncelikle parametre optimizasyonu için bir deney tasarımları yapılmış, bulunan en iyi parametre değerleri ile 4'üne ait tahmin değerleri elde edilmiştir. DVR ile tahmin yaparken MATLAB programının makine öğrenme aracı kullanılmıştır ve YSA'da olduğu gibi veriler normalize edilmiştir. Verilerin %70'i eğitim için, %15'i geçerlilik için ve geri kalan %15'i de test için kullanılmıştır.

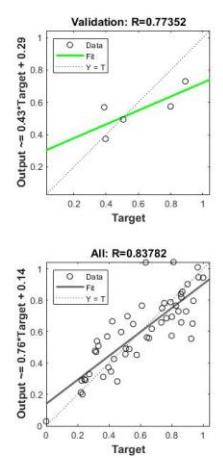
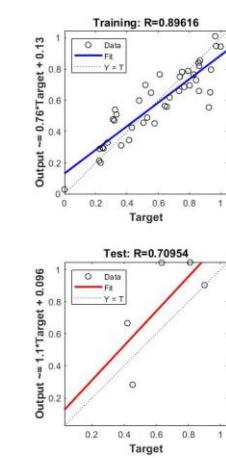
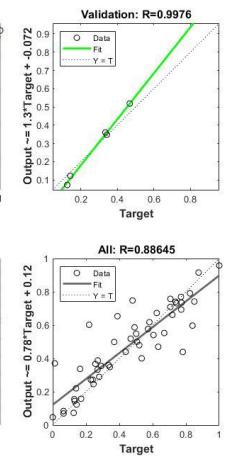
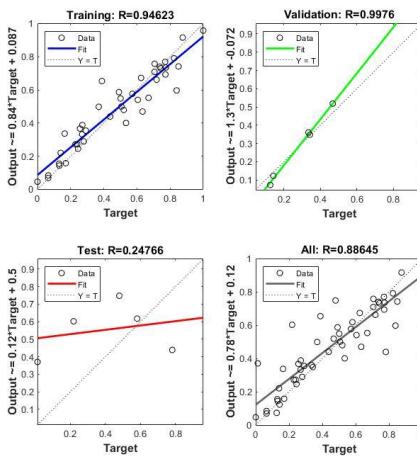
Tablo 7'de her ürüne ait tahminler sonucunda elde edilen hata ve R^2 değerleri görülmektedir. OHK ve OMH değerleri dikkate alındığında DVR'nin sadece Ürün 3 için iyi tahmin sonuçları ürettiği görüldürken diğer ürünler için aynı başarayı yakalayamadığı görülmektedir.

Şekil 7, 8, 9 ve 10'da her bir ürün için DVR ile yapılan tahminlerle verilerin uyumunu gösteren grafikler (fitted plots) gösterilmiştir. Bu grafiklerden de görüldüğü gibi DVR Ürün 3 için iyi bir tahmin performansı gösterirken, diğer ürünlerde aynı performans görülmemektedir.



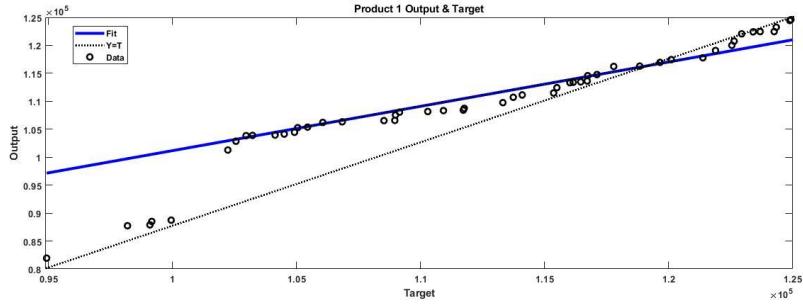
Şekil 3. YSA Ürün 1 için regresyon grafiği

Şekil 4. YSA Ürün 2 için regresyon grafiği

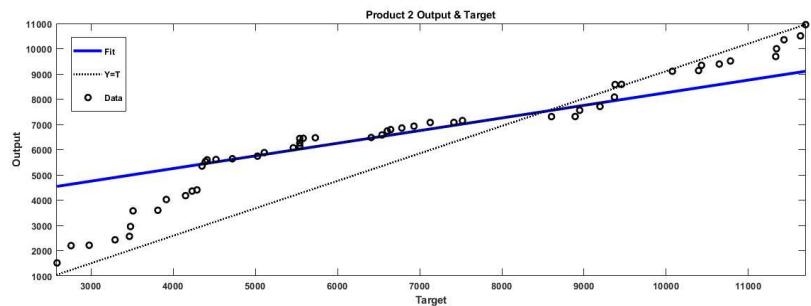


Şekil 5. YSA Ürün 3 için regresyon grafiği

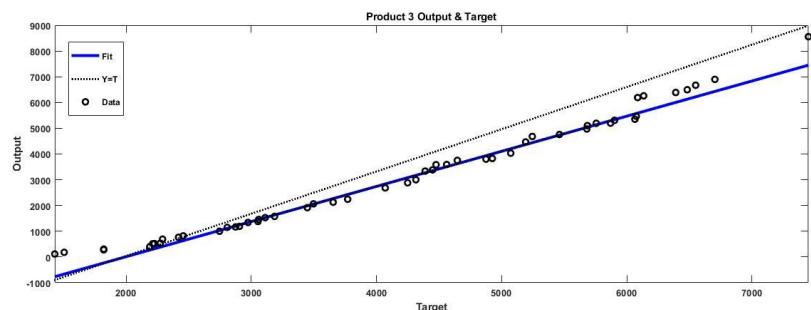
Şekil 6. YSA Ürün 4 için regresyon grafiği



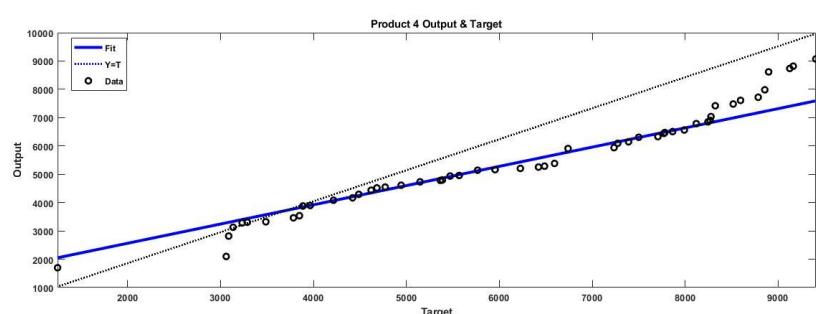
Şekil 7. DVR Ürün 1 grafiği



Şekil 8. DVR Ürün 2 grafiği



Şekil 9. DVR Ürün 3 grafiği



Şekil 10. DVR Ürün 4 grafiği

Tablo 7. DVR ile yapılan tahminlere ait hata değerleri

Ürün	OHK	OMH	OMYH (%)	R^2
Ürün 1	137231390	8053	7,01	0,52
Ürün 2	10550935	2420	42,10	0,76
Ürün 3	6248869	2010	53,38	0,57
Ürün 4	8736926	2372	48,46	0,34

3.4. Yöntemlerin karşılaştırılması

Her iki yöntemin ürün bazındaki tahmin performansı karşılaştırımları olarak Tablo 8'de verilmiştir. Tablo 8'de yapılan karşılaştırımlar OMYH kriteri baz alınarak yapılmıştır. Bu kriter tahmin değerlerinin verilerin % olarak ne kadarını doğruladığını göstermesi bakımından daha doğru ve adil olacağı düşünüldüğünden tercih edilmiştir.

Ayrıca her bir ürün için yapılan tahminler ile gerçekleşen satış miktarlarının karşılaştırıldığı grafikler Şekil 11-14'te verilmiştir. Grafikler ve Tablo 8 birlikte incelendiğinde YSA'nın tahmin performansının Ürün 2 haricindeki diğer tüm ürünler için DVR'ye göre daha iyi olduğu görülmektedir. Yalnızca ikinci üründe DVR daha iyi tahmin değerleri üretmiştir. Ancak bu üründe de YSA'nın OHK değeri açısından DVR'den daha iyi olduğu görülmektedir. Sonuçlar genel olarak yorumlandığında YSA'nın ele alınan ürünler için DVR'den daha iyi tahmin sonuçları verdiği söylenmek mümkündür.

Elde edilen bulgular ışığında her iki yöntemin tahmin performanslarını sağlıklı bir şekilde karşılaştırıbmek ve daha genel yorumlar yapabilmek için veri sayısının artırılması gerekmektedir. Bu çalışmada sadece 52 aylık veriler ele alındığı ve bu veriler de çok fazla değişkenlik içерdiği için, Tablo 6 ve 7'deki R^2 değerlerine bakıldığında YSA en iyi tahmini 0,82 R^2 değeri ile Ürün 3 için gerçekleştirirken, DVR'nın en iyi tahmin değeri 0,76 R^2 değeri ile Ürün 2 için gerçekleştirmiştir.

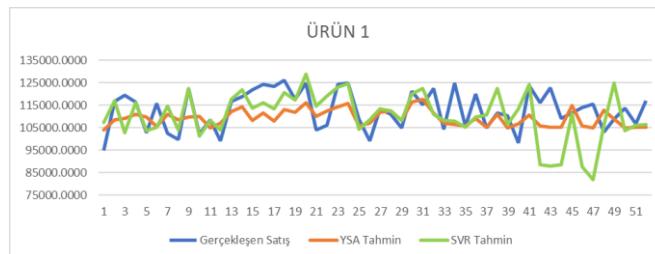
4. Sonuç

Son yıllarda hızla gelişen teknoloji birçok alanda faaliyetlerin daha etkin yürütülmesini sağlamıştır. Özellikle yapay zekânın gelişimi ile tahmin gibi öğrenmeye dayalı konularda büyük ilerlemeler kaydedilmiştir. Bu ilerlemeler sonucunda geliştirilen yapay zekâ teknikleri ile

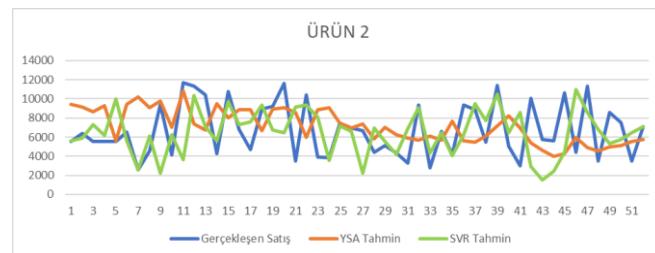
talep değişkenliğinin ve belirsizliğinin fazla olduğu koşullarda yapılan tahminlerde geleneksel yöntemlerden çok daha başarılı sonuçlar elde edilmektedir. Bu çalışmada, gıda sektöründeki bir işletmede talebin değişken olduğu ve belirsizlik içерdiği ürünler için yapay zekâ teknikleri kullanılarak talep tahmini yapılmıştır. Çalışmada YSA ve DVR yöntemleri kullanılmıştır.

Çalışma kapsamında seçilen 4 ürüne ait 52 aylık veriler analiz edilerek sırası ile YSA ve DVR yöntemleri ile tahmin yapılmıştır. Yöntemler uygulanmadan önce her bir yöntemde kullanılacak en iyi parametre değerlerini belirlemek üzere bir deney tasarımı çalışması gerçekleştirilmiştir. Böylelikle uygulanan yöntemlerin tahmin gücünün artırılması hedeflenmiştir. Tahmin performansı Ortalama Mutlak Hata, Ortalama Mutlak Yüzde Hata ve Ortalama Hata Kare ölçütlerine göre değerlendirilmiş ve yöntemler bu performans ölçütlerine göre karşılaştırılmıştır. Elde edilen sonuçlar yöntemlerin performansının üründen ürune ve dikkate alınan hata ölçütüne göre değiştiğini ancak genel olarak YSA'nın DVR'ye göre daha başarılı tahminler yaptığı göstermiştir.

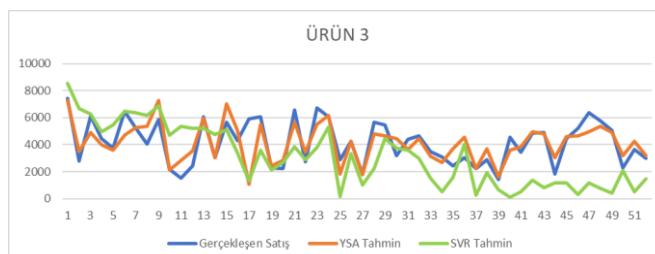
Bu çalışma kapsamında iki yapay zekâ teknığının belirsiz ve değişken koşullar altında tahmin performansı karşılaştırılmıştır. Ele alınan yöntemlerin etkinliğinin artırılması için çapraz doğrulamaya ihtiyaç olduğu görülmüştür. Bu bağlamda, gelecekte yapılabilecek bir araştırma konusu olarak bu çalışmada ele alınan veri setinde olduğu gibi çok fazla değişkenlik içeren veriler için nasıl daha iyi tahminler gerçekleştirilebileceği konusu araştırılabilir. Ayrıca, bu karşılaştırmalara gri tahmin ve çok değişkenli uyarlanabilir regresyon eğrileri gibi belirsizlikte birden fazla değişkeni göz önünde bulunduran yöntemler eklenerek, bu yöntemlerin performansları kıyaslanabilir.



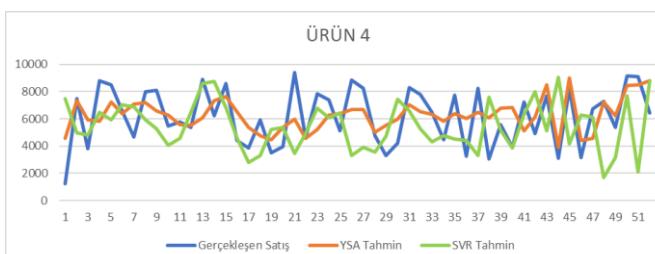
Şekil 11. Gerçekleşen ve tahmin edilen satış miktarları-Ürün 1



Şekil 12. Gerçekleşen ve tahmin edilen satış miktarları-Ürün 2



Şekil 13. Gerçekleşen ve tahmin edilen satış miktarları-Ürün 3



Şekil 14. Gerçekleşen ve tahmin edilen satış miktarları-Ürün 4

Table 8. Ürün bazında tahmin hataları: Yöntemlerin karşılaştırılması

Yöntem	Ürün 1			Ürün 2			Ürün 3			Ürün 4		
	OHK	OMH	OMYH (%)	OHK	OMH	OMYH (%)	OHK	OMH	OMYH (%)	OHK	OMH	OMYH (%)
YSA	76263797	7527	6,5	11517215	2904	54,11	1094733	721	19,45	2869915	1432	30,75
DVR	137231390	8053	7,01	10550935	2420	42,10	6248869	2010	53,38	8736926	2372	48,46

Teşekkür

Bu makale birinci yazarın Pamukkale Üniversitesi Fen Bilimleri Enstitüsü Endüstri Mühendisliği Anabilim Dalında yapmış olduğu yüksek lisans tez çalışmasından üretilmiştir. Çalışma sürecindeki katkılarından dolayı Yüksek Endüstri Mühendisi İlhan Sağer'e teşekkür ederiz.

Kaynakça

- [1] McCarthy, T.M., Davis, D.F., Golicic, S.L., Mentzer, J.T. 2006. The Evolution of Sales Forecasting Management: A 20-Year Longitudinal Study of Forecasting Practices, Journal of Forecasting, Cilt. 25(5), s. 303-324. DOI: 10.1002/for.989.
- [2] Villegas, M.A., Pedregal, D.J., Traper, J.R. 2018. A Support Vector Machine for Model Selection in Demand Forecasting Applications, Computers & Industrial Engineering, Cilt. 121, s. 1-7. DOI: 10.1016/j.cie.2018.04.042.
- [3] Petropoulos, F., Hyndman, R.J., Bergmeir, C. 2018. Exploring the sources of uncertainty: Why does bagging for time series forecasting work?, European Journal of Operational Research, Cilt. 268(2), s. 545-554. DOI: 10.1016/j.ejor.2018.01.045.
- [4] Guo, H., Wang, X., Gao, Z. 2014. Uncertain linear regression model and its application, Journal of Intelligent Manufacturing, Cilt. 28(3), s. 559-564. DOI: 10.1007/s10845-014-1022-4.
- [5] Murphy, M.D., O'Mahony, M.J., Shalloo, L., French, P., Upton, J. 2014. Comparison of modeling techniques for milk-production forecasting, Journal of Dairy Science, Cilt. 97(6), s. 3352-3363. DOI: 10.3168/jds.2013-7451.
- [6] Jaipuria, S., Mahapatra, S.S. 2014. An improved demand forecasting method to reduce bullwhip effect in supply chains, Expert Systems with Applications, Cilt. 41(5), s. 2395-2408. DOI: 10.1016/j.eswa.2013.09.038.
- [7] Babu, C.N., Reddy, B.E. 2014. A moving-average filter based hybrid ARIMA-ANN model for forecasting time series data, Applied Soft Computing, Cilt. 27(10), s. 27-38. DOI: 10.1016/j.asoc.2014.05.028.
- [8] Du, X.F., Leung, S.C. H., Zhang, J.L., Lai, K.K. 2013. Demand forecasting of perishable farm products using support vector machine, Int. J. Systems Science, Cilt. 44(3), s. 556-567. DOI: 10.1080/00207721.2011.617888.
- [9] Kandananond, K. 2012. Consumer Product Demand Forecasting Based on Artificial Neural Network and Support Vector Machine. World Academy of Science, Engineering and Technology International Journal of Economics and Management Engineering, Cilt. 6(3), s. 313-316.
- [10] Sun, Z.L., Choi, T.M., Au, K.F., Yu, Y. 2008. Sales forecasting using extreme learning machine with applications in fashion retailing, Decision Support Systems, Cilt. 46(1), s. 411-419. DOI: 10.1016/j.dss.2008.07.009.
- [11] Kılıç, F., Akkaya, M.R., Memili N., 2018. Yemekhane için Yapay Zekâ Teknikleri Kullanımı ile Günlük Talep Tahmini, Avrupa Bilim ve Teknoloji Dergisi, Cilt. 13, s. 65-71. DOI: 10.31590/ejosat.397549.
- [12] Sönmez, O., Zengin, K. 2019. Yiyecek ve İçecek İşletmelerinde Talep Tahmini: Yapay Sinir Ağları ve Regresyon Yöntemleriyle Bir Karşılaştırma. Avrupa Bilim ve Teknoloji Dergisi, Özel Sayı, s. 302-308. DOI: 10.31590/ejosat.638104.
- [13] Olgun, S. 2009. Tedarik zinciri yönetiminde talep tahmini yöntemleri ve yapay zeka tabanlı bir talep tahmini modelinin uygulanması. İstanbul Üniversitesi, Fen Bilimleri Enstitüsü, Yüksek Lisans Tezi, 106s. İstanbul.
- [14] McCulloch W.S., Pitts W. 1943. A logical calculus of ideas immanent in nervous activity, Bulletin of Mathematical Biophysics, Cilt. 5(4), s. 115-133. DOI: 10.1007/bf02478259.
- [15] Demir L., Akkaş S. 2018. A comparison of sales forecasting methods for a feed company: A case study, Pamukkale University Journal of Engineering Sciences, Cilt. 24(4), s. 705-712. DOI: 10.5505/pajes.2018.58235.
- [16] Biçer, A., Yönetken, A. 2018. Program Development for Energy Demand Forecasting and Its Application For A Site, International Journal of Scientific & Engineering Research, Cilt. 9(8), s. 18-27. ISSN 2229-5518.
- [17] Öztemel, E. 2012. Yapay Sinir Ağları. Papatya Yayıncılık, İstanbul, 232s.
- [18] Vapnik, V. 1995. The Nature of Statistical Learning Theory. Springer, New York, 314s.
- [19] Drucker, H., Burges, C.J. C., Kaufman, L., Smola, A., Vapnik, V. 1997. Support vector regression machines, Advances in Neural Information Processing Systems, Cilt. 9, s. 155-161.