

Önem Tahminleme Tabanlı Tek Sınıf Sınıflayıcı ile Doku Tanıma

Gökhan TIĞİLSEL¹, Güleser Kalaycı DEMİR^{*2}

¹ Dokuz Eylül Üniversitesi, Fen Bilimleri Enstitüsü, İzmir (ORCID: 0000-0003-3722-3067)

² Dokuz Eylül Üniversitesi, Mühendislik Fakültesi, Elektrik ve Elektronik Mühendisliği Bölümü, İzmir (ORCID: 0000-0003-3808-5305)

(Alınış / Received: 23.01.2017, Kabul / Accepted: 28.09.2017,
Online Yayınlanması / Published Online: 20.01.2018)

Anahtar Kelimeler **Özet:** Tek Sınıf Sınıflayıcı (TSS) ile doku tanıma, farklı sınıflara ait Önem Tahminleme, dokular içinde sadece ilgilenilen hedef dokuya ilişkin eğitim Yoğunluk Dağılım, verileri ile hedef dokunun tanınması problemidir. Bu çalışmada, Tek Sınıf Sınıflayıcı, Doku önem değerinin tahminlenmesine dayanan bir doku sınıflayıcı önerilmiştir. Önem değeri, test ve eğitim verilerinden elde edilen yoğunluk fonksiyonlarının oranından hesap edilmiştir. Girilen test verisi ile hedef sınıf verisi birbirine benzer ise önem değeri bire yakın olduğundan elde edilen önem değerlerine eşikleme işlemi uygulanarak sınıflama işlemi gerçekleştirilmiştir. Önem değeri, Kısıtsız En Küçük Kareler Önem Uydurma (KEKK-ÖU) yöntemi ile elde edilmiştir. Önerilen yöntemin etkinliği, farklı doku setleri üzerinde farklı sınıflama ölçütleri ile değerlendirilmiştir. Elde edilen sonuçlar önerilen yöntemin TSS problemlerinde başarılı ve güvenilir olduğunu göstermektedir. Sonuçlar, ayrıca literatürde referans yöntem olarak alınan tek-sınıf destek vektör makinaları yöntemine göre de karşılaştırılmış ve önerilen yöntem ile daha yüksek TSS başarım performansı elde edilmiştir.

Texture Recognition Using Importance Based One-Class Classifier

Keywords
Importance Estimation, Density Distribution, One Class Classification, Texture Recognition

Abstract: Texture recognition by Single-Class Classifier (SCC) refers to the problem of recognizing the target texture by using only the training data pertaining to the texture under concern. In this study, a texture classifier, based on the estimation of importance, is proposed. Importance is calculated as the ratio of two density functions obtained from the training and test data. Since the importance value is close to the one if the inputted test and target class data are similar to each other, classification is performed by applying a thresholding process to the obtained importance values. Importance is estimated by Unconstrained Least Square Importance Fitting (uLSIF) algorithm. The effectiveness of the proposed method is examined on different texture sets with different classification metrics. Our results show that the proposed

algorithm is powerful and reliable in SCC problems. Results are also compared with the one-class support vector machines which is the reference algorithm in the literature and higher SCC performance is obtained with the proposed method for applied textures .

*Sorumlu yazar: Güleser Kalaycı DEMİR e-mail: guleser.kalayci@deu.edu.tr

1. Giriş

Tek-Sınıf Sınıflayıcı (TSS) probleminde hedef sınıfa ilişkin nesnelerin farklı sınıflara ait nesneler içinde bulunması amaçlanmaktadır ve bu amaç için sadece hedef sınıfa ilişkin eğitim verilerinin kullanımı mümkündür.[1]. Sadece hedef sınıfa ait eğitim seti kullanıldığından ve diğer sınıflara ilişkin veri bulunmadığından dolayı sınıflayıcının karar sınırları sadece bir yönden belirlenebilmiştir. Bu nedenle bitişik sınıflara ait tüm eğitim verilerini kullanarak karar sınırlarını oluşturan çok-sınıf sınıflayıcılarından daha farklı ve daha zor bir problemdir. Yazında, izinsiz giriş tespiti [2], imza doğrulama [3] ve değişim tespiti [4] gibi farklı uygulama alanlarında son zamanlarda sıkılıkla kullanılmıştır.

Bu tür uygulamalarda genellikle bir sınıfa ait örnek veri sayısı fazla olmakla birlikte diğer sınıflara ait örnek verilerin elde edilmesi çok zor veya pahalıdır. Bu duruma bir örnek olarak makine arızalarının bulunması problemi verilebilir [5]. Bu problemde, sınıflayıcının, normal (hedef sınıf) veya hatalı makine çalışmasını tespit etmesi beklenmektedir. Makinenin normal çalıştığı durumlara ait örnekler (hedef sınıf eğitim verisi), rahatlıkla elde edilebilmekle birlikte, hatalı çalışma durumlarına ilişkin örnekler (aykırı değerler) ya hiç ya da çok çok az elde edilebilmektedir. Çok fazla sayıda saklanmış görüntü içinde belli bir görüntünün bulunması problemi bir başka örnek olarak verilebilir. Burada, istenen görüntüye ait bazı öznitelikler biliniyorken bu özniteliklere sahip olmayan tüm görüntülerin elimine edilmesi amaçlanmaktadır [6,7]. Bu çalışmada da benzer bir problem üzerine

çalışılacak ve özgün bir yaklaşım kullanılarak TSS ile sadece hedef dokuyu içeren alanlar tüm görüntü içinde bulunacaktır.

Genel olarak doku sınıflaması, görüntü içinde yer alan farklı dokuların hangi sınıfa ait olduğunu bulmayla ilgilenir. Yazında, bu tür problem için önerilmiş çok fazla sayıda çok-sınıf sınıflayıcı yöntemleri bulunmaktadır. [8-10]. Bu çalışmalarдан çoğu Gri Seviye Birliktelik Matrisi (GSBM), Gabor ve Dalgacık öznitelikleri gibi öznitelik setlerinin kullanılmasına dayanmaktadır. Amaç, çok-boyutlu uzayda farklı sınıfları temsil eden bölgelerin belirlenmesi ve test verisi ile ilişkilendirilen bölgeye göre çok-sınıf sınıflama yapılmasıdır. Bu çalışmada, sadece ilgilenilen hedef dokuya ilişkin eğitim verileri olduğundan, bir başka deyişle dış sınırları belirleyen negatif örnekler olmadığından çok-sınıf sınıflayıcı yaklaşımı uygulanabilir değildir. Yazında, Tek-sınıf Destek Vektör Makineleri (TS-DVM) [11], başarım performansı ile sık tercih edilen bir yöntem olarak ön plana çıkmaktadır [2,5,12]. [13] 'de bu yöntem doku sınıflaması problemine uygulanmıştır. TS-DVM'in çözümü, aykırı değer oranı ve kullanılan Gauss çekirdek genişliği gibi parametre değerlerine bağlıdır. Bu parametrelerin seçilmesi için sistematik bir yöntem bulunmamakta ve elle deneyerek ayarlama gerçekleştirildiğinden dolayı öznel ve daha az güvenilirdir. [6]'de ise aynı probleme çok-katmanlı yapay sinir ağları modeli kullanımı ile yaklaşılmıştır. Tek sınıf sınıflayıcı problemi için yazında yoğunluk tabanlı yaklaşımlar da sıkılıkla kullanılmıştır. Genellikle bu tür yöntemlerde, incelenen veri noktasının yakın çevresinde bulunan diğer verilerin

sıklığı veya seyrekligine göre karar verilmektedir ve performans, veri boyutunun artması ile ciddi anlamda düşebilmektedir [14, 15]. Bu çalışmada daha farklı bir yaklaşım kullanılacak ve yoğunluk dağılım tahminlemesi yerine ilgilenilen veri ve yakın komşu verilerinin dağılım fonksiyonunun hedef sınıf dağılım fonksiyonuna ne kadar benzeştiği araştırılarak sonuca ulaşılacaktır. Benzeşme kriteri olarak test verisine ilişkin yoğunluk fonksiyonunun, eğitim verisi yoğunluk fonksiyonuna oranı (önem) önerilmiştir. Bildiğimiz kadarı ile bu tür bir yaklaşım, tek sınıf doku sınıflamasında daha önce kullanılmamıştır. Önem değerinin hesaplanması yüksek boyutlarda ayrı ayrı yoğunluk dağılımlarının hesaplanmasıdan kaçınan ve parametre seçimlerini sistematik olarak hesaplayabilen Kısıtsız En Küçük Kareler Önem Uydurma (KEKK-ÖU) yöntemi tercih edilmiştir [16].

2. Önerilen Yöntem

2.1 Genel yapı

Bu çalışmada, hedef ve test verisi yoğunluk fonksiyonlarının oranından elde edilen önem değeri sınıflama için kullanılacaktır. Önerilen yöntemin çıkış noktası, test dokusunun hedef dokuya olan benzerliğinin artması ile yoğunluk fonksiyonlarının benzerliklerinin de artması ve iki yoğunluk fonksiyonu arasındaki oranın bire yaklaşacağının dikkate alınmasıdır. Test verisi, hedef sınıfından ayrıldıkça önem değeri, 1 değerinden uzaklaşacaktır. Bu doğrultuda, öncelikle hedef dokunun öznitelikleri kullanılarak eğitim seti oluşturulmuştur. Daha sonra test verisinin öznitelikleri hesaplanmış ve önem tahminlemesinde bulunulmuştur. Elde edilen önem değerleri üzerinde eşikleme işlemi yapılarak sınıflama işlemi gerçekleştirilmiştir.

2.2 Doku Öznitelik Seti

Bu çalışmada doku tespiti amacı ile istatistiksel özniteliklerden faydalanyılmıştır. Ortalama, varyans gibi bireysel piksel değerlerinden elde edilen, pikseller arasındaki uzamsal etkileşimi göz arı eden birinci-derece istatistiksel öznitelikler yerine daha ayırt edici özellikler olan ikinci-derece öznitelikler tercih edilmiştir. GSBM matrisinden yararlanarak bulunan ikinci-derece istatistiksel doku öznitelikleri, yazında sıkılıkla yüksek başarım performansı ile kullanılmıştır. Bu çalışmanın odağı, doku sınıflamaya ilişkin en uygun özniteliklerin bulunmasından ziyade elde bulunan özniteliklerin en yüksek sınıflama başarım performansı ile değerlendirilmesi olduğundan farklı öznitelik setlerinin kullanımı üzerine odaklanılmamıştır.

GSBM yöntemi, doku içinde yer alan piksellerin diğer komşu piksellere göre göreceli konumu hakkında bilgi veren istatistiksel bir yaklaşımdır. p farklı piksel değerine sahip $N \times N$ boyutlu bir I görüntüsünden elde edilen $p \times p$ boyutlu birlilik matrisi P , şu şekilde tanımlanmaktadır:

$$P(i,j) = \sum_{x,y}^N \begin{cases} 1, & \text{eğer } I(x,y) = i \text{ ve} \\ & I(x + \Delta_x, y + \Delta_y) = j, \\ 0, & \text{diğer durumlar.} \end{cases} \quad (1)$$

Burada, i ve j piksel değerleri, x ve y görüntüdeki uzamsal pozisyonlar ve ofset (Δ_x, Δ_y), ilgilenilen piksel ile komşu pikselleri arasındaki uzaklığını belirtmektedir.

Yazında GSBM'in kullanımı ile çeşitli istatistiksel doku öznitelikleri önerilmiştir [17]. Bu özniteliklerin tamamının kullanımı, hesapsal maliyeti artırdığından ve yapılan nümerik denemelerde sınıflama performansını doğrusal olarak yukarı çekmediğinden

dolayı içlerinden üç tanesi öznitelik setinin oluşturulması amacı ile seçilmiştir. Bunlar, GSBM yerel değişimlerini ölçen kontrast K , GSBM elemanlarının karelerinin toplamından oluşan açısal ikinci momentin karesi M ve GSBM elemanların dağılımının GSBM köşegenine yakınlığını ölçen homojenlik H_o değerleridir. GSBM matrisi P 'den K , M ve H_o değerlerinin elde edilişi Denklem 2-4'de verilmiştir.

$$K = \sum_i \sum_j (i-j)^2 P(i,j) \quad (2)$$

$$M = \sum_i \sum_j P(i,j)^2 \quad (3)$$

$$H_o = \sum_i \sum_j \frac{1}{1 + (i-j)^2} P(i,j) \quad (4)$$

2.3 Önem Tahminleme

Bu çalışmada KEKK-ÖU yönteminin teknik doku tanıma amacı ile kullanımı önerilecektir. Bu çalışmada geliştirilen yaklaşım, hedef sınıfı ve test sınıfına ilişkin iki olasılık yoğunluk fonksiyonunun oranının kestirimini (/tahminini) temel almaktadır. Test verisine ilişkin dağılım, hedef sınıfına ilişkin dağılıma ne kadar yakınsa önem değeri 1'e yaklaşmakta olduğundan önem değerine göre sınıflama işleminin yapılabileceği öngörülmüştür. Literatürde, bu oran "önem" olarak adlandırılmaktadır ve durağan olmayan uyarlama [18], değişim-noktası tespiti [19], ortak değişinti tahmini [20] gibi farklı veri işleme amaçları için kullanılmaktadır.

Önem fonksiyonunun tahmini için yazında bulunan çalışmalar göz önüne alındığında kullanılabilecek yaklaşımın en doğal ve naif olanının, iki farklı dağılıma ait verilerden olasılık yoğunluk fonksiyonlarını ayrı ayrı tahmin etmek ve daha sonra oranını alarak önemini hesap

etmek olduğu görülmektedir. Ancak, olasılık yoğunluk fonksiyonu tahmini özellikle yüksek boyutlu durumlarda zor bir problem olarak bilinmektedir ve tahminlenen dağılımların oranının alınması hatanın yükselmesine neden olmaktadır. Bu nedenle, bu çalışmada yoğunluk olasılık yoğunluk fonksiyonlarını ayrı ayrı tahmin etmeden önem değerini tahminleyebilen KEKK-ÖU yöntemi [16] tercih edilmiştir.

$\widehat{D} \in R^d$ veri tanım kümesi olsun ve $\{x_i^{tr}\}_{i=1}^{n_{tr}}$ eğitim veri örneklerinin, $p_{tr}(x)$ hedef sınıfı ilişkin eğitim yoğunluk dağılımından ve $\{x_j^{te}\}_{j=1}^{n_{te}}$ test veri örneklerinin, $p_{te}(x)$ test yoğunluk dağılımından verilmiş olduğunu kabul edelim. Amaç, önem fonksiyonu $w(x)$ 'in $\{x_i^{tr}\}_{i=1}^{n_{tr}}$ ve $\{x_j^{te}\}_{j=1}^{n_{te}}$ kullanarak tahminini/kestirimini bulmaktır:

$$w(x) = \frac{p_{te}(x)}{p_{tr}(x)} \quad (5)$$

Burada temel kısıt, önem $w(x)$ 'in kestiriminde, yoğunluklar $p_{tr}(x)$ ve $p_{te}(x)$ 'in ayrı ayrı tahminlenmesinden kaçınılmasıdır. Önem $w(x)$, doğrusal bir model olarak aşağıda verildiği şekilde modellenebilir.

$$\widehat{w}(x) = \sum_{l=1}^b \alpha_l \varphi_l(x) \quad (6)$$

Burada, $\alpha = (\alpha_1, \alpha_2, \dots, \alpha_b)^T$, veri örneklerinden öğrenilecek parametreleri, T matris veya vektörün transpozunu, b baz fonksiyonlarının sayısını ve $\{\varphi_l(x)\}_{l=1}^b$, baz fonksiyonlarını temsil etmektedir. $\widehat{w}(x)$ modelindeki $\{\alpha_l\}_{l=1}^b$ parametreleri Denklem (7)'de verilen kare hata J_0 en azlanarak hesap edilebilir.

$$J_0(\alpha) = \frac{1}{2} \int (\widehat{w}(x) - w(x))^2 p_{tr}(x) dx \quad (7)$$

$$\begin{aligned}
 &= \frac{1}{2} \int \hat{w}(x)^2 p_{tr}(x) dx \\
 &- \int \hat{w}(x) w(x) p_{tr}(x) dx \\
 &+ \frac{1}{2} \int w(x)^2 p_{tr}(x) dx
 \end{aligned} \tag{8}$$

$$\begin{aligned}
 &= \frac{1}{2} \int \hat{w}(x)^2 p_{tr}(x) dx \\
 &- \int \hat{w}(x) p_{te}(x) dx \\
 &+ \frac{1}{2} \int w(x)^2 p_{tr}(x) dx
 \end{aligned} \tag{9}$$

$J_0(\alpha)$ 'da ki son terim sabittir ve bu nedenle gözardı edilebilir. İlk iki terimi J ile tanımlayalım. Bu durumda,

$$\begin{aligned}
 J(\alpha) &= \frac{1}{2} \int \hat{w}(x)^2 p_{tr}(x) dx \\
 &- \int \hat{w}(x) p_{te}(x) dx
 \end{aligned} \tag{10}$$

$$\begin{aligned}
 &= \frac{1}{2} \sum_{l,l'}^b \alpha_l \alpha_{l'} \left(\int \varphi_l(x) \varphi_{l'}(x) p_{tr}(x) dx \right. \\
 &\quad \left. - \sum_l \alpha_l \left(\int \varphi_l(x) p_{te}(x) dx \right) \right) \\
 &= \frac{1}{2} \alpha^T H \alpha - h^T \alpha
 \end{aligned} \tag{11} \tag{12}$$

'dir. Denklem (12)'de, H , $b \times b$ boyutlu bir matristir ve (l, l') 'inci elemanı

$$H_{l,l'} = \int \varphi_l(x) \varphi_{l'}(x) p_{tr}(x) dx \tag{13}$$

şeklinde yazılabilir. h , b boyutlu bir vektördür ve l' inci elemanı

$$h_l = \int \varphi_l(x) p_{te}(x) dx \tag{14}$$

'dir. J' de yer alan beklenenlere, empirik ortalamalar alınarak yaklaşıldığında,

$$\begin{aligned}
 \hat{J}(\alpha) &= \frac{1}{2n_{tr}} \sum_{i=1}^{n_{tr}} \hat{w}(x_i^{tr})^2 \\
 &- \frac{1}{n_{te}} \sum_{j=1}^{n_{te}} \hat{w}(x_j^{te})
 \end{aligned} \tag{15}$$

$$\begin{aligned}
 &= \frac{1}{2} \sum_{l,l'}^b \alpha_l \alpha_{l'} \left(\frac{1}{n_{tr}} \sum_{i=1}^{n_{tr}} \varphi_l(x_i^{tr}) \varphi_{l'}(x_i^{tr}) \right. \\
 &\quad \left. - \sum_l \alpha_l \left(\frac{1}{n_{te}} \sum_{j=1}^{n_{te}} \varphi_l(x_j^{te}) \right) \right)
 \end{aligned} \tag{16}$$

$$= \frac{1}{2} \alpha^T \hat{H} \alpha - \hat{h}^T \alpha \tag{17}$$

elde edilir. Burada, \hat{H} , $b \times b$ boyutlu bir matristir ve (l, l') 'inci elemanı

$$\hat{H}_{l,l'} = \frac{1}{n_{tr}} \sum_{i=1}^{n_{tr}} \varphi_l(x_i^{tr}) \varphi_{l'}(x_i^{tr}) \tag{18}$$

şeklinde elde edilmektedir. \hat{h} ise, b boyutlu bir vektördür ve l' inci elemanı

$$\hat{h}_l = \frac{1}{n_{te}} \sum_{j=1}^{n_{te}} \varphi_l(x_j^{te}) \tag{19}$$

'dir. Eğer negatif değer almama ($\alpha \geq 0_b$) kısıtı göz ardı edilirse aşağıda Denklem (20) ile verilen kısıtsız en iyileme problemi elde edilir.

$$\min_{\alpha \in R^b} \left[\frac{1}{2} \alpha^T \hat{H} \alpha - \hat{h}^T \alpha + \frac{\lambda}{2} \alpha^T \alpha \right] \tag{20}$$

Burada, $\alpha^T \alpha$ terimi karesel düzenlenştirme amacıyla denkleme dahil edilmiştir ve $\lambda (\geq 0)$ düzenlenştirme parametresidir. Denklem (20), kısıtsız dışbükey karesel programlama olduğundan dolayı çözüm, analitik olarak

$$\tilde{\alpha}(\lambda) = (\hat{H} + \lambda I_b)^{-1} \hat{h} \tag{21}$$

şeklindedir. Burada I_b , b boyutlu birim matristir. $\alpha \geq 0_b$ negatif olmama kısıtı gözardı edildiğinden bazı öğrenilen parametreler negatif elde edilebilir. Bu durumu deneleyebilmek amacı ile

$$\tilde{\alpha}(\lambda) = \max(0_b, \tilde{\alpha}(\lambda)) \tag{22}$$

olarak alınmıştır. Baz fonksiyonu olarak

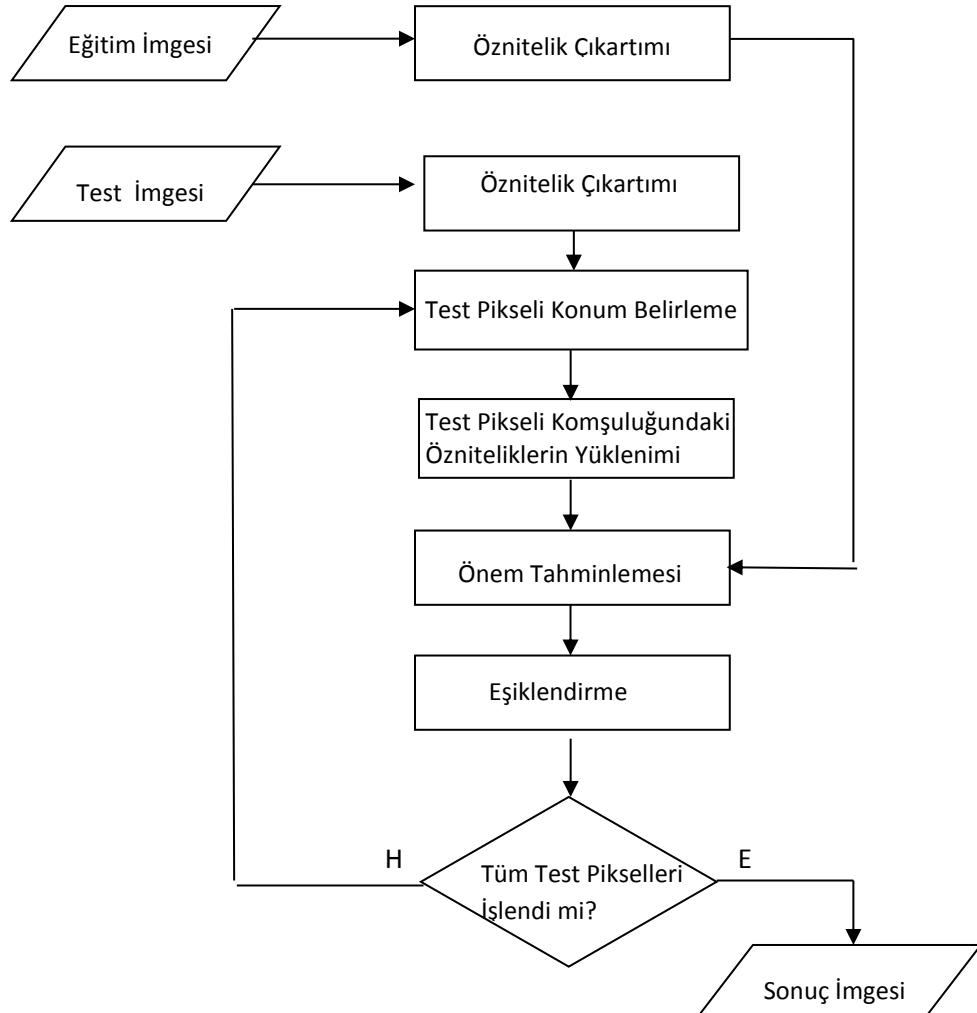
$$\varphi_l = \exp \left(- \frac{\|x - c_l\|^2}{2 \sigma^2} \right) \tag{22}$$

şeklinde tanımlanan Gauss fonksiyonu seçilmiştir. $\sigma > 0$ Gauss genişliği ve $c_l, \{x_i\}_{i=1}^{n_{te}}$ 'den rastgele seçilen Gauss merkezidir.

Önem değeri tahminlemesinde tercih edilen yöntem KEKK-ÖU, çekirdek genişliği σ ve düzenleme parametresi λ değerlerini birisi-dışarıda çapraz geçerlilik sınavası ile hesapsal karmaşıklık derecesini artırmadan en uygun değere ayarlayabilmektedir.

2.4 Önerilen Yöntem

Bölüm 2.3 'de verilen yöntem ile hesaplanan önem değeri, aşağıda verilecek algoritmada kullanılarak doku tanıma gerçekleştirilmiştir. Önerilen yöntem sonucu elde edilen ikili imgede beyaz pikseller hedef sınıfa (ilgilenilen doku) ilişkin bölgeleri temsil ederken siyah pikseller arkaplanı (/aykırı değerleri) temsil etmektedir.



Şekil 1. Önerilen yöntemin akış diyagramı

İmge I içinde bulunan doku D'yi bulmak için önerilen yöntem şu şekildedir: Öncelikle hedef sınıf eğitim seti oluşturulur. Bunun için hedef doku D'yi içeren bir alt imgeye ilişkin öznitelikler elde edilir. Daha sonra test görüntüsünde sınıflanmak istenen pikseli merkez alacak şekilde bir pencere seçilir ve bu pencere içindeki verilere ait öznitelikler bulunur. Test verisi ve eğitim verisi kullanılarak önem değeri tahminlenir. Tüm test pikselleri için bu adımlar tekrarlanır. İşlem sonunda, elde edilen önem değerlerine uygun bir eşik değeri bulunur. Eğer önem değeri, eşik değerinden daha yüksekse ilgili pikseli beyaz (/hedef sınıf) olarak değilse siyah (/arkaplan) olarak etiketlenerek ikili sonuç görüntüsü elde edilir. Önerilen algoritmanın akış şeması Şekil 1. 'de verilmiştir

Önerilen yöntemin sonucunu etkileyen parametrelerden bir tanesi seçilen pencere genişliği n 'dir. n değerinin küçük olması, dokuyu temsil eden yoğunluk dağılımının yeterli şekilde örneklenmemesi ile sonuçlanacaktır. n değerinin büyük seçilmesi ise yöntemin hesapsal zamanının artmasına neden olacaktır. Önem tahminlemesinde kullanılan temel baz fonksiyonlarının sayısı b , önerilen yöntemin bir başka serbest parametresidir. b değerinin az olması önem fonksiyonunun yeteri kadar baz fonksiyonu ile temsil edilememesine yol açarken bu sayının çok yüksek tutulması komplikasyonu arattığından performans üzerinde ters etki yaratabilmektedir. Seçilen eşik değerinin, sonuç ikili imgesi üzerinde etkisi vardır ve farklı yaklaşımalar sonucu hesaplanan eşik değeri, sonuç performansında farklılıklara neden olmaktadır. Ayrıca yanlış onaylanmış cevabı veren tek veya çok az piksel içeren bölgelerin, morfolojik işlemler gibi ek uygulamalar ile yok edilmesi mümkün olmakla birlikte bu çalışmada, doku alanının en doğru şekilde

bölütlenmesinden ziyade dokunun varlığının tespiti ile ilgilenildiğinden önerilen yöntemde bu tür yaklaşımalar eklenmemiştir. Parametre değişimlerinin sonuç üzerindeki etkileri Bölüm 3'de detaylı olarak incelenmiştir.

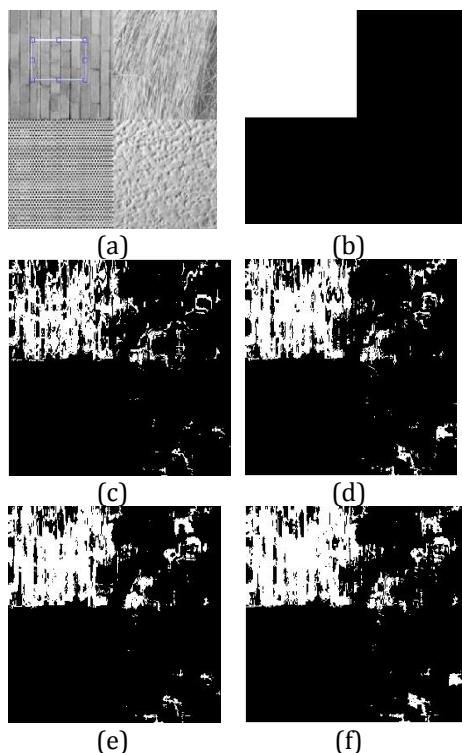
3. Deneysel Sonuçlar

KEKK-ÖU'nın doku tanıma probleminin çözümündeki etkinliğini test etmek için önerilen yöntem farklı doku örneklerine uygulanmıştır. Çalışmada kullanılan görüntüler, Brodatz Doku verisetinden alınmıştır [21]. Problem Matlab ortamında, 2,0 GHz Çift Çekirdekli Intel İşlemcili, 2 GB RAM'e sahip bir kişisel bilgisayarda gerçekleşmiştir. Ayrıca, elde edilen sonuçlar, yanında sıkılıkla tercih edilen Tek-Sınıf Destek Vektör Makinaları yöntemi ile karşılaştırılmıştır.

Önerilen yöntemin performansının değerlendirilebilmesi amacı ile farklı performans ölçütleri kullanılmıştır. Bunlar, Doğru Kabul Oranı (DKO), Doğru Reddetme Oranı (DRO), Kesinlik (KSN), Doğrululuk (DGR), F-ölçüm ve sınıflama için geçen hesaplama süresi (S) 'dır.

Önerilen yöntemin başarısının araştırılması amacı ile ilk aşamada yöntemde kullanılan baz fonksiyonlarının sayısı b 'nin performans üzerindeki etkisi incelenmiştir. Öncelikle hedef sınıfa ilişkin örnek pikseller, görüntü üzerinde işaretlenmiş ve ilgili öznitelik eğitim seti oluşturulmuştur. Önerdiğimiz yöntem ile elde edilen önem değerleri Otsu yöntemi [22] ile elde edilen eşik değeri ile karşılaştırılmış ve sonuca göre test pikseli hedef sınıfa veya arkaplan sınıfına atanmıştır. KEKK-ÖU yönteminde Birisi-Dışarıda Çapraz Doğrulama (BDÇD) değeri analitik olarak hesaplanabilmektedir. Bu özelliği nedeni ile BDÇD gerçeklemesi, hesapsal karmaşıklık olarak tek bir çözümün hesaplanması ile aynı dereceye sahiptir. Bu çalışmada da, bu avantajdan yararlanabilmek amacıyla KEKK-ÖU

yönteminin düzenlileştirme parametresi λ ve Gauss genişliği σ , BDÇD uygulanarak en optimal sonucu verecek şekilde bulunmuştur. Bulunan σ ve λ değerleri sırası ile 0,01 ve 0,001'dir.



Şekil 2 (a) Giriş imgesi ve hedef sınıfından seçilen eğitim veriseti, (b) istenen sonuç imgesi, kullanılan baz fonksiyon sayısı (c) $b=50$, (d) $b=100$, (e) $b=150$ ve (f) $b=200$ olduğu durumda elde edilen sonuç imgeleri.

Şekil 2 farklı baz fonksiyon sayıları için TSS'in çıkışlarını göstermektedir. Test verisi için kullanılan pencere genişliği n , 10'dur. Şekil 2(a)'da dört farklı dokuya içeren test giriş imgesi verilmiştir. Ayrıca eğitim seti olarak kullanılacak hedef doku bölgesi, giriş imgesi üzerinde sol üst doku içinde kutu içine alınmış alan olarak belirlenmiştir. İstenen sonuç imgesi, sadece sol üst dokuya ilişkin piksel

değerlerinde bir (hedef sınıf), diğer piksel bölgelerinde sıfır (hedef dışı sınıf) değeri vermelidir (Şekil 2(b)). Şekil 2(c)-(f), baz fonksiyon sayısının 50, 100, 150 ve 200 olduğu durumlar için elde edilen TSS sonuç imgelerini göstermektedir. Baz fonksiyon sayısı arttıkça hedef sınıf doğru bulma oranları artmaktadır. Bu duruma paralel olarak yanlış kabul değerlerinde de azalış gözlemlenmektedir. Sonuçların daha iyi değerlendirilebilmesi amacıyla hata matrisleri de hesaplanmıştır ve Şekil 3 'te verilmiştir. Burada, sütunlarda yer alan Kabul ve Ret istenen çıkışları, sütunlarda yer alan Doğru ve Yanlış uygulanan yöntemin bulmuş olduğu çıkış değerlerini temsil etmektedir. Doğru kabul değerleri $b=50$ için 8502, $b=100$ için 10070, $b=150$ için 10479 ve $b=200$ için 11247'dir. En iyi değerin baz fonksiyon sayısının artması ile elde edilebileceği gözlemlenmekte birlikte yapılan deneylerde baz fonksiyon sayısının 200 değerinden daha yüksek değerlere çekilmesi doğru kabul değerlerinde önemli bir değişikliğe yol açmamıştır. Yanlış kabul değerleri $b=50$ için 7882, $b=100$ için 6314, $b=150$ için 5905 ve $b=200$ için 5137'dir. Baz fonksiyon sayısının artması yanlış kabul değerlerinin düşmesine neden olmaktadır. Bununla birlikte, b değerinin artması doğru ret oranlarında da düşüse neden olmaktadır. Sonuçların daha bütüncül incelenmesi amacıyla hata matrislerinden elde edilen DKO, DRO, KSN, DĞR ve F-ölçüm değerleri Tablo 1'de verilmiştir. Sonuçlar incelendiğinde, önem tahminlemede kullanılan baz fonksiyon sayısının artması, doğru kabul oranını düşürmekle birlikte doğru ret oranını, kesinliği, doğruluğu ve F-ölçüm değerlerini artırmaktadır. Örnek olarak F-ölçüm değeri $b=50$ için 0,645, $b=100$

İçin $0,708$, $b=150$ için $0,724$ ve $b=200$ için $0,747$ 'dir. Baz fonksiyon sayısının artışı ile hesaplama süresinde de belirgin artışlar oluşmuştur. $b=50, 100, 150$ ve 200 değerleri için geçen hesaplama süreleri sırası ile $0,758, 1,341, 1,983$ ve $2,917$ saniyedir. Elde edilen sonuçlar, beklenildiği üzere, sınıflama başarımı ve hesaplama süresi arasında bir ö dünlüşme olduğunu göstermektedir.

	Kabul	Ret
Doğru	8502	7882
Yanlış	1453	47699

(a)

	Kabul	Ret
Doğru	10070	6314
Yanlış	1961	47191

b)

	Kabul	Ret
Doğru	10479	5905
Yanlış	2071	47081

(c)

	Kabul	Ret
Doğru	11247	5137
Yanlış	2476	46676

d)

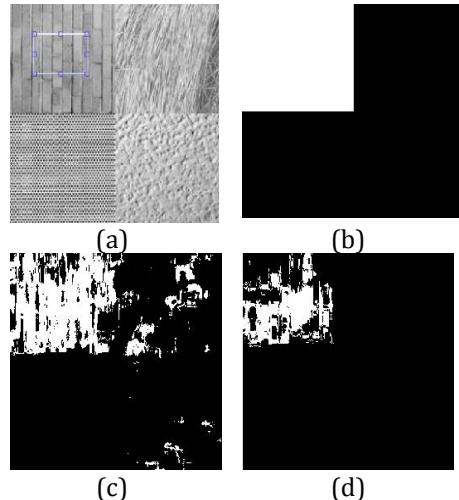
Şekil 3 Kullanılan baz fonksiyon sayısı (a) $b=50$, (b) $b=100$, (c) $b=150$ ve (d) $b=200$ için elde edilen hata matrisleri.

Tablo 1. Farklı baz fonksiyon sayılarına sahip KEKK_ÖÜ yönteminin performansı

	$b=50$	$b=100$	$b=150$	$b=200$
DKO	0,854	0,837	0,831	0,819
DRO	0,858	0,881	0,888	0,900
KSN	0,518	0,614	0,639	0,686
DĞR	0,857	0,873	0,878	0,883
F-ölçüm	0,645	0,708	0,7224	0,747
S (sn)	0,758	1,341	1,983	2,917

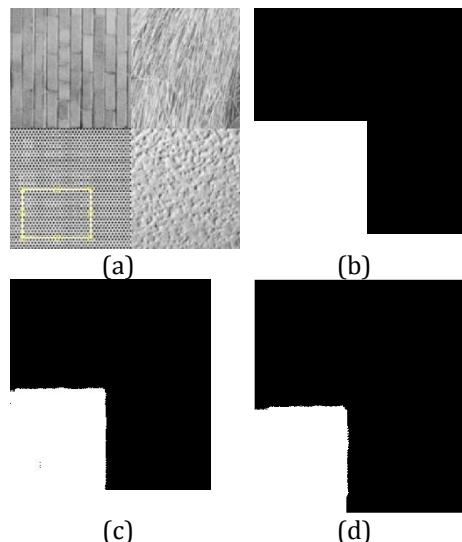
Yöntemin farklı pencere genişliklerine gösterdiği tepki, $b=150$ durumu için Şekil 4 'de verilmiştir. Bölüm 2 'de açıklandığı gibi her bir test pikseli için test pikselinin yakın komşuluğundaki piksellere ilişkin öznitelik dağılım fonksiyonunun, hedef sınıf dağılım fonksiyonuna oranı tahminlenmektedir. Beklendiği üzere, dağılım fonksiyonunu temsil edecek veri sayısı arttıkça doğru kabul değeri artmaktadır. Hedef sınıf, Şekil 4(a)'da verilen imgenin sol üst bölgesinde yer alan dokudur. Dolayısı ile istenen sonuç

imgesi Şekil 4(b) 'de verildiği gibidir. Pencere genişliği $n=10$ ve $n=20$ için elde edilen sonuç imgeleri Şekil 4(c) ve Şekil 4(d)'de gösterilmiştir. Pencere genişliğinin artmasının, diğer sınıf dokuların hedef sınıfından ayırt edilmesinde etkin bir rolü olduğu görülmektedir. $n=20$ için DKO 1, DRO 0,811, KSN 0,302, DĞR 0,825 ve F-ölçüm 0,464'tür (Tablo 2). Elde edilen sonuçlar, $n=10$ olduğu durumla karşılaştırıldığında DKO oranını, yüksek pencere genişliğinin artırıldığı görülmektedir. Diğer ölçütlerde ise azalmaya neden olmuştur. Yoğunluk dağılımlarının hesaplanmasıında çok daha fazla sayıda örnek kullanılmasından dolayı hesaplama süresinde belirgin artışlar olmuş ve süre 2,434 saniyeye ulaşmıştır. KEKK-ÖÜ yönteminin sonuçları, farklı hedef dokular ile de incelenerek yöntemin başarımı araştırılmıştır. Şekil 5'de hedef doku olarak dört farklı dokudan sol alt bölgede yer alan doku (Şekil 5(a)), hedef sınıf olarak seçilmiş ve kutu içine alınan pikseller eğitim setini oluşturmuştur. $n=10$ ve $n=20$ için elde edilen sonuç imgeleri Şekil 5(c) ve Şekil 5(d)'de verilmiştir. Her iki durum için de DKO birdir. F-ölçüm değeri $n=10$ için 0,954 iken $n=20$ için 0,886'dır.



Şekil 4 (a) Giriş imgesi ve hedef sınıfından seçilen eğitim veriseti , (b) istenen sonuç

imgesi, test pikseli için kullanılan pencere genişliği (c) $n=10$, (d) $n=20$ için elde edilen sonuç imgeleri.



Şekil 5 (a) Giriş imgesi ve hedef sınıfından seçilen eğitim veriseti , (b) istenen sonuç imgesi, test pikseli için kullanılan pencere genişliği (c) $n=10$, (d) $n=20$ için elde edilen sonuç imgeleri.

Tablo 2. KEKK-ÖÜ ve TS-DVM yöntemlerinin performansları

Şekil 4		Şekil 5	
KEKK_ÖÜ	TS_DVM	KEKK_ÖÜ	TS_DVM
DKO	1 1	1 1	
DRO	0,811 0,800	0,936 0,895	
KSN	0,302 0,252	0,795 0,650	
DĞR	0,825 0,813	0,948 0,912	
F-ölçüm	0,464 0,402	0,886 0,787	
S(sn)	2,434 3,355	2,216 4,744	

Önerilen tek-sınıf sınıflayıcı KEKK_ÖÜ'nün başarısının değerlendirilmesi amacıyla elde edilen sonuçlar, yanında sıkılıkla kullanılagelen ve güçlü bir algoritma olarak kabul gören TS-DVM yönteminin sonuçları ile karşılaştırılmıştır. TS-DVM yönteminde

baz fonksiyonu olarak gauss fonksiyonu seçilmiştir. Bu yöntemde serbest parametreleri olan aykırı değer oranı ve Gauss çekirdek genişliği, ızgara arama yöntemi ile en optimal sonucu verecek şekilde bulunmuştur. Uygulanan aykırı değer oranı 0,1 ve gauss çekirdek genişliği 1'dir. Önerilen yöntem KEKK_ÖÜ ve TS_DVM sonuçları Şekil 4(a) ve Şekil 5(b) de belirtilen hedef dokular için Tablo 2'de verilmiştir. Burada KEKK_ÖÜ için uygulanan pencere genişliği, n , 20 ve kullanılan baz fonksiyon sayısı, b , 150'dir. Her iki farklı hedef sınıf durumu için DKO birdir. Şekil 4(a) da verilen hedef sınıf için KEKK_ÖÜ yönteminin sonuçlarına göre DRO 0,811, KSN 0,302, DĞR 0,825 ve F-ölçüm 0,464'tür. Aynı hedef sınıf için TS_DVM sonuçlarına göre DRO 0,800, KSN 0,252, DĞR 0,813, F-ölçüm 0,464'dür. Sonuçlar, her ölçütte önerilen yöntemin TS_DVM'e göre daha iyi sonuçlar verdiği göstermektedir. Şekil 5(a) da gösterilen diğer hedef sınıf için de sonuçlar incelemiş ve doğru reddetme oranı KEKK_ÖÜ için 0,936 TS_DVM için 0,895 olarak, kesinlik KEKK_ÖÜ için 0,795 TS_DVM için 0,650 olarak, doğruluk KEKK_ÖÜ için 0,948 TS_DVM için 0,787 olarak ve F-ölçüm, KEKK_ÖÜ için 0,936 TS_DVM için 0,895 olarak bulunmuştur. Sonuçlar, bu hedef sınıf için de önerilen yöntemin daha iyi sonuçlar verdiği göstermektedir. KEKK_ÖÜ yöntemi farklı hedef sınıflar için 2,432 sn ve 2,216 sn sürerken TS_DVM 3,355 ve 4,744 -sn sürmektedir. İki yöntem süre yönünden incelendiğinde önerilen yöntemin daha hızlı olduğunu göstermektedir. Burada belirtmek isteriz ki TS_DVM yönteminin hesaplama süresinde, uygulanan gauss çekirdek genişliğinin otomatik aranması da etkilidir.

4. Tartışma

Bu makalede, iki yoğunluk fonksiyonu arasındaki oran olan önem değerine dayanan bir tek-sınıf sınıflayıcı yöntemi önerilmiştir. Önem değeri hesabında, hedef ve test sınıfı yoğunluk

fonksiyonlarının ayrı ayrı tahminlenmesinden kaçınılmış ve yüksek boyutlarda da başarılı sonuçlar veren KEKK_ÖÜ tercih edilmiştir. Önerilen yöntemin başarımı, doku sınıflama probleminde uygulanmış ve önem tahminlemeye dayalı bir TSS yönteminin kullanışlı olduğu gösterilmiştir. Önerilen yöntemde, önem değeri tahminlemesinde kullanılan baz fonksiyonlarının sayısı ve yoğunluk fonksiyonlarında kullanılan veri sayısının etkin olduğu ve en iyi sonucu verecek şekilde dikkatli bir şekilde seçilmesi gerektiği görülmüştür. Elde edilen sonuçlar, literatürde referans yöntem olarak kullanılan tek-sınıf destek vektör makinaları ile karşılaştırılmıştır. Sonuçlar, önerilen yöntemin daha az hesaplama süresinde daha yüksek tek sınıf sınıflama performansı verdiği göstermektedir.

Önerilen yöntemin daha da hızlandırılabilmesi için test pikseli komşuluğundaki tüm piksellerin kullanımı yerine k-ortalama benzeri bir öbekleme yöntemi ile veri sayısının azaltılmasının etkin olabileceği düşünülmektedir. Bu konuda ilerde yapılabilecek bir incelemenin yanısıra sadece bir test pikseli özeline dönen önem değeri yerine farklı uzamsal ölçeklerde alınmış test bölgesine ilişkin önem değerlerinin hiyerarşik bir yapı ile incelenmesi de bir sonraki araştırma konuları arasındadır.

Kaynakça

- [1] Tax, D. M.J. 2001. One-Class Classification. TU Delft, Delft University of Technology.
- [2] Maglaras, L. A., Jiang, J., Cruz, T. 2014. Integrated OCSVM mechanism for intrusion detection in SCADA systems. Electronics Letters, Cilt: 50(25), s. 1935-1936.
- [3] Guerbai, Y., Chibani, Y., Hadjadj, B., 2015. The effective use of the one-class SVM classifier for handwritten signature verification based on writer-independent parameters, Pattern Recognition, Cilt 48, s. 103-113.
- [4] Guillermo, L.G. , Lucas, C.U., Pablo M.G. 2013. Abrupt Change Detection with One-Class Time-Adaptive Support Vector Machines, Expert Systems with Applications, Cilt 40, s. 7242-7249.
- [5] Hyun, J.S., Dong-Hwan, E., Sung-Shick, K., 2005. One-class Support Vector Machines—An Application In Machine Fault Detection and Classification, Computers and Industrial Engineering, Cilt 48, s. 395-408.
- [6] Ciesielski, V., Phuong Ha V. 2009, Texture Detection Using Neural Networks Trained on Examples of One Class, s.140-149, Nicholson, A., Li, X. ed. 2009, LNAA 5866, Springer-Verlag Berlin Heidelberg.
- [7] Sanchez-Yanez, R.E., Kurmyshev, E.V., Fernandez, A. 2003. One-class texture classifier in the CCR feature space, Pattern Recognition Letters Cilt. 24, s. 1503–1511
- [8] Chen, C.H. (Ed.), 2015. Handbook of pattern recognition and computer vision. World Scientific.
- [9] Demir, G.K. 2017, A Spectral Graph Theoretical Approach to Oriented Energy Features, International Journal of Pattern Recognition and Artificial Intelligence, Cilt. 31, s. 1755001_1 – 1755001_27.
- [10] Depeursinge, A., Püspöki, Z., Ward, J. P., & Unser, M. 2017. Steerable wavelet machines (SWM): learning moving frames for texture classification. IEEE Transactions on

- Image Processing, Cilt 26, s. 1626-1636.
- [11] Scholkopf, J., Platt, J., Shawe-Taylor, J., Smola, A., Williamson, R. 2001, Estimating the Support of a High-Dimensional Distribution. Neural Computation, Cilt 13, s.1443-1471.
- [12] Erfani, S. M., Rajasegarar, S., Karunasekera, S., & Leckie, C. 2016. High-dimensional and large-scale anomaly detection using a linear one-class SVM with deep learning. Pattern Recognition, Cilt 58, s. 121-134.
- [13] Gondra, I., Heisterkamp, D., Peng, J. 2004, Improving Image Retrieval Performance by Inter-query Learning with One-class Support Vector Machines, Neural Computing and Applications, Cilt 13, s. 130-139
- [14] Breunig, M.M., Kriegel,H.P., Ng.R.T., Sander J. 2000, Lof: Identifying Density-Based Local Outliers, ACM Sigmod Record, Cilt 29, s. 93-104.
- [15].Hempstalk, K., Frank, E., Witten, I.H., 2008, One-Class Classification by Combining Density and Class Probability Estimation, Daelemans, W., Goethals, B., Morik, K. ed. Machine Learning and Knowledge Discovery in Databases. ECML PKDD 2008. Lecture Notes in Computer Science, Cilt 5211, Springer, Berlin, Heidelberg.
- [16] Kanamori, T., Hido, S., Sugiyama, M. 2009, A least-squares approach to direct importance estimation, Machine Learning Research, Cilt 10, s.1391-1445.
- [17] Haralick,R.M., Shanmugam, K., Dinstein, I. 1973, Textural Features for Image Classification, IEEE Transactions on Systems, Man and Cybernetics, Cilt 3, s. 610-621.
- [18] Hido, S., Tsuboi, Y., Kashima, H., Sugiyama, M., Kanamori, T. 2011, Statistical Outlier Detection Using Direct Density Ratio Estimation, Knowledge and Information Systems, Cilt 26, s. 309-336.
- [19] Liu, S., Yamada, M., Collier, N., & Sugiyama, M. 2013. Change-point detection in time-series data by relative density-ratio estimation. Neural Networks, Cilt 43, s. 72-83.
- [20] Balzi, A., Yger, F., & Sugiyama, M. 2015. Importance-weighted covariance estimation for robust common spatial pattern. Pattern Recognition Letters, Cilt 68, s. 139-145.
- [21] Brodatz, P. 1966, Textures: A Photographic Album for Artists and Designers, Dover, Newyork.
- [22] Otsu, N. 1979, A Threshold Selection Method from Gray-Level Histograms, IEEE Transaction on Systems Man and Cybernetics, Cilt. 9, s. 62-66.