

Biyomedikal Görüntülerde Derin Öğrenme ile Mevcut Yöntemlerin Kıyaslaması

Mesut TOĞAÇAR^{1*}, Burhan ERGEN²

¹ Bilgisayar Teknolojileri Programı, Teknik Bilimler Meslek Yüksekokulu, Fırat Üniversitesi, Elazığ, Türkiye

² Bilgisayar Mühendisliği, Mühendislik Fakültesi, Fırat Üniversitesi, Elazığ, Türkiye

*¹ mtogacar@firat.edu.tr, ² bergen@firat.edu.tr

(Geliş/Received: 26/04/2018;

Kabul/Accepted: 07/12/2018)

Özet: Son zamanlarda görüntü işleme ile ilgili gelişmeler, hızla gelişen teknolojik sistemlerin ilerlemesinde katkıda bulunmuştur. Özellikle sağlık alanındaki görüntü işleme ile ilgili çalışmaların popülerliğini daha da artırmıştır. Gerek tıbbi görüntüler olsun gerekse diğer alandaki görüntüler olsun, mevcut yöntemler üzerinde başarı sağlatılmasına rağmen; derin öğrenme modeli, mevcut yöntemlere kiyasla zaman ve performans açısından daha fazla katkıda bulunan bir modeldir. Mevcut yöntemler ile tek katmanlı görüntüler üzerinden işlem yapılyorken, derin öğrenme modeliyle, çok katmanlı görüntüler üzerinden performansı yüksek sonuçlar alınabilmektedir. Derin öğrenmenin en önemli özelliği, görüntü üzerindeki işlemleri tek bir sefer de işleme tabi tutan ve el ile girilmesi gereken parametreleri kendi kendine keşif edebilmesidir. Ayrıca teknoloji firmalarının da derin öğrenmeye yönelik, kendi aralarında rekabet gücünü artırdığı gibi, bilimsel anlamda derin öğrenme üzerine kurdukları yöntemler, mevcut yöntemlere göre daha fazla tercih edilmeye başlanılmıştır. Veri kümesi erişimi sınırlı olan alanlardan biri olan biyomedikal alanında veri kümelerinin son zamanlarda hızlı bir şekilde elde edilmesi bu alandaki görüntü işleme çalışmalarına, derin öğrenme modeliyle beraber daha çok katkıda bulunacağı öngörmektedir.

Anahtar kelimeler: KSA, derin öğrenme, görüntü işleme, biyomedikal, biyomedikal görüntüler

Comparison of Deep Learning and Existing Methods in Biomedical Imagery

Abstract: Recent developments in image processing have contributed to the advancement of rapidly developing technological systems. In particular, work on image processing in the health field has further increased its popularity. Whether it is medical images or images on the other side, although the success of existing methods is ensured, the deeper learning model is a model that contributes more in terms of time and performance compared to existing methods. High-performance results can be obtained on multi-layered images with deep learning model while the existing methods are operated on single layer images. The most important feature of deep learning is that it can process the operations on the image in a single pass and discover the parameters that need to be entered manually. Moreover, as technology companies try to deepen their learning and increase their competitive power among themselves, the methods they have built on deep learning in the scientific sense have begun to be preferred over existing methods. It is envisaged that the data sets in the biomedical field, which is one of the limited access areas of the dataset, to be obtained quickly in the recent times will contribute more to the image processing studies in this area together with the deep learning model.

Key words: CNN, deep learning, image processing, biomedical, biomedical imaging

1. Giriş

Görüntü işleme, insan gözünün yaptığı işlevleri bilgisayar ortamında çeşitli ara yüz yazılımlarıyla hızlı sonuçlar alan bir teknolojidir. Bu teknolojide çeşitli modeller geliştirilmiş ve bu modeller, yapılan bilimsel çalışmalar da katkıda bulunmuştur. Görüntü işleme ve kümeleme yöntemleri kullanılarak, imge üzerinde; şekil algılama, etiketli sınıflandırma, şekil ayırma, alt sınıflara yapılandırma gibi birçok kategoride analizler yapılmaktadır [1]. Yapılan bu analiz sonuçlarında en çok tercih edilen model makine öğrenmenin alt dalı olan derin öğrenme modelidir. Makine öğrenme yöntemine göre çok katmanlı bir yapıya sahip olan ve insan beyinin işleyişinden esinlenen derin öğrenme, son zamanlarda artan ilgi görüyor [2].

Görüntü işleme uzmanları, üniversitelerdeki akademisyenler; videoyu analiz etme, analiz sonucu elde edilen görüntüyü sınıflandırma, doğal dil öğrenme vb. uygulama alanlarında makine öğrenmesini kullanmaktadır. Bu süreçte makine öğrenmesi, özellikle devrim niteliğinde hızlı ve yüksek performanslı sonuçlar elde edebilmek

* Sorumlu yazar: mtogacar@firat.edu.tr. Yazarların ORCID Numarası: ¹ 0000-0002-8264-3899, ² 0000-0003-3244-2615

icin "Grafik İşlemci Ünitesi" (GİÜ) kullanmaktadır. GİÜ'ler "Merkezi İşlem Birimi" (MİB)'ler ile karşılaşıldığında, GİÜ'ler uygulamalarında 10 ile 100 kat arasında performans üstünlüğüne sahip olduğu için tercih edilmektedir. Özellikle, Yapay Sinir Ağı(YSA) mimarisinde gizli ağlar ile ağlar derinleştirilmiştir. Bu da çok fazla bellek tüketimi anlamına gelmek demektir. Belleğin fazla tüketimi hem zamansal hem de performans açısından yeterli donanıma sahip olunmasıyla karşılanabilir. O yüzden MİB yerine GİÜ'ler tercih edilmektedir.

Derin Öğrenme, etiketlenmiş imgeler içeren eğitim setlerinde kendiliğinden özellik çıkarma işlemini birebilen, makine öğrenmesinin aksine çok katmanlı sinir ağlarını bir arada kullanmasını sağlayan sistemin adıdır. Görüntü ve ses analizi, robot teknolojisi, uzaktan algılama, genetik analizler, kanser ve hastalık teşhis vb. birçok alanda kullanılmaya başlandı. Çok fazla tercih edilmesinin sebebi hızlı ve yüksek sonuçlar verebilmesidir. Bu durum bazen insan ölçütlerinin bile üzerine çıkmıştır. Bu alanlarda özellikle büyük firmaların(Google, Facebook, Samsung, Microsoft, Intel vs.) yatırımları ve çalışmaları yoğun bir şekilde sürdürmektedir [3].

Günümüzde her alanda kullanılan kamera sayısının artması ve kameralarda elde edilen imgeler içerisinde yer alan objelerin tespitini aynen insan gözü gibi makinelerle anlamlı hale getirilmesi; makinelerin görüntü işleme konusunda derin öğrenme modeliyle inanılmaz sonuçlar elde edilmesini sağlamıştır. Bu sayede binlerce imgeler setleri derin öğrenme modeliyle, oldukça başarılı sonuçlar ortaya koymuştur [4].

Görüntü işleme üzerinde çalışma yapan akademisyenler, son yıllarda biyomedikal alanında yapılan görüntü işlemeyle ilgili çalışmalarla yoğunlaşmış olup; model olarak ta derin öğrenme üzerindeki faaliyetleri artırmıştır. Derin öğrenme modeline ilgi görülmüşenin en önemli bir diğer sebebi ise, yeteri kadar eğitlecek verinin bulunması ve bu verilerin işlenmesinde gerekli fiziksel alt yapının hazır olmasıdır.

Bu makalede, çeşitli firmalar tarafından desteklenen derin öğrenme modellerinin, biyomedikal alanında mevcut mimarilerle kıyaslanmasına değindi. Biyomedikal alanına yoğunlaşmasının en önemli sebepleri: "Bu alanda elde edilen veri kümelerinin geçmişe nispeten hızlı bir şekilde daha kolay elde edilebilmesi; klasik yöntemlere kıyasla derin öğrenme modeliyle birlikte yeni bir çözüm yöntemi bulunmasıdır. Ayrıca, biyomedikal alanında derin öğrenme modellerine ait geçmiş bilgilerin fazla olmaması; sağlık gibi insan hayatını önem arden bir alanda çeşitli hastalıkların görüntü işleme üzerinde daha hızlı ve yüksek oranda tespit edilmesi", gibi nedenleri sıralanabilir. Biyomedikal alanında yapılan çalışmaları incelemeden önce, derin öğrenme modelleri ve ilgili kütüphaneleri hakkında kısa bilgiler vermektedir.

2. Derin Öğrenme Kütüphaneleri

Derin öğrenme, birçok alanda büyük atılımlara yol açtı. Tabii bunu sağlayan en önemli etken, derin öğrenme üzerinde çeşitli programlama dillerinde (Java, C#, C++, Python vb.) yazılmış birçok kütüphane dosyasının olmasıdır. "TensorFlow, Lasagne, Keras, MXNet, Caffe, Torch vs." en çok tercih edilen kütüphanelerdir. Bu kütüphaneler, çok katmanlı sinir ağları (KSA), tekrarlanabilen sinir ağları(RNN), ileri besleme ağları gibi birçok derin öğrenme modellerini desteklemektedirler.

Caffe: Derin öğrenme ve görüntü işleme üzerine yazılmış bir kütüphanedir. Python ve Matlab gibi uygulama dillerinde de çalıştırılabilir. Önceden eğitilmiş modellere sahip olması Caffe kütüphanesinin en önemli özelliğiştir [5].

Keras: Python programlama dili üzerine yazılmış yüksek seviyeli bir derin öğrenme kütüphanesidir. En önemli özelliği TensorFlow Kütüphanesi üzerinde de çalışabiliyor olmasıdır [4].

TensorFlow: Google firması tarafından desteklenen açık kaynak kodlu bir derin öğrenme kütüphanesidir. GİÜ'ler üzerinde derin ağ kurmayı kolaylaştırır. Genelde görüntü işlemede sayısal hesaplamalar için tercih edilir [6].

Torch: En karmaşık problemleri bile basitleştirip, problemin çözümüyle ilgili algoritmayı hızlı ve esnek bir yapıda hazırlayan kütüphanedir. Torch ile görüntü işleme, ses işleme, video, resim vb. formatlar üzerinde çalışma yapılabilir. Desteklendiği programlama dilleri Lua ve Python'dur.

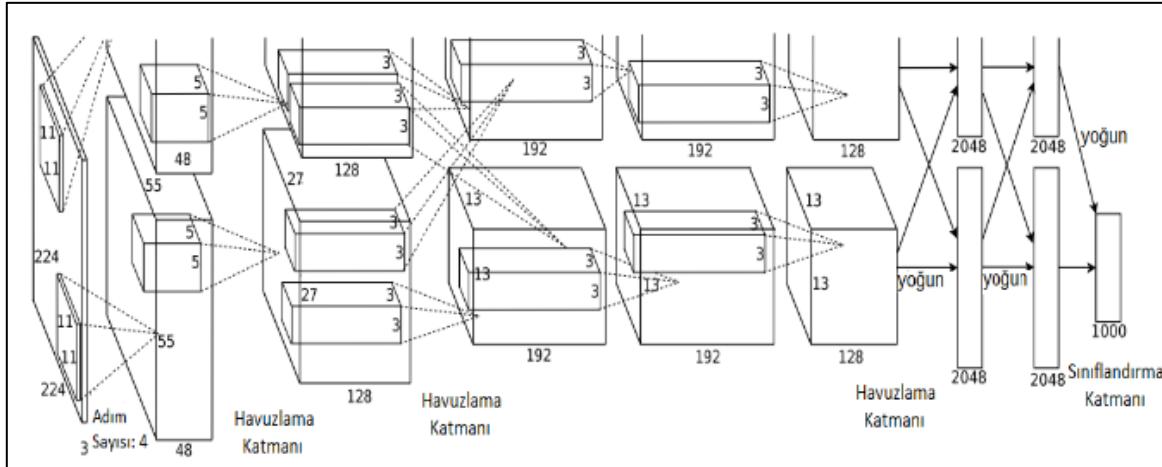
MXNet : R, Python, Scala, Julia gibi programlama dilleri tarafından desteklendiği için bu kütüphane, çok dil desteği sunulan kütüphane olarak bilinir. Bu sayede, yapılan çalışmayı farklı programlama dillerinde karşılaştırma imkânına sahip olunur.

3. Derin Öğrenme Modelleri

Derin Öğrenme, özellikle ImageNet'in 2012 yılından bu yana düzenlediği yarışmalarla daha da ilgi görmeye başladı ve düzenlenen yarışmalarda görüntü sınıflandırmasında derin öğrenme modelleri tercih edilmeye başlandı. Popüler olan bu modeller hakkında ön bilgiler vermek gereklidir:

3.1 AlexNet

2012 yılında ImageNet yarışmasında adını duyuran; yaklaşık bir milyon üstü resim ile eğitilmiş olup, resimleri sınıflandırma başarısı oldukça yüksek olan bir derin öğrenme modelidir. Bu model bin adet objeyi sınıflandırmak için modellenmiştir [8].

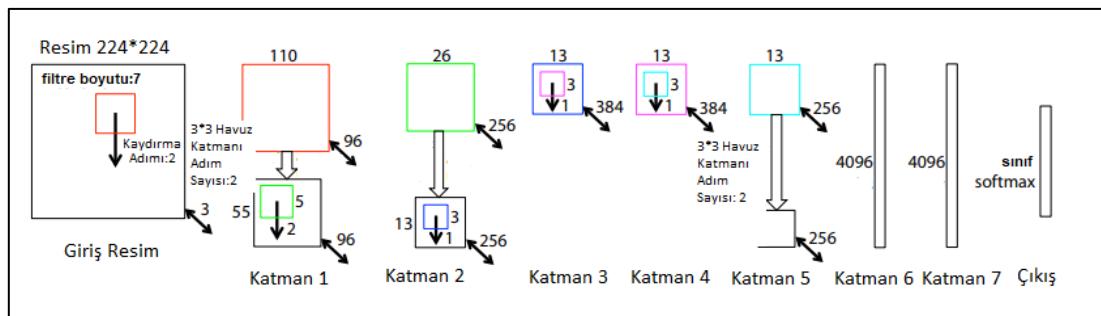


Şekil 1. AlexNet mimarisi [8]

AlexNet mimarisi; 224×224 boyutlu resimde, adım kayma sayısı 4 olarak olup, filtre boyutu 11×11 seçilmiştir. Mimari; konvansiyonel katman, havuz katmanı ve tam bağlantılı katmandan meydana gelmektedir [8].

3.2 ZF Net

Bu model AlexNet modelden esinlenerek tasarlanmıştır, AlexNet'e göre daha iyi sonuçlar alınmıştır. 2013 yılında ImageNet yarışmasında birinci olmuştur. AlexNet'e göre farkı; filtre boyutunu 7×7 ve adım sayısını 2 almıştır. Ayrıca, “Çapraz Entropi”, “Olasılıksal Eğim İniş” ve “ReLU” algoritmalarını kendi mimarisinde kullanmıştır. ZF Net mimarisi 7 katmandan oluşmaktadır [9].

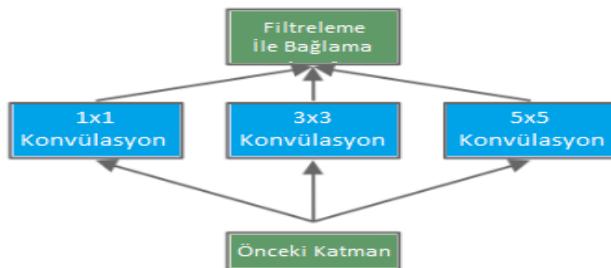


Şekil 2. ZF Net mimarisi [9]

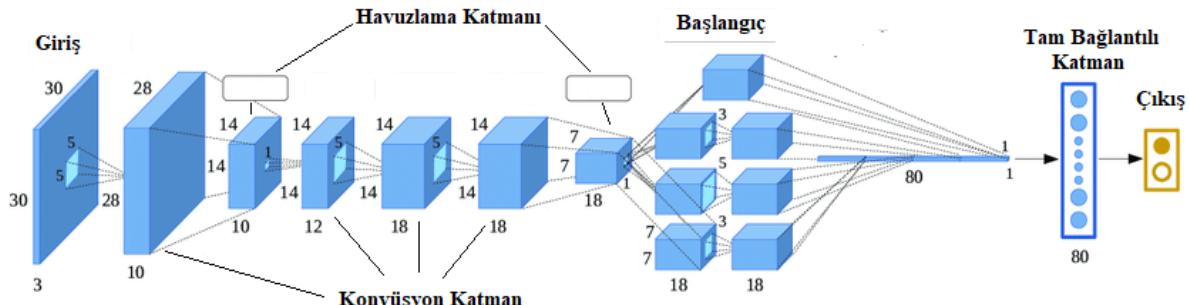
3.3 GoogLeNet

ImageNet 2014 resim sınıflandırma yarışmasında birinci olmuştur. 2012 yılında girdiği ImageNet yarışmasında %89.06 başarı oranını, 2014 yılında %93.33' e çıkarmıştır. GoogLeNet mimarı yapısı 22 katmandan oluşmaktadır ve bu mimari, katman sayısının artırılması ile veri kümelerinin çok fazla olması sınıflandırma işleminin performansını artırdığını ispatlamıştır. Büyük boyutlu resimlerin aşırı yüklenmesini önlemek içinde “ 1×1 , 3×3 , 5×5 ” gibi çeşitli boyutlarda aynı zaman diliminde resimleri filtrelerden

geçirmektedir. Şekil 3' e bakınız [10]. Bu mimari, önceki mimarilerin aksine, oluşturduğu katmanları üst üste yığmaktadır, paralel bir şekilde resimleri işliyor. Çünkü üst üste yığılan işlemler için bellek boyutu artırımı, zaman kaybı vb. olumsuz faktörleri de göz önünde bulundurmuştur. GoogLeNet ağ mimari yapısı ise Şekil 4' te verilmiştir.



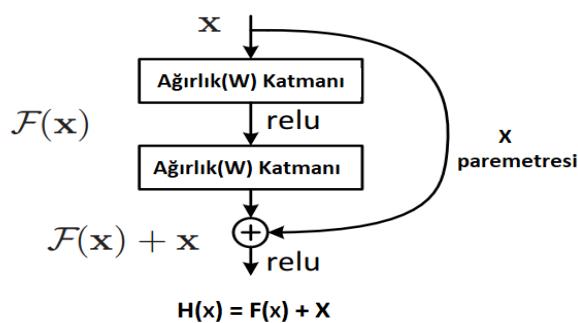
Şekil 3. GoogLeNet başlangıç modülü [10]



Şekil 4. GoogLeNet mimari yapısı

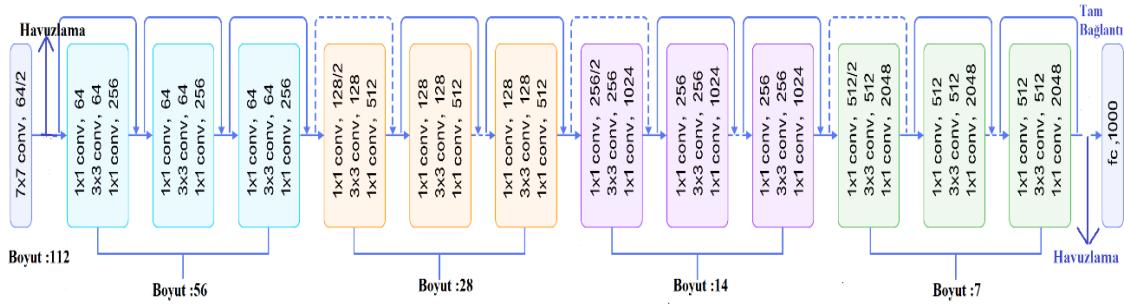
3.4 Microsoft ResNet

ResNet mimarisi, diğer mimari yapılarına göre daha fazla katman içermekte ve yapısında 152 adet katman bulunmaktadır. Katman sayısı GoogLeNet mimarisine göre neredeyse 7 kat fazla katman parametresi içermektedir. 2015 yılında yapılan ImageNet resim sınıflandırma yarışmasında ResNet birinci olmuştur. İnsan hata oranı %5-10 arası olarak kabul edilirken, ResNet 2015 yılında yapılan yarışmada bu oranı %3.57' ye düşürmüştür [11]. Bu mimarinin yapısında "Residual" bloklar bulunmaktadır. Bu blokların iç yapısı Şekil 5' de, ResNet mimari yapısı ise Şekil 6' da gösterilmiştir. Bu mimaride her katman arası Şekil 5' de ifade edilen şekilde girilen " \times " değerine karşılık elde edilen " $f(x)$ " değeri ile birleştirilip bir sonraki katmana aktarımı sağlanıyor.



Şekil 5. ReLu blok yapısı [11]

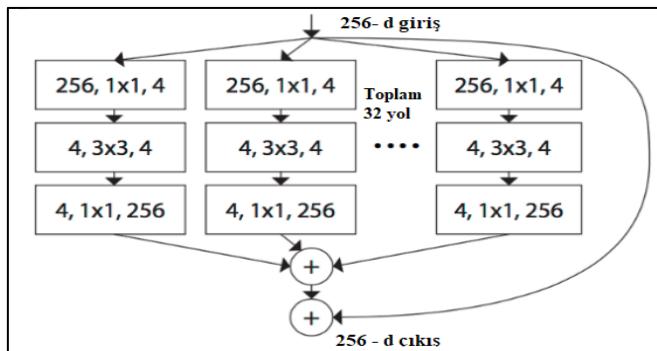
Şekil 5' de de anlaşıldığı gibi “ \times ” girişi ağırlık(W) katmanlarından geçerek bir “ $F(\times)$ ” sonucu elde edilmektedir ve işlem bittiğinde “ \times ” parametresi üzerine “ $F(\times)$ ” parametresi ilave ediliyor [11].



Şekil 6. ResNet mimari yapısı [11]

3.5 ResNeXt modeli

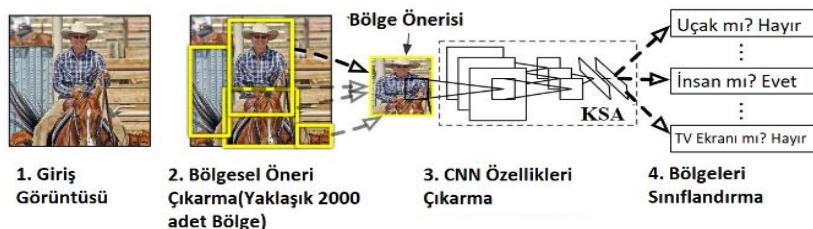
Bu model, Facebook yazılım şirketi tarafından geliştirilmiş derin öğrenmeyle resimleri sınıflandıran modeldir. Resim girdileri bir kaç özel filtre yöntemiyle (1×1 , 3×3 , 5×5 vb.) “bölmeye, dönüştürme ve birleştirme” stratejisini benimsemiş olup; homojen çok dallı bir mimari yapısı vardır. ResNeXt modeli, ResNet ve VGG modellerinden esinlenmiştir. ResNeXt Model mimarisi Şekil 7' de gösterilmiştir.



Şekil 7. ResNeXt blok yapısı [12]

3.6 R-KSA modeli

Bölgelik KSA olarak bilinen bu modelin amacı, görüntü üzerindeki nesneleri doğru bir şekilde tespit etmektir. Yani, Şekil 8' e bakıldığında bu mimari de aynı ortamin farklı açılardan veya farklı zamanlarda çekilmiş resimleri üzerinde bulunan nesneleri tespit edip, nesneler arasındaki ilişkileri de bize veren mimaridir. Bölge, bölge seçim araması yaparak her resim için farklı boyutlarda pencerelerden görüntüyü analiz eder ve her bir nesne tanımlaması için pikselleri rengine, dokusuna ve yoğunluğuna göre sınıflama yapar [13].



Şekil 8. Bölgesel KSA temel mimarisi [13]

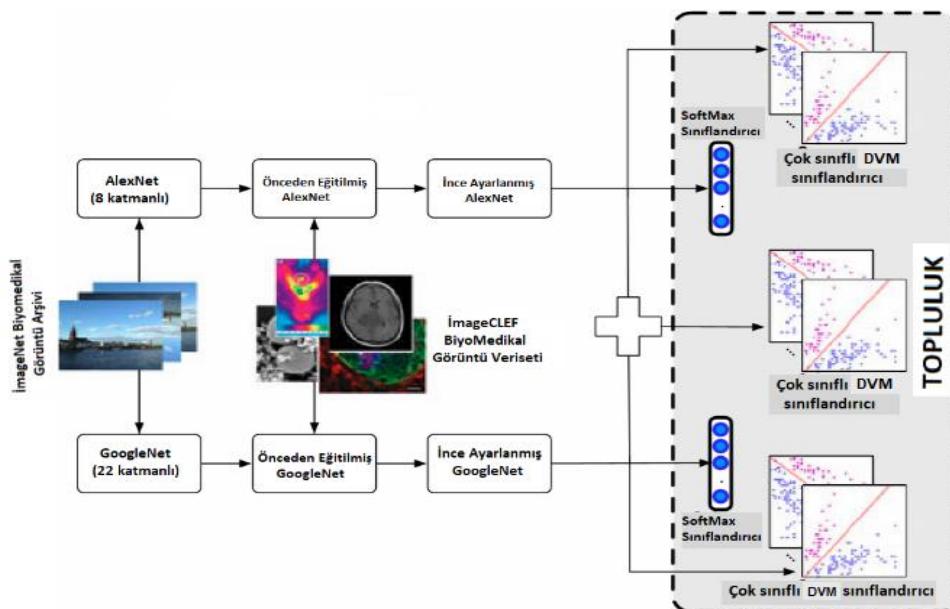
B-KSA modelin en önemli eksikliği, veri kümesini eğitirken fazla zaman harcamaktadır. Bu eksikliği gidermek için “Daha Hızlı B-KSA” modeli geliştirilmiştir. Bu model ile her bir resim için binlerce kez çalıştırılmak yerine; bir resim çalıştırılıyor ve diğer resimler çalıştırılan resmin değerlerini çalıştırılmadan kabul ediliyor [7].

4. Biyomedikal Alanda Derin Öğrenme

Son zamanlarda özellikle derin öğrenme modeliyle yapılan çalışmalar, çeşitli alanlarda başarılı sonuçlar elde edilirken, biyomedikal alanda da faaliyetler hızla artmıştır. Bu alanda büyük ölçekli veri kümelerine ulaşılmasıyla birlikte biyomedikal üzerinde derin öğrenme çalışmalarında yoğunluk hızlı bir şekilde artmaya başlamıştır. Bu kısımda biyomedikal alanında derin öğrenme ile ilgili yapılmış olan akademik çalışmalarдан bahsedilmiştir.

Biyomedikal görüntülerin sınıflandırılmasının da yapılan çalışmalarından biri: Sınıflandırma işleminde ince ayarlı KSA yönteminin kullanılmış olmasıdır. İnce ayarlama yöntemiyle var olan KSA modeli, hazır veri kümeleri ile eğitilip, modelin ağırlık güncellemeleri elde ediliyor. Sonrasında farklı veri kümeleri model de eğitmek için bırakıldığında, daha önceden ağırlık güncellemeleri yapıldığı için öznitelik ve sınıflandırma işlemi daha hızlı oluyor.

Bu çalışmada veri kümesi, ImageNet 2016 medikal görüntülerini adlı veri kümesinden elde etmişlerdir. Veri kümelerinin 6776 adet görüntüsü eğitim için, 4166 adet görüntü ise test verisi olarak kullanılmıştır. Eğitilmiş resimler üzerinde, KSA yöntemi ile yapılan çalışmalarda başarılı sonuçlar alınmasına rağmen, görüntüler arasında ince farklılıklar yakalayamayabilir. Bu çalışmadaki esas amaç ise bu farklılıklar da yakalayabilecek bir KSA modeli geliştirmektir. Veri kümesi üzerinden farklı KSA yöntemleriyle elde edilen öznitelikler; kendi aralarında kıyaslanıp, birbirinden farklı olan özniteliklerin çıkartılması ile ince ayarlı KSA topluluğu oluşur. Bu topluluğun amacı performansta artış sağlamaktır. Şekil 9’da ince ayarlı KSA topluluğu, tasarımları gösterilmiştir [14].

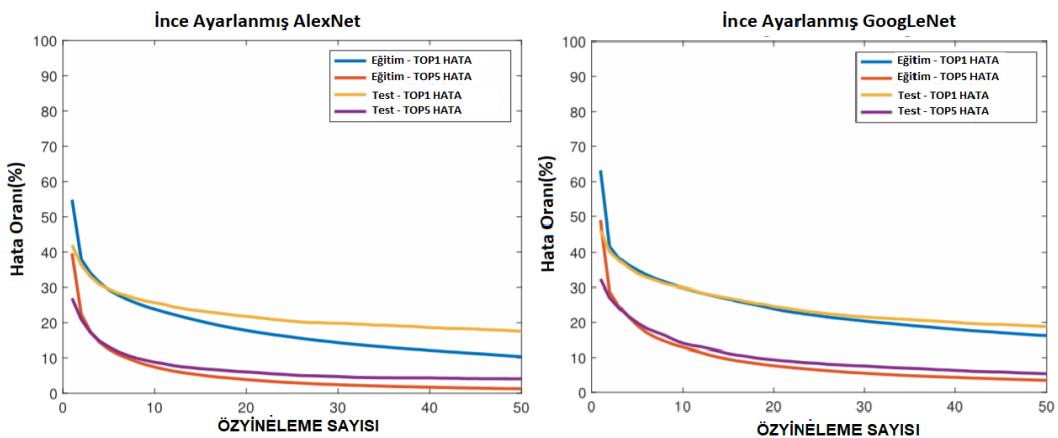


Şekil 9. Ince ayarlanmış KSA' da topluluk modeli [14]

Görüntü sınıflanmasında AlexNet ve GoogLeNet mimarilerini kullanılarak ince ayarlı görüntüler elde edildi. Daha sonra görüntünün sınıfını belirlemek için SoftMax sınıflandırıcıları ile çoklu Destek Vektör Makineleri (DVM) birlikte, topluluk modeli kullanılmıştır. Bu iki yöntemde derin öğrenme ağının son aşamasında yer alır ve çoklu sınıflandırma işlemi için her bir girdiye karşı $[1,0]$ arası çıkış değeri üretip, sınıflandırma yapar [21].

Çalışmaya ait veri kümesi üzerinde ince ayarlama işlemleri, geri yayılım yöntemiyle ve ağırlık (W) parametrelerinin güncellenmesi ile düzeltildi. Ayrıca görüntülerde elde edilen özelliklerini düşürmek için, Temel

Bileşen Analizi (TBA) yöntemi de kullanıldı [14]. Sırasıyla GoogLeNet ve AlexNet mimarilerinin ince ayarlanma işleminden sonra hata oranındaki düşüş grafiği Şekil 10' da yer almaktadır. Tablo 1' de ise kendi oluşturdukları topluluk mimarisinde başarı oranları, bu toplulukta kullanılan yöntemlerin tek tek kullanılarak elde edilen sonuçlar kıyaslanmış ve topluluğu oluşturan DVM, Softmax yöntemlerinin birlikte çalıştırılmasıyla doğruluk oranını daha da artırdığı görülmektedir. Ayrıca KSA' da SoftMax yöntemi AlexNet mimarisine göre iyileştirme yaparken, GoogLeNet mimarisine göre sınıflandırmada iyileştirme yapmadığı bilinmektedir. İyileştirme yapamamasının sebebi, GoogLeNet mimarisinde SoftMax' da görüntü sınıflandırılırken karşılaştırma yapamamasıdır [14].



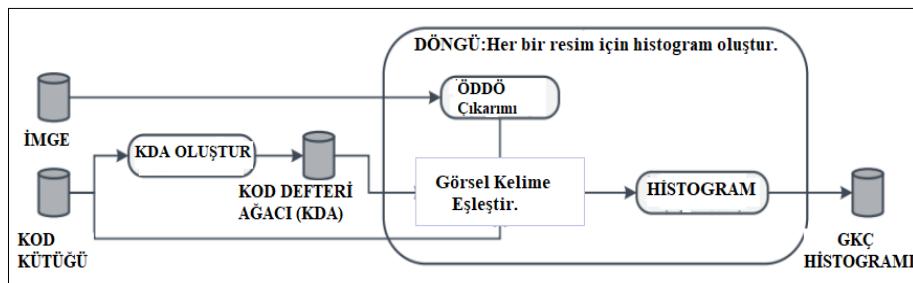
Şekil 10. İnce ayarlanmış KSA' da hata oranı [14]

Tablo 1. Sınıflandırma doğruluk tablosu [14]

TOP1 SINIFLANDIRMA DOĞRULUK ORANI (%)			TOP5 SINIFLANDIRMA DOĞRULUK ORANI (%)		
	MİMARİ			MİMARİ	
	ALexNet	GoogLeNet		ALexNet	GoogLeNet
Eğitimli Veri + DVM	79.21	78.61	Eğitimli Veri + DVM	96.71	96.33
İnce Ayarlı + SoftMax	79.62	77.17	İnce Ayarlı + SoftMax	94.48	91.31
İnce Ayarlı + DVM	79.60	80.75	İnce Ayarlı + DVM	96.47	96.54
Topluluk Modeli	82.48		Topluluk Modeli	96.59	

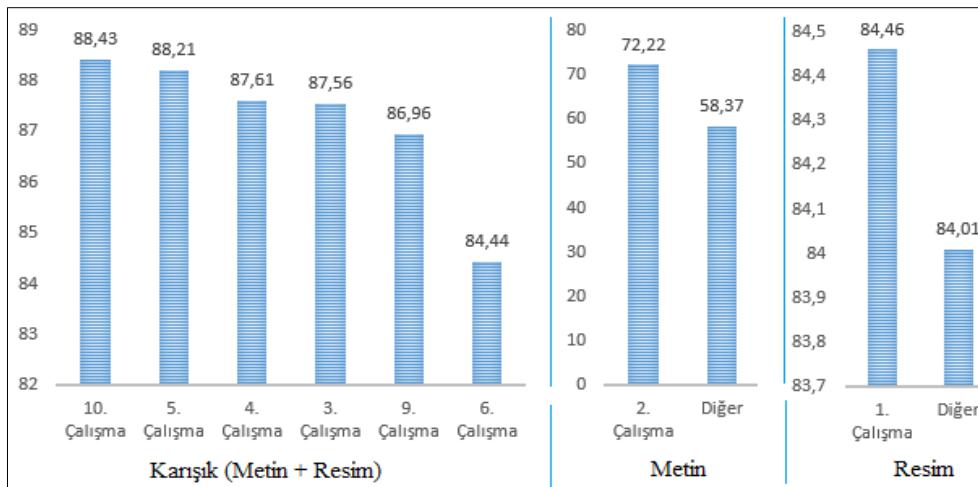
Başka bir çalışmada ise bilim adamları, ImageCLEF 2016' da biyomedikal alanındaki veri kümeleri üzerinde KSA' yi kullanarak kendilerinin geliştirdiği "Biyomedikal Bilgisayar Bilimi Grubu" (BBBG) adını verdikleri yöntemle sınıflandırma işlemi yapmışlardır. Bu çalışmada, veri kümlesi üzerinde bazı sınıflara ait görüntüler, renkler ile ayırt edilebileceğini düşünerek "Görsel Kelime Çantası" (GKÇ) yaklaşımını KSA modelinde kullanmışlardır. Bu yaklaşım, her görüntü için sözlük adında "şekil başlıklarları" ile "tam metinler" olmak üzere iki kısımdan oluşan kelime hazinesini içermektedir. Görüntülerden çıkarılan kelime hazineleri ne kadar sık kullanıysa; elde edilen sıklık sayısı, bir dizi içerisinde tutulması prensibine dayanmaktadır [1].

Çalışmada veri kümesi, eğitilmeden önce TBA yaklaşımıyla özellikleri düşürüldü. Sonraki işlemede ise GKÇ işlemi kullanıldı. Burada GKÇ yaklaşımı içerisinde "Ölçeksiz Değişken Dönüşümü Ölçeği" (ÖDDÖ) teknigi kullanıldı. ÖDDÖ ile orjinal görüntünün üzerinde ayırt edilebilme özelliği yüksek anahtar yerler oluşturup, bunu farklı açılardan çekilmiş görüntüler üzerinde anahtar noktaları tespit ederek görüntünün doğruluğunu bulmayı amaçlamaktadır. Bu durum Şekil 11' de anlatılmaktadır.



Şekil 11. GKÇ histogram oluşumu [1]

BBBG modeli ile tibbi görüntülerin; “Metin, Görsel, Karışık (Metin + Görsel)” sınıflandırılması amaçlanmıştır. Ve bunun için kendi geliştirdikleri model ile birlikte geleneksel yaklaşım modelleriyle, ResNet modelini iç içe kullanmışlardır. Şekil 12’ de görüldüğü gibi, BBBG modeli, 3 kategoride başarılı sonuçlar almıştır.



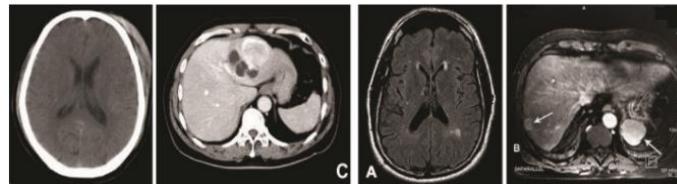
Şekil 12. BBBG modelinin başarı oranları [1]

Diğer bir çalışmada ise bilim adamları, sınıflandırma işleminde performansı artırmak için “El ile işlenmiş görsel niteliklerle birlikte derin öğrenme” (EİGNDÖ) modelinin kodlarını tasarlamışlardır. Bu modelde, ImageCLEF 2016’ da ki 30 kategoride yer alan, veri kümesi kullanılmıştır. Kategorilerden bazıları yeterli veri kümesine sahip olmaması, bazıları da uygun sınıf olmamasından dolayı elde edilen performans sonucunu olumsuz etkilemiştir. EİGNDÖ modeliyle, %85.47 orana varan bir başarı elde etmişlerdir. Burada KSA modeliyle elle işlenmiş görsel nitelikler birleştirilerek, görüntüleri sınıflandırma modeline gidilmiştir. Görüntüler üzerinde görsel öznitelik çıkarmı için, tek tanımlayıcılar (renk, doku, şekil), çoklu tanımlayıcılar ve bulanık renk dokusu histogramları kullanılmıştır. Sınıflandırma işleminde kullanılan diğer teknikler ise; Özellik çantası yöntemi (ÖCY), mekânsal piramit eşleştirme (MPE) yöntemi, ÖDDÖ yöntemi, TBA, geri yayılım sınır ağı (GYSA), yerel ikili desen (local binary patterns-YİD) yöntemleri kullanılmıştır [2].

ÖCY ile görüntü üzerindeki kelimelerin görme sıklık dereceleri bir dizide toplanarak sınıflandırma işlemine gidilmesi yöntemidir. MPE yönteminde; görüntü mekânsal olarak bir kaç böülübü görüntüye ayrılır. Ve görüntünün bir bülütü ÖCY çantasındaki kelimelerin içerisinde varsa, diğer bülütleri tahmin edilerek sınıflandırma işlemi yapılır. Bu yöntemlerin kullanılmasındaki amaç, performans ve zamandan kazançtır. GYSA ile hata çıktıları hesaplanır ve geri yayılma ağa tekrar parametreler güncel bir şekilde geri döndürülür. YİD yöntemiyle, görüntüler arasında parlaklık değişimine karşı dayanıklı olmasıdır. Bu yöntemle, her piksel değeri için bir etiket oluşturulur ve bu etiket 1 veya 0 dan oluşur. Bu tekniklerin kendi modellerinde kullanılma sebebi örneğin; beyin organına ait ImageCLEF veri kümesinde hem Tomografi (BT) hem de manyetik rezonans (MR) görüntüleri mevcuttur. Bu iki görüntü tipi görsel yönden pek çok benzerlik gösterirler. Şekil 13’ e bakınız. Bu

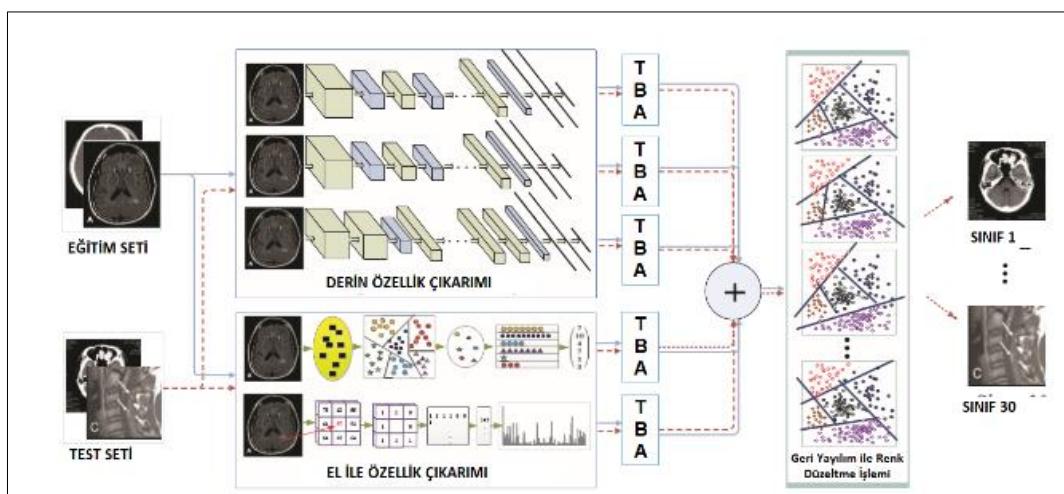
sebepten dolayı bu benzerlikleri sınıflandırmak için yukarıdaki tekniklerle beraber KSA yöntemini, kendi tasarladıkları model ile birlikte kullanmışlardır [2]. Kısaca oluşturdukları EİGNDÖ Yöntemi;

KSA + ÖCY, YİD Tanımlayıcı + TBA + GYSA (1)

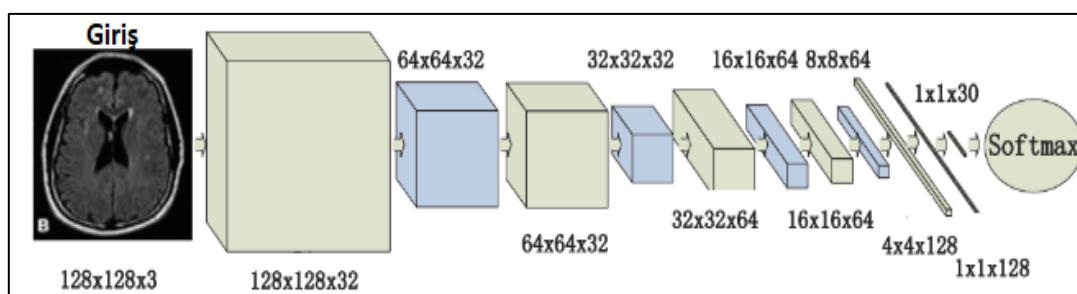


Şekil 13. Beyin MR ve tomografi görüntüleri [2]

Denklem 1' de görüldüğü gibi KSA ile diğer tekniklerin birleştirilmesiyle oluşur. EİGNDÖ yönteminin çalışma algoritması ise Şekil 14' te dir.



Şekil 14. EİGNDÖ algoritması tasarımı [2]



Şekil 15. KSA modeli özellik çıkartma aşamaları

EİGNDÖ yönteminde, “Caffe-Ref, VGG-f, VGG-19” 3 adet KSA modeli kullanılmıştır. Bu yöntemde, diğer yöntemlere kıyasla %85.47 oranında başarı sağlanmıştır. Başarı oranı, Tablo 2' de yer almaktadır.

EİGNDÖ yöntemi içerisinde kullanılan Derin KSA modelinin özellik çıkartma aşamaları Şekil 15' te gösterilmiştir. Benzer alanda yapılan önceki çalışmaların sonuçlarını EİGNDÖ yöntemiyle kıyaslanması yapılmış ve gayet başarılı bir sonuç elde edilmiştir. Sonuçlar Tablo 3' te gösterilmiştir.

Tablo 2. EİGNDÖ modelinin diğer modellere göre performans göstergesi [2]

	Özellikler	Sınıflandırma Doğruluğu(%)
El İş Yöntemler	ÖÇY	70.86
	YİD	71.29
Tam Eğitilmiş KSA ile	Derin Özellik	67.02
	Derin Özellik + ÖÇY	72.39
	Derin Özellik + YİD	73.98
	Derin Özellik + ÖÇY + YİD	75.37
Önceden Eğitilmiş KSA ile	Derin Özellik + Caffe-Ref	79.81
	Derin Özellik + VGG-f	80.77
	Derin Özellik + VGG-19	81.71
	3 Derin Özellik + ÖÇY + YİD (EİGNDÖ Modeli)	85.47

Tablo 3. EİGNDÖ yönteminin, benzer çalışmalarla kıyaslanması

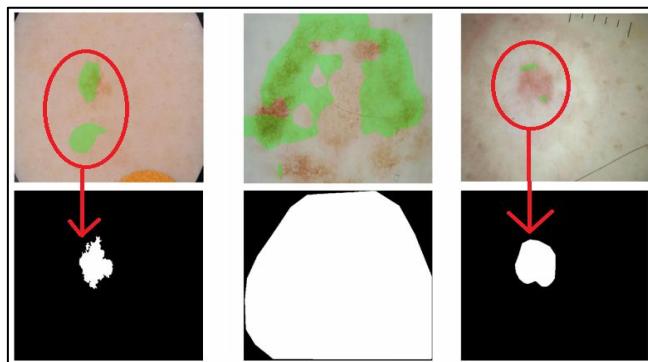
Yöntem	Çalışma Yöntemi	Sınıflandırma Doğruluğu(%)
EİGNDÖ	Görsel	85.47
Koitka et al.(ResNet) [1]	Görsel	85.38
Koitka et al.(1 el işi özellikler çıkarma) [1]	Görsel	84.46
Valavanis et al. [15]	Görsel	84.01
Kumar ea al. [16]	Görsel	77.55
Li et al. [17]	Görsel	72.46
Semedo et al. [18]	Görsel	65.31

Derin öğrenme de görüntüyü sınıflandırma aşamasında kullanılan yeni yöntemlerden birisi de süper pikseldir. Süper pikseller, görüntü bölütleme ve sınıflandırma işlemlerinde kullanılan kümeleme yöntemidir. Bu yöntem ile görüntü tutarlı küçük bölgelere bölünür ve bu bölgelere değişen yoğunlukta tohumlar (pikseller) homojen olarak yerleştirilerek çok çözünürlüklü bir görüntü elde edilir.

Biyomedikal alanda yapılan çalışmada cilt doku bozuklıklarının tespitini derin öğrenme yöntemiyle tespitini yapmak için, süper piksel yöntemiyle KSA modeli beraber kullanılmıştır [20]. Cilde oluşan doku bozukluğu görüntüsü için Şekil 16' ya bakınız.

**Şekil 16.** ISBI (Uluslararası Biyomedikal Görüntü Sempozyumu) 2016' da ki dermoskopik görüntüler

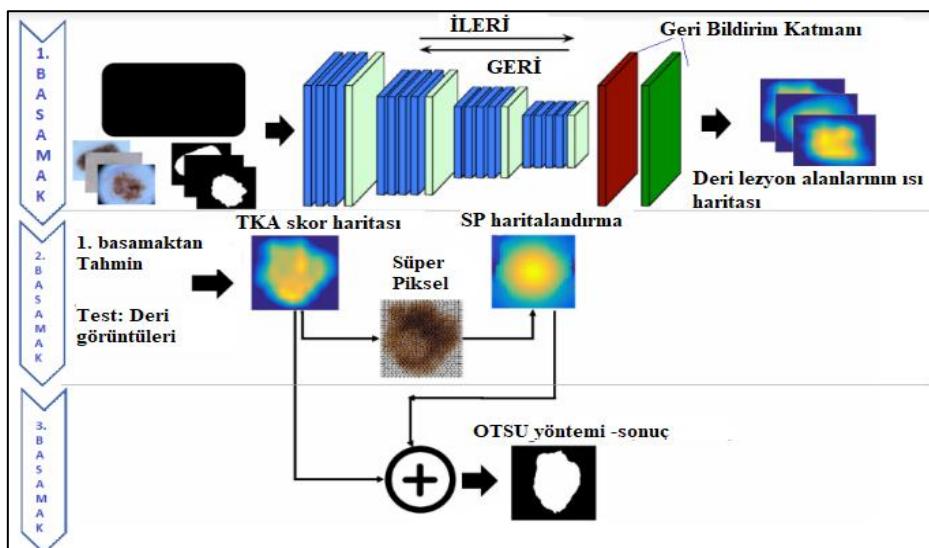
Bu çalışmada, TKA yöntemiyle deri üzerindeki lezyon tabaka sekil olarak kabaca tespit edildi [19]. Sadece TKA yöntemiyle deri lezyonun tespit sonuçlarını Şekil 17' de görebilirsiniz.



Şekil 17. ISBI (Uluslararası Biyomedikal Görüntü Sempozyumu) 2016' da deri görüntüler üzerinde kullanılan TKA yöntemi

Şekil 17' de kullanılan TKA yönteminde “otsu eşiği” teknigi kullanılmıştır. Bu teknikle, belirlenen bir eşik değeri üzerinde çıkan pikseller 1; eşik değeri altında kalan piksel değeri ise 0 olarak etiketlenerek resmin siyah beyaz görüntüsü elde etmeye yarar. Önerdikleri yöntemle; TKA ile tespit edilen kaba şekilli görüntülerin; süper piksellerle birleştirilerek daha ince ve doğru bir şekilde lezyon tespitini sağlamayı amaçlamıştır.

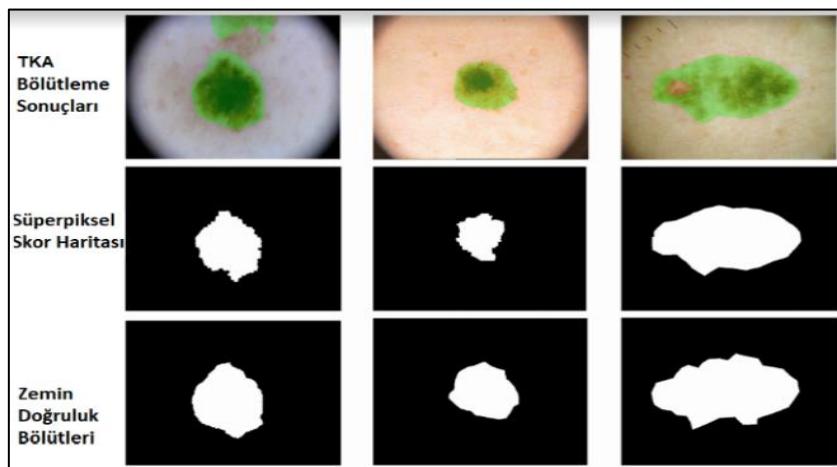
Şekil 18' i incelediğimizde 1. Basamakta tamamen derin öğrenme modeli TKA yöntemiyle elde edilen lezyon görüntüler, 2. basamakta süper piksellerle piksel haritalandırılması yapılmaktadır. Ve yöntemin sonunda “otsu eşiği” teknigiyle lezyon bölge tespit edilmektedir. Burada 1. Basamakta her bir görüntünün 5 farklı kamera açısından görüntüsü istiflenerek eğitim kümesinde, artırılma işlemi yapılmıştır. Ayrıca süper piksel yönteminde kullanılan algoritma ise “Basit Doğrusal Yinelemeli Kümeleme” (BDYK) tekniğidir. Bu teknik ile sonradan yerleştirilen pikseller eşit bir dağılım (homojen) göstermektedir [19].



Şekil 18. “TKA + Süper piksel” yöntemi işleyiş şeması [19]

Süper piksel, yönteminde kullanılan skor haritaları 0 ve 1 den oluşmaktadır. Sıfır düşük güvenilirlikli süper piksel; bir ise yüksek güvenilirlikli süper piksel anlamına gelmektedir. 0 veya 1 olmasındaki karar mekanizması: Süper piksel görüntünün içerisindeki piksellerin ortalama değeri hesaplanır. Elde edilen sonuç, tüm süper piksellerin ortalama değerinden büyükse 1; değilse 0 kabul edilir.

Çalışma yönteminin deneysel sonuçlarında ISBI 2016 biyomedikal veri kümesi kullanıldı. Toplam 900 eğitim ve 379 test dermoskopi görüntüsünden oluşmaktadır. Süper piksel sayısına göre deride ki lezyon tespiti analizi yapılmıştır. SP-400 (Süper piksel adeti: 400) en iyi performansı gösterdiği için (% 80.6 başarı oranı) SP-400 kendi yöntemlerinde kullanılmıştır. Elde edilen başarı oranı % 92.3' tür [19]. Bu yöntemde, elde edilen bölütleme işlemi örnek sonuçları için Şekil 19' a bakınız.



Şekil 19. “TKA”, “süper piksel” yöntemlerinin böülütleme işlemi örnek sonuçları [19]

5. Tartışma ve Sonuç

Derin öğrenme, yapay zekâının bir koludur. Amaç, görüntü işlemelerde daha hızlı, verimli ve en önemlisi otomatik olarak öznitelikler çıkarıp ve bunu sonuca yansitmaktır. Geleneksel yöntemler ise bu işlev elle girmektedir. Derin öğrenme modellerinin belki de en iyi özelliği, bir imgenin sınıflandırılmasında çok sayıda tasarılanan modellerle ve birçok geleneksel yöntemlerin de iç içe kullanabilmesine olanak sağlamasıdır.

Derin öğrenme modellerini birbiriley kıyasladığımızda en önemli dezavantajı ise çok sayıda katman sayısından ve parametrelerden oluşmaktadır. Kimi derin öğrenme mimarilerin çoğu istiflenerek yani sırasıyla çalışır. Bu durum ne kadar katmanların bazıları kendi yapılarında paralel bir şekilde işlene de derin öğrenme modelinde dezavantaj olarak görülebilmektedir. Mimarilerin karmaşıklığı, elde edilen performansı da olumsuz etkileyebilmektedir.

Sonuç olarak, derlemiş olduğumuz bu makalede, derin öğrenme ile ilgili biyomedikal alanında son zamanlarda yapılan çalışmalar hakkında kısa bilgiler sunuldu. Biyomedikal alanında çalışma yapmak isteyenler için; derin öğrenme modelleri ile kütüphanelerinden temel seviyede bahsedilmiş olup; bu modellerin, geleneksel yöntemlerle kullanılmasından ve elde edilen performans sonuçlarına etkisinden bahsedildi.

Kaynaklar

- [1] J. Zhang, Y. Xia, Y. Xie, M. Fulham, and D. Feng, “Classification of Medical Images in the Biomedical Literature by Jointly Using Deep and Handcrafted Visual Features,” *IEEE J. Biomed. Heal. Informatics*, vol. 2194, no. 2, pp. 1–10, 2017.
- [2] S. Koitka and C. M. Friedrich, “Traditional feature engineering and deep learning approaches at medical classification task of imageCLEF 2016,” *CEUR Workshop Proc.*, vol. 1609, pp. 304–317, 2016.
- [3] “Makineyle Öğrenme – GPU Hızlandırmalı Uygulamalar | Tesla Yüksek Başarılı Hesaplama|NVIDIA.” [Online]. Available: <http://www.nvidia.com/tr/object/tesla-gpu-machine-learning-tr.html>. [Accessed: 12-Mar-2018]
- [4] “Keras Documentation.” [Online]. Available: <https://keras.io/>. [Accessed: 12-Mar-2018].
- [5] Y. Jia et al., “Caffe: Convolutional Architecture for Fast Feature Embedding,” Jun. 2014.
- [6] “TensorFlow.” [Online]. Available: <https://www.tensorflow.org/>. [Accessed: 12-Mar-2018].
- [7] Ö. R. Girshick, J. Donahue, T. Darrell, and J. Malik, “Rich feature hierarchies for accurate object detection and semantic segmentation,” *Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit.*, pp. 580–587, 2014.
- [8] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks,” *Adv. Neural Inf. Process. Syst.*, pp. 1–9, 2012.
- [9] M. D. Zeiler and R. Fergus, “Visualizing and Understanding Convolutional Networks arXiv:1311.2901v3 [cs.CV] 28 Nov 2013,” *Comput. Vision–ECCV 2014*, vol. 8689, pp. 818–833, 2014.
- [10] C. Szegedy et al., “Going deeper with convolutions,” *Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit.*, vol. 07–12–June, pp. 1–9, 2015.
- [11] S. Wu, S. Zhong, and Y. Liu, “Deep residual learning for image steganalysis,” *Multimed. Tools Appl.*, pp. 1–17, 2017.

- [12] S. Xie, R. Girshick, P. Dollár, Z. Tu, and K. He, “Aggregated Residual Transformations for Deep Neural Networks,” 2016.
- [13] R. Girshick, J. Donahue, T. Darrell, and J. Malik, “Rich feature hierarchies for accurate object detection and semantic segmentation,” Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit., pp. 580–587, 2014.
- [14] A. Kumar, J. Kim, D. Lyndon, M. Fulham, and D. Feng, “An Ensemble of Fine-Tuned Convolutional Neural Networks for Medical Image Classification,” IEEE J. Biomed. Heal. Informatics, vol. 21, no. 1, pp. 31–40, 2017.
- [15] T. Valavanis, L.; Stathopoulos, S.; Kalamboukis, “CLEF 2016 | Conference and Labs of the Evaluation Forum,” 2016. [Online]. Available: <http://clef2016.clef-initiative.eu/index.php?page=Pages/cfLabsParticipation.html>. [Accessed: 12-Mar-2018]
- [16] A. Kumar, D. Lyndon, J. Kim, and D. Feng, “Subfigure and Multi-Label Classification using a Fine-Tuned Convolutional Neural Network,” pp. 1–4.
- [17] P. Li et al., “UDEL CIS at imageCLEF medical task 2016,” CEUR Workshop Proc., vol. 1609, pp. 334–346, 2016.
- [18] D. Semedo and J. Magalhães, “NovaSearch at imageCLEFmed 2016 subfigure classification task,” CEUR Workshop Proc., vol. 1609, pp. 386–398, 2016.
- [19] R. Achanta, A. Shaji, K. Smith, A. Lucchi, P. Fua, and S. Süsstrunk, “SLIC superpixels compared to state-of-the-art superpixel methods,” IEEE Trans. Pattern Anal. Mach. Intell., vol. 34, no. 11, pp. 2274–2281, 2012.
- [20] B. Bozorgtabar, S. Sedai, P. K. Roy, and R. Garnavi, “Skin lesion segmentation using deep convolution networks guided by local unsupervised learning,” IBM J. Res. Dev., vol. 61, no. 4, p. 6:1-6:8, 2017.
- [21] “ Softmax .” [Online]. Available: <https://www.semanticscholar.org/topic/Softmax-function/966784/> [Accessed: 16-Nov-2018].