

Derin Öğrenme Kullanarak Otonom Araçların İnsan Sürüsünden Öğrenmesi

Mehmet Safa BİNGÖL¹, Çağrı KAYMAK², Ayşegül UÇAR^{3*}

¹ Mekatronik Mühendisliği, Mühendislik Fakültesi, Erciyes Üniversitesi, Kayseri, Türkiye

^{2,3} Mekatronik Mühendisliği, Mühendislik Fakültesi, Fırat Üniversitesi, Elazığ, Türkiye

¹ msbingol@erciyes.edu.tr, ² ckaymak@firat.edu.tr, ^{*3} agulucar@firat.edu.tr

(Geliş/Received: 20/09/2018;

Kabul/Accepted: 19/01/2019)

Özet: Otonom araçlar, çevre koşullarını algılayarak kararlar alan ve alındıkları kararlar doğrultusunda hareket eden araçlardır. Günümüzde otonom araçlara olan ilgi hızla artmaktadır. Gelişen sensör, Grafik İşleme Birimi teknolojisi ve yapay öğrenme yöntemlerindeki yenilikler ile birlikte otonom araç teknolojisi de gelişmektedir. Bu çalışmada, küçük bir yer aracı ile yapay öğrenme yöntemlerini kullanan otonom bir araç tasarlanmıştır. Bu amaçla, yer aracı üzerine çeşitli sensörler, kamera ve NVIDIA TX2 kartı yerleştirilmiştir. Otonom yer aracının insan sürüsünden öğrenmesi için, Evrişimsel Sinir Ağları ve Uzun Kısa-Vade Hafiza Ağları birlikte kullanan bir model önerilmiştir. Geliştirilen modelleri kullanan otonom araç, tasarılanan parkur üzerinde test edilmiştir. Tüm uygulamalar başarılı bir şekilde gerçekleştirilmiştir. Elde edilen sonuçlar grafikler ve şeiller ile verilmiştir.

Anahtar kelimeler: Otonom araçlar, Grafik İşleme Birimi, Evrişimsel Sinir Ağları, Uzun Kısa-Vade Hafiza Ağları, derin öğrenme.

Learning of Autonomous Vehicles from the Human Driving Using Deep Learning

Abstract: Autonomous vehicles are that perceive environmental conditions and act in accordance with decisions. At present, interest in autonomous vehicles is increasing rapidly. With the development of sensor and Graphics Process Unit technology, and innovations in artificial learning methods, autonomous vehicle technology is also developing. In this paper, a small autonomous land vehicle was built using artificial learning methods. For this purpose, various sensors, camera and NVIDIA TX2 card were installed on the land vehicle. In order for the autonomous car to learn from human driving, a model using Convolutional Neural Networks and Long Short-Term Memory Networks have been proposed. The autonomous vehicle was tested on the designed racecourse. All applications were realized successfully. The results were given by graphics and figures.

Key words: Autonomous vehicles, Graphics Process Unit, Convolutional Neural Networks, Long Short-Term Memory Networks, deep learning.

1. Giriş

Otonom araçlara olan ilgi dünya çapında giderek artmaktadır. Bu teknolojideki gelişim potansiyeli çok açık bir şekilde görülmektedir. Yakın zamanda ulaşım ve taşımacılık alanında ciddi gelişmelerin yaşanması beklenmektedir. Otonom sürüş, trafik akışı ve park problemlerine yardımcı olarak, sürüs özelliklerini geliştirecek ve yakıtı daha verimli kullanarak şehirlerdeki kirlenmeyi azaltmaya yardımcı olmaktadır. Bunlara ek olarak, otonom araçlar ile birlikte insan ve nakliye taşımacılığında insan kaynaklı hatalar azaldığından güvenlik oldukça artmaktadır [1].

Bir otonom araç için çevresinden bilgi almanın ilk yolu sensörlerdir. Günümüzde, sensör teknolojisinin gelişmesi ile birlikte, mobil robotların ve otonom araçların ihtiyaç duyduğu sensörler verimli bir şekilde kullanılabilmektedir [2].

Donanımsal gelişmelere bağlı olarak, geçtiğimiz yıllarda bilgisayar görmesi, makine öğrenmesi ve mobil robot araştırmaları alanlarında önemli gelişmeler yaşanmıştır. Özellikle derin öğrenme alanındaki gelişmeler umut verici sonuçlar içermektedir [3]. Yukarıda ifade edilen hem donanım hem yazılım alanındaki yenilikler bizi araştırmalara ve yeni gelişmelere katılmak için cesaretlendirmiştir. Bu sayede, geleneksel bilgisayar görmesi yaklaşımlarının yerine derin öğrenme tabanlı algoritmaları, otonom araçların algılama sistemlerinde kullanmaya yönelmiştir.

* Sorumlu yazar: agulucar@firat.edu.tr. Yazarların ORCID Numarası: ¹ 0000-0002-4188-2025, ² 0000-0001-5343-226X, ³ 0000-0002-5253-3779

Nesne algılama ve tanıma, otonom sürüs uygulamalarının en önemli araştırma konularından biridir. Bunun sebebi, otonom sürüste bir kontrol hareketinin öncelikle nesneyi algılaması ve sonra da o nesneyi tanımlamasının gerekliliğidir. Son zamanlarda, gerçek hayatı kullanılan araçlar için nesne tanıma uygulamaları hızla büyümüştür. Bu uygulamalara örnek olarak, şerit algılama asistanı, stereo görüntü kullanarak engel algılama, kızılıtesi görüntü kullanarak yaya algılama uyarı sistemi [4-7], lazer radar ve tek lensli kamera sistemi birleşimi kullanarak araç algılama sistemleri verilebilir [8].

Son yıllarda, derin öğrenme yöntemleri nesne algılama ve tanıma için güçlü makine öğrenmesi yöntemleri olarak ortaya çıkmıştır [9-11]. Derin öğrenme yöntemleri, bütün geleneksel yaklaşımlardan farklıdır. Derin öğrenme yöntemleri, özellikleri ham piksellerden doğrudan öğrenir. Derin öğrenme yöntemlerinde, yerel algılama alanları katman katman büyür. Çizgi, sınır ve köşe gibi basit özellikleri düşük seviyeli katmanlar algılarken yaya, araba veya trafik işaretleri gibi yüksek özellikleri yüksek seviyeli katmanlar algılar. Diğer bir ifadeyle derin öğrenme yöntemleri, nesneleri farklı ayrıntı düzlemlerinde temsil etmeye müsaade eder. Derin öğrenme yöntemlerinin başarıları ImageNet sınıflama yarışmalarında kendini göstermiştir [12, 13]. Bu yarışmadada derin sinir ağlarının bir türü olan Evrişimsel Sinir Ağları (ESA'lar) kullanılmıştır.

Yeni nesil otonom araçlarda araç içerisindeki tüm çoğul ortamlı sistemler ve durumsal farkındalık sağlayıcılar, tek birim tarafından komuta edilmektedir. Araç yönetim sistemi sahip olduğu derin öğrenme yapısı sayesinde kameralar vasıtıyla aldığı görüntüleri eş zamanlı sınıflandırarak sürücü destek sistemini oluşturmaktadır. Bu sayede özellikle kısıtlı görüş şartları gibi birçok durumda kazaların önüne geçilebileceği değerlendirilmektedir.

Bu çalışmada, otonom yer aracının insan sürüsünden alınan veriler yardımıyla otonom sürüs öğrenmesi amaçlanmıştır. Bilimsel yazında, insan tecrübesini kullanarak farklı çalışmalar yapılmıştır. Bu çalışmalarda ESA'lar, Uzun Kısa-Vade Hafiza Ağları (UKVHA'lar) ve otomatik kodlayıcılar kullanılmıştır [14-17]. Bu çalışmada ise, daha kararlı otonom sürüs için hem evrişim katmanı hem de UKVHA katmanı içeren bir model önerilmiştir. Daha kararlı bir sürüs sağlanmıştır. Bu çalışmanın geri kalan bölümlerinde, sırasıyla otonom araç tasarımları, ESA ve UKVHA'lar, önerilen model ve deneyel sonuçlar anlatılmıştır.

2. Otonom Araç Uygulaması

Çalışmanın bu bölümünde, otonom araçlar ile ilgili yapılan çalışmalar doğrultusunda, bir otonom araç yapılmaya çalışılmıştır [18-21]. İlk olarak uygulamada kullanılan araç ve sensörler tanıtılmış, sonrasında yapılan çalışmalar ayrıntılı olarak anlatılmıştır.

2.1. Donanım

2.1.1. Araç platformu

Otonom araç uygulaması için, Traxxas firmasının ürettiği, radyo kontrollü ve uzaktan kumandalı Traxxas Slash 4×4 Platinum araç kullanılmıştır [22].

Günümüzdeki araçlarda, genellikle Ackermann direksiyon sistemi kullanılmaktadır. Ackermann direksiyon sistemi, Rudolph Ackermann tarafından 1817 yılında geliştirilmiştir [23]. Ackermann direksiyon sistemi, aracın dönüşü sırasında içteki tekerleğin dıştaki tekerleğe göre daha keskin bir dönüş yapmasını sağlar. Traxxas'ın kullanılan aracında, Ackermann direksiyon sistemi kullanılmıştır. Aracında direksiyon kontrolü için bu çalışmada servo motor kullanılmıştır. Servo motoru sürmek için Darbe Genişlik Modülasyonu ile tetiklenen servo sürücü kullanılmıştır. Araçta, Velineon 3500 fırçasız motor kullanılmıştır. Bu motor güç ve uzun عمر için, yüksek sıcaklıkta sinterlenmiş Neodymium mıknatıslar ve yüksek hızlı bilyalı rulmanlar ile üretilmiştir [24].

Uygulamada aracın üzerindeki orijinal Elektronik Hız Kontrolör (Ehk) çıkarılarak onun yerine Vedder EHK (VEHK) takılmıştır. Aracın üzerindeki EHK'nın en düşük hızı, saatte yaklaşık 9 kilometredir. VEHK kullanımının ana sebebi, hızı düşürerek aracın kontrolünü artırmaktır. VEHK mimari olarak, STM32 ARM Cortex işlemciye sahiptir ve açık kaynak kodludur [25]. Veri toplama aşamasında, aracı kontrol etmek için Logitech F710 kablosuz oyun kolu kullanılmıştır. Bu oyun kolu, radyo kontrol ile haberleşen 2.4 GHz hızında nano alıcıya sahiptir.

2.1.2. NVIDIA Jetson TX2

NVIDIA Jetson TX2, düşük güç ve yüksek performans ile gerçek zamanlı yapay zekâ ve görüntü işleme uygulamaları için kullanılabilir. Jetson TX2, GİB olarak NVIDIA Pascal™, 256 CUDA çekirdeğine sahipken Merkezi İşlem Birimi (MİB) olarak, HMP Dual Denver 2/2 MB L2 + Quad ARM® A57/2 MB L2 sahiptir [26].

Otonom araçlarda bulunan kamera, mesafe sensörü ve diğer sensörlerden anlık olarak birçok veri gelmektedir. Bu nedenle, GİB'ler otonom sürüsüz uygulamaları için kilit rol oynamaktadır. GİB'ler tarafından sağlanan yüksek paralellik, aracın hareket planlaması için sensörlerden gelen verileri hızlı bir şekilde değerlendirek karar vermesini sağlar.

2.1.3. Stereo kamera

ZED kamera, derinlik algılama ve hareket izleme için dünyanın ilk 3 boyutlu (3B) kamerası olarak Stereolabs firması tarafından geliştirilmiştir [27]. ZED kamerada, insan görüşünü temel alan gelişmiş algıma sistemleri kullanılmıştır. ZED kamera, derinlik algılama, hareket izleme ve 3B haritalama gibi uygulamalar için kullanılabilir. 2.2K video çekerken saniyede 15 görüntü alma kapasitesi ile dünyanın en hızlı kamerası olmuştur. Geniş açılı lensleri sayesinde algılama açısı 110 derecedir. 0.5 metre ile 20 metre arasında algılama yapabilmektedir.

2.1.4. İki boyutlu lazer tarayıcı

İki boyutlu (2B) lazer tarayıcı (LIDAR) olarak A2M6 isimli 2B-LIDAR kullanılmıştır. Kullanılan 2B-LIDAR 360 derece tarama özelliğine sahiptir. Bir saniyede 4000 adet örnek alabilmektedir. Menzili 20 metredir. Normal tarama hızı 10 Hz olmasına karşın, istenilen durumlarda 5-15 Hz arasında kullanılabilir [28].

2.2. Yazılım

Aracın işletim sistemi, Linux for Tegra (L4T) isimli bir Linux sürümüdür. Bu işletim sistemine CUDA, cuDNN, VisionWorks, OpenCV4Tegra yazılımları NVIDIA'nın JetPack isimli yazılım paketi kurularak yüklenmiştir. Ayrıca, Atalet Ölçüm Birimi (AÖB), VEHK, LIDAR ve kameranın çalışması için sürücülerini yüklenmiştir. Mobil robotun benzetimi ve kontrolü için Robot İşletim Sistemi (ROS-Robot Operating System) yüklenmiştir.

2.3. Parkur

Aracın üzerinde hareket etmesi için eni 4 metre, boyu 5,5 metre olan bir parkur hazırlanmıştır. Parkur üzerinde yol çizgileri yapılmıştır. Parkura yerleştirmek için çeşitli trafik levhaları hazırlanmıştır. Parkura ait fotoğraf Şekil 1'de verilmiştir.



Şekil 1. Parkur görüntüsü.

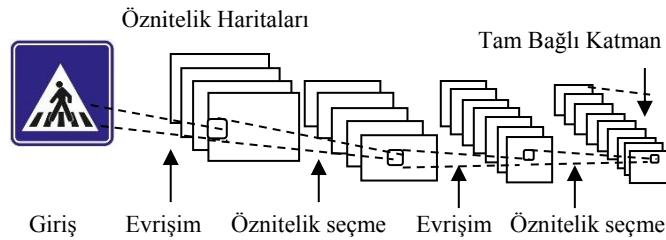
2.4. Yöntem

2.4.1. Evrişimsel Sinir Ağları

Çok katmanlı ileri beslemeli Yapay Sinir Ağları'nın (YSA'ların) bir alt türü olan ESA'lar 1998 yılında Yann LeCun tarafından tanıtılmıştır [29]. ESA'lar, görüntü işleme uygulamalarında, nesne algılama ve

sınıflandırma için etkin bir şekilde kullanılmaktadır. ESA'nın örnek bir yapısı Şekil 2'de verilmiştir. ESA'ların en önemli getirişi, el ile öznitelik çıkarma işlemeye ihtiyaç duymamasıdır.

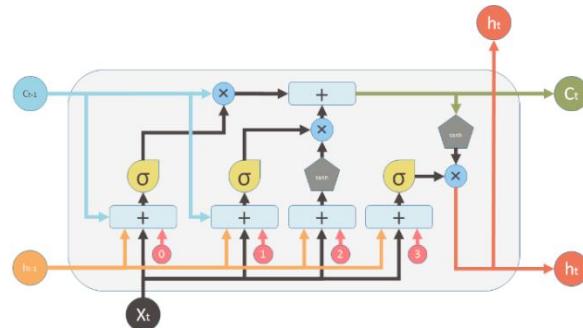
ESA'lar, evrişim katmanı, öznitelik seçici katman, Doğrultulmuş Doğrusal Birim (DDB) [30], tam bağlı katman ve değerlendirme katmanından oluşmaktadır [31-33]. Evrişim katmanı, ESA'ların temel katmanıdır ve giriş görüntüsünden öznitelik çıkarılmasını sağlar. Öznitelik seçici katman ile öznitelik haritalarının boyutu azaltılır. Öznitelik seçici katman ile boyut azaltma işlemi yapılrken, önemli olan özelliklerin kaybolmamasına dikkat etmek gereklidir. DDB, doğrusal olmayan işlemler içerir ve negatif değerleri sıfır olarak değiştirir. Tam bağlı katman, evrişim katmanları, öznitelik seçici katmanlar ve DDB katmanlarından sonra gelen katmandır. Tam bağlı katmanın nöronları, önceki katmandaki tüm nöronlara bağlıdır. Tam bağlı katmandan sonra genellikle değerlendirme katmanı gelir.



Şekil 2. Örnek bir ESA mimarisi.

2.4.2. Uzun-Kısa Vade Hafıza Ağları

UKVHA'lar, Sepp Hochreiter ve Jürgen Schmidhuber tarafından 1997 yılında tekrarlayan sinir ağlarının bir çeşidi olarak tasarlanmıştır [34, 35]. YSA'larda, çıkıştı sadece o anki giriş değeri değil önceki giriş değerleri de etkileyebilir. Bu yüzden, UKVHA'lara tekrarlayan sinir ağlarına ek olarak birde hafıza birimi eşlik etmektedir. Şekil 3'te örnek bir UKVHA yapısı verilmiştir. Burada; X_t giriş vektörünü, h_t çıkış vektörünü ve C_t hafıza birimini ifade etmektedir.



Şekil 3. Örnek bir UKVHA mimarisi [36].

2.5. Uygulama

Uygulamada kullanmak için Traxxas aracının kaporta kısmı sökülmüştür. Otonom araç için gerekli olan kamera ve sensörler aracın şasesine sabitlenmiştir. Aracın yandan görüntüsü Şekil 4'te verilmiştir.



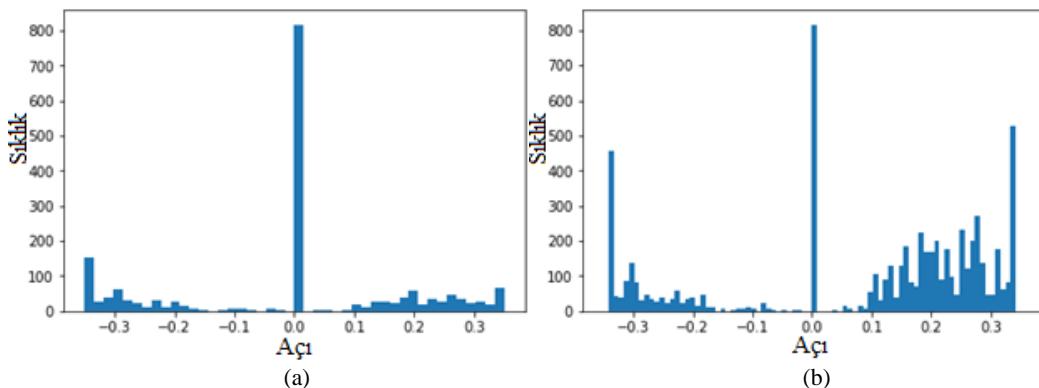
Şekil 4. Aracın yandan görünüsü.

Sonra araç parkura konularak Logitech F710 oyun kolu yardımıyla el ile kontrol edilmiştir. Araç, öğrenmesi istenilen alanlarda sürülmüştür. Bunun amacı, otonom aracın eğitiminde kullanılmak üzere kamera ve sensörlerden eğitim verileri toplayarak eğitim kümesi oluşturmaktır. El ile sürüş sonucunda, kameradan 1860 tane görüntüye ek olarak, araca ait hız ve direksiyon açılarının değerleri de kayıt altına alınmıştır. Kameradan alınan ilk 30 görüntü düzgün olmadığı için eğitim için kullanılmamıştır. Elde edilen görüntülerin %80'i eğitim kümesi, %20'si test kümesi olacak şekilde ayrılmıştır [37]. Kameradan alınan görüntü örneği Şekil 5'te verilmiştir.



Şekil 5. Araç kamerasından alınan bir görüntü.

Araç parkur üzerinde sürülürken kameradan alınan görüntülerin, açıya göre dağılımını görmek için Şekil 6 (a)'daki gibi bir histogram çizilmiştir. Açıların [-1, 1] aralığında düzgün dağılması için veri çoğaltma işlemi uygulanmıştır. Sayısı az olan açı değerleri veri kümesine yeni bir veri olarak tekrar eklenmiştir. Dengeli bir histogram Şekil 6 (b)'deki gibi elde edilmiştir.



Şekil 6. (a) Tekerin açı değerlerine ait histogram grafiği, (b) Veri artırma yöntemi ile elde edilmiş histogram grafiği.

Aracın her ortamda doğru bir şekilde hareket edebilmesi için, veriye parlaklık değişimi uygulanmıştır. Araçtan alınan görüntünün tüm pikselleri gerekli değildir. Bu nedenle üstten 144, alttan 76, soldan 0 ve sağdan 672 piksel alınmıştır. Bu nedenle ilk olarak, ağa kırpıcı bir katman oluşturulmuştur. Daha sonra elde edilen bu veriler ile oluşturulan ağ yapısı eğitilmiştir. Eğitim sonuçları Şekil 7 (a)'da verilmiştir. Sonuçta elde edilen direksiyon açısı, ağ sonuç verdikten sonra -0.3 ila 0.3 aralığından -1 ila 1 aralığına çevirmek için 3 ile çarpılmıştır.

İnsan göstergelerinden öğrenme amacı için iki farklı ağ kullanılmıştır. Birinci ağ yapısı, [14]'teki NVIDIA'nın ESA yapısıdır. Bu ağa ilişkin ayrıntılar Tablo 1'de verilmiştir. Bu ağ sırasıyla, görüntü ön işleme katmanı, dört evrişim katmanı, vektöre dönüştürme katmanı, 0.2 olasılıklı düğüm düşürme ve dört tam bağlı katmanı ile oluşturulmuştur. İkinci ağ yapısı ise UKVHA katmanı eklenerek bu çalışmada önerilmiştir. Ayrıntıları Tablo 2'de verilen önerilen ağ, sırasıyla görüntü ön işleme katmanı, iki evrişim katmanı, en-çok işlevi kullanan öznitelik seçici katman, bir evrişim katmanı, 0.2 olasılıklı düğüm düşürme katmanı, zamansal vektöre dönüştürme katmanı, UKVHA katmanı ve dört tam bağlı katmanı ile oluşturulmuştur. [14]'teki ağda oluşabilecek aşırı uygunluk yani ezberleme probleminden kurulmak için önerilen ağda 0.2 olasılıklı düğüm

düşürme katmanı kullanılmıştır. Ayrıca en-çok işlevi kullanan öznitelik seçici katman ile evrişim katmanın giriş boyutunu azaltmak amaçlanmıştır. Böylece bir sonraki katmanda daha az hesaplama yükü oluşturmuştur hem de ağın ezberlemesini önlemek amaçlanmıştır. UKVHA katmanı sayesinde daha kararlı sonuçlar elde etmek amaçlanmıştır. Modeller, Adam en iyilemeli küçük toplu geriye yayılım algoritması kullanarak eğitilmiştir. Amaç ölçütü olarak Ortalama Karesel Hata (OKH) kullanılmıştır. Eğitim, Intel i7 8700K 3.70 GHz 12M 1151p işlemci ve NVIDIA GTX Titan X Pascal ekran kartı içeren bir bilgisayar üzerinde gerçekleştirilmiştir. Eğitilen model daha sonra Jetson TX2 kartına gömülüdür ve 1860 görüntü toplanmıştır.

Şekil 7 (a) ve Şekil 7 (b)'den görüldüğü gibi aşırı uygunluk çarpıcı bir şekilde azaltılmıştır. Böylece önerilen ağın geçerlilik hatası diğer ağdan daha düşük olarak elde edilmiştir. Her iki modelin, her bir öz yineleme için eğitim süresi yaklaşık 83 ms'dir. Tablo 1 ve Tablo 2'den görüldüğü gibi [14]'ün toplam parametre sayısı 6050619 iken önerilen ağın 350875'dir. Bu da test aşamasında hesapsal yükün daha az olduğunu göstergesidir.

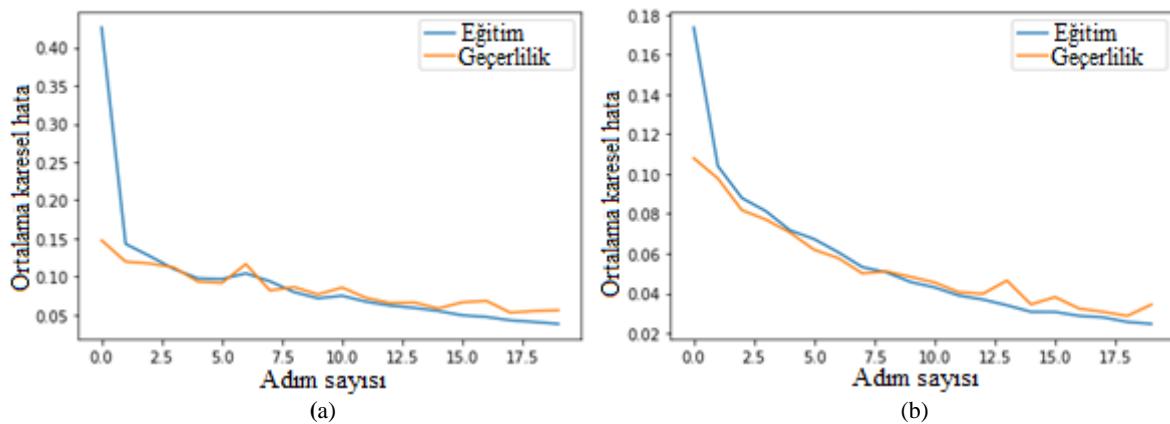
Aracın parkur üzerindeki görüntüsü Şekil 8'de verilmiştir. Otonom sürüste hedef, yüksek hızda aracın kararlı bir şekilde sürüsunun gerçekleştirilmesi ve direksiyon açısı üzerindeki hatanın düşük olmasıdır. Bu da UKVHA katmanı ile başarılmıştır. Özellikle yüksek hızlarda virajlarda kararlı dönüşler elde edilmiştir.

Tablo 1. [14]'teki CNN yapısı.

Katman	Filtre Boyutu	Öznitelik Uzayı Boyutu	Kaydırma Boyutu	Etkinleştirme İşlevi	Çıkış Boyutu	Parametre Sayısı
2B Kırpmak Katmanı (cropping2d_1)	-	-	-	-	156, 672, 3	0
Düzgeleme Katmanı (lambda_1)	-	-	-	-	156, 672, 3	0
2B Evrişim katmanı (conv2d_1)	5x5	24	2x2	DDB (ReLU)	76, 334, 24	1824
2B Evrişim katmanı (conv2d_2)	5x5	36	2x2	DDB (ReLU)	36, 165, 36	21636
2B Evrişim katmanı (conv2d_3)	5x5	48	2x2	DDB (ReLU)	16, 81, 48	43248
2B Evrişim katmanı (conv2d_4)	3x3	64	1x1	DDB (ReLU)	14, 79, 64	27712
2B Evrişim katmanı (conv2d_5)	3x3	64	1x1	DDB (ReLU)	12, 77, 64	36928
Vektöre dönüştürme (flatten_1)	-	-	-	-	59136	0
Tam bağlı katman (dense_1)	-	100	-	-	100	5913700
Tam bağlı katman (dense_2)	-	50	-	-	50	5050
Tam bağlı katman (dense_3)	-	10	-	-	10	510
Tam bağlı katman (dense_4)	-	1	-	-	1	11

Tablo 2. Önerilen UKVHA yapısı.

Katman	Filtre Boyutu	Öznitelik Uzayı Boyutu	Kaydırma/Azaltma Boyutu	Etkinleştirme İşlevi	Çıkış Boyutu	Parametre Sayısı
2B Kırpmak Katmanı (cropping2d_1)	-	-	-	-	156, 672, 3	0
Düzgeleme Katmanı (lambda_1)	-	-	-	-	156, 672, 3	0
2B Evrişim katmanı (conv2d_1)	5x5	24	2x2	DDB (ReLU)	76, 334, 24	1824
2B Evrişim katmanı (conv2d_2)	5x5	36	2x2	DDB (ReLU)	36, 165, 36	21636
Öznitelik Seçici Katman (Max pooling)	-	-	2x2	-	18, 82, 36	0
2B Evrişim katmanı (conv2d_3)	5x5	48	2x2	DDB (ReLU)	7, 39, 48	43248
Düğüm düşürme katmanı- (Dropout)	-	-	0.2	-	7, 39, 48	0
Vektöre dönüştürme Katmanı (Time-distributed flatten_1)	-	-	-	-	7, 1872	0
UKVHA katmanı		36			36	274896
Tam bağlı katman (dense_1)	-	100	-	-	100	3700
Tam bağlı katman (dense_2)	-	50	-	-	50	5050
Tam bağlı katman (dense_3)	-	10	-	-	10	510
Tam bağlı katman (dense_4)	-	1	-	-	1	11



Şekil 7. (a) [14]'teki ağır eğitim sonuçları, (b) Önerilen ağır eğitim sonuçları.



Şekil 8. Aracın parkur üzerindeki görüntüsü.

3. Sonuçlar

Bu çalışmada, insan gösterimlerinden öğrenen bir otonom yer aracının tasarımları amaçlanmıştır. Bu amaçla ilk olarak, Traxxas marka araç, VEHK, LIDAR, AÖB ve kamera kullanılarak otonom yer aracı oluşturulmuştur. İkinci olarak aracın üzerinde hareket edebileceği parkur oluşturulmuştur. Araç, oluşturulan bu parkur üzerinde kullanıcı tarafından hareket ettirilmiş ve ağır eğitmek için gerekli veriler toplanmıştır. Üçüncü olarak, eşişim katmanlarından sonra UKVHA katmanı içeren yeni model önerilmiştir. Dördüncü olarak, toplanan veriler ile ağ eğitilmiştir. Son olarak, tasarlanan otonom araç parkur üzerinde test edilmiştir. Önerilen ağır, direksiyon açısının tahmini üzerinde NVIDIA'nın ESA'sından daha iyi sonuçlar verdiği görülmüştür. Gelecek çalışma olarak daha kapsamlı bir algılama sistemi tasarlanarak daha gelişmiş bir otonom araç gerçekleştirilebilir. Algılama yapısı yanlışlıklarını en aza indirmek, aracın hızını artırmak ve aracın daha verimli çalışmasını sağlamak gelecek araştırmalara konu olabilir.

4. Teşekkür

Bu çalışma, "Grafik İşleme Ünitesi (GPU) Tabanlı Öğrenme Kullanarak Otonom Araçlar İçin Algılama Sisteminin Geliştirilmesi" isimli tez çalışması kapsamında, FÜBAP MF.17.05 nolu Yüksek Lisans Tez Projesi ve FÜBAP MF.18.06 nolu performans projesi desteğiyle gerçekleştirilmiştir. Ayrıca, NVIDIA ve Open Zeka Şirketlerine donanım desteklerinden dolayı teşekkür ederiz.

Kaynaklar

- [1] Gomez V. Object detection for autonomous driving using deep learning. PhD Thesis, Universitat At Politecnica De Catalunya, Automatica Robotica I Visio, Barcelona, 2015.
- [2] Nikbay K. Otonom araçların güzergah takibi için bir uygulama. Yüksek Lisans Tezi, Okan Üniversitesi Fen Bilimleri Enstitüsü, İstanbul, 2015.
- [3] Wason R. Deep learning: Evolution and expansion. Cognitive System Research 2018; 52: 701-708.
- [4] Mobileye pedestrian collision warning system, <https://www.mobileye.com/our-technology/> (Erişim: 28 Ağustos 2018)
- [5] Coelingh E, Eidehall A and Bengtsson M. Collision warning with full auto brake and pedestrian detection - a practical example of automatic emergency braking. In Proceedings of the 13th International IEEE Conference on Intelligent Transportation Systems (ITSC); 19-22 September 2010; Funchal, Portugal, pp. 155-160.
- [6] Autonomous driving, <https://www.bmw.com/en/index.html/> (Erişim: 17 Ağustos 2018)
- [7] VW Emergency Assistance System, <https://safecarnews.com/> (Erişim: 11 Temmuz 2018)
- [8] Active safety technology, https://www.toyota-global.com/innovation/safety_technology/toyota-safety-sense/ (Erişim: 3 Eylül 2018)
- [9] Deng L and Yu D. Deep Learning: methods and applications, Foundations and Trends in Signal Processing 2014; 7: 3-4.
- [10] Christian S, Toshev A and Erhan D. Deep neural networks for object detection. In Proceeding of the Advances in Neural Information Processing Systems; 5-10 December 2013; Lake Tahoe, USA; pp. 2553-2561.
- [11] Krizhevsky A, Sutskever I and Hinton GE. Imagenet classification with deep convolutional neural networks. In Proceedings of the Advances in Neural Information Processing Systems; 3-6 December 2012; Lake Tahoe, USA; pp. 1097-1105.
- [12] Deng J, Berg A, Satheesh S, Su H, Khosla A and Fei-Fei L (2012). <http://www.image-net.org/challenges/LSVRC/2012/>
- [13] Berg A, Deng J and Fei-Fei L. Large scale visual recognition, International Journal of Computer Vision 2010; 115(3): 211-252.
- [14] Bojarski M, Del Testa D, Dworakowski D, Firner B, Flepp B, Goyal P and Zhang X. End to end learning for self-driving cars 2016; arXiv preprint arXiv:1604.07316.
- [15] Santana E and Hotz G. Learning a driving simulator 2016; arXiv preprint arXiv:1608.01230.
- [16] Eraqi HM, Moustafa MN and Honer J. End-to-end deep learning for steering autonomous vehicles considering temporal dependencies 2017; arXiv preprint arXiv:1710.03804.
- [17] Karslı M, Satılmış Y, Şara M, Tufan F, Eken S and Sayar A. End-to-end learning model design for steering autonomous vehicle. In Proceedings of the 26th Signal Processing and Communications Applications Conference (SIU); 2-5 May 2018.
- [18] Du X, Ang MH, Karaman S and Rus D. A general pipeline for 3d detection of vehicles 2018; arXiv:1803.00387 [cs.CV].
- [19] Ma F, Cavalheiro GV and Karaman S. Self-supervised sparse-to-dense: self-supervised depth completion from lidar and monocular camera 2018; arXiv:1807.00275 [cs.CV].
- [20] Amini A, Soleimany A, Karaman S and Rus D. Spatial uncertainty sampling for end-to-end control 2018; arXiv:1805.04829 [cs.AI].
- [21] Shin R, Karaman S, Ander A, Boulet MT and Connor J. Project based, collaborative, algorithmic robotics for high school students: Programming self driving race cars at MIT. In Integrated STEM Education Conference (ISEC); 11 March 2017; New Jersey, USA; pp. 195-203.
- [22] Slash 4x4 Platinum Edition, <https://traxxas.com/products/models/electric/6804Rslash4x4platinum/> (Erişim: 10 Ocak 2018)
- [23] Weinstein AJ and Moore KL. Pose estimation of Ackerman steering vehicles for outdoors autonomous navigation. In Proceedings of the IEEE International Conference on Industrial Technology; 14-17 March 2010; Vina del Mar, Chile; pp. 579-584.
- [24] Velineon 3500 Brushless Motor, <https://traxxas.com/products/parts/motors/velineon3500motor/> (Erişim: 10 Ocak 2018)
- [25] FOCBOX motor controller, <https://www.enertionboards.com/electric-skateboard-parts/FOCBOX-programmable-brushless-motor-controller/> (Erişim: 22 Şubat 2018)
- [26] Autonomous machines, <https://www.nvidia.com/en-us/autonomous-machines/embedded-systems-dev-kits-modules/> (Erişim: 7 Temmuz 2018)
- [27] Zed stereo camera, <https://www.stereolabs.com/> (Erişim: 19 Haziran 2018)
- [28] RPLidar A2M6, <https://www.seeedstudio.com/RPLidar-A2M6-The-Thinest-LIDAR-p-2919.html> (Erişim: 5 Haziran 2018)
- [29] LeCun Y, Bottou L, Bengio Y and Haffner P. Gradient-based learning applied to document recognition. In Proceedings of the IEEE 1998; 86(11): 2278-2323.
- [30] Uçar A ve Bingöl MS. Derin öğrenmenin Caffe kullanılarak grafik işleme kartlarında değerlendirilmesi. DÜMF Mühendislik dergisi 2018; 9(1): 39-49.
- [31] Jarrett K, Kavukcuoglu K, Ranzato M and LeCun Y. What is the best multi-stage architecture for object recognition. In Proceedings of the International Conference on Computer Vision (ICCV); 29 September-2 October 2009; Nevada, USA; pp. 2146-2153.

- [32] LeCun Y, Kavukcuoglu K and Farabet C. Convolutional networks and applications in vision. In Proceeding of the Circuits and Systems International Symposium; 30 May-2 June 2010; Grenoble, France; pp. 253-256.
- [33] Ucar A, Demir Y and Guzelis C. Object recognition and detection with deep learning for autonomous driving applications. SIMULATION 2017; 93(9): 759-769.
- [34] Hochreiter S and Schmidhuber J. Long short-term memory. Neural computation 1997; 9(8): 1735-1780.
- [35] Martin S, Schlüter R and Ney H. LSTM neural networks for language modeling. In Proceedings of Thirteenth annual conference of the international speech communication association; 9-13 September 2012; Portland, USA; pp. 194-197.
- [36] LSTM and its diagrams, <https://medium.com/mlreview/understanding-lstm-and-its-diagrams-37e2f46f1714/> (Erişim: 15 Ağustos 2018)
- [37] Bingöl MS. Grafik işleme ünitesi (GPU) tabanlı öğrenme kullanarak otonom araçlar için algılama sisteminin geliştirilmesi. Yüksek Lisans Tezi, Fırat Üniversitesi Fen Bilimleri Enstitüsü, Elazığ, 2018.