

Kapsül Ağları Kullanılarak EEG Sinyallerinin Sınıflandırılması

Suat TORAMAN*

Enformatik Bölümü, Fırat Üniversitesi, Elazığ, Türkiye

*storaman@firat.edu.tr

(Geliş/Received: 20/12/2019;

Kabul/Accepted: 02/02/2020)

Öz: Epilepsi dünyadaki her yüz kişiden birinin sıkıntı çektiği en yaygın nörolojik hastalıklardan biridir. Gerçekleşecek bir nöbetin önceden tahmin edilebilmesi, epilepsi hastalarının yaşam kalitesinin artırılmasında önemli bir rol oynayacaktır. Ayrıca, etkili bir nöbet tahmin sistemi, hastlığın daha kontrol edilebilir olmasını sağlayacaktır. Bu çalışmada, Elektroensefalogram (EEG) sinyallerindeki interiktal ve preiktal beyin aktivitelerini ayırt etmek için bir yöntem önerilmiştir. Önerilen yöntemde, yeni bir sinir ağı modeli olan kapsül ağları kullanılmıştır. Preiktal aktivite, nöbet başlangıcından 30dk ileride seçilmiştir. Preiktal ve interiktal kısımlar kayan pencere ile segmentlere ayrılmış ve her segmentin spektrogram görüntüler elde edilmiştir. Spektrogram görüntüler, kapsül ağları kullanılarak C3-P3 için ortalama %94.05 doğruluk ile sınıflandırılmıştır. Bu çalışma ile kapsül ağlarının preiktal/interiktal sınıflandırma başarımı incelenmiştir. Elde edilen sonuçlar, kapsül ağlarının epilepsinin tahmini için umut verici bir yöntem olduğunu göstermektedir.

Anahtar Kelimeler: EEG, Epilepsi, Kapsül ağları, Preiktal/interiktal tanıma

Classification of EEG Signals Using Capsule Networks

Abstract: Epilepsy is one of the most common neurological diseases in which one in every hundred people in the world suffers. Predicting a seizure will play an important role in improving the quality of life of epilepsy patients. In addition, an effective seizure prediction system will ensure that the disease is more controllable. In this study, a new method was proposed to differentiate the interictal and preictal activities of electroencephalogram (EEG) signals. The proposed method uses capsule networks that a new model of neural network. Preictal activity was selected 30 min before seizure onset. The preictal and interictal sections were segmented with a sliding window and then each segment was transformed into spectrograms. Spectrogram images were classified with an average accuracy of 94.05% for C3-P3 using capsule networks. In this study, preictal/interictal classification performance of capsule networks was investigated. The results show that capsule networks are a promising method for the prediction of epilepsy.

Key words: EEG, Epilepsy, Capsule networks, Preictal/Interictal recognition

1. Giriş

Epilepsi, dünya genelinde milyonlarca insanın sıkıntı çektiği merkezi sinir sisteminde görülen nörolojik bir rahatsızlıktır [1]. Epileptik nöbetler, beyindeki nöronlar normal çalışırken aniden bu nöronların yanlış çalışması sonucunda oluşmaktadır [1, 2]. Elektroensefalogram (EEG), beyin aktivitesindeki değişikliklerin incelenmesi veya olabilecek bir nöbetin belirlenmesinde kullanılan bir yöntemdir. Nöbet tahmininde önemli olan preiktal durumun belirlenebilmesidir. Preiktal, beyin aktivitelerinde değişikliğin oluşmaya başladığı durumdur. Bu nedenle etkili bir nöbet tahmin sistemi için önemli bilgiler içeren preiktal durumun belirlenebilmesi büyük öneme sahiptir. EEG sinyalleri kullanılarak beyin aktivitesindeki değişikliklerin tespit edilmesi için çeşitli geleneksel özellik çıkarım yöntemleri kullanılmıştır. Liu ve diğ. çok kanallı intrakranial EEG sinyalini dalgacık dönüşümü ile alt batlarına ayırmıştır ve daha sonra çeşitli özellikler çıkararak EEG sinyallerini sınıflandırmıştır [3]. Zhang ve diğ, preiktal ve interiktal ayrımı için EEG sinyallerinin spektral analizini kullanmıştır [4]. Cho ve diğ. interiktal ve preiktal sınıflandırma için faz kilitleme değerleri kullanmıştır [5]. Tsioris ve diğ. Frekans domainı, zaman domain ve graf teorisini ile elde ettikleri özellikleri kullanarak preiktal ve interiktal durumları sınıflandırmıştır [2]. Bu yöntemler ile EEG sinyalleri farklı teknikler kullanılarak sınıflandırılmıştır [6,7]. GPU (Grafik işlem birimi) teknolojisinde gelişmelere paralel olarak son yıllarda derin öğrenme kullanılarak gerçekleştirilen sinyal / görüntü işleme ve sınıflandırma uygulamaları da oldukça artmıştır. Başarılı sonuçlar üretmesi nedeniyle derin öğrenme modelleri birçok alanda olduğu gibi tıp alanında da oldukça tercih edilmektedir [8–11]. Derin öğrenme modelleri sayesinde geleneksel yöntemlerde olduğu gibi elle tasarlanmış özellik çıkarımına ihtiyaç kalmamıştır [8,12]. Son zamanlarda, EEG sinyallerinin incelenmesinde derin öğrenme yöntemleri de sıkça kullanılmaya başlanmıştır

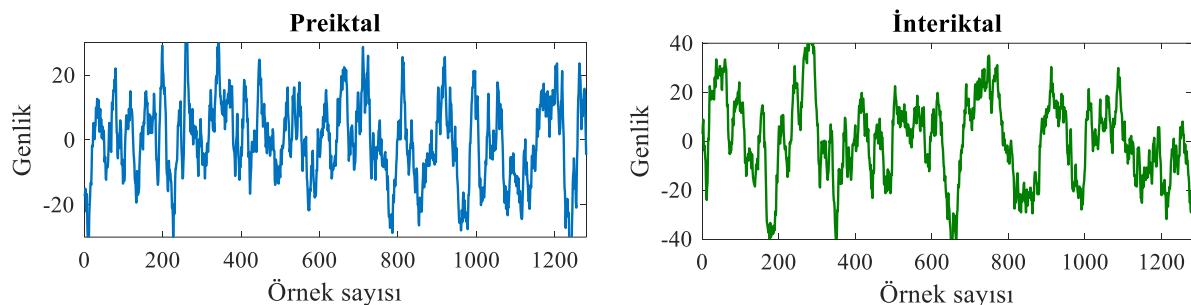
* Sorumlu yazar: storaman@firat.edu.tr. Yazının ORCID Numarası: 0000-0002-7568-4131

[13,14]. EEG sinyallerinin 1 boyutlu sinyal veya 2 boyutlu resim formunda incelenmesine yönelik çeşitli uygulamalar bulunmaktadır. Özal ve diğ. bir boyutlu ESA modelini kullanarak EEG sinyallerini normal ve abnormal olarak sınıflandırmıştır [15]. Toraman ve diğ. konuşma lateralitesinin belirlenmesi için EEG sinyallerini iki boyutlu spektrogram görüntüsüne çevirip özellik çıkarmayı yaptıktan sonra sınıflandırmıştır [16]. İhsan Ullah ve diğ. EEG sinyallerini otomatik olarak normal, ictal ve interiktal sınıflandırmıştır [17]. Bu çalışmada ise, nöbet tahmini için önemli olan preiktal/interiktal aktivite belirlenmesine yönelik yeni bir sinir ağı modeli olan kapsül ağları kullanılmıştır. Kapsül ağlarının eğitilmesi için EEG sinyalleri spektrogram görüntülerine dönüştürülmüş ve kapsül ağlarına giriş olarak uygulanmıştır. Literatür araştırmasında, kapsül ağları EEG sinyallerinden duyu tahmini [18] ve motor imgeleme [19] gibi konularda çalışılmışsa da, preiktal ve interiktal EEG sinyallerin sınıflandırılmasında kullanılmamıştır. Çalışmanın diğer bir katkısı, geleneksel EEG sınıflandırma yöntemlerinde olduğu gibi özellik çıkarımına gereksinim duyulmamasıdır. Sinalden özellik çıkarımında, ayırt edici yöntemin belirlenmesi, uzman tecrübe başıramı etkileyen önemli faktörlerdir. Bu çalışmada, elle özellik çıkarımına ihtiyaç duyulmadan kapsül ağları verilen giriş görüntülerini yüksek doğruluk ile sınıflandırmıştır. Çalışmanın geri kalanı aşağıdaki şekilde düzenlenmiştir. Bölüm 2'de, veri seti, preiktal-interiktal durum seçimi ve kapsül ağlarına ilişkin temel bilgiler verilmiştir. Bölüm 3'te, deneysel sonuçlar ve tartışma, Bölüm 4'te sonuçlar sunulmuştur.

2. Materyal ve Metot

2.1. Veri seti

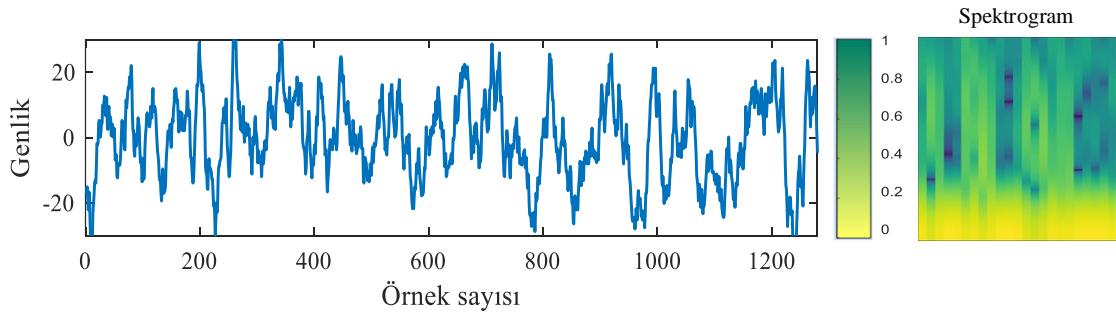
Çalışmada, Boston Çocuk Hastanesinde (CHB) nöbet geçiren beş çocuk denekten alınan EEG veri kümesi kullanılmıştır [20]. Veriler, 10-20 EEG elektrot pozisyon sistemi kullanılarak 18 ile 23 kanallı ve 256 örneklem frekansı ile alınmıştır. CHB-MIT EEG kayıtların çoğu birer saatlik dönemlerden (epoch) oluşurken, bazıları iki ile dörder saatlik dönemlerden oluşmaktadır. Her hastanın nöbet başlangıcı klinik uzmanı tarafından işaretlenmiştir. Bu bilgiler veri tabanındaki ek açıklama dosyasında bulunmaktadır. Bu çalışma için chb01, chb02, chb03, chb04 ve chb05 vakaları kullanılmıştır. Seçilen vakaların üç farklı kanal (FP1-F7, F7-T7, C3-P3) bilgisi incelenmiştir. Epilepsi hastalarının beyin aktiviteleri interiktal, preiktal, ictal ve postiktal olmak üzere dört durum içerir. Preiktal, nöbet başlangıcından önce gerçekleşen aktiviteler ifade etmektedir. İctal, nöbetin başladığı ve bitti ana kadar olan durumu, postiktal, nöbet sonrası durumu ve interiktal ise diğer üç durum dışında kalan normal beyin aktivitelerini ifade etmektedir. Çalışmada kullanılan preiktal ve interiktal sinyallerine ait temsili örnekler Şekil 1'de verilmiştir.



Şekil 1. 5sn'lık preiktal ve interiktal sinyal örneği

2.2. Sinyal bölümlleme ve spektrogram

Çalışma için preiktal eğitim aralığı nöbet başlangıcından önceki 30dk da bitecek şekilde 30dk'lık aralık seçilmiştir. İnteriktal ise nöbetten en az 2 saat uzaklıkta olacak şekilde belirlenmiştir. Veri setinde birbirine yakın birçok nöbet olduğu için önce gerçekleşen nöbet kullanılmıştır. Yukarıdaki şartlara göz önüne alındığında chb01 için 5, chb02 ve chb03 için 2, chb04 için 3 ve chb05 için ise 4 nöbet bulunmaktadır. Her nöbet öncesi 30dk'lık preiktal ve interiktal aralıklar örtüşmesiz kayan pencere yöntemi ile 5sn'lık böülümlere ayrılmıştır. Chb01 için 1800 preiktal ve 1800 interiktal bölüm oluşurken, chb02 ve chb03 için 720, chb04 için 1080 ve chb05 için 1440 bölüm olmuştur. Her bir preiktal ve interiktal sinyal parçası 16ms pencere genişliği (hamming), 8ms binişme ve FFT sayısı 512 olacak şekilde spektrograma dönüştürülmüştür. Renk haritası olarak viridis kullanılmıştır. Spektrogram görüntülerini kapsül ağları için 64x64 piksel olacak şekilde boyutlandırılmıştır. Şekil 2'de spektrograma dönüştürülmüş sinyal örneği verilmiştir.



2.3. Kapsül ağları

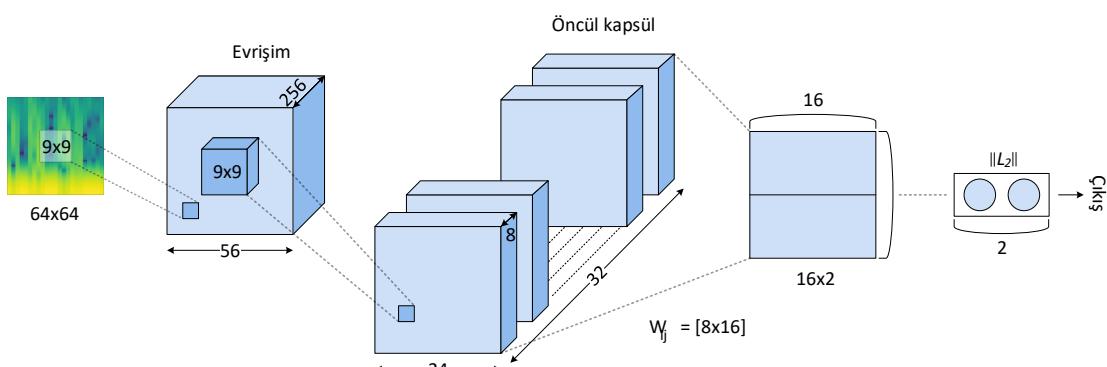
ESA'lar, ilk evrişim katmanında görüntüdeki basit özelliklerini (kenar, köşe vb.) öğrenir. Daha karmaşık özellikleri öğrenmek için doğrusal olmayan aktivasyon fonksiyonu kullanılır. Verideki önemli bilgiyi ön plana çıkarmak için havuzlama uygulanır. Art arda eklenmiş bloklar sayesinde bir önceki bloktan gelen bilgiden özellik çıkarımı devam eder. Böylece ağ daha karmaşık özelliklerini öğrenir. ESA'lar görüntüdeki nesneleri sınıflandırmada başarılıdır. Fakat ESA görüntüdeki nesnelerin konumlarını veya nesnenin parçaları arasındaki ilişkiye ortaya koyamaz. Bu eksiklikten yola çıkararak Hinton ve ark. görüntüdeki nesnelerin konumlarını korumak, nesnedeki özelliklerinin hiyerarşik ilişkileri modellemek için kapsül ağları olarak adlandırılan yeni bir sinir ağı modeli geliştirmiştir [21,22]. Kapsül ağları, birçok nöronu bir arada tutan kapsül olarak adlandırılan yapılardan oluşmaktadır. Mevcut ESA'ların çıkışı skaler bir değer iken, kapsül ağlarının çıkışı vektörelidir. ESA'lar aktivasyon fonksiyonu olarak ReLu, Sigmoid, Tanjant gibi skaler girdi alan fonksiyonları kullanmaktadır. Kapsül ağlarında ise ezme (squashing) olarak adlandırılan vektörel bir aktivasyon fonksiyonu kullanılmaktadır (Denklem 1) [21,23].

$$v_j = \frac{\|s_j\|^2}{1 + \|s_j\|^2} \frac{s_j}{\|s_j\|} \quad (1)$$

Denklemde, s_j kapsül girişi ve v_j ise kapsülün çıkış vektörünü gösterir. Çıkış vektörü (v_j), görüntüde bir nesne varsa uzun vektörleri 1'e doğru daraltırken, görüntüde nesne bulunmuyorsa kısa vektörleri sıfıra doğru baskılardır [21,23]. Kapsül ağlarında, belirli bir sınıfın nesnelerin mevcut olup olmadığını belirlemek için Denklem2 'deki aynı bir marj kaybı önerilmiştir.

$$L_k = T_k \max(0, m^+ - \|v_k\|)^2 + \lambda(1 - T_k) \max(0, \|v_k\| - m^-)^2 \quad (2)$$

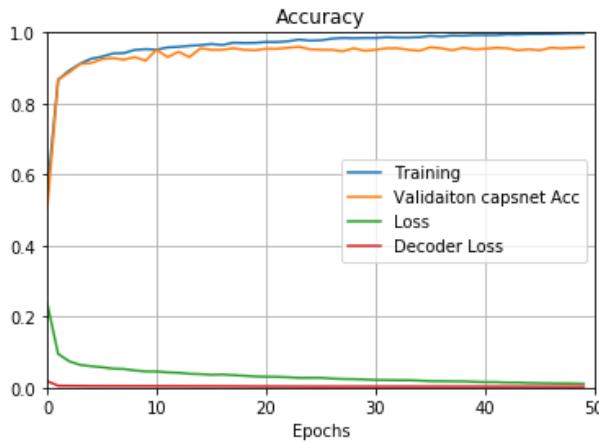
Burada eğer bir sınıf yoksa $T_k=0$, varsa, $T_k = 1$ ve $m^+ = 0.9$ ve $m^- = 0.1$ 'dır. Hesaplanan vektörlerin uzunluğu, görüntüdeki nesnenin, o kısmında bulunma olasılığını gösterir. Vektörün yönü, nesnenin doku, poz, renk, vb. bilgilerini içermektedir [22]. Çalışmada kullanılan kapsül ağ yapısı Şekil 3'de gösterilmiştir.



Şekil 3. EEG sinyallerinin spektrogram görüntülerinin sınıflandırılması için kapsül ağ yapısı

3. Deneysel Sonuç ve Tartışma

Çalışmada, EEG sinyallerinin preiktal ve interiktal aktivitelerini kapsül ağları ile sınıflandırma işlemi gerçekleştirilmiştir. CHB-MIT veri setindeki beş vakanın (chb01, chb02, chb03, chb04, chb05) FP1-F7, F7-T7, C3-P3 kanal bilgileri incelenmiştir. Örneğin chb01 vakasında, herhangi bir nöbetten 30dk uzaklıkta bitecek şekilde, şartlara uygun beş nöbet bulunmaktadır. Beş nöbet için ($5 \times 30\text{dk}$) 150dk preiktal bölge alınmıştır. Dengeli bir eğitim aşaması için aynı uzunlukta interiktal aktivite seçilmiştir. Interiktal bölge, nöbetlerden en az iki saat uzaklıkta olacak şekilde 150dk seçilmiştir. 150dk'lık preiktal ve interiktal bölgeler 5sn'lik örtüşmesiz kalan pencere yöntemi kullanılarak 1800 parçaaya ayrılmıştır. Her bir parça spektrograma dönüştürülmüştür. Sonuç olarak chb01 vakası için 3600 spektrogram görüntüsü elde edilmiştir. Aynı işlemler diğer vakalar içinde gerçekleştirilmiştir. Chb01 vakasının eğitim sürecine ait bir katlama (fold) için performans grafiği Şekil 4'de gösterilmiştir.



Şekil 4. Chb01 vakasının bir katlama için eğitim ve kayıp grafikleri

Beş vakanın her üç kanal için elde edilen doğruluk, duyarlılık ve özgüllük sonuçları Tablo 1'de verilmiştir. Önerilen yöntemin sonuçlarının daha nesnel olarak değerlendirilebilmesi için k -katlamalı çapraz doğrulama yöntemi kullanılmıştır. k değeri 5 olarak belirlenmiştir. Tablo 1'de görüldüğü gibi en yüksek sınıflama doğruluğuna chb02'nin FP1-F7 ve C3-P3 kanallarında ulaşılmıştır. En düşük doğruluk chb05 vakasında görülmektedir. Hangi kanalın vaka incelemesinde daha etkili olduğunu incelemek için Tablo 2'de beş vaka için her bir kanalın ortalama değeri hesaplanmıştır.

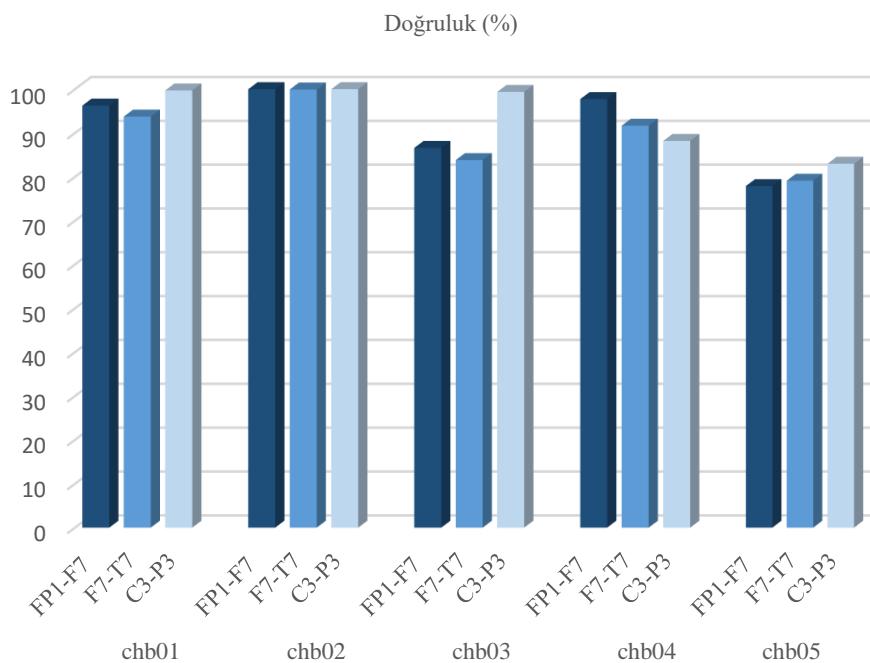
Tablo 1. Beş vakanın üç ayrı kanal için sınıflandırma performansları

Vaka	Kanal	Duyarlılık (%)	Özgüllük (%)	Doğruluk (%)
chb01	FP1-F7	97.38	95.10	96.25 ± 0.64
	F7-T7	92.50	94.99	93.75 ± 0.85
	C3-P3	99.66	99.77	99.72 ± 0.20
chb02	FP1-F7	100.0	100.0	100.0 ± 0.00
	F7-T7	100.0	99.86	99.93 ± 0.14
	C3-P3	100.0	100.0	100.0 ± 0.00
chb03	FP1-F7	86.66	86.52	86.60 ± 1.21
	F7-T7	86.24	81.38	83.82 ± 2.25
	C3-P3	100.0	98.75	99.38 ± 0.64
chb04	FP1-F7	95.37	99.81	97.73 ± 0.90
	F7-T7	87.22	96.11	91.67 ± 0.96
	C3-P3	94.81	81.57	88.19 ± 1.25
chb05	FP1-F7	85.76	70.00	77.88 ± 1.15
	F7-T7	84.79	73.40	79.10 ± 1.25
	C3-P3	93.75	72.22	82.99 ± 2.22

Tablo 2'de görüldüğü gibi, en yüksek ortalama doğruluk %94.05 ile C3-P3 kanalında elde edilmiştir. Diğer iki kanalında ortalama doğruluk değerlerine bakıldığı zaman bu kanallarında preiktal/interiktal ayrimında etkili bir şekilde kullanılabileceği görülmektedir. Şekil 5'te vakaların doğruluk değerleri grafiksel olarak karşılaştırılmıştır.

Tablo 2. Her üç kanalın ortalama performans değerleri

Ölçütler	FP1-F7	F7-T7	C3-P3
Duyarlılık (%)	93.03 ± 6.45	90.15 ± 6.22	97.64 ± 3.10
Özgüllük (%)	90.28 ± 12.59	89.15 ± 11.24	90.46 ± 12.83
Doğruluk (%)	91.69 ± 9.26	89.65 ± 8.24	94.05 ± 7.95



Şekil 5. Beş vakanın her üç kanal için elde edilen doğruluk değerleri

Preiktal/interiktal aktivitelerin sınıflandırılması üzerine geleneksel makine öğrenme tekniklerinin veya yeni teknolojilerin kullanıldığı bazı çalışmalar vardır. Bu çalışmalarda, aşırı öğrenme makineleri (ELM) [24], destek vektör makineleri (DVM) [25], yapay sinir ağları [26] gibi çeşitli sınıflandırma yöntemleri kullanılmıştır. Tablo 3'te, CHB-MIT veri seti kullanılarak gerçekleştirilen preiktal/interiktal sınıflandırması üzerine yapılan çalışmaların sonuçları karşılaştırılmış olarak verilmiştir.

Tablo 3. Preiktal ve interiktal aktivite sınıflandırılması üzerine yapılan önceki çalışmalar

Yazarlar	Metotlar	Veri seti	Sonuçlar
Cho et al. [5] (2017)	PLV (Faz kilitleme değeri), DVM	CHB-MIT	Doğruluk: 83.17 Duyarlılık: 82.44 Özgüllük: 82.76
Tsiouris vd. [2] (2017)	Yerel ve global özellikler, DVM	CHB-MIT	Doğruluk: --- Duyarlılık: 85.75 Özgüllük: 85.75
Mengie et al. [27] (2018)	ESA	CHB-MIT	Doğruluk: 95.60 Duyarlılık: 94.20 Özgüllük: 96.60
Önerilen Yöntem	Kapsül ağları	CHB-MIT	Doğruluk: 94.05 Duyarlılık: 97.64 Özgüllük: 90.46

Tablo 3'te görüldüğü gibi kapsül ağları ile iyi bir sınıflandırma başarısına ulaşılmıştır. Önceki çalışmalarında belirtildiği gibi [2] preiktal durum nöbet başlangıcından iki saat öncesine kadar uzanan geniş bir aralığı kapsamaktadır. Elde edilen sonuçlar bu görüşü desteklemektedir. Bu çalışmanın kısıtlarından biri, veri kümesinin yarım saatlik EEG sinyallerinden oluşmasıdır. Preiktal bölgenin nöbet başlangıcından iki saat öncesine kadar uzandığı düşünülürse, incelenen kısım daha geniş bir aralığa yayılabilir. Fakat, aralığın artırılmasının ciddi bir donanımsal kaynak ihtiyacı ve işlem yükü getireceği de göz önünde bulundurulmalıdır. Çalışmanın diğer bir kısıtlaması ise, görüntülerin kapsül ağlarına 64x64 boyutunda verilmesidir. Resim boyutunun küçülmesi görüntüdeki birçok önemli bilginin kaybolmasına neden olabilmektedir.

4. Sonuçlar

Bu çalışmada, EEG sinyal bileşenlerinden preiktal ve interiktal aktivitelerin kapsül ağları kullanılarak sınıflandırıldığı bir yaklaşım önerilmiştir. Bu çalışma ile literatürde yeni bir sinir ağı olan kapsül ağlarının EEG sinyallerinden elde edilen spektrogram görüntülerini sınıflandırma yeteneği incelenmiştir. Sınıflandırma işleminin sonucu, yapılan ön çalışma için tatmin edicidir. Ayrıca, bu çalışmanın diğer bir sonucu, preiktal bölgenin nöbet başlangıcından önceki 30dk da bitecek şekilde seçilmesi ile bu bölgenin, oluşabilecek herhangi bir nöbet için önemli bilgiler içerdigini göstermektedir. Meydana gelebilecek bir nöbetin önceden tahmin edilmesi hekimlerin hastaya daha etkili bir şekilde müdahale edebilmesi sağlayacaktır. Bu nedenle, kapsül ağlarının, spektrogram görüntülerini sınıflandırma başarısının daha net bir şekilde ortaya konulabilmesi için daha büyük veri setleri ile eğitilmesine ihtiyaç vardır. Büyük veri seti kullanılarak yapılacak bir eğitim, sistemin geçerliliği ve güvenirlüğünü önemli ölçüde artıracaktır.

Kaynaklar

- [1] Hussain L. Detecting epileptic seizure with different feature extracting strategies using robust machine learning classification techniques by applying advance parameter optimization approach. *Cogn Neurodyn* 2018;12 (3):271–294.
- [2] Tsioris KM, Pezoulas VC, Koutsouris DD, Zervakis M, Fotiadis DI. Discrimination of Preictal and Interictal Brain States from Long-Term EEG Data. 2017 IEEE 30th International Symposium on Computer-Based Medical Systems (CBMS). IEEE, pp 318–323
- [3] Yinxia L, Weidong Z, Qi Y, Shuangshuang C. Automatic Seizure Detection Using Wavelet Transform and SVM in Long-Term Intracranial EEG. *IEEE Trans Neural Syst Rehabil Eng* 2012;20 (6):749–755.
- [4] Zhang Z, Parhi KK. Low-Complexity Seizure Prediction From iEEG/sEEG Using Spectral Power and Ratios of Spectral Power. *IEEE Trans Biomed Circuits Syst* 2016;10 (3):693–706.
- [5] Cho D, Min B, Kim J, Lee B. EEG-Based Prediction of Epileptic Seizures Using Phase Synchronization Elicited from Noise-Assisted Multivariate Empirical Mode Decomposition. *IEEE Trans Neural Syst Rehabil Eng* 2017;25 (8):1309–1318.
- [6] Ramgopal S, Thome-Souza S, Jackson M, Kadish NE, Sánchez Fernández I, Klehm J, Bosl W, Reinsberger C, Schachter S, Loddenkemper T. Seizure detection, seizure prediction, and closed-loop warning systems in epilepsy. *Epilepsy Behav* 2014;37 291–307.
- [7] Alotaiby TN, Alshebeili SA, Alshawi T, Ahmad I, Abd El-Samie FE. EEG seizure detection and prediction algorithms: a survey. *EURASIP J Adv Signal Process* 2014;2014 (1):183.
- [8] Tan JH, Hagiwara Y, Pang W, Lim I, Oh SL, Adam M, Tan RS, Chen M, Acharya UR. Application of stacked convolutional and long short-term memory network for accurate identification of CAD ECG signals. *Comput Biol Med* 2018;94 19–26.
- [9] Arslan Tuncer S, Akilotu B, Toraman S. A deep learning-based decision support system for diagnosis of OSAS using PTT signals. *Med Hypotheses*. doi: 10.1016/j.mehy.2019.03.026
- [10] Yıldırım O, Baloglu UB, Tan R-S, Ciaccio EJ, Acharya UR. A new approach for arrhythmia classification using deep coded features and LSTM networks. *Comput Methods Programs Biomed* 2019;176 121–133.
- [11] Acharya UR, Oh SL, Hagiwara Y, Tan JH, Adeli H, Subha DP. Automated EEG-based screening of depression using deep convolutional neural network. *Comput Methods Programs Biomed* 2018;161 103–113.
- [12] Giri EP, Fanany MI, Arymurthy AM, Wijaya SK. Ischemic stroke identification based on EEG and EOG using ID convolutional neural network and batch normalization. 2016 International Conference on Advanced Computer Science and Information Systems (ICACIS). IEEE, pp 484–491
- [13] Lotte F, Congedo M, Lécuyer A, Lamarche F, Arnaldi B. A review of classification algorithms for EEG-based brain-computer interfaces. *J Neural Eng* 2007;4 (2):R1–R13.
- [14] Acharya UR, Hagiwara Y, Adeli H. Automated seizure prediction. *Epilepsy Behav* 2018;88 251–261.
- [15] Yıldırım Ö, Baloglu UB, Acharya UR. A deep convolutional neural network model for automated identification of abnormal EEG signals. *Neural Comput. Appl.*
- [16] Toraman S, Arslan Tuncer S, Balgetir F. Is it possible to detect cerebral dominance via EEG signals by using deeplearning? *Med Hypotheses* 2019;131

- [17] Ullah I, Hussain M, Qazi E-H, Aboalsamh H. An automated system for epilepsy detection using EEG brain signals based on deep learning approach. *Expert Syst Appl* 2018;107:61–71.
- [18] Chao H, Dong L, Liu Y, Lu B. Emotion recognition from multiband EEG signals using CapsNet. *Sensors* 2019;19:2212.
- [19] Ha KW, Jeong JW. Motor imagery EEG classification using capsule networks. *Sensors* 2019; 19(13).
- [20] CHB-mit scalp EEG database, Physionet.org, [Online]. Available:<https://www.physionet.org/pn6/chbmit>. (2010) (accessed 04 April 2019)
- [21] Mukhometzianov R, Carrillo J. CapsNet comparative performance evaluation for image classification. *arXiv:1805.11195*. arXiv.org
- [22] Beser F, Kizrak MA, Bolat B, Yildirim T. Recognition of sign language using capsule networks. 26th IEEE Signal Processing and Communications Applications Conference, SIU 2018. pp 1–4
- [23] Sabour S, Frosst N, Hinton GE. Dynamic routing between capsules. Advances in Neural Information Processing Systems
- [24] Song Y, Zhang J. Discriminating preictal and interictal brain states in intracranial EEG by sample entropy and extreme learning machine. *J Neurosci Methods* 2016;257:45–54.
- [25] Lin L-C, Chen SC-J, Chiang C-T, Wu H-C, Yang R-C, Ouyang C-S. Classification Preictal and Interictal Stages via Integrating Interchannel and Time-Domain Analysis of EEG Features. *Clin EEG Neurosci* 2017;48 (2):139–145.
- [26] Bou Assi E, Gagliano L, Rihana S, Nguyen DK, Sawan M. Bispectrum Features and Multilayer Perceptron Classifier to Enhance Seizure Prediction. *Sci Rep* 2018;8 (1):15491.
- [27] Zhou M, Tian C, Cao R, Wang B, Niu Y, Hu T, Guo H, Xiang J. Epileptic Seizure Detection Based on EEG Signals and CNN. *Front Neuroinform* 2018;12