

Zatürre Hastalığının Derin Öğrenme Modeli ile Tespiti

Mesut TOĞAÇAR^{1*}, Burhan ERGEN², Mehmet Emre SERTKAYA³

¹ Bilgisayar Teknolojileri Programı, Teknik Bilimler Meslek Yüksekokulu, Fırat Üniversitesi, Elazığ, Türkiye

^{2,3} Bilgisayar Mühendisliği, Mühendislik Fakültesi, Fırat Üniversitesi, Elazığ, Türkiye

*¹ mtogacar@firat.edu.tr, ² bergen@firat.edu.tr, ³ m.emre357@gmail.com

(Geliş/Received:17/12/2018;

Kabul/Accepted: 20/02/2019)

Özet: Zatürre Hastalığı, insanın hayatının herhangi bir döneminde karşılaşabileceği hastalıklardan biridir. Enfeksiyon hastalıklarının yaklaşık %18'ini zatürre hastalığı oluşturmaktadır. Bu hastalık ilerleyen bazı durumlarda ölüme sebep olabilmektedir. Tibbi olarak zatürre teşhisini kesin olarak konulabilmesi için akciğer röntgen görüntülerinin bir doktor tarafından incelenmesi gereklidir. Bu çalışmada, zatürre hastalığının teşhisi için geliştirilen tanıma sistemi için erişime açık olan akciğer röntgen görüntülerinden faydalananmıştır. Elde edilen imgé kümesinde öznitelik çıkarımı için derin öğrenme modellerinden evrişimsel sini ağı (ESA) kullanılmıştır. Hastalığın teşhisi için elde edilen öznitelikler farklı sınıflandırıcılar kullanılarak başarımla karşılaştırmaları yapılmıştır. Karşılaştırma sonucunda sınıflandırma işlemi içinde kullanılan, destek vektör makineleri (DVM) ile %95,8 gibi bir yüksek başarı oranı elde edilmiştir. Zatürre gibi ölümcül hastalıkların erken teşhisisinde, derin öğrenme modellerinin daha hızlı ve doğru sonuçlar verdiği bu çalışmada izlenmiştir. Yapılan bu çalışma, ESA ile özellik çıkarmanın biyomedikal alanındaki mevcut yöntemlere kıyasla performans açısından daha iyi sonuçlar verdiği, yapılan bu çalışmada görülmüştür.

Anahtar kelimeler: ESA, Derin öğrenme, Görüntü işleme, Biyomedikal, Zatürre hastalığı.

Detection of Pneumonia with Deep Learning Model

Abstract: Recently, rapid developments in image processing have gained different perspective in deep learning models. Deep learning models continue to contribute to the areas of human health. Pneumonia is one of the diseases that people may encounter in any period of their lives. Pneumonia accounts for about 18% of infectious diseases. In some cases, this disease can cause death. In this study, lung x-ray images were used for the diagnosis of pneumonia. The convolutional neural network (CNN) from deep learning models was used for feature extraction in the resulting image set. The results of CNN with different classifiers were compared. As a result of the comparison, a success rate of approximately 95.8% was obtained with support vector machines (SVM). In the early diagnosis of deadly diseases such as pneumonia, deep learning models were found to be faster and more accurate. This study has shown that feature extraction with CNN provides better results in terms of performance than current methods in biomedical field.

Key words: CNN, Deep learning, Image processing, Biomedical, Pneumonia disease.

1. Giriş

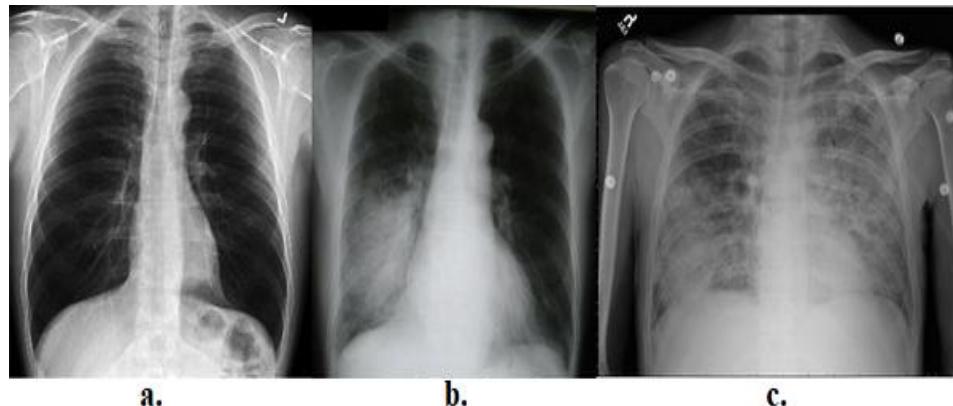
Görüntü işleme, insan gözünün yaptığı işlevleri bilgisayar ortamında çeşitli ara yüz yazılımlarıyla hızlı sonuçlar elde eden bir teknolojidir [1]. Bu teknolojide çeşitli modeller geliştirilmiştir. Geliştirilen bu modeller ile yapılan bilimsel çalışmalar da katkıda bulunulmuştur [2]. Son yıllarda, yapılan bu analiz sonuçlarında en çok tercih edilen model, makine öğrenmesinin bir parçası olan derin öğrenme modelidir. Makine öğrenmesi yöntemine kıyasla çok katmanlı bir yapıya sahip olan derin öğrenme, insan beyninin işleyişinden esinlenerek, son zamanlarda oldukça artan bir ilgi görmektedir [3]. Derin öğrenme modellerinin, görüntü işleme üzerinde yoğunlaştiği alanlardan biri de biyomedikal uygulamalarıdır. Özellikle bu alanlarda elde edilen biyomedikal imgeler üzerinde, derin öğrenme modellerinin uygulanması sonucu oldukça yüksek başarılar elde edilmiştir [4,5].

Geçmişten günümüze enfeksiyon hastalıkları, insan sağlığını tehdit eden en önemli unsurlardan biridir. Enfeksiyon hastalıklarının ilk sırasında ise latince tıbbi terim olarak pnömoni adı verilen zatürre hastalığı gelmektedir [6].

Zatürre, virüs ve bakteri gibi canlıların mikroskopik hava keselerini etkilemesi sonucu oluşan akciğer iltihaplanması olarak tanımlanır [7,9]. Her yıl dünya nüfusunun yaklaşık %7'si zatürre hastalığından etkilenir ve

* Sorumlu yazar: mtogacar@firat.edu.tr. Yazarların ORCID Numarası: ¹ 0000-0002-8264-3899, ² 0000-0003-3244-2615, ³ 0000-0001-5060-1857

etkilenen hastaların 4 milyon kadarı ölümle sonuçlanır [8]. Bu tip hastalıklarda erken tanı önemlidir [10]. Tipik belirtiler arasında göğüs ağrısı, nefes darlığı, öksürük vs. yer alır. Tanı araçları arasında balgam kültürü ve göğüs röntgeni görüntüleri bulunmaktadır [11]. Zatürre hastalığına ilişkin örnek röntgen görüntüleri Şekil 1'de gösterilmiştir.



Şekil 1. (a) Normal, (b) ve (c) zatürre hastası.

Tıbbi alanda doktorların göğüs röntgenine bakıp teşhis koyması, günümüz teknoloji çağında zaman kaybettiren bir süreçtir. Bunun yerine var olan teknolojik imkânlardan ve yazılımlardan faydalananarak teşhis yapabilmek, zaman ve maliyet açısından son derece olumlu bir gelişmedir [12]. Zatürre hastalarından elde edilen göğüs röntgen görüntülerini, derin öğrenme modelleri ile eğiterek, mevcut yöntemlere göre daha başarılı sonuçlar elde edilebilmektedir [13].

Bu çalışmada, erişime açık olan göğüs röntgeni görüntüleri, derin öğrenme yöntemlerinden biri olan ESA kullanılarak eğitilmiştir [14]. Eğitilen veri kümelerinden elde edilen öznitelikler, farklı sınıflandırıcılar kullanılarak elde edilen sonuçlar kıyaslanmıştır. En başarılı sonuç DVM sınıflandırıcısı ile elde edilmiştir.

2. Veri Kümesi ve Yöntem

Veri kümesi, bir ile beş yaş arası çocukların göğüs röntgenleri kullanılarak oluşturulmuş bir imgé veri tabanıdır [14]. Zatürre hastalığı, çocuklarda daha fazla görüldüğü için veri kümesi oluşturulurken, bu yaş aralığı tercih edilmiştir. Veri kümesi, "normal ve pnömoni" adında iki kategoriden oluşmuştur. 1583 adet normal, 4266 adet pnömoni görüntü verisi olmak üzere toplam 5849 adet görüntü kümesi kullanıldı. Görüntülerin dosya uzantısı jpeg, derinliği 8 bit ve çözünürlüğü $1448 \times 1056'$ dir. Veri kümesi, ESA modellerinden biri olan AlexNet mimarisi kullanılarak öznitelik çıkarımı elde edildi.

AlexNet mimarisi, 2012 yılında ImageNet yarışmasında adını duyuran, yaklaşık bir milyon görüntü ile eğitilme özelliğine sahip, görüntüleri sınıflandırmada son derece başarılı bir ESA modelidir. Mimari yapısı, beş adet evrişim katmanı, havuz katmanı, relu katmanı ve üç adet tam bağlantılı katmandan oluşmaktadır [15]. Evrişimsel katman, belirli bir filtrenin tüm görüntü üzerinde dolaştırılması işlemeye dayanmaktadır. Filtreler 3×3 , 5×5 gibi farklı boyutlarda olabilir. Filtreler, bir önceki katmandan gelen görüntülere konvolusyon işlemini uygulayarak çıkış verisini oluştururlar. Bu konvolusyon işlemi sonucu aktivasyon haritası oluşur. Aktivasyon haritası, her bir filtreye özgü niteliklerden oluşur [16]. AlexNet mimarısında kullanılan havuzlama katmanı; görüntü boyutunu öznitelikleri koruyarak azaltma işleminde kullanılan, maliyeti düşüren ve görüntü bilgilerini koruyan bir yapıya sahiptir. Bu yapıyla parametre sayısı azaltılarak görüntüden elde edilecek bilgileri korumayı amaçlar [15,19].

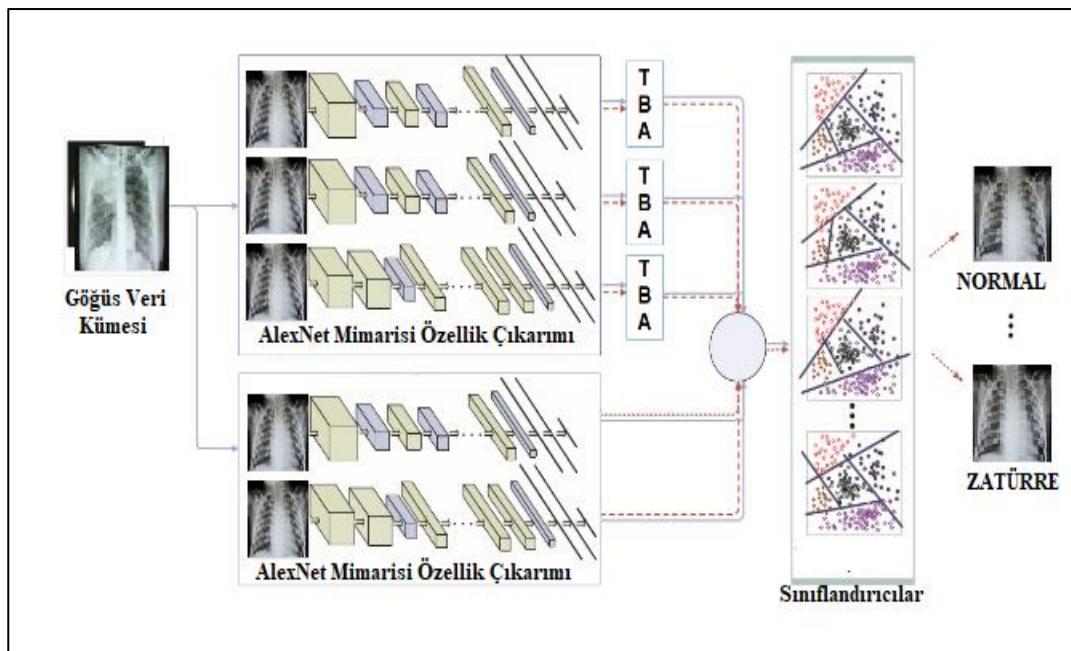
AlexNet mimarisi Tablo 1'de görüldüğü üzere, resim boyutu 227×227 seçilmiş olup, filtre boyutu 11×11 ve adım sayısı dört olarak seçilmiştir [17]. Bu değerler, yapılan bu çalışmada da korunmuştur.

Çalışmada kullanılan görüntü boyutu (1448×1056), AlexNet mimarı yapısına uygun (227×227) formata dönüştürülmüştür. Mimarının içerisinde, temel bileşenler analizi (TBA) kullanılarak öznitelik indirgenmesi gerçekleştirildi [18]. AlexNet mimarisi iki yöntem seçilerek veri kümesi üzerinde uygulandı. Birinci yöntemde, AlexNet ile elde edilen nitelikler TBA ile etkin öznitelikler belirlendikten sonra sınıflandırma yapıldı. İkinci yöntemde ise TBA uygulanmadan öznitelikler doğrudan sınıflandırıldı. İki yöntemde de sınıflandırıcı olarak; karar ağacı (KA), doğrusal ayrımçılık analizi (DAA), lineer regresyon (LR), DVM, en yakın komşu (eYK) ve

softmax yöntemleri kullanıldı. Kullanılan sınıflandırıcı yöntemlerinin performans sonuçları birbirleri ile kıyaslandı. Amaç, bu çalışmada kullanılan en iyi sınıflandırıcıyı tespit etmektir. Önerilen mimarinin tasarımları, Şekil 2'de gösterilmiştir.

Tablo 1. Çalışmada kullanılan AlexNet mimari yapısı [15,17].

Katman		Özellik Haritası	Boyut	Filtre Boyutu	Adım	Aktivasyon
Giriş	Görüntü	1	227×227×3	-	-	-
1	Evrişimsel	96	55×55×96	11×11	4	relu
	Mak. Havuzlama	96	27×27×96	3×3	2	relu
2	Evrişimsel	256	27×27×256	5×5	1	relu
	Mak. Havuzlama	256	13×13×256	3×3	2	relu
3	Evrişimsel	384	13×13×384	3×3	1	relu
4	Evrişimsel	384	13×13×384	3×3	1	relu
5	Evrişimsel	256	13×13×256	3×3	1	relu
	Mak. Havuzlama	256	6×6×256	3×3	2	relu
6	Tam Bağlantılı	-	4096	-	-	relu
7	Tam Bağlantılı	-	4096	-	-	relu
8	Tam Bağlantılı	-	1000	-	-	relu
Cıkış	Softmax	-	1000	-	-	Softmax



Şekil 2. Önerilen uygulamanın algoritma tasarımı [17, 18, 20].

2.1 Sınıflandırıcılar

KA, veri madenciliğinde sınıflandırma da kullanılan yöntemlerden birisidir. Sınıflandırma problemlerinde çokça kullanılmaktadır. KA'dan önce bir karar ağacı oluşturulmakta, daha sonra karar ağacından üretilen kurallar ile veri kümesinden çıkartılan öznitelikler birleştirilerek sınıflandırma işlemi yapılmaktadır [21].

DAA yöntemi, en çok desen sınıflandırması ve makine öğrenimi uygulamaları için ön işlem aşamasında boyut azaltma teknigi olarak kullanılır. Amaç, aşırı uyumu önlemek ve aynı zamanda hesaplama maliyetlerini azaltarak sınıflandırma işlemini yapmaktadır [22].

LR yönteminin amacı, parametreler arasındaki ilişki fonksiyonunu elde etmektir. En basit makine öğrenme modelidir. Neden ve sonuç arasında doğrusal ilişki olup olmadığını belirleyerek sınıflandırma işlemi yapmaktadır. Belirli nedene ait veri kümelerinden çıkartılan özniteliklerin değerlerine göre, sonuç değerlerini tahmin ederek sınıflandırma işlemi yapmaktadır [23].

DVM yöntemi, sınıflandırma için kullanılabilen denetimli bir makine öğrenmesi yöntemidir. Bu yöntem, her bir veri görüntüsünden elde edilen öznitelikler koordinat düzlemine yerleştirilir. Ardından, iki sınıfı iyi bir şekilde ayıran hiper-düzlemi bularak sınıflandırma işlemi gerçekleştirilir [24].

eYK yönteminin sınıflandırılmasında ki temel amacı; nesnelerin sahip olduğu özelliklere bakarak, nesnelerin hangi sınıfı ait olduğunu belirlemesi işlemine dayanmaktadır. Seçilen bir özelliğin kendine en yakın olan özellikle arasındaki yakınlığı kullanarak sınıflandırma işlemi yapılır. Nesneler arasındaki mesafelerin belirlenmesinde Denklem (1)'deki Öklid formülü kullanılmaktadır. Yeni gelen veri ile diğer veriler arasındaki mesafeler hesaplanırken Kosinüs, Öklid ya da Manhattan uzaklılığı gibi yöntemler kullanılır [25].

$$\text{Uzaklık}_{(i,j)} = \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2} \quad (1)$$

Son olarak bu çalışmada kullanılan Softmax yöntemi ise, LR yönteminin genelleştirilmiş halidir. Yani sınıflandırma etiketinin daha fazla değer alabileceği, sınıflandırma işlemlerinde kullanılır. MNIST rakam sınıflandırılması probleminde, 10 farklı rakamı ayırt edip sınıflandırma işlemi yapmıştır [26].

3. Bulgular

AlexNet mimarisi, 64 bitlik Windows 10 işletim üzerinde kurulan Matlab R2017b görüntü işleme yazılımı kullanılarak derlendi. Kullanılan bilgisayarın özellikleri; Nvidia GForce 2 GB grafik kartı, Intel i5 çekirdekli 2.5 GHz işlemci ve 8 GB ram bellektir.

Bu çalışmanın geçerliliğinin ölçülmesi; duyarlılık, özgürlük ve doğruluk ile ilişkili olarak doğru pozitif (DP), doğru negatif (DN), yanlış pozitif (YP), yanlış negatif (YN) anlamındadır [27,28].

$$\text{Duyarlılık} = \frac{(DP)}{(DP+YN)} \quad (2)$$

$$\text{Hassasiyet} = \frac{(DP)}{(DP+YP)} \quad (3)$$

$$\text{Özgünlük} = \frac{(DN)}{(DN+YP)} \quad (4)$$

$$F\text{-skor} = \frac{(2 \times DP)}{(2 \times DP + YP + YN)} \quad (5)$$

$$\text{Doğruluk} = \frac{(DP+DN)}{(DP+YN)+(YP+DN)} \quad (6)$$

- DP, zatürre hastası olarak sınıflandırılan zatürre hastası röntgen görüntülerin sayısını temsil eder.
- DN, normal olarak sınıflandırılan normal göğüs röntgen görüntülerinin sayısını temsil eder.
- YP, zatürre hastası olarak yanlış sınıflandırılan normal göğüs röntgen görüntülerin sayısını temsil eder.
- YN, normal göğüs röntgen olarak yanlış sınıflandırılan zatürre hastası görüntülerin sayısını temsil eder.

Bu çalışmada, görüntü kümelerinin %30' u test, %70'i eğitim kümeleri olarak ayarlandı. Veri kümelerinin doğrulama kümelerinde 16 adet görüntü yer almaktadır. Doğrulama kümelerindeki veri sayısı az olduğundan dolayı, bu kümeye yer alan görüntüler de test ve eğitim kümelerine ilave edildi. Ayrıca bu çalışmada, çapraz doğrulama kullanılmadı. Verilerin eğitiminde transfer öğrenme kullanılmadı. Özellikle çıkarımında AlexNet mimarisinin Tablo 1'de belirtilen parametreleri ve katmanları kullanıldı. Sınıflandırıcı olarak; KA, DAA, LR, DVM, eYK ve softmax yöntemleri kullanıldı. Her bir özellik çıkarımı ve sınıflandırma işlemi için, ortalama 371,45 saniye

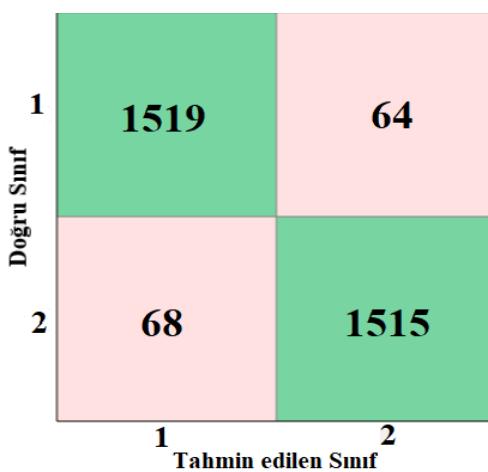
zaman harcandı. Sınıflandırma yöntemlerinden en başarılı sınıflandırma işlemini DVM ile gerçekleştirildi. Her bir sınıflandırma yöntemi, Şekil 2'de görüldüğü gibi TBA kullanılmadan ve TBA kullanılarak elde edilen tasarımın performans ölçümleri, sırasıyla Tablo 2 ve 3'de gösterilmiştir. TBA yöntemiyle kullanılan sınıflandırıcılar ile TBA yöntemi dâhil edilmeden kullanılan sınıflandırıcılardan elde edilen sonuçlar, birbirine yakın sonuçlardır. TBA'nın en önemli avantajı, öznitelik düşürümü yaptığı için sonuçlandırma işleminde zamansal açıdan kazanç sağlamıştır [29]. DVM ile ilgili karmaşıklık matrisi Şekil 3'te ve ROC eğrisi Şekil 4'te yer almaktadır.

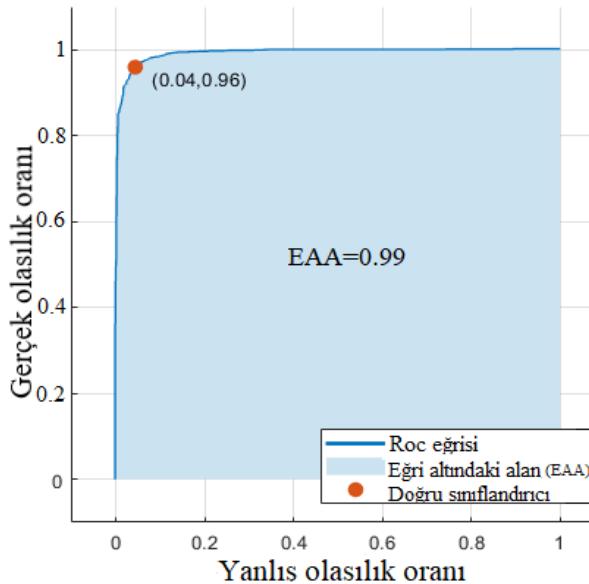
Tablo 2. TBA kullanılmadan sınıflandırıcı sonuçları.

Sınıflandırıcı	Doğruluk (%)	Duyarlılık (%)	Özgünlük (%)	Hassasiyet (%)	F1 Skor (%)
KA	92,80	91,74	93,91	94,06	92,89
DAA	73,50	96,28	65,72	48,96	64,91
LR	60,71	70,60	57,23	36,70	48,30
DVM	95,83	95,72	95,95	95,96	95,84
eYK	93,59	92,65	94,57	94,69	93,66
SOFTMAX	92,95	88,78	98,12	98,32	93,31

Tablo 3. TBA kullanılarak sınıflandırıcı sonuçları.

Sınıflandırıcı	Doğruluk (%)	Duyarlılık (%)	Özgünlük (%)	Hassasiyet (%)	F1 Skor (%)
KA	92,61	91,66	93,60	93,75	92,69
DAA	72,80	94,79	65,30	48,26	63,96
LR	60,90	70,81	57,38	37,08	48,67
DVM	95,40	95,68	95,10	95,07	95,37
eYK	92,10	91,27	92,97	93,11	92,18
SOFTMAX	92,95	88,78	98,12	98,32	93,31

**Şekil 3.** DVM sınıflandırıcıya ait karmaşıklık matrisi.



Şekil 4. DVM sınıflandırıcıya ait ROC eğrisi.

Çalışmada kullanılan veri kümesi yakın zaman içerisinde erişime sunulduğu için, önerilen çalışmanın aynı veri seti kullanan diğer çalışma ile karşılaştırılması Tablo 4'te gösterilmiştir. Kendi çalışmamızda önerilen modelin başarı oranı diğer çalışmaya göre daha iyi sonuç verdiği Tablo 4'te görülmektedir.

Tablo 4. Aynı veri kümelerini kullanan çalışmaların sonuçları.

Yazar, Yıl	Sınıflandırıcı	Başarı(%)
Bai Cheng Shi, 2018 [30]	CNN + R programlama	92,63
Önerilen Çalışma	CNN+ Quadratik DVM	95,8

4. Tartışma

Enfeksiyon hastalıklarının birinci sırasında yer alan zatürre, dünya genelinde çocuklarda en sık görülen hastalıklar arasında yer almaktadır [31,32]. Bu hastalığa yakalanmış hastalarda erken teşhis yapılmadığı sürece, neticesi ölümle sonuçlanabilekmektedir. Hastalığın erken teşhisi, görüntü analiz sonuçlarının hızlı ve doğru sonuçlar vermesiyle eşdegerdir.

Bu çalışmada, erişime açık görüntü kümelerini kullanarak, zatürre hastalığının tanısı için katkıda bulunuldu. Ayrıca, donanım özellikleri daha iyi bir bilgisayar ile veri kümeleri derlenebilseydi, elde edilen sonuçlar daha yüksek sonuçlanabilecekti.

TBA yönteminin ESA modelinin içerisinde kullanılması, elde edilen performans sonuçlarına olumlu katkıda bulunamasa da, veri kümelerinin fazla olduğu durumlar da verilerin sınıflandırma işleminin fazla zaman almasını önlediği tespit edildi.

5. Sonuç

Son zamanlarda biyomedikal alanda derin öğrenme modeliyle ilgili birçok çalışma yapılmıştır. Derin öğrenmenin etkili sonuçlar verdiği yapılmış çalışmaların analiz sonuçlarında anlaşılmıştır. ESA modeli diğer alanlarda olduğu gibi biyomedikal alanda da etkili olduğu, bu makalede de gözlemlenmiştir. Burada ESA modelinin en önemli özelliği, görüntü işlemelerde daha hızlı, verimli ve en önemlisi otomatik olarak öznitelikler çıkarıp ve bunu sonuca yansıtmasıdır [29]. Bu modelin, göğüs röntgen görüntüleri üzerinde uygulanması; zatürre hastalığının erken teşhisi için önemlidir.

Bu makalede, AlexNet mimarisi kullanılarak bir özellik çıkarım kümeli elde edilmiştir. Elde edilen

özellikler, KA, DAA, LR, DVM, eYK ve softmax sınıflandırıcılar kullanılarak görüntü kümeleri arasında sınıflandırılma işlemi gerçekleştirilmiştir. TBA'nın kullanılmasının sonuçlar üzerindeki etkisi analiz edilmiş olup, zamanдан kazanç sağladığı görülmüştür [33]. Kullanılan sınıflandırıcılar içerisinde en başarılı sınıflandırıcı %95,8 başarı orıyla DVM sınıflandırıcı olmuştur.

Kaynaklar

- [1] P. P. P., "DIGITAL IMAGE PROCESSING TECHNIQUES – A SURVEY," vol. 5, no. 11, 2017.
- [2] J. Zhang, Y. Xia, Y. Xie, M. Fulham, and D. Feng, "Classification of Medical Images in the Biomedical Literature by Jointly Using Deep and Handcrafted Visual Features," *IEEE J. Biomed. Heal. Informatics*, vol. 2194, no. 2, pp. 1–10, 2017.
- [3] S. Koitka and C. M. Friedrich, "Traditional feature engineering and deep learning approaches at medical classification task of imageCLEF 2016," *CEUR Workshop Proc.*, vol. 1609, pp. 304–317, 2016.
- [4] D. Ravi, C. Wong, F. Deligianni, M. Berthelot, J. Andreu-Perez, B. Lo, and G. Z. Yang, "Deep Learning for Health Informatics," *IEEE J. Biomed. Heal. Informatics*, vol. 21, no. 1, pp. 4–21, 2017.
- [5] M. Bakator and D. Radosav, "Deep Learning and Medical Diagnosis: A Review of Literature," *Multimodal Technol. Interact.*, vol. 2, no. 3, p. 47, 2018.
- [6] S. Akter, Shamsuzzaman, and F. Jahan, "Community Acquired Pneumonia," pp. 1–5, 2015.
- [7] McLuckie, A. (editor), *Respiratory disease and its management.*, New York, Springer, p. 51, ISBN 978-1-84882-094-4, 2009.
- [8] Osler, William (1901). *Principles and Practice of Medicine*, 4th Edition. New York: D. Appleton and Company. s. 108.
- [9] Jeffrey C. Pommerville (2010) . Alcamo's Fundamentals of Microbiology (9. bas.). Sudbury MA: Jones & Bartlett. s. 323. ISBN 0-7637-6258-X.
- [10] J. M. Qu and H. Summeh, "Biomarkers: A definite plus in pneumonia," *Mediators Inflamm.*, vol. 2009, 2009.
- [11] D. Berliner, N. Schneider, T. Welte, and J. Bauersachs, "The differential diagnosis of dyspnoea," *Dtsch. Arztbl. Int.*, vol. 113, no. 49, pp. 834–844, 2016.
- [12] J. D. Howell and A. Arbor, "Early Clinical Use of the X-Ray," *Trans. Am. Clin. Climatol. Assoc.*, vol. 127, pp. 341–349, 2016.
- [13] V. Menger, F. Scheepers, and M. Spruit, "Comparing Deep Learning and Classical Machine Learning Approaches for Predicting Inpatient Violence Incidents from Clinical Text," *Appl. Sci.*, vol. 8, p. 981, 2018.
- [14] "Chest X-Ray Images (Pneumonia) | Kaggle ." [Online]. Available: <https://www.kaggle.com/paultimothymooney/chest-xray-pneumonia/data>. [Accessed: 25-Nov-2018].
- [15] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet Classification with Deep Convolutional Neural Networks," *Adv. Neural Inf. Process. Syst.*, pp. 1–9, 2012.
- [16] J. Koushik, "Understanding Convolutional Neural Networks," 2016.
- [17] J. Nagi and F. Ducatelle, "Max - pooling convolutional neural networks for vision-based hand gesture recognition," 2011 IEEE Int. Conf. Signal Image Process. Appl., pp. 342–347, 2011.
- [18] M. D. Zeiler and R. Fergus, "Visualizing and Understanding Convolutional Networks arXiv:1311.2901v3 [cs.CV] 28 Nov 2013," *Comput. Vision-ECCV 2014*, vol. 8689, pp. 818–833, 2014.
- [19] S. Gu, L. Ding, Y. Yang, and X. Chen, "A New Deep Learning Method Based on AlexNet Model and SSD Model for Tennis Ball Recognition," pp. 159–164, 2017.
- [20] S. Koitka and C. M. Friedrich, "Traditional feature engineering and deep learning approaches at medical classification task of imageCLEF 2016," *CEUR Workshop Proc.*, vol. 1609, pp. 304–317, 2016.
- [21] L. Rokach and O. Maimon, "Decision Trees," no. January, 2005.
- [22] A. Tharwat, T. Gaber, A. Ibrahim, and A. E. Hassanien, "Linear discriminant analysis: A detailed tutorial," no. July, 2017.
- [23] S. E. E. Profile, "Linear Regression Based Feature Selection for Microarray Data Classification," no. November, 2015.
- [24] A. Pradhan, "SUPPORT VECTOR MACHINE-A Survey," no. April, 2015.
- [25] S. Zhang, X. Li, M. Zong, X. Zhu, and R. Wang, "Efficient kNN classification with different numbers of nearest neighbors," *IEEE Trans. Neural Networks Learn. Syst.*, vol. 29, no. 5, pp. 1774–1785, 2018.
- [26] R. Memisevic, G. Hinton, C. Zach, and M. Pollefeys, "Gated Softmax Classification," pp. 1–9.
- [27] Z. Cömert, A.F. Kocamaz, Comparison of Machine Learning Techniques for Fetal Heart Rate Classification, *Acta Phys. Pol. A.* 132 (2017) 451–454. doi:10.12693/APhysPolA.131.451.
- [28] D. M. W. Powers and Ailab, "Evaluation: From Precision, Recall and F-Measure To Roc, Informedness, Markedness & Correlation," vol. 2, no. 1, pp. 37–63, 2011.

- [29] Z. Cömert, A.F. Kocamaz, V. Subha, Prognostic model based on image-based time-frequency features and genetic algorithm for fetal hypoxia assessment, *Comput. Biol. Med.* (2018). doi:<https://doi.org/10.1016/j.combiomed.2018.06.003>.
- [30] “Pneumonia – Diagnosis - using- XRays” [Online]. Available:<https://github.com/fr407041/Pneumonia-Diagnosis-using-XRays/>. [Accessed: 26-Nov-2018].
- [31] Er, O., Yumusak, N., Temurtas, F., “Diagnosis of chest diseases using artificial immune system”, *Expert Systems with Applications*, 39., 1862–1868, 2012.
- [32] Global Strategy for the Diagnosis, Management, and Prevention of Chronic Obstructive Pulmonary Disease, Global Initiative For Chronic Obstructive Lung Disease (GOLD) Inc., 2015.
- [33] J. Shlens, “Shlens2006_PCATutorial,” *Measurement*, pp. 1–13, 2005.