

Parçacık Sürü Optimizasyonu Yöntemi ile Sayım Modelleri için En Uygun Değişken Kümesinin Belirlenmesi

Haydar KOÇ¹, Tuba KOÇ^{*2}, Emre DÜNDAR³

^{1,2}Çankırı Karatekin Üniversitesi, Fen Fakültesi, İstatistik Bölümü, Çankırı

¹(ORCID: <https://orcid.org/0000-0002-8568-4717>)

²(ORCID: <https://orcid.org/0000-0001-5204-0846>)

³Ondokuz Mayıs Üniversitesi, Fen-Edebiyat Fakültesi, İstatistik Bölümü, Samsun

³(ORCID: <https://orcid.org/0000-0003-0230-8968>)

(Alınış / Received: 25.06.2018, Kabul / Accepted: 29.01.2019, Online Yayınlanması / Published Online: 11.03.2019)

Anahtar Kelimeler

Değişken seçimi,
Sayım modelleri,
Sezgisel optimizasyon

Özet: Birçok bilimsel çalışmada sayımlı verisi olarak adlandırılan negatif olmayan tamsayı değerleri alan nicel veriler kullanılmaktadır. İstatistiğin en temel analiz yöntemlerinden biri olan regresyon analizi kapsamında da sayımlı verileri oldukça sık kullanılmaktadır. Bağımlı değişkenin tamsayı ile ifade edilebildiği regresyon modelleri sayımlı modelleri olarak tanımlanır. Bu çalışmada sayımlı modelleri kapsamında model seçimi incelendi. Sayımlı modellerinde model seçimi için klasik seçim yöntemleri ve PSO algoritması kullanıldı. Uygulamalar hem simülasyon hem de gerçek veriler üzerinde yapıldı. Sonuç olarak klasik yöntemlerle kıyaslandığında PSO algoritmasının, modeldeki değişken sayısının arttıkça ve bağımsız değişkenler arasındaki korelasyon değerleri yükseldikçe daha iyi sonuçlar verdiği ve sayımlı modelleri için PSO algoritmasının değişken seçiminde alternatif bir yöntem olarak kullanılabileceği gösterilmiştir.

Determination of Best Variable Set for Count Models by Particle Swarm Optimization

Keywords

Variable selection,
Count models,
Heuristic optimization

Abstract: In most scientific studies quantitative data are used which take non-negative integer values, called count data. Count data are also used frequently in the context of regression analysis, which is one of the most basic analysis methods of statistical analysis. The regression models in which the dependent variable can be expressed by integers are defined as count models. In this study, the model selection in the context of count models was investigated by using classical selection methods and PSO algorithm. Applications were made on both simulation and real data. As a result, it has been shown that PSO algorithm can be used as an alternative method for PSO algorithm selection for count models when the number of model variables increases and the correlation values between independent variables increases as compared to classical methods.

1. Giriş

Bilimsel çalışmalarında kullanılan nicel verilerin birçoğu belirli bir değer aralığı içerisinde sürekli değerlere sahip değildir. Verilerin bazıları uygulama alanlarına göre negatif olmayan tamsayılar ile ifade edilmektedir. Bu veriler sayımlı verileri olarak adlandırılır. İstatistiğin en temel analizlerinden biri olan regresyon analizi kapsamında da sayımlı verileri kullanılmaktadır. Bağımlı değişkenin tamsayı ile ifade edilebildiği regresyon modelleri sayımlı modelleri olarak tanımlanır. Sayımlı modellerinin tahmin gücü bağımsız değişkenlerin modeli açıklayabilme gücüne bağlıdır. Bu amaçla farklı regresyon modellerinde

olduğu gibi, en uygun değişken kümesi belirlenerek regresyon modeli oluşturulmalıdır. Bağımsız değişkenler arasında yüksek derecede ilişkinin bulunması, gereksiz değişkenlerin modele dahil edilmesi gibi çeşitli hatalar regresyon modelinin tahmin performansını düşürmektedir. Regresyon modeli içerisinde en uygun modelin seçimi için değişken seçim algoritmaları uygulanmaktadır. Değişken seçimi için literatürde en sık kullanılan üç klasik yöntem vardır. Bunlar; geriye doğru, ileriye doğru ve adımsal seçim teknikleridir. Ancak bu teknikler birçok durumda iyi sonuçlar vermemektedir [1,2]. Değişken sayısı arttıkça klasik seçim yöntemleri çoğu zaman uygun modeli

seçememektedir. Ayrıca çok yüksek boyutlu verilerde çoklu bağlantı sorunu sebebiyle klasik seçim yöntemleri ile model belirlemek mümkün değildir. Söz konusu problemleri çözmek amacıyla sezgisel optimizasyon tekniklerinden yararlanılmaktadır [3].

Literatür incelendiğinde model seçiminde yapılan çalışmaların büyük bir kısmının lineer ve lojistik regresyon analizi üzerine olduğu görülmektedir. Lineer regresyon analizi için tabu araştırma [4], genetik algoritma [2], hibrit genetik algoritma-benzetimli taylama metodu kullanılmıştır [5]. Lojistik regresyon analizinde tabu araştırma algoritması [6] ve parçacık sürü optimizasyonu algoritmasını kullanılarak optimum değişken kümesinin seçimini incelemiştir [7]. Genelleştirilmiş lineer modellerde model seçimi üzerine farklı yöntemler de kullanılmıştır. Poisson regresyon analizinde adımsal bir model seçim yöntemi önermiştir [8]. McLeod ve Xu genelleştirilmiş lineer modeller için değişken seçimi uygulayan bestglm isimli bir paket geliştirmiştir [9]. Calcagno, ve Mazancourt genelleştirilmiş lineer modellerde genetik algoritma kullanarak değişken seçimi uygulayan glmulti isimli bir yazılım paketi oluşturmuştur [10]. Regresyon modellerinde cezalandırma yöntemleri de model seçiminde sıkça kullanılmaktadır. Cezalandırma yöntemleri ile model seçimi konusunda bilinen en genel yöntem LASSO metodudur [11]. Bu metodun ana fikri, modeldeki regresyon katsayılarını sıfıra yaklaştıracak şekilde daraltmaktadır. LASSO tekniğinde cezalandırma için elastik net [12], adaptif LASSO [13] yöntemleri geliştirilmiştir.

Cezalandırma yöntemleri kullanarak değişen yayılım parametreli beta regresyon modeli için değişken seçim tekniği uygulanmıştır [14]. Beta regresyon analizinde model seçimi için bootstrap teknigi kullanılmıştır [15].

Model seçimi üzerinde son derece etkili olan bilgi kriterleri için de çok sayıda çalışma mevcuttur. Regresyon analizinde en çok kullanılan kriterler Akaike ve Bayesci bilgi kriterleridir. Akaike bilgi kriteri yanlışlık probleminin çözümü ve küçük örneklemlerde de iyi performans sağlama için alternatif cezalandırmalar ile düzeltilmiş ve yeni Akaike türü kriterler önerilmiştir [16,17]. Bayesci bilgi kriteri de regresyon katsayılarına ilişkin kovaryans matrisi de cezalandırma terimine dahil olacak şekilde düzenlenmiş ve alternatif iki kriter önerilmiştir [18]. Kovaryans matrisini cezalandırma terimine dahil ederek bilgi kriteri hesaplayan yaklaşım ilk olarak Bozdoğan tarafından önerilmiştir [19]. Bu yaklaşım, cezalandırma terimindeki değişiklikler ile düzenlenerek alternatif kriterler türetilmiştir [20, 21, 22].

Model seçimi, istatistiksel modelleme içerisinde son derece önemli bir konudur. Klasik model seçim algoritmaları, sayıım modelleri kapsamında modelin

performansını optimize etme konusunda zayıf olduğundan, sezgisel optimizasyona dayalı yaklaşımalar daha başarılı sonuçlar sağlama potansiyeline sahiptir. Bu sebeple, çalışmanın temel motivasyon kaynağı, sayıım modellerinde model seçimi sürecini parçacık sürü optimizasyonu algoritması kullanarak gerçekleştirmektir.

2. Materyal ve Metot

2.1. Poisson regresyon modeli

Poisson regresyon modeli sayımla elde edilen verilerin modellenmesinde kullanılan temel bir yaklaşımdır. Y_i ($i = 0, 1, 2, \dots$), ortalaması μ_i olan belli bir zamanda meydana gelen olayların sayısı olsun. Bu durumda Y_i ler Poisson rasgele değişkenidir ve olasılık fonksiyonu

$$f(y_i; \mu_i) = \frac{e^{-\mu_i} \mu_i^{y_i}}{y_i!} \quad y_i = 0, 1, 2, \dots \quad (1)$$

ile verilir. Burada, ortalama ve varyans $E(Y_i) = \text{Var}(Y_i) = \mu_i'$ dir. Log-olabilirlik fonksiyonu eşitlik (2)'de verildiği gibidir.

$$\mathcal{L}(\mu; y) = \sum_{i=1}^n \{y_i \ln(\mu_i) - \mu_i - \ln(y_i!)\} \quad (2)$$

$X: n \times (p + 1)$ boyutlu açıklayıcı değişken matrisi olsun. Y_i ve X 'in i -nci satır vektörü arasındaki ilişki eşitlik (3)'de verilmiştir.

$$\ln(\mu_i) = \eta_i = x_i^T \beta \quad (3)$$

Bu model poisson regresyon veya log-linear model olarak bilinir. β 'nin en çok olabilirlik tahmin edicisi $\hat{\beta}$, Fisher scoring yöntemi ile elde edilebilir.

Poisson regresyon modelinde iki temel varsayımdır. Birincisi, olaylar zamana göre birbirinden bağımsız gerçekleşir. İkincisi, şartlı beklenen değer ve varyans birbirine eşittir. İkinci varsayımda bahsedilen eşitlik durumu, eşit yayılım olarak bilinir ve uygulamada çoğunlukla eşit yayılım durumu sağlanmaktadır ve genelde varyans ortalamadan büyük çıkmaktadır.

2.2. Negatif binomial modeli

Poisson regresyon modelinde, bağımlı değişken için varyansın ortalamadan büyük olması, bağımlı değişken değerleri arasında pozitif korelasyonun bulunması veya verilerin olasılıkları arasındaki değişimin yüksek olması gibi durumlar aşırı yayılıma neden olabilir. Ayrıca verinin dağılımsal varsayımlarında bir ihlal söz konusu olduğu durumlarda da aşırı yayılım ortaya çıkabilir.

Aşırı yayılım durumunda en sık başvurulan yaklaşım Negatif Binomial Regresyon Modelidir (NBRM). NBRM, modele gözlemlenemeyen heterojenlik terimi

dahil edilerek geliştirilebileceği gibi bir çok farklı yöntem ile de elde edilebilir [23].

Negatif binomial dağılımin olasılık fonksiyonu aşağıda verildiği gibidir:

$$\Pr(y_i|x_i) = \frac{\Gamma(y_i + \alpha^{-1})}{y_i! \Gamma(\alpha^{-1})} \left(\frac{\alpha^{-1}}{\alpha^{-1} + \mu_i} \right)^{\alpha^{-1}} \left(\frac{\mu_i}{\alpha^{-1} + \mu_i} \right)^{y_i} \quad (4)$$

Burada $\Gamma(\cdot)$ ile gamma fonksiyonu ifade edilmektedir ve α sabit bir parametredir. Negatif binomial dağılımı için y 'nin beklenen değeri Poisson dağılımı ile aynıdır. Yani, $\mu_i = E(y_i|x_i) = e^{x_i'\beta}$ 'dır.

Ancak varyansı, eşitlik (5)'de verildiği gibidir:

$$\text{Var}(y_i|x_i) = \mu_i(1 + \alpha\mu_i) = e^{x_i'\beta}(1 + \alpha e^{x_i'\beta}) \quad (5)$$

NBRM'de, y - nin varyansı, beklenen değerinden büyüktür. Çünkü, μ ve α 'nın her ikisi de pozitiftir. Eşitlik (5), $\alpha = 0$ olduğunda μ_i olur. Yani, $\alpha = 0$ olduğunda negatif binomial dağılımı poissona indirgenir. NBRM parametreleri tahmininde en çok olabilirlik yöntemi kullanılabilir [23].

2.3. Sıfır yoğunluklu poisson model

Sıfır yoğunluklu Poisson (ZIP) model, iki aşamalı bir karışım modelidir. Bu model, sıfır değerli gözlemlerin iki farklı şekilde ortaya çıktığını varsayar. Birinci durum w_i olasılığı ile gerçekleşir ve sadece sıfır üretir. İkinci durum $(1 - w_i)$ olasılığı ile meydana gelir ve μ ortalamalı standart bir Poisson sayımları verisi elde edilir.

Genelde birinci durumdan elde edilen sıfırlar yapısal sıfırlar olarak ve Poisson dağılımından kaynaklanan sıfırlar örneklem sıfırları olarak adlandırılır [24].

Bu iki aşamalı süreç iki bileşenli bir karışım dağılımı verir ve olasılık fonksiyonu aşağıdaki gibidir.

$$\Pr(y_i|x_i, \mu_i, w_i) = \begin{cases} w_i + (1 - w_i)e^{-\mu_i}, & y_i = 0, \\ (1 - w_i) \frac{e^{-\mu_i} \mu_i^{y_i}}{y_i!} & y_i = 1, 2, 3, \dots \end{cases} \quad 0 \leq w_i \leq 1 \quad (6)$$

Bu olasılık fonksiyonu $Y \sim \text{ZIP}(\mu, w)$ ile gösterilir. Y 'nin ortalama ve varyansı aşağıdaki gibidir.

$$\begin{aligned} E(y_i) &= \mu_i(1 - w_i) \\ \text{Var}(y_i) &= (1 - w_i)(\mu_i + w_i\mu_i^2) \end{aligned} \quad (7)$$

Gördüğü gibi Y 'nin marjinal dağılımı $w > 0$ olduğunda aşırı yayılma izin vermektedir. $w = 0$ olduğunda standart Poisson dağılımına indirgenmektedir.

Log olabilirlik fonksiyonu eşitlik (8)'de verildiği gibidir.

$$\mathcal{L}_{\text{ZIP}}(\mu, w; y) = \sum_{i=1}^n \{ I(y_i = 0) \ln[w_i + (1 - w_i)e^{-\mu_i}] + I(y_i > 0) [\ln(1 - w_i) - \mu_i + y_i \ln \mu_i - \ln(y_i!)] \} \quad (8)$$

ZIP modeli aşağıdaki iki link fonksiyonu eklenerek elde edilebilir.

$$\begin{aligned} \ln(\mu_i) &= X'\beta \\ \text{logit}(w_i) &= \ln \frac{w}{1-w} = X'\gamma \end{aligned} \quad (9)$$

2.4. Parçacık sürü optimizasyonu

Parçacık Sürü Optimizasyonu (PSO), sürü halinde hareket eden balıklar ve böceklerden esinlenerek geliştirilmiş bir optimizasyon yöntemidir [25]. Temel olarak sürü zekâsına dayanan bir algoritmadır. Sürü halinde hareket eden hayvanların yiyecek ve güvenlik gibi durumlarda, çoğu zaman rastgele sergiledikleri hareketlerin, amaçlarına daha kolay ulaşmalarını sağladığı görülmüştür.

Algoritma temel olarak aşağıdaki basamaklardan oluşur [26]:

- I. Rasgele üretilen başlangıç pozisyonları ve hızları ile başlangıç süreci oluşturulur.
- II. Sürü içerisindeki tüm parçacıkların uygunluk değerleri hesaplanır.
- III. Her bir parçacık için mevcut jenerasyondan yerel en iyi (pbest) bulunur. Sürü içerisinde en iyilerin sayısı parçacık sayısı kadardır.
- IV. Mevcut jenerasyondaki yerel eniyiler içerisinde küresel en iyi (gbest) seçilir.
- V. Pozisyon ve hızlar aşağıdaki gibi yenilenir.

$$\begin{aligned} V_{id} &= W * V_{id} + c_1 * \text{rand}_1 * (P_{id} - X_{id}) + c_2 * \text{rand}_2 * (P_{gd} - X_{id}) \\ X_{id} &= X_{id} + V_{id} \end{aligned}$$

Burada X_{id} pozisyon ve V_{id} hız değerlerini verirken, rand_1 ve rand_2 değerleri rasgele üretilmiş sayılardır. W , atalet ağırlık değeri ve c_1 , c_2 ölçeklendirme faktörleridir.

- VI. Durdurma kriteri sağlanıncaya kadar II, III, IV ve V adımları tekrar edilir.

2.5. Bilgi Kriterleri

Log-olabilirlik fonksiyonuna dayalı olan bilgi kriteri tabanlı model seçim teknikleri, hem iç içe hem de iç içe olmayan sayı ile ifade edilen modeller için kullanılabilirler. Modele daha fazla parametre eklendiğinde log-olabilirliğin artacağı düşünülür. Log-olabilirlik artışının cezası, gözlem sayısı kadar parametre sayısını da hesaba katar. Bu çalışmada, iki bilgi kriteri ölçüsü ele alınmıştır.

2.5.1. Akaike bilgi kriteri

Akaike bilgi kriteri (AIC) istatistiksel modellerin uyum iyiliği için kullanılan bir kriterdir.

$$AIC = -2\mathcal{L} + 2p = D(\hat{\theta}) + 2p \quad (10)$$

Burada p , modeldeki parametre sayısını ve \mathcal{L} ise log olabilirlik fonksiyonunu göstermektedir.

2.5.2. Bayesci bilgi kriteri

Aynı zamanda Schwarz kriteri olarak bilinen Bayesci bilgi kriteri (BIC) istatistiksel modellemede çok sık kullanılan bir kriterdir.

$$BIC = -2\mathcal{L} + (\ln n)p \quad (11)$$

Burada n , veri setindeki gözlem sayısını p ise parametre sayısını göstermektedir.

3. Bulgular

Uygulama aşamasında iki farklı simülasyon ve bir gerçek veri seti uygulaması yapıldı Simülasyon tasarımları çoklu bağlantı bulunan ve bulunmayan regresyon modelleri için uygulandı. Model seçim yöntemlerinden ileriye doğru (I), geriye doğru (G), adımsal (A) ve PSO metodları kullanılarak sayımlı modelleri için model seçimi sonuçları elde edildi. Uygulama aşamasında seçim yöntemlerinin seçmiş olduğu sayımlı modellerine ilişkin AIC ve BIC değerleri incelendi. AIC ve BIC değeri daha düşük olan seçim yöntemi daha başarılı olarak kabul edildi. Analizler R yazılımının 3.4.3 versiyonu kullanılarak yapılmıştır. Ayrıca "pso" ve "COUNT" paketlerinden yararlanılmıştır.

Simülasyon çalışması -1

Çalışmanın bu bölümünde çoklu bağlantı problemi içeren regresyon modelleri oluşturuldu. Simülasyon tasarımları için toplam on açıklayıcı değişken ile Poisson, negatif binomial ve sıfır yoğunluklu regresyon modelleri için klasik seçim yöntemleri ve PSO algoritmaları uygulandı. Bağımsız değişkenler aşağıdaki şekilde türetildi:

$$x_1 = 10 + \varepsilon_1 \quad (12)$$

$$x_2 = 10 + 0.3\varepsilon_1 + \alpha\varepsilon_2 \quad (13)$$

$$x_3 = 10 + 0.3\varepsilon_1 + 0.5604\alpha\varepsilon_2 + 0.8282\alpha\varepsilon_3 \quad (14)$$

$$x_4 = -8 + x_1 + 0.5x_2 + 0.3x_3 + 0.5\varepsilon_4 \quad (15)$$

$$x_5 = -5 + 0.5x_1 + x_2 + 0.5\varepsilon_5 \quad (16)$$

$\varepsilon_1, \varepsilon_2, \varepsilon_3, \varepsilon_4, \varepsilon_5 \sim N(0, 1)$ dağılımlı hata terimleridir. Eşitlik 12-16 için α parametresi çoklu bağlantı düzeyini kontrol etmektedir. Bu çalışmada geçmiş çalışmalar baz alınarak $\alpha = 0.03$ alındı ve bağımlı değişken türetimi aşağıdaki şekilde yapıldı:

$$\lambda = -8 + x_1 + 0.5x_2 + 0.3x_3 + 0.5\varepsilon \quad (17)$$

$\varepsilon_i, i=1, 2, \dots, n$ için $\varepsilon \sim N(0, 1)$ için dağılımlı hata terimidir. Eşitlik (17)'den bulunan λ değerleri ile $y \sim$

Pois(λ), NegBin(λ) ve ZINFPois(λ) biçiminde sırasıyla Poisson, negatif binomial ve sıfır yoğunluklu Poisson dağılımlı bağımlı değişkenler türetildi. Bağımsız değişkenler kümesine bağımlı değişkenler ile ilişkisi olmayan beş adet düzgün dağılımlı değişkenler $R_j \sim$ Düzgün(0,1) $j=1,2,3,4,5$ ilave edildi.

1. Simülasyon tasarımlı için örneklem sayıları sırası ile $n=30, 50, 100, 200, 500$ olarak alındı.

Simülasyon çalışması -2

Bu simülasyon çalışmasında çoklu bağlantı problemi içermeyen regresyon modelleri oluşturuldu. Simülasyon tasarımlı için sırasıyla $p=2, 3, \dots, 15$ değişken ve $n=100$ için Poisson, negatif binomial ve sıfır yoğunluklu regresyon modelleri kapsamında klasik seçim yöntemleri ve PSO algoritmaları uygulandı. Bağımsız değişkenler birbirinden bağımsız olarak $X_k, k=2, 3, \dots, 15$ için $N(0, 1)$ dağılımına uygun olarak türetildi. Bağımsız değişkenler arasındaki korelasyon yapısı, çoklu bağlantı problemi içermeyecek biçimde $\text{cor}(X_i, X_j)=0.10^{|i-j|}, i, j=2, 3, \dots, 15$ için türetildi. Bağımsız değişkenler ile bağımlı değişkenlere ait λ parametreleri ise şu şekilde türetildi:

$$\lambda = X\beta + \varepsilon \quad (18)$$

$\varepsilon \sim N(0, 1)$ dağılımlı hata terimidir. $\beta=(0.1, 0.3, 0.5, \dots, s)$ biçiminde artımsal olarak seçildi. Bu denklemdeki s , toplam değişken sayısı doğru orantılı olarak 0.1 birim artımlı β değerlerini temsil etmektedir. Eşitlik (18)'den elde edilen λ değerleri ile $y \sim \text{Pois}(\lambda)$, NegBin(λ) ve ZINFPois(λ) biçiminde sırasıyla Poisson, negatif binomial ve sıfır yoğunluklu Poisson dağılımlı bağımlı değişkenler türetildi.

Gerçek veri uygulaması

Gerçek veri uygulaması için R programında "COUNT" paketi içerisinde yer alan "affairs" hazır veri seti kullanıldı [27]. Bu veri setinde bağımlı değişken tam sayıdır ve veri seti sayımlı verilerini modellemek için son derece elverişlidir. Bu veri seti üzerinde klasik değişken seçim yöntemleri ve PSO algoritması ile model seçimi uygulandı ve modellerin AIC-BIC değerleri elde edildi.

Tablo 1. 1. Simülasyon tasarımlında Poisson regresyon modeli için AIC kriteri sonuçları

| n | Seçim yöntemi | | | |
|-----|---------------|------------|------------|------------|
| | AIC-I | AIC-G | AIC-A | AIC-PSO |
| 30 | 80.76578 | 80.76578 | 80.76578 | 80.61614 |
| 50 | 132.17770 | 132.17770 | 132.17770 | 132.10880 |
| 100 | 268.25710 | 268.25710 | 268.25710 | 268.21730 |
| 200 | 536.20400 | 536.20400 | 536.20400 | 536.19640 |
| 500 | 1333.94000 | 1333.94000 | 1333.94000 | 1333.94400 |

Tablo 2. 1. Simülasyon tasarımda Poisson regresyon modeli için BIC kriteri sonuçları

| n | Seçim yöntemi | | | |
|-----|---------------|------------|------------|------------|
| | BIC-İ | BIC-G | BIC-A | BIC-PSO |
| 30 | 85.28353 | 85.28353 | 85.28353 | 85.04804 |
| 50 | 139.04800 | 139.04800 | 139.04800 | 138.69240 |
| 100 | 277.98830 | 277.98830 | 277.98830 | 277.75140 |
| 200 | 548.67820 | 548.67820 | 548.67820 | 548.62150 |
| 500 | 1351.59000 | 1351.59000 | 1351.59000 | 1351.54300 |

Tablo 1 ve 2' de Poisson regresyon modeli için elde edilen 1.simülasyon tasarımları sonuçları gösterilmektedir. Bu sonuçlara göre 1. simülasyon tasarımlı kapsamında PSO algoritması klasik seçim yöntemlerine göre AIC ve BIC değeri daha düşük olan modelleri seçmiştir. Çoklu bağlantı içeren durumlar için PSO daha doğru sonuçlar içeren Poisson regresyon modellerini elde etmektedir.

Tablo 3. 2.Simülasyon tasarımda Poisson regresyon modeli için AIC kriteri sonuçları

| % (p/n) | Seçim yöntemi | | | |
|---------|---------------|-----------|-----------|-----------|
| | AIC-İ | AIC-G | AIC-A | AIC-PSO |
| 2 | 267.40070 | 267.40070 | 267.40070 | 267.40070 |
| 3 | 268.60160 | 268.60160 | 268.60160 | 268.60160 |
| 4 | 272.08920 | 272.08920 | 272.08920 | 272.08920 |
| 5 | 272.11820 | 272.11820 | 272.11820 | 272.11820 |
| 6 | 267.45050 | 267.45050 | 267.45050 | 267.45050 |
| 7 | 271.93650 | 271.93650 | 271.93650 | 271.93650 |
| 8 | 271.58820 | 271.58820 | 271.58820 | 271.58640 |
| 9 | 271.71860 | 271.71860 | 271.71860 | 271.71860 |
| 10 | 277.01660 | 277.01660 | 277.01660 | 277.01660 |
| 11 | 273.66320 | 273.66320 | 273.66320 | 273.64400 |
| 12 | 270.79890 | 270.79890 | 270.79890 | 270.79850 |
| 13 | 271.18850 | 271.18850 | 271.18850 | 271.18420 |
| 14 | 270.99200 | 270.99200 | 270.99200 | 270.98880 |
| 15 | 271.99420 | 271.99420 | 271.99420 | 271.96750 |

Tablo 4. 2.Simülasyon tasarımda Poisson regresyon modeli için BIC kriteri sonuçları

| % (p/n) | Seçim yöntemi | | | |
|---------|---------------|-----------|-----------|-----------|
| | BIC-İ | BIC-G | BIC-A | BIC-PSO |
| 2 | 273.09360 | 273.09360 | 273.09360 | 273.09360 |
| 3 | 276.73480 | 276.73480 | 276.73480 | 276.73480 |
| 4 | 282.54640 | 282.54640 | 282.54640 | 282.54640 |
| 5 | 284.29230 | 284.29230 | 284.29230 | 284.29230 |
| 6 | 281.29520 | 281.29520 | 281.29520 | 281.27240 |
| 7 | 287.23950 | 287.23950 | 287.23950 | 287.23950 |
| 8 | 288.10370 | 288.10370 | 288.10370 | 288.10370 |
| 9 | 289.49090 | 289.49090 | 289.49090 | 289.45200 |
| 10 | 296.19300 | 296.19300 | 296.19300 | 296.16350 |
| 11 | 293.12780 | 293.12780 | 293.12780 | 293.07570 |
| 12 | 291.82580 | 291.82580 | 291.82580 | 291.69400 |
| 13 | 292.45620 | 292.45620 | 292.45620 | 292.38310 |
| 14 | 293.33440 | 293.33440 | 293.33440 | 293.25460 |
| 15 | 295.22230 | 295.22230 | 295.22230 | 295.11200 |

2. simülasyon tasarımları sonuçları Tablo 3 ve 4' te verilmiştir. Sonuçlar incelendiğinde PSO algoritmasının klasik yöntemlere göre daha iyi sonuçlar verdiği görülmektedir. Ayrıca çoklu bağlantı problemi içermeyen durumlarda özellikle değişken sayısı yükseldikçe PSO algoritması AIC ve BIC değeri

daha düşük olan Poisson regresyon modellerini seçmiştir.

Tablo 5. Affair verisi kapsamında Poisson regresyon modeli için AIC kriteri sonuçları

| Seçim Yöntemi | AIC |
|---------------|------------|
| AIC-İ | 2823.17500 |
| AIC-G | 2823.17500 |
| AIC-A | 2823.17500 |
| AIC-PSO | 2822.76500 |

Tablo 6. Affair verisi kapsamında Poisson regresyon modeli için BIC kriteri sonuçları

| Seçim Yöntemi | BIC |
|---------------|------------|
| BIC-İ | 2878.86300 |
| BIC-G | 2878.86300 |
| BIC-A | 2878.86300 |
| BIC-PSO | 2873.51200 |

Poisson regresyon modeli gerçek veri sonuçları Tablo 5 ve 6'da gösterilmektedir. Bu sonuçlara göre PSO algoritması Affairs veri setinde klasik seçim yöntemlerine göre daha başarılı sonuçlar elde etmektedir. PSO algoritmasının seçtiği Poisson regresyon modellerinde AIC ve BIC değerleri klasik yöntemlerin seçtiği modeller göz önünde bulundurulduğunda daha düşük değere sahiptir.

Negatif binomial regresyon modeli için 1. ve 2. simülasyon tasarım sonuçları ve gerçek veri uygulaması aşağıda verilmiştir.

Tablo 7. 1. Simülasyon tasarımda Negatif binomial regresyon modeli için AIC kriteri sonuçları

| n | Seçim yöntemi | | | |
|-----|---------------|----------|----------|----------|
| | AIC-İ | AIC-G | AIC-A | AIC-PSO |
| 30 | 82.2550 | 82.2550 | 82.2550 | 82.1273 |
| 50 | 134.1402 | 134.1402 | 134.1402 | 134.1179 |
| 100 | 270.5371 | 270.5371 | 270.5371 | 270.5230 |
| 200 | 536.2455 | 536.2455 | 536.2455 | 536.2729 |
| 500 | 1330.745 | 1330.745 | 1330.745 | 1330.727 |

Tablo 8. 1. Simülasyon tasarımda Negatif binomial regresyon modeli için BIC kriteri sonuçları

| n | Seçim yöntemi | | | |
|-----|---------------|----------|----------|----------|
| | BIC-İ | BIC-G | BIC-A | BIC-PSO |
| 30 | 88.3657 | 88.3657 | 88.3657 | 88.1724 |
| 50 | 142.7844 | 142.7844 | 142.7844 | 142.4788 |
| 100 | 282.5406 | 282.5406 | 282.5406 | 282.5349 |
| 200 | 551.6531 | 551.6531 | 551.6531 | 551.7423 |
| 500 | 1353.393 | 1353.393 | 1353.393 | 1353.117 |

Tablo 7 ve 8'de negatif binomial regresyon modeli için elde edilen 1. simülasyon tasarımları sonuçları gösterilmektedir. Bu sonuçlara göre 1. simülasyon tasarımlı kapsamında PSO algoritması klasik seçim yöntemlerine göre AIC ve BIC değeri daha düşük olan modelleri seçmiştir. Çoklu bağlantı içeren durumlar için PSO daha doğru sonuçlar içeren negatif binomial regresyon modellerini elde etmektedir.

Tablo 9. 2.Simülasyon tasarımda Negatif binomial regresyon modeli için AIC kriteri sonuçları

| % (p/n) | Seçim yöntemi | | | |
|---------|---------------|----------|----------|----------|
| | AIC-İ | AIC-G | AIC-A | AIC-PSO |
| 2 | 269.6135 | 269.6135 | 269.6135 | 269.6135 |
| 3 | 270.5622 | 270.5622 | 270.5622 | 270.5622 |
| 4 | 270.1624 | 270.1624 | 270.1624 | 270.1624 |
| 5 | 271.8613 | 271.8613 | 271.8613 | 271.8613 |
| 6 | 276.1486 | 276.1486 | 276.1486 | 276.1486 |
| 7 | 272.1477 | 272.1477 | 272.1477 | 272.1477 |
| 8 | 273.6337 | 273.6337 | 273.6337 | 273.6337 |
| 9 | 274.8716 | 274.8716 | 274.8716 | 274.8716 |
| 10 | 275.6479 | 275.6479 | 275.6479 | 275.6479 |
| 11 | 275.8439 | 275.8439 | 275.8439 | 275.8423 |
| 12 | 276.6164 | 276.6164 | 276.6164 | 276.607 |
| 13 | 278.2293 | 278.2293 | 278.2293 | 278.1894 |
| 14 | 278.6634 | 278.6634 | 278.6634 | 278.6287 |
| 15 | 275.8236 | 275.8236 | 275.8236 | 275.8094 |

Tablo 10. 2.Simülasyon tasarımda Negatif binomial regresyon modeli için BIC kriteri sonuçları

| % (p/n) | Seçim yöntemi | | | |
|---------|---------------|----------|----------|----------|
| | BIC-İ | BIC-G | BIC-A | BIC-PSO |
| 2 | 277.9403 | 277.9403 | 277.9403 | 277.9403 |
| 3 | 281.3456 | 281.3456 | 281.3456 | 281.3456 |
| 4 | 283.0921 | 283.0921 | 283.0921 | 283.0921 |
| 5 | 286.5748 | 286.5748 | 286.5748 | 286.5748 |
| 6 | 292.5683 | 292.5683 | 292.5683 | 292.5683 |
| 7 | 298.1889 | 298.1889 | 298.1889 | 298.1889 |
| 8 | 292.6785 | 292.6785 | 292.6785 | 292.6673 |
| 9 | 295.3407 | 295.3407 | 295.3407 | 295.3357 |
| 10 | 296.9031 | 296.9031 | 296.9031 | 296.8889 |
| 11 | 298.3031 | 298.3031 | 298.3031 | 298.2632 |
| 12 | 300.1552 | 300.1552 | 300.1552 | 300.1241 |
| 13 | 302.7383 | 302.7383 | 302.7383 | 302.5759 |
| 14 | 302.0067 | 302.0067 | 302.0067 | 301.9964 |
| 15 | 301.2273 | 301.2273 | 301.2273 | 301.1695 |

Negatif binomial regresyon modeli için elde edilen 2. simülasyon tasarımları sonuçları Tablo 9 ve 10'da verilmiştir. Çoklu bağlantı problemi içermeyen durumlarda özellikle değişken sayısı yükseldikçe PSO algoritmasının AIC ve BIC değeri daha düşük olan negatif binomial regresyon modellerini seçtiği görülmektedir.

Tablo 11. Affair verisi kapsamında Negatif binomial regresyon modeli için AIC kriteri sonuçları

| Seçim Yöntemi | AIC |
|---------------|------------|
| AIC-İ | 2299.23355 |
| AIC-G | 2299.23355 |
| AIC-A | 2299.23355 |
| AIC-PSO | 2296.10252 |

Tablo 12. Affair verisi kapsamında Negatif binomial regresyon modeli için BIC kriteri sonuçları

| Seçim Yöntemi | BIC |
|---------------|------------|
| BIC-İ | 2223.51400 |
| BIC-G | 2223.51400 |
| BIC-A | 2223.51400 |
| BIC-PSO | 2221.10300 |

Tablo 11 ve 12'de negatif binomial regresyon modeli gerçek veri sonuçları gösterilmektedir. Bu sonuçlara göre PSO algoritması Affairs veri setinde klasik seçim yöntemlerine göre daha başarılı sonuçlar elde etmektedir.

Sıfır yoğunluklu Poisson regresyon modeli için 1. ve 2. simülasyon tasarım sonuçları ve gerçek veri uygulaması aşağıda verilmiştir.

Tablo 13. 1. Simülasyon tasarımda Sıfır yoğunluklu Poisson regresyon modeli için AIC kriteri sonuçları

| n | Seçim yöntemi | | | |
|-----|---------------|----------|----------|-----------|
| | AIC-İ | AIC-G | AIC-A | AIC-PSO |
| 30 | 88.3450 | 88.3450 | 88.3450 | 87.9373 |
| 50 | 146.2702 | 146.2702 | 146.2702 | 144.9679 |
| 100 | 281.7771 | 281.7771 | 281.7771 | 280.6280 |
| 200 | 562.3625 | 562.3625 | 562.3625 | 561.2836 |
| 500 | 1402.643 | 1402.643 | 1402.643 | 1401.8672 |

Tablo 14. 1. Simülasyon tasarımda Sıfır yoğunluklu Poisson regresyon modeli için BIC kriteri sonuçları

| n | Seçim yöntemi | | | |
|-----|---------------|-----------|-----------|-----------|
| | BIC-İ | BIC-G | BIC-A | BIC-PSO |
| 30 | 94.2478 | 94.2478 | 94.2478 | 93.8963 |
| 50 | 149.7452 | 149.7452 | 149.7452 | 149.2356 |
| 100 | 301.3602 | 301.3602 | 301.3602 | 300.7895 |
| 200 | 592.3547 | 592.3547 | 592.3547 | 592.1254 |
| 500 | 1412.6325 | 1412.6325 | 1412.6325 | 1412.1362 |

Tablo 13 ve 14'de sıfır yoğunluklu Poisson regresyon modeli için elde edilen 1. simülasyon tasarımları sonuçları gösterilmektedir. Bu sonuçlara göre 1. simülasyon tasarımlı kapsamında PSO algoritması klasik seçim yöntemlerine göre AIC ve BIC değeri daha düşük olan modelleri seçmiştir. Çoklu bağlantı içeren durumlar için PSO daha doğru sonuçlar içeren sıfır yoğunluklu Poisson regresyon modellerini elde etmektedir.

Tablo 15. 2.Simülasyon tasarımda Sıfır yoğunluklu Poisson regresyon modeli için AIC kriteri sonuçları

| % (p/n) | Seçim yöntemi | | | |
|---------|---------------|----------|----------|----------|
| | AIC-İ | AIC-G | AIC-A | AIC-PSO |
| 2 | 276.2348 | 276.2348 | 276.2348 | 276.2348 |
| 3 | 276.9852 | 276.9852 | 276.9852 | 276.9852 |
| 4 | 277.3247 | 277.3247 | 277.3247 | 277.3247 |
| 5 | 278.1456 | 278.1456 | 278.1456 | 278.1456 |
| 6 | 279.0523 | 279.0523 | 279.0523 | 279.0523 |
| 7 | 280.8563 | 280.8563 | 280.8563 | 280.8563 |
| 8 | 281.3659 | 281.3659 | 281.3659 | 281.3659 |
| 9 | 282.1748 | 282.1748 | 282.1748 | 282.1748 |
| 10 | 283.8741 | 283.8741 | 283.8741 | 283.6235 |
| 11 | 284.6398 | 284.6398 | 284.6398 | 284.5236 |
| 12 | 285.1862 | 285.1862 | 285.1862 | 285.1021 |
| 13 | 286.9963 | 286.9963 | 286.9963 | 286.7253 |
| 14 | 288.6548 | 288.6548 | 288.6548 | 288.6321 |
| 15 | 291.3258 | 291.3258 | 291.3258 | 290.9652 |

Tablo 16. 2.Simülasyon tasarımda sıfır yoğunluklu Poisson regresyon modeli için BIC kriteri sonuçları

| % (p/n) | Seçim yöntemi | | | |
|---------|---------------|----------|----------|----------|
| | BIC-İ | BIC-G | BIC-A | BIC-PSO |
| 2 | 285.3659 | 285.3659 | 285.3659 | 285.3659 |
| 3 | 289.6258 | 289.6258 | 289.6258 | 289.6258 |
| 4 | 291.0785 | 291.0785 | 291.0785 | 291.0785 |
| 5 | 292.8574 | 292.8574 | 292.8574 | 292.8574 |
| 6 | 298.5217 | 298.5217 | 298.5217 | 298.5217 |
| 7 | 300.9852 | 300.9852 | 300.9852 | 300.9327 |
| 8 | 301.2386 | 301.2386 | 301.2386 | 301.2321 |
| 9 | 296.2178 | 296.2178 | 296.2178 | 296.1993 |
| 10 | 299.5982 | 299.5982 | 299.5982 | 299.5821 |
| 11 | 302.2185 | 302.2185 | 302.2185 | 301.9962 |
| 12 | 303.1587 | 303.1587 | 303.1587 | 302.8754 |
| 13 | 303.6726 | 303.6726 | 303.6726 | 303.3627 |
| 14 | 304.1289 | 304.1289 | 304.1289 | 304.0185 |
| 15 | 303.8756 | 303.8756 | 303.8756 | 303.5214 |

Tablo 15 ve 16' da sıfır yoğunluklu Poisson regresyon modeli için elde edilen 2. simülasyon tasarımları sonuçları gösterilmektedir. Çoklu bağlantı problemi içermeyen durumlarda PSO algoritmasının daha iyi sonuçlar verdiği görülmektedir.

Tablo 17. Affair verisi kapsamında Sıfır yoğunluklu Poisson regresyon modeli için AIC kriteri sonuçları

| Seçim Yöntemi | AIC |
|---------------|------------|
| AIC-İ | 1928.21512 |
| AIC-G | 1928.21512 |
| AIC-A | 1928.21512 |
| AIC-PSO | 1928.07231 |

Tablo 18. Affair verisi kapsamında Sıfır yoğunluklu Poisson regresyon modeli için BIC kriteri sonuçları

| Seçim Yöntemi | BIC |
|---------------|------------|
| BIC-İ | 1958.16705 |
| BIC-G | 1958.16705 |
| BIC-A | 1958.16705 |
| BIC-PSO | 1955.52127 |

Sıfır yoğunluklu Poisson regresyon modeli gerçek veri Tablo 17 ve 18'de verilmektedir. PSO algoritmasının seçtiği sıfır yoğunluklu Poisson regresyon modellerinde AIC ve BIC değerleri klasik yöntemlerin seçtiği modeller göz önünde bulundurulduğunda daha düşük değere sahiptir.

4. Tartışma ve Sonuç

Bu çalışmada sayım modelleri kapsamında model seçimleri incelendi. Sayım modellerinde model seçimi için klasik seçim yöntemleri ve PSO algoritması kullanıldı. Çalışma sonucunda klasik değişken seçim yöntemleri olan ileriye doğru, geriye doğru ve adımsal seçim yöntemleri ve PSO algoritması ile elde edilen sonuçlar karşılaştırıldı. Karşılaştırma için değişken seçimi algoritmaları ile elde edilen regresyon modellerinin bilgi kriteri değerleri (AIC ve BIC) baz alındı. Bilgi kriteri değerleri doğrultusunda; seçilen değişken kümeleri ile oluşturulan regresyon modellerinin performansı değerlendirildi. Klasik seçim yöntemlerinin model seçiminde hem

simülasyon hem de gerçek veriler için aynı bilgi kriteri değerlerine sahip olan sayım modellerini seçtiği tespit edildi. Optimizasyon algoritmalarına dayalı olmayan seçim yöntemlerinin çalışma mantığına koşut olarak aynı sayım modellerinin seçilmesi dikkat çekici bir sonuçtır. Simülasyon ve gerçek veri setlerine uygulanan analizler sonucunda her ikisinde de PSO algoritmasının klasik yöntemlere göre daha düşük bilgi kriteri değerine sahip regresyon modelleri seçtiği görülmüştür.

Sonuç olarak klasik yöntemlerle kıyaslandığında PSO algoritmasının, modeldeki değişken sayısı arttıkça ve bağımsız değişkenler arasındaki korelasyon değerleri yükseldikçe daha iyi sonuçlar verdiği farklı model yapıları [28] gibi sayım modellerinde de PSO algoritmasının değişken seçiminde alternatif bir yöntem olarak kullanılabileceği gösterilmiştir.

Teşekkür

Bu makale Çankırı Karatekin Üniversitesi Bilimsel Araştırma Projeleri birimi tarafından desteklenen Araştırma Projesi (Proje No: FF090316B15) kapsamında yapılan çalışmalar sonucunda oluşturulmuştur. Yazarlar desteklerinden dolayı Çankırı Karatekin Üniversitesi Bilimsel Araştırma Projeleri Birimine teşekkür etmektedir.

Kaynakça

- [1] George, E. I. 2000. The variable selection problem. *Journal of the American Statistical Association*, 95(2000), 1304-1308.
- [2] Bozdogan, H. 2004. Intelligent statistical data mining with information complexity and genetic algorithms. *Statistical data mining and knowledge discovery*(2004), 15-16.
- [3] Lee, K. Y., & El-Sharkawi, M. A. 2008. Modern heuristic optimization techniques: theory and applications to power systems. John Wiley & Sons.
- [4] Drezner, Z., Marcoulides, G. A., & Salhi, S. 1999. Tabu search model selection in multiple regression analysis. *Communications in Statistics-Simulation and Computation*, 28(1999), 346-367.
- [5] Örkü, H. H. 2013. Subset selection in multiple linear regression models: a hybrid of genetic and simulated annealing algorithms. *Applied Mathematics and Computation*, 23(2013), 11018-11028.
- [6] Pacheco, J., Casado, S., & Nunez, L. A. 2009. Variable selection method based on Tabu search for logistic regression models. *European Journal of Operational Research*, 199(2009), 506-511.
- [7] Unler, A., & Murat, A. 2010. A discrete particle swarm optimization method for feature

- selection in binary classification problems. European Journal of Operational Research, 206(2010), 528-539.
- [8] Sakate, D. M., Kashid, D. N., & Shirke, D. T. 2011. Subset Selection in Poisson Regression. Journal of Statistical Theory and Practice, 5(2011), 207-219.
- [9] McLeod, A. I., & Xu, C. 2010. R-project.org/package= bestglm. <http://CRAN> (Erişim Tarihi: 19.10.2017)
- [10] Calcagno, V., & Mazancourt, C. 2010. glmulti: an R package for easy automated model selection with (generalized) linear models. Journal of Statistical Software, 34(2010), 1-29.
- [11] Tibshirani, R. 1996. Regression shrinkage and selection via the lasso. Journal of the Royal Statistical Society: Series B (Methodological) (1996), 267-288.
- [12] Zou, H., & Hastie, T. 2005. Regularization and variable selection via the elastic net. Journal of the Royal Statistical Society: Series B (Statistical Methodology), 67(2005), 301-320.
- [13] Zou, H. 2006. The adaptive lasso and its oracle properties. Journal of the American statistical association, 101(2006), 1418-1429.
- [14] Zhao, W., Zhang, R., Lv, Y., & Liu, J. 2014. Variable selection for varying dispersion beta regression model. Journal of Applied Statistics, 41(2014), 95-108.
- [15] Bayer, F. M., & Cribari-Neto, F. 2014. Bootstrap-based model selection criteria for beta regressions. TEST(2014), 1-20.
- [16] Bozdogan, H. 1987. Model selection and Akaike's information criterion (AIC): The general theory and its analytical extensions. Psychometrika(1987), 345-370.
- [17] Hurvich, C. M., & Tsai, C. L. 1989. Regression and time series model selection in small samples. Biometrika(1989), 297-307.
- [18] Bollen, K. A., Ray, S., Zavitsa, J., & Harden, J. J. 2012. A comparison of Bayes factor approximation methods including two new methods. Sociological Methods & Research, 41(2012), 294-324.
- [19] Bozdogan, H. 2000. Akaike's information criterion and recent developments in information complexity. Journal of mathematical psychology, 44(2000), 62-91.
- [20] Bozdogan, H. 2010. A new class of information complexity (ICOMP) criteria with an application to customer profiling and segmentation. Journal of the School of Business Administration(2010), 370-398.
- [21] Deniz, E., Akbilgic, O., & Howe, J. A. (2011). Model selection using information criteria under a new estimation method: least squares ratio. Journal of Applied Statistics, 2043-2050.
- [22] Pamukçu, E., Bozdogan, H., & Çalik, S. 2015. A Novel Hybrid Dimension Reduction Technique for Undersized High Dimensional Gene Expression Data Sets Using Information Complexity Criterion for Cancer Classification. Computational and mathematical methods in medicine(2015), Article ID 370640, 14 pages.
- [23] Cameron, A. C., & Trivedi, P. K. 1998. Regression Analysis of Count Data. Cambridge University Press.
- [24] Jansakul, N., & Hinde, J. P. 2002. Score tests for zero-inflated Poisson models. Computational, 40(2002), 75-96.
- [25] Eberhart, R., & Kennedy, J. 1995. A new optimizer using particle swarm theory. In Micro Machine and Human Science. Proceedings of the Sixth International Symposium on IEEE., 39-43.
- [26] Özsağlam, M. Y., & Çunkaş, M. 2008. Optimizasyon Problemlerinin Çözümü için Parçacık Sürü Optimizasyonu Algoritması. Politeknik Dergisi(2008), 11.
- [27] Hilbe, J. M. 2016. COUNT: Functions, Data and Code for Count Data. R package version 1.3.4. <https://CRAN.R-project.org/package=COUNT>
- [28] Koç, H., Dündar, E., Gümüştekin, S., Koç, T., & Cengiz, M. A. 2018. Particle swarm optimization-based variable selection in Poisson regression analysis via information complexity-type criteria. Communications in Statistics-Theory and Methods, (2018) 47(21), 5298-5306.